



Prévision probabiliste de la production photovoltaïque à 72 h par apprentissage profond : application à la centrale de Diass, Sénégal

Baye Mor Gaye

Université Cheikh Anta Diop de Dakar
Département Mathématiques et Informatique
Section Informatique

Encadrant

Dr Ndiouma Bame

UCAD

Maîtres de stage

Dr Saidou Abdoul Soumare

Dr Abdoulaye Ba

SENELEC

Dakar, le 10 octobre 2026

Table des matières

Introduction générale **3**

I Contexte physique et données **5**

1 Cadre de la transition énergétique au Sénégal et présentation des sites **6**

1.1 Contexte du secteur électrique sénégalais 6

1.2 Analyse et constats sur la prévision 7

1.3 Contexte de l'énergie solaire 8

2 Physique et technologie photovoltaïque **12**

2.1 Physique du rayonnement solaire 12

2.2 Principe physique de la conversion photovoltaïque 14

2.3 Analyse de la variabilité et de l'intermittence 17

2.4 Référentiel unifié des variables pour la centrale de Diass 17

2.5 Conclusion 18

II Architectures d'apprentissage profond **19**

3 Fondations de l'apprentissage supervisé et régularisation **20**

3.1 Du modèle linéaire au perceptron multicouche 20

3.2 Fonctions d'activation 23

3.3 Fonctions de coût et métriques d'évaluation 24

3.4 Optimisation 27

3.5 Régularisation 28

3.6 Vanishing et exploding gradients 30

3.7 Généralisation et protocole d'évaluation 31

4 Modèles pour séries temporelles **33**

4.1 Réseaux convolutifs (CNN) 33

4.2 Réseaux récurrents et architectures à portes (RNN, LSTM, GRU) 36

4.3 Mécanisme d'attention 39

4.4 Architecture Transformer 40

5 Architectures avancées appliquées **43**

5.1 Solaire : Temporal Fusion Transformer (TFT) 43

5.2 Photovoltaïque : Temporal Convolutional Network (TCN) 47

5.3 Entraînement : encodage et évaluation 49

6 Stratégie MIMO et prévision probabiliste par quantiles **51**

6.1 La stratégie MIMO de prévision multi-horizon 51

6.2 La prévision par quantiles : type de sortie probabiliste 52

6.3 L'approche d'incertitude retenue dans le code : perte hybride multi-tâche 53

6.4 Recalibrage de l'enveloppe : le CQR adopté dans le code 54

6.5 Scores stricts et calibration : juger une prévision par quantiles 54

6.6 Protocole d'évaluation sur le cas Diass 55

6.7 Conclusion 55

III Application et évaluation **57**

7 Étude de cas : Diass (solaire) **58**

7.1 Le site de Diass, centrale solaire photovoltaïque 58

7.2 Discussion et perspectives 83

7.3 Conclusion 85

Introduction générale

Contexte et motivation

Le secteur électrique sénégalais fait face à un double défi stratégique : garantir l'accès universel à une électricité fiable tout en accélérant l'intégration des sources renouvelables dans le réseau interconnecté de la SENELEC. Conformément au Plan Sénégal Émergent (PSE) et à la Stratégie Nationale pour la Transition Énergétique, l'ambition nationale vise à porter la part des énergies renouvelables à 40 % du mix à l'horizon 2030.

Avec la mise en service de plusieurs parcs solaires d'envergure comme Ten Merina, Senergy (24,35 MWc), Santhiou Mékhé (29,5 MWc), Diass (23 MWc), Kahone (44 MWc / 35 MWac), Malicounda (22 MWc) et Sakal (20 MWc), combinés au parc éolien de Taïba N'Diaye (158,7 MW), le principal verrou technologique et opérationnel ne réside plus dans le déploiement des infrastructures, mais dans la **prévision fiable de la production**. En raison de la forte variabilité climatique propre au Sahel (alternance de saisons sèches et humides, passages nuageux, ou encore les épisodes d'harmattan de novembre à février et d'hivernage de juillet à septembre), la production photovoltaïque est intrinsèquement intermittente. Des erreurs de prévision induisent des déséquilibres majeurs sur le réseau, contraignant le dispatching à mobiliser en urgence des réserves thermiques fossiles et alourdissant les coûts d'exploitation.

Ce mémoire propose d'apporter une réponse méthodologique et opérationnelle à cette problématique en concevant un cadre d'apprentissage profond adapté au contexte climatique sénégalais. Il vise à produire des prévisions photovoltaïques de court terme à 72 heures, tout en intégrant une gestion explicite des incertitudes par des approches probabilistes (prévision par quantiles).

Problématique

La problématique centrale de ce travail s'articule autour de la question suivante :

> *Comment concevoir un modèle d'apprentissage profond capable de prédire, avec précision et robustesse, la production électrique solaire à court terme à 72 h dans le contexte climatique sénégalais, tout en intégrant et en quantifiant l'incertitude inhérente à cette source renouvelable intermittente ?*

Objectifs et contributions

Pour répondre à la problématique posee, les contributions de ce travail s'articulent autour d'une démarche globale, allant de l'analyse physique jusqu'à la validation opérationnelle.

Dans un premier temps, ce mémoire s'attache à **caractériser la variabilité physique** de la production photovoltaïque au Sénégal, qu'il s'agisse des cycles astronomiques, des facteurs stochastiques liés aux nuages, à l'impact des aérosols de l'harmattan, de la température ou encore du *soiling*, afin de structurer ces éléments au sein d'un référentiel unifié de variables. Sur le plan méthodologique, le travail intègre les covariables futures issues des modèles de prévision numérique meteorologique (NWP) à l'ensemble des pipelines d'entraînement, d'évaluation et de test, tout en s'appuyant sur des méthodes avancées de sélection de *features* par approche d'union finale.

L'effort de modélisation se concrétise ensuite par l'**évaluation comparative d'architectures de deep learning** dédiées aux séries temporelles, telles que les TCN à convolutions causales dilatées et les Temporal Fusion Transformers (TFT) à attention interprétable. Conçues pour la prévision multi-horizon à 72 h, ces architectures délivrent une sortie probabiliste par quantiles ($q_{0,1}$ à $q_{0,9}$), dont l'enveloppe est finement recalibrée à l'aide de la méthode CQR (*Conformal Quantile Regression*) pour garantir des intervalles de confiance robustes. Enfin, le pipeline complet est rigoureusement validé sur le cas d'étude de la centrale de Diass : de l'exploration des données et du *feature engineering* causal (garantissant l'absence de fuite d'information) jusqu'à l'évaluation face aux modèles de référence par persistance.

Plan du mémoire

Le présent mémoire est structuré en trois grandes parties progressives :

- **La Partie I** pose le cadre physique et contextuel de l'étude. Elle aborde d'abord, au chapitre 1, la transition énergétique et la configuration des parcs, puis, au chapitre 2, la physique de la conversion photovoltaïque, l'analyse approfondie de la variabilité et le référentiel unifié des variables.
- **La Partie II** plonge au cœur de la méthodologie algorithmique. Elle pose les fondements de l'apprentissage supervisé (Chapitre 3), explore les modèles dédiés aux séries temporelles (Chapitre 4), détaille les architectures avancées, le TFT et le TCN (Chapitre 5), et explicite les stratégies de prévision multi-horizon et probabiliste (Chapitre 6).
- **La Partie III** concrétise ces travaux par la mise en œuvre pratique et l'évaluation globale sur la centrale de Diass (Chapitre 7). Elle conclut en ouvrant sur les perspectives et les implications opérationnelles directes de ces outils pour le gestionnaire de réseau SENELEC.

Première partie

CONTEXTE PHYSIQUE ET DONNÉES

Chapitre 1

Cadre de la transition énergétique au Sénégal et présentation des sites

Ce chapitre décrit la transition énergétique au Sénégal : l'organisation de la SENELEC, l'évolution du mix électrique, la montée en puissance des sources renouvelables et le gisement solaire national, ainsi que les défis qu'elles posent à la prévision de production. Une place particulière est ensuite consacrée au site de Diass, première centrale solaire publique du pays, dont les choix techniques, l'environnement local et les paramètres physiques conditionnent les modèles de prévision.

1.1 Contexte du secteur électrique sénégalais

La Société nationale d'électricité du Sénégal (SENELEC) gère l'ensemble de la chaîne, de la production jusqu'à la distribution. Les chiffres clés de la période 2022–2025 permettent de mesurer la réalité du terrain sur lequel s'appuie la centrale photovoltaïque étudiée dans ce travail.

Puissances installées par source.

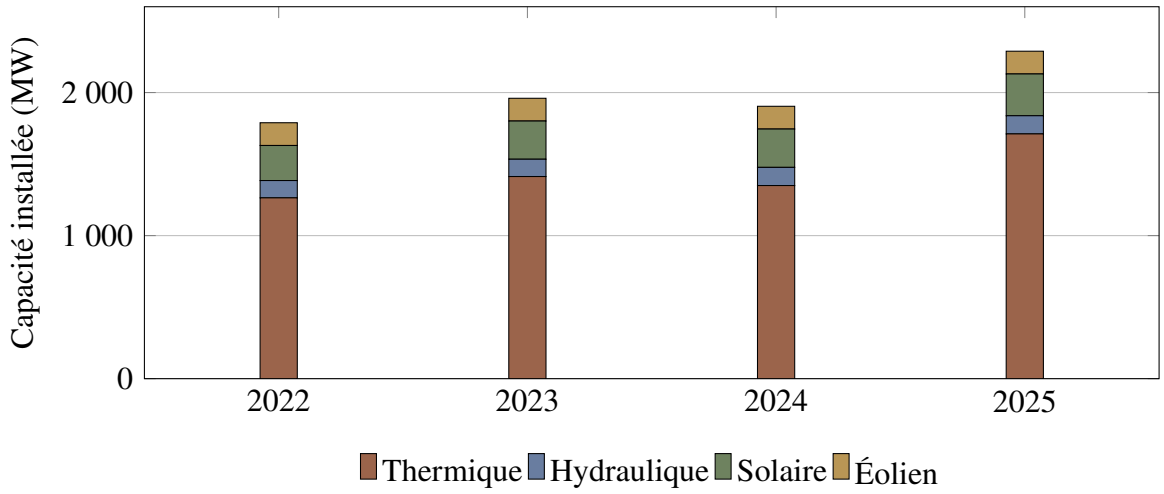


Figure 1.1 : Puissances installées SENELEC par source (MW), 2022–2025.

Le thermique reste le pilier central du mix énergétique avec près de 75 % de la capacité globale en 2025. Pour autant, le solaire trace sa route et progresse régulièrement, passant de 245 MW

en 2022 à 292 MW en 2025, soit une augmentation de 19 %. De son côté, l'éolien ne bouge pas (porté par le parc de Taïba Ndiaye à 158,7 MW), tout comme l'hydraulique. Au total, la puissance installée globale bondit de 28 %, grimpant de 1 789 à 2 290 MW entre 2022 et 2025, une croissance essentiellement tirée par le thermique qui rajoute à lui seul 447 MW.

Production et achats.

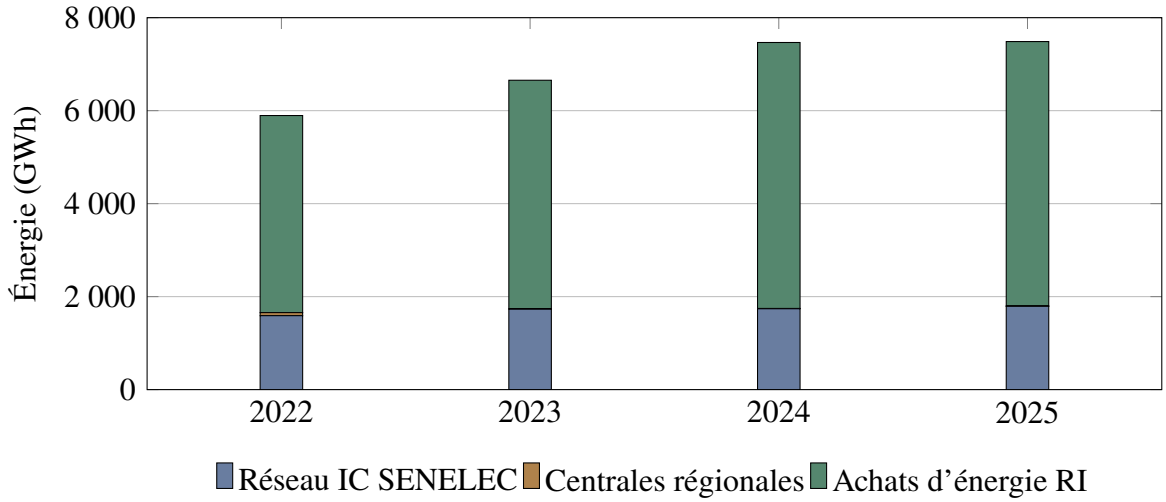


FIGURE 1.2 : Production et achats d'énergie du réseau SENELEC (GWh), 2022–2025.

Côté volumes, l'énergie injectée sur le réseau interconnecté passe de 5 895 à 7 486 GWh, affichant une hausse de 27 % sur la même période. Ces évolutions traduisent une même réalité : la dépendance aux achats extérieurs s'accentue. Les achats auprès des producteurs indépendants pèsent 72 % du total en 2022 pour atteindre 76 % en 2025, tandis que la production en propre de la SENELEC stagne presque (+13 %). Les petites centrales régionales non interconnectées sont quant à elles devenues anecdotiques, avec environ 7 GWh par an depuis 2023. Le réseau dépend donc clairement de ces approvisionnements externes, dont une portion croissante provient du renouvelable. Plus récemment, en mai 2026, la production globale progresse de 7,7 % sur le mois et 8,6 % sur l'année, un dynamisme alimenté exclusivement par les achats (+10,6 % et +12,3 %), alors même que la production interne recule légèrement (-2,1 % et -3,5 %) [25].

1.2 Analyse et constats sur la prévision

Le détail du mix énergétique et des volumes réels de 2022 (7 549 GWh produits au total selon l'ANSD et la SENELEC) confirme la domination du thermique fossile, qui fournit 77 % de la production, suivi du charbon (7,9 %), du solaire (7,9 %) et de l'éolien (5,2 %). Il ne faut pas confondre production effective (en GWh) et capacité installée (en MW) : les chiffres de 9 % pour l'éolien et de 15 % pour le solaire, souvent cités, désignent uniquement la puissance théorique installée, et non la production réelle, naturellement freinée par l'intermittence des flux naturels.

Cette place prépondérante des achats d'énergie (76 % en 2025) couplée à un parc solaire de 292 MW met en lumière tout l'intérêt de la prévision. Mieux anticiper la ressource renouvelable

permet d'ajuster l'appel au thermique et d'amortir les à-coups de production. Les énergies intermittentes imposent une instabilité structurelle quotidienne : le solaire suit une courbe nette (rien la nuit, un pic à midi, des chutes nettes au passage d'un nuage), tandis que le vent dicte sa loi à l'éolien. Sans prévision solide, les gestionnaires du dispatching doivent mobiliser en permanence des réserves thermiques.

Le réseau interconnecté offre en outre une soupape de sécurité : la synchronisation avec les voisins maliens et guinéens via les organisations sous-régionales (OMVS, OMVG). Ces passerelles permettent des flux d'énergie croisés qui lissent en partie les déséquilibres locaux. Le pilotage de ce parc se heurte néanmoins à son hétérogénéité technologique : entre les panneaux polycristallins fixes de Ten Merina ou Diass (modules Jinko, Renesola), les modules bifaciaux de Kahone et les suiveurs solaires (trackers) de Sakal, aucun modèle de prévision unique ne convient. Chaque site exige une approche sur mesure, calée sur ses spécificités techniques.

1.3 Contexte de l'énergie solaire

À l'origine de la plupart des énergies propres, le rayonnement solaire est converti directement en électricité par effet photovoltaïque dans des matériaux semi-conducteurs [1].

Au Sénégal, la filière a poussé à grande vitesse : de 2 MWc en 2007, le pays est monté à 113 MWc en 2017 pour atteindre 292,47 MWc connectés au réseau SENELEC en 2025 [7, 24]. Les grandes centrales font désormais partie intégrante du paysage électrique. Ainsi, le réseau SENELEC a écoulé 6 218 GWh en 2025, soit 28 % de plus qu'en 2022 (4 863 GWh), une croissance soutenue par les achats d'énergie (5 687 GWh) face à une production propre de 1 792 GWh [24].

1.3.1 Défis de la production photovoltaïque

L'utilité d'une prévision fine s'explique principalement par deux réalités de terrain.**Une écart entre théorie et l'environnement reel**, c'est a dire La production réelle d'un champ photovoltaïque est toujours inférieure aux prévisions nominales à cause de la température des cellules, des ombrages, de l'empoussièrement et de l'usure du matériel et d'autre facteurs de pertes d'energies [1, 7].Mais aussi, **la volatilité de la ressource**. En effet la production subit de plein fouet les caprices de la météo a savoire les nuages, les variations saisonnières, donc des fluctuations que les modèles de prévision du chapitre 3 s'attachent à maîtriser.

1.3.2 Présentation des principales centrales solaires du Sénégal

A. Ten Merina (29,5 MWc, première centrale solaire du Sénégal)

Inaugurée en novembre 2017 à Mérina Dakhar (région de Thiès, à 145 km au nord-est de Dakar), Ten Merina ouvre la marche des grandes centrales raccordées au réseau. Porté par Meridiam, Eiffage et le FONSIS (10 %), le site affiche 29,5 MWc. Sur ses 40 hectares, on compte

92 000 panneaux polycristallins Jinko de 320 Wp, couplés à 12 stations de conversion. Liée à la SENELEC par un contrat de 25 ans, elle produit environ 50 GWh chaque année.

D. Diass (23 MWc, centrale publique SENELEC, cas d'étude)

Mise en service le 22 mai 2022 à Diass (département de Mbour, à environ 40–50 km au sud-est de Dakar, près de l'aéroport Blaise Diagne), cette centrale de 23 MWc est la toute première centrale solaire publique du pays. Propriété de la SENELEC qui l'exploite en direct, elle a été financée par un prêt de 18 milliards de FCFA de la KfW allemande. Le site s'étale sur 40 hectares et regroupe 85 248 modules polycristallins sur structures fixes, épaulés par 36 onduleurs et 16 transformateurs. Elle injecte environ 34 GWh par an avec un performance ratio publié entre 64,7 et 75,8 %, pour une implantation vers 14,65°N et 17,10°O. C'est sur cette centrale que repose le cas d'étude de ce mémoire.



Figure 1.3 : Localisation de la centrale solaire de Diass.

E. Kahone (44 MWc, jumelle de Diass)

Mise en service en mai 2021 dans la région de Kaolack (à 200 km au sud-est de Dakar), Kahone est la sœur jumelle de Diass. Portée par le même consortium (Meridiam/ENGIE/FONSIS), elle s'est distinguée par un tarif record en Afrique subsaharienne de 3,80 c€/kWh sur un PPA de 25 ans. Répartie sur 36 hectares, elle est reliée au réseau via une liaison souterraine de 300 m et produit près de 80 GWh par an.

G. Sakal (20 MWc, première centrale à trackers)

Mise en service début 2018 dans la région de Louga, Sakal (20 MWc) a été entièrement développée par InnoVent pour 17 millions d'euros. Sa particularité réside dans son installation : ses 62 100 panneaux reposent sur 240 suiveurs solaires (trackers mono-axe) qui pivotent au rythme du soleil, connectés à 354 onduleurs Delta. Ce suivi dynamique optimise la production pour atteindre environ 41 800 MWh par an.

1.3.3 Potentiel solaire du Sénégal

Le gisement solaire national s'évalue à partir des données de la base NASA-SSE, moyennées sur 22 ans à travers 65 points d'observation répartis dans les 14 régions. Le rayonnement global horizontal y oscille entre 1 825 et 2 194 kWh/m²/an, avec une composante directe montant jusqu'à 2 325 kWh/m²/an et une composante diffuse comprise entre 613 et 686 kWh/m²/an, le tout baigné par près de 3 000 heures de soleil par an. Sur le plan géographique, la ressource reste homogène mais suit un léger gradient d'ouest en est : le littoral Dakar–Thiès affiche les valeurs maximales, proches de 2 190 kWh/m²/an, suivi de Saint-Louis avec environ 2 179, puis la région centrale autour de 2 160 et l'est avec environ 2 127 kWh/m²/an.

Cartes du gisement solaire (GHI, DNI, DHI).

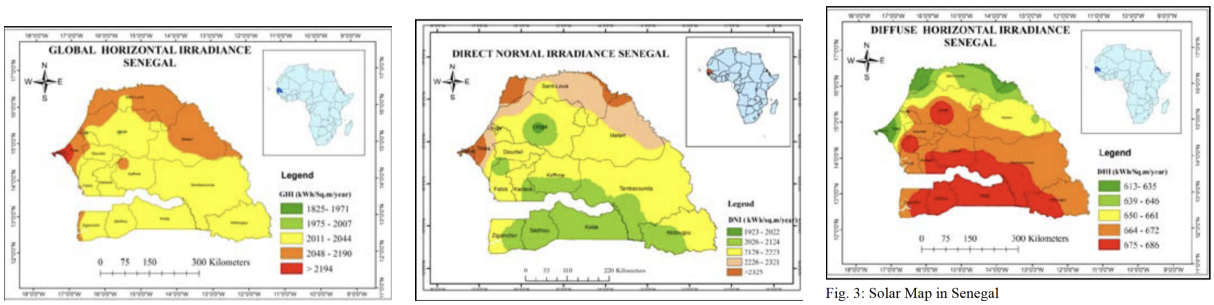


Fig. 3: Solar Map in Senegal

(a) Irradiance globale horizontale. **(b)** Irradiance directe normale. **(c)** Irradiance diffuse horizontale.

FIGURE 1.4 : Gisement solaire du Sénégal : cartes des trois composantes du rayonnement [8].

En matière de potentiel exploitable, les surfaces disponibles représentent environ 42 613 km², soit 21 % du pays. En tablant sur l'utilisation de seulement 3 % de ces espaces (avec une densité de 50 MW/km², des modules monocristallins à 15,64 % de rendement et un ratio de performance de 75 %), le potentiel installable atteindrait près de 63 920 MW. Cet immense gisement se concentre massivement à l'intérieur des terres : Tambacounda arrive largement en tête avec environ 20 879 MW, suivie de Kédougou (≈ 12 359 MW) et de Saint-Louis (≈ 10 628 MW).

Ce potentiel est toutefois très mal réparti : à elles seules, trois régions concentrent près de 31 682 MW, soit la moitié du total national. L'est et le nord détiennent la quasi-totalité des réserves, tandis que des zones comme Dakar (≈ 50 MW) ou Diourbel (≈ 1 MW) disposent d'un foncier très restreint. Ce décalage géographique entre les zones de production massive et les grands pôles de consommation côtiers confirme tout le défi du transport de l'électricité à l'échelle nationale.

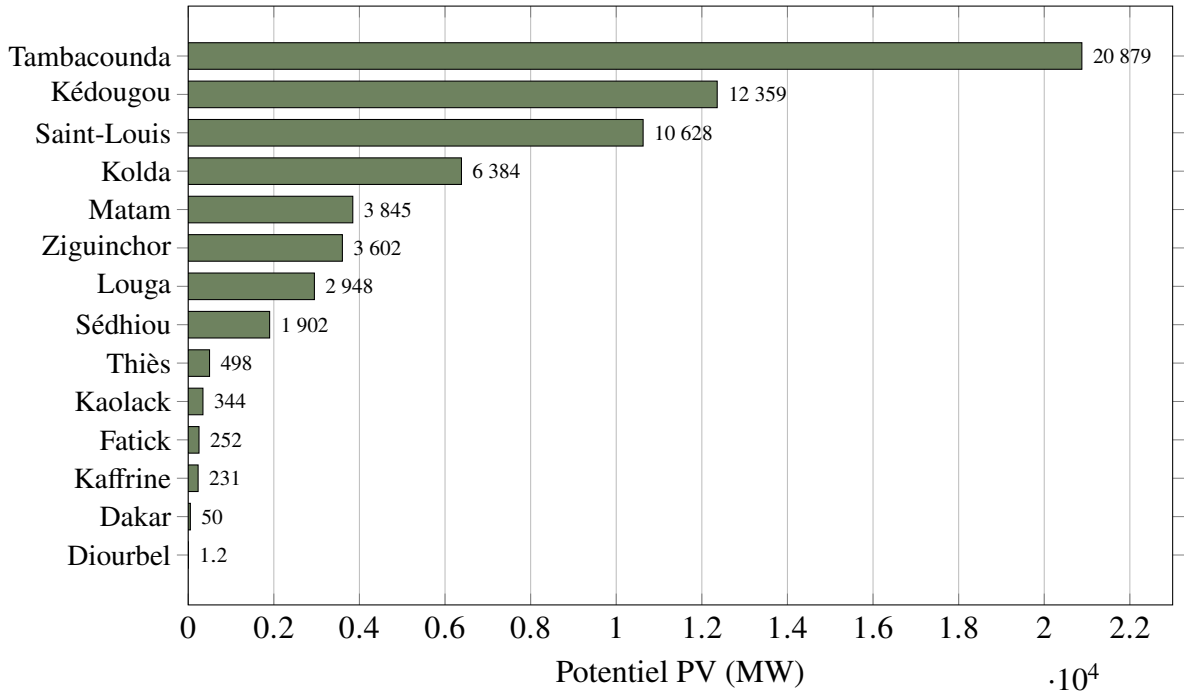


FIGURE 1.5 : Rayonnement solaire et potentiel photovoltaïque par région (adapté de 5).

Chapitre 2

Physique et technologie photovoltaïque

Ce chapitre présente les bases physiques de la filière photovoltaïque et les mécanismes qui régissent la production d'électricité. Du rayonnement solaire au comportement de la cellule semi-conductrice, chaque maillon éclaire les grandeurs clés que tout modèle de prévision se doit de capturer.

2.1 Physique du rayonnement solaire

2.1.1 Structure et fonctionnement du Soleil

Le Soleil est une étoile d'environ **1 400 000 km de diamètre** animée par des réactions de **fusion d'hydrogène en hélium**, qui libèrent des quantités colossales d'énergie [1]. Une infime fraction de ce flux parvient jusqu'à la Terre sous forme de rayonnement électromagnétique.

La puissance globale émise par un corps incandescent obéit à la **loi de Stefan–Boltzmann** :

$$P_{\text{dégagée}} = S \cdot \sigma \cdot T^4$$

où S représente la surface de l'astre, σ la constante de Stefan–Boltzmann, et T sa température de surface. La puissance rayonnée augmentant avec la quatrième puissance de la température, de légères variations thermiques influencent considérablement l'énergie émise par l'étoile.

En dehors de l'atmosphère, le spectre de référence est l'orbe **AM0** (Air Mass 0), qui correspond à une irradiance extraterrestre d'environ **1 367 W/m²**. Au niveau du sol, la convention **AM1,5** modélise le rayonnement après la traversée d'une masse d'air standard, fixant la puissance incidente de référence à **1 000 W/m²** [1, 28].

2.1.2 Géométrie solaire et orientation du panneau

L'énergie interceptée par un panneau dépend directement de la position apparente du Soleil, liée à la latitude du site, à la date et à l'heure. Les angles sont exprimés dans le repère local (x, y, z) (x vers l'est, y vers le nord, z vers le zénith), avec des azimuts comptés depuis le nord et positifs vers l'est (0° = nord, 90° = est, 180° = sud, 270° = ouest).

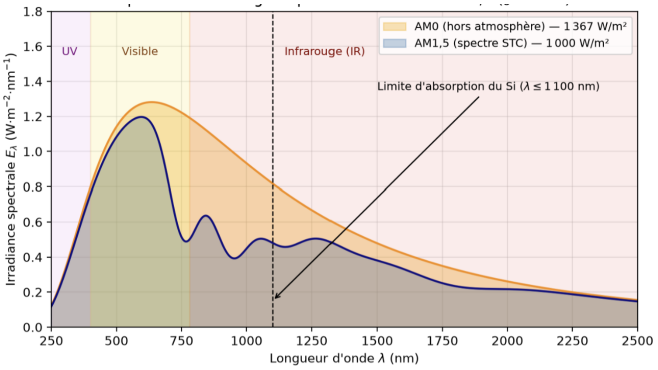


FIGURE 2.1 : Spectre électromagnétique solaire : AM0 (extraterrestre) et AM1,5 (convention standard).

La latitude φ du site ($\varphi = 14{,}65°$ N à Diass) et le jour de l'année N dictent la trajectoire solaire. La **déclinaison solaire** δ, qui traduit la latitude du point subsolaire, s'obtient par la formule de Cooper :

$$\delta = 23{,}45° \cdot \sin\left(\frac{360°}{365}\,(N - 81)\right).$$

Elle varie de $-23{,}45°$ à $+23{,}45°$ au fil des saisons, un calcul directement repris par le module `SolarPhysicalEngineer` du pipeline.

Pour caler l'heure civile sur la course réelle du Soleil, l'**équation du temps** E_q (en minutes) corrige l'excentricité de l'orbite terrestre :

$$E_q = 9{,}87\,\sin(2b) - 7{,}53\,\cos b - 1{,}5\,\sin b, \qquad b = \frac{360°}{365}\,(N - 81).$$

Le temps solaire local t_{sl} s'en déduit, ce qui permet de calculer l'**angle horaire** $\omega = 15° \cdot (t_{sl} - 12)$, nul à midi solaire.

La hauteur solaire α_s et l'azimut A_s se déduisent de ces coordonnées. Pour un panneau caractérisé par son inclinaison β et son azimut A_p (par exemple $\beta = 15°$ et $A_p = 180°$ pour la structure fixe de Diass), l'**angle d'incidence** θ_i entre les rayons solaires et la normale du panneau $\mathbf{n}$ s'exprime via le produit scalaire $\cos\theta_i = \mathbf{n} \cdot \mathbf{s}$:

$$\cos\theta_i = \sin\beta\cos\alpha_s\cos(A_p - A_s) + \cos\beta\sin\alpha_s.$$

Cette relation fondamentale gouverne l'apport direct de l'irradiance sur le module : $G_{\text{dir,POA}} = G_{\text{dir}}\cos\theta_i$. Les trackers solaires exploitent précisément ce principe en ajustant en continu l'orientation du panneau pour maintenir $\cos\theta_i \approx 1$.

2.1.3 Rayonnement solaire

Hors de l'atmosphère, l'irradiance extraterrestre AM0 atteint environ **1 367 W/m²** [28]. En traversant la couche atmosphérique, ce flux subit des pertes par diffusion et absorption, une atténuation quantifiée par la masse d'air AM [28, 1].

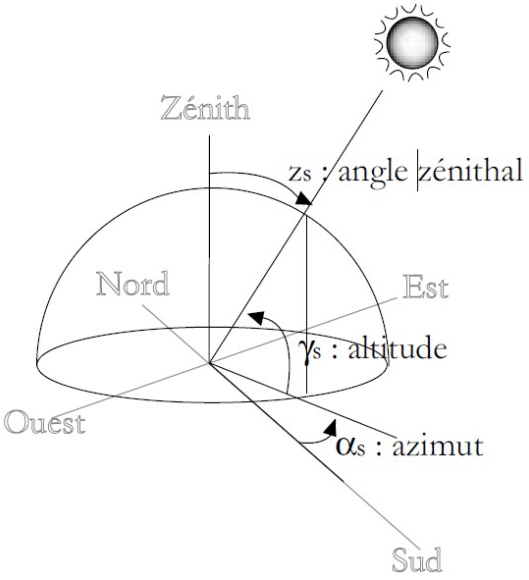


FIGURE 2.2 : Géométrie solaire : déclinaison δ, angles zénithal θ_z, élévation α_s, azimut A_s et inclinaison β du panneau.

Au sol, le rayonnement se compose de trois apports distincts : l'**irradiance directe** (G_{dir}) reçue en ligne droite depuis le disque solaire [1], l'**irradiance diffuse** (G_{dif}) renvoyée de toutes parts par la voûte céleste nuageuse ou chargée d'aérosols, et enfin le rayonnement **réfléchi** par le sol, ou albédo (ρ_g). L'irradiance globale reçue sur le plan incliné du panneau (G_{POA}) s'écrit ainsi comme la sommation de ces contributions :

$$G_{POA} = G_{\text{dir,POA}} + G_{\text{dif,POA}} + G_{\text{ref,POA}}.$$

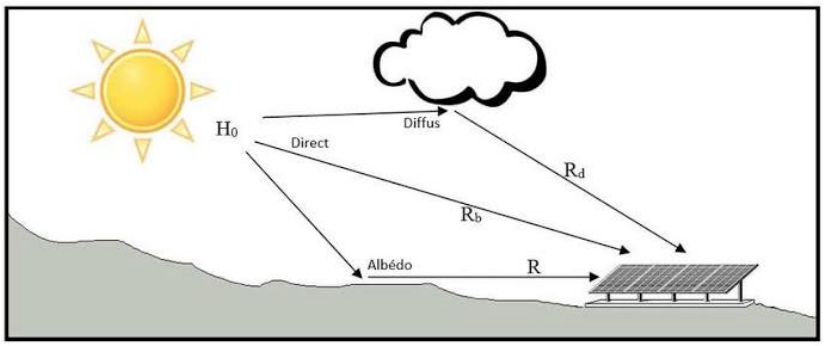


FIGURE 2.3 : Décomposition du rayonnement solaire : direct, diffus, global horizontal et réfléchi (albédo).

2.2 Principe physique de la conversion photovoltaïque

2.2.1 Structure atomique du silicium et bandes d'énergie

Matériau de référence pour plus de 90 % des cellules mondiales, le **silicium (Si)** possède 4 électrons de valence qui forment un réseau cristallin stable par liaisons covalentes. À l'état pur, il se comporte toutefois comme un isolant à température ambiante.

La théorie des bandes distingue la **bande de valence** (presque pleine à basse température) de la **bande de conduction** (où les électrons libres assurent le transport du courant). Entre les deux s'étend la **bande interdite** ($E_g \approx 1{,}12$ eV à 300 K pour le silicium) [1, 7]. Lorsqu'un photon d'énergie supérieure à E_g frappe le matériau, il excite un électron de la bande de valence vers la bande de conduction.

Table 2.1 : Valeurs de bande interdite E_g des principaux semi-conducteurs.

Matériau	E_g (eV)	Type
Silicium (Si)	1,12	Indirect
Germanium (Ge)	0,66	Indirect
Arséniure de gallium (GaAs)	1,42	Direct
Séléniure de cuivre–indium–gallium (CIGS)	1,0–1,7 (variable)	Direct
Tellure de cadmium (CdTe)	1,45	Direct
Pérovskites ($CH_3NH_3PbI_3$)	~1,55	Direct

2.2.2 Dopage et jonction PN

Pour rendre le silicium conducteur, on réalise un **dopage** en y introduisant des impuretés contrôlées. Le **type N (donneur)** s'obtient par l'ajout d'éléments à cinq électrons (comme le phosphore) pour libérer des charges négatives excédentaires, tandis que le **type P (accepteur)** fait appel à des éléments à trois électrons (comme le bore) pour générer des lacunes mobiles, appelées trous.

La mise en contact intime de ces deux matériaux engendre la **jonction PN**. Au voisinage de l'interface, la diffusion des porteurs de charge crée une zone d'appauvrissement exempte de charges libres, dite zone de déplétion, qui donne naissance à un **champ électrique interne**. Ce champ joue un rôle moteur indispensable en agissant comme une barrière naturelle et un séparateur de charges.

2.2.3 Effet photovoltaïque

La conversion de la lumière en électricité s'opère à travers un enchaînement de processus physiques continus. Tout d'abord, l'**absorption** des photons incidents par le semi-conducteur insuffle l'énergie nécessaire à la **génération** de paires électron–trou. Sous l'action du champ électrique inhérent à la jonction PN, ces porteurs subissent une **séparation** spatiale immédiate qui prévient leur recombinaison précoce [1]. Enfin, la **collecte** de ces charges par les contacts métalliques frontaux et arrière alimente le circuit extérieur sous forme de courant continu [1, 28].

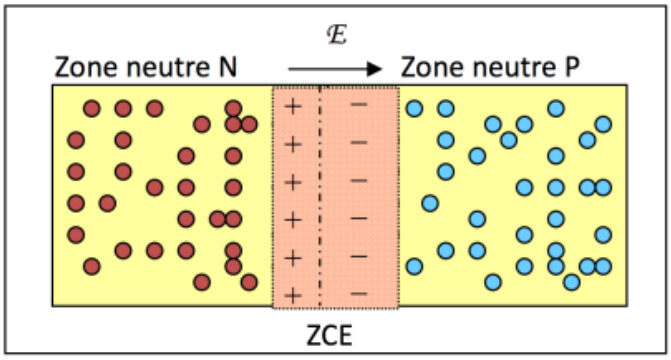


FIGURE 2.4 : Jonction PN à l'équilibre : zone neutre N, zone de charge d'espace (ZCE) et zone neutre P. Les donneurs ionisés (+) côté N et les accepteurs ionisés (−) côté P créent le champ électrique interne $\vec{\mathcal{E}}$ orienté de N vers P, qui sépare les paires électron–trou photo-générées.

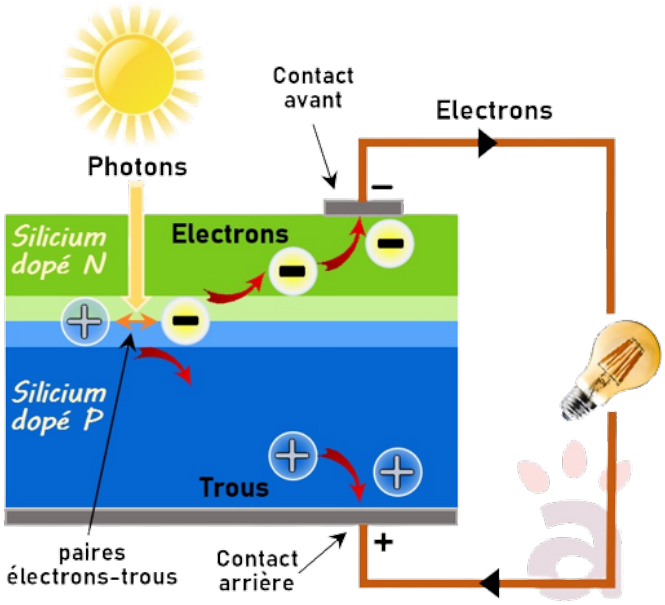


FIGURE 2.5 : Effet photovoltaïque dans une cellule au silicium : les photons créent des paires électron–trou, les électrons sont collectés par le contact avant (silicium dopé N) et les trous par le contact arrière (silicium dopé P), produisant un courant continu dans le circuit extérieur.

2.3 Analyse de la variabilité et de l'intermittence

Comme établi au Chapitre 2, la production d'une centrale photovoltaïque dépend conjointement de cycles déterministes et de perturbations stochastiques. Du point de vue de la modélisation, la variabilité déterministe et prévisible liée à la mécanique céleste (cycles journalier et saisonnier), directement intégrée via les éphémérides et les composantes géométriques ($\cos\theta_i$), se distingue de l'incertitude stochastique provoquée par la dynamique atmosphérique (passages nuageux rapides, épisodes d'harmattan et dépôt de poussières τ_a). La valeur ajoutée des modèles d'apprentissage profond réside sur cette seconde composante, par nature imprévisible.

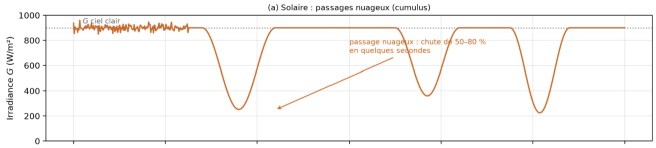


FIGURE 2.6 : Variabilité à court terme de la production induite par les passages nuageux.

2.4 Référentiel unifié des variables pour la centrale de Diass

Afin d'éviter le surapprentissage et de garantir l'explicabilité des modèles (notamment via les mécanismes d'attention temporelle et de sélection de variables propres au modèle TFT [17]), l'ensemble des grandeurs mesurées ou calculées sur le site de Diass (23 MWc) a été regroupé au sein d'un dictionnaire structuré présenté dans le tableau 2.2.

TABLE 2.2 : Référentiel unifié des variables pour la modélisation photovoltaïque (Centrale de Diass).

Catégorie	Variable / Feature	Définition et rôle physique
Météorologie et Climat	$G, G_{dir}, G_{dif}, G_{POA}$	Irradiances globale, directe, diffuse et dans le plan du panneau (W/m²).
	$c_{cov}, G_{sw}, \alpha_c$	Fraction nuageuse (%), rayonnement descendant et albédo de ciel clair.
	T_{amb}, T_{mod}, T_d	Températures de l'air, de la surface du module et du point de rosée (°C).
	v_{2m}, P_{atm}, RH	Vitesse du vent (m/s), pression atmosphérique (hPa) et humidité relative (%).
	τ_a	Épaisseur optique des aérosols (suivi des poussières sahariennes et de l'harmattan).

Suite page suivante

(suite)

Catégorie	Variable / Feature	Définition et rôle physique
Grandeurs Électriques	P_{dc}, V_{dc}, I_{dc}	Puissance brute (kW), tension (V) et courant (A) continus mesurés côté champ.
	$P_{ac}, V_{ac}, I_{ac}, E_{ac}$	Puissance active injectée (kW), tension, courant et énergie livrée au réseau (kWh).
	$\eta_{inv}, T_{inv}, V_{dc,inv}$	Rendement (%), température interne (°C) et tension d'entrée de l'onduleur.
	$\mathbb{1}_{clip}, \mathbb{1}_{op}, \mathbb{1}_{run}$	Indicateurs binaires d'écrêtage (*clipping*), de fonctionnement normal et de disponibilité.
Exploitation et Milieu	S_f, Soiling	Ratio d'encrassement (perte de transmission due au sable) et historique des lavages.
	$\theta_{AOI}, \theta_z, \gamma_{az}$	Angle d'incidence et coordonnées célestes (angle zénithal, azimut solaire).
	Degradation, LID, PID	Paramètres de vieillissement lent des cellules et de pertes par polarisation.
Temporalité et Features Dérivées	Encodage cyclique	Représentations trigonométriques (sin/cos) de l'heure, du jour et du mois.
	Lags et statistiques	Retards temporels ($t-1$h à $t-168$h) et moyennes glissantes sur 24 heures.
	ξ_{cc} (Ciel clair)	Indice de nébulosité relatif défini par le rapport $\xi_{cc} = G_{obs}/G_{clear}$.
	Indicateurs saisonniers	Marqueurs binaires spécifiques au contexte sahélien (‘is_harmattan‘, ‘is_hivernage‘).

2.5 Conclusion

En ramenant l'ensemble des grandeurs physiques, électriques et temporelles à un référentiel unifié et rigoureusement structuré, ce chapitre relie les phénomènes d'intermittence observés sur le terrain aux exigences de la modélisation statistique. Chaque entrée transmise au modèle de prévision correspond ainsi à un phénomène physique clairement identifiable, ce qui garantit la transparence et l'exploitabilité opérationnelle des résultats pour le gestionnaire du réseau (SENELEC) [24].

Deuxième partie

ARCHITECTURES D'APPRENTISSAGE PROFOND

Chapitre 3

Fondations de l'apprentissage supervisé et régularisation

Ce chapitre fixe les notions théoriques que mobilisent les chapitres suivants : le neurone artificiel et le perceptron multicouche, les fonctions d'activation et de coût, l'optimisation par descente de gradient et rétropropagation, les schémas de régularisation, enfin le protocole d'évaluation. Les développements historiques (perceptron de Rosenblatt, régression logistique, classification multi-classe) restent à l'écart : aucune des architectures évaluées aux chapitres 5 à 8 ne les réactive. L'ambition est de fournir un socle opérationnel, non un panorama.

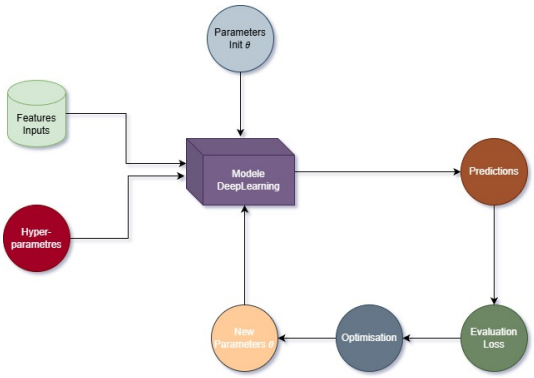


Figure 3.1 : Boucle d'apprentissage supervisé : les données traversent un modèle paramétré, la prédiction est comparée à la cible par une fonction de coût, et l'optimisation ajuste les paramètres.

3.1 Du modèle linéaire au perceptron multicouche

3.1.1 Régression linéaire et conditionnement

Le point de départ est la régression linéaire. Pour un jeu de N observations (x_i, y_i), on cherche a et b minimisant la somme des carrés des écarts

$$f(a, b) = \sum_{i=1}^{N} (ax_i + b - y_i)^2.$$

Géométriquement, f définit un paraboloïde dont les lignes de niveau sont des ellipses d'autant plus allongées que le conditionnement $\kappa = \lambda_{\max}/\lambda_{\min}$ de la Hessienne est grand. Cette anisotropie, illustrée à la figure 3.2, annonce la difficulté qui traverse tout le chapitre : dans une vallée étroite, la descente de gradient oscille transversalement et progresse lentement le long de l'axe utile. C'est précisément cette observation qui motivera les optimiseurs adaptatifs de la section 3.4.

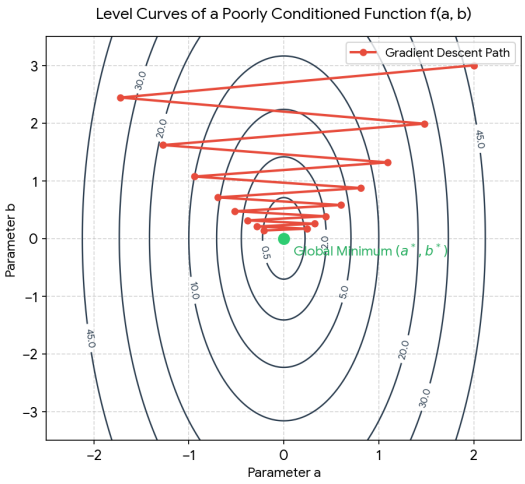


Figure 3.2 : Lignes de niveau de $f(a, b)$: le minimum se trouve dans une région plate et allongée.

La généralisation à p variables suit immédiatement. Avec $\hat{y} = Wx + b$, annuler le gradient conduit aux équations normales $W = (X^\top X)^{-1} X^\top Y$.

3.1.2 Neurone artificiel

Un neurone artificiel généralise cette forme en intercalant une transformation non linéaire φ entre la combinaison linéaire et la sortie :

$$z = Wx + b, \qquad \hat{y} = \varphi(z).$$

La frontière de décision reste l'hyperplan $z = 0$; φ n'en modifie que la transition. Le produit scalaire Wx s'interprète comme une mesure de similarité entre l'entrée et le motif encodé par les poids. Le biais s'absorbe en posant $x_0 = 1$, ce qui permet d'écrire $\hat{y} = \varphi(W'x')$ avec $x' \in \mathbb{R}^{p+1}$, convention systématiquement retenue en pratique (figure 3.3).

Pour un lot de n exemples, la forme matricielle s'écrit $\hat{Y} = \varphi(WX + b\mathbb{1}^\top)$: un seul produit matriciel réalise $q \times n$ produits scalaires en parallèle, ce qui explique l'adéquation de ces modèles aux processeurs graphiques. Si φ est linéaire, la composition de plusieurs couches se réduit à un produit matriciel unique. La non-linéarité n'est donc pas un raffinement : c'est la condition d'existence du deep learning.

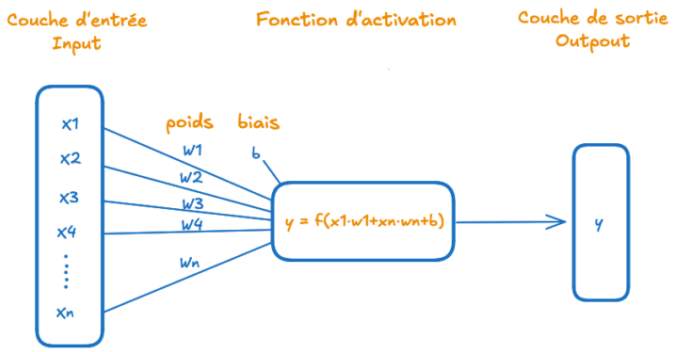


FIGURE 3.3 : Architecture d'un neurone artificiel : les entrées sont pondérées, sommées avec le biais, puis transformées par une activation.

3.1.3 Perceptron multicouche

Le perceptron multicouche répond à une limite structurelle du modèle linéaire, que résume le problème du XOR : les classes $\{(0,0),(1,1)\}$ et $\{(0,1),(1,0)\}$ ne sont séparables par aucune droite, si bien qu'un neurone isolé ne peut les distinguer (figure 3.4). L'empilement de couches et l'intercalation de non-linéarités permettent de construire de telles frontières de décision non linéaires.

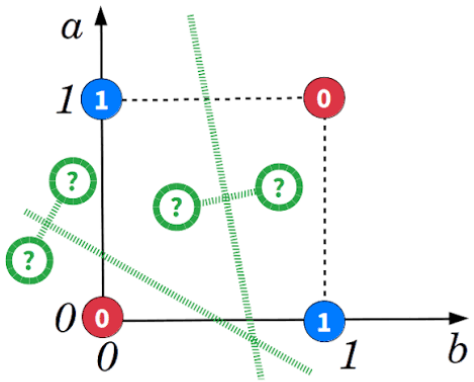


FIGURE 3.4 : Le problème du XOR : les deux classes ne sont pas linéairement séparables, ce qui motive l'empilement de couches et la non-linéarité.

L'empilement des couches produit le perceptron multicouche (MLP). Pour $\ell = 1, \dots, L$:

$$\mathbf{h}^{(\ell)} = \varphi_\ell\Big(W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\Big), \qquad \mathbf{h}^{(0)} = \mathbf{x}.$$

Le vecteur $\mathbf{h}^{(\ell)}$ constitue une représentation interne des données. L'intérêt de la profondeur est hiérarchique : les premières couches détectent des motifs simples, les suivantes les combinent en structures plus abstraites. À capacité égale, un réseau profond nécessite généralement moins de paramètres qu'un réseau large pour approximer une même fonction.

Un résultat classique justifie a posteriori cette architecture : toute fonction continue sur un compact peut être approximée à précision arbitraire par un réseau à une seule couche cachée suffisamment large (Cybenko, 1989 ; Hornik, 1991). Le théorème ne dit rien sur la généralisation

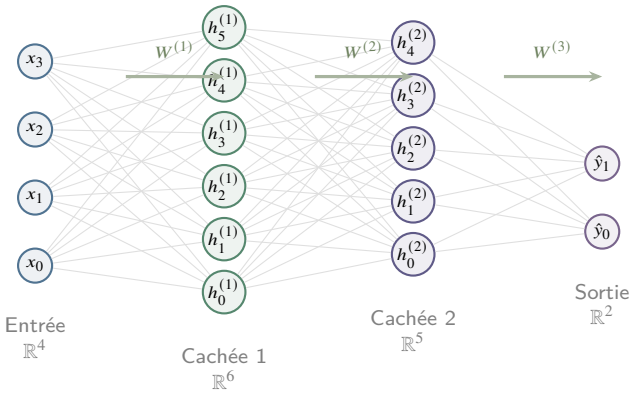


FIGURE 3.5 : Architecture d'un MLP à deux couches cachées.

ni sur la facilité d'apprentissage : la profondeur reste utile en pratique, non pour la capacité de représentation, mais pour l'efficacité statistique.

3.1.4 Stabilité de l'entraînement : normalisation, dropout, initialisation

La stabilité de l'entraînement des réseaux profonds repose sur trois mécanismes complémentaires. La Batch Normalization [11] normalise les activations par mini-batch, ce qui lisse le paysage de la perte et autorise des taux d'apprentissage plus élevés. Le Dropout [27] désactive aléatoirement chaque neurone avec probabilité p, forçant le réseau à ne pas dépendre d'une unité particulière. Les initialisations Xavier/Glorot ($\mathcal{N}(0, 2/(n_{\text{in}}+n_{\text{out}}))$) et He/Kaiming ($\mathcal{N}(0, 2/n_{\text{in}})$) préservent la variance des activations à travers les couches, He doublant la variance pour compenser la moitié des neurones annulés par ReLU. Ces trois leviers sont réexaminés à la section 3.5, sous l'angle de la régularisation.

3.2 Fonctions d'activation

Le choix de l'activation détermine la dynamique du gradient. Sigmoïde et tanh, historiquement dominantes, souffrent d'un gradient maximal borné (0,25 et 1,0 respectivement). Dans un réseau de L couches, le gradient est multiplié par un produit de L facteurs inférieurs à 1 : c'est le *vanishing gradient*, analysé à la section 3.6.

ReLU [16] lève cette limitation en adoptant un gradient constant de 1 pour $z > 0$:

$$\text{ReLU}(z) = \max(0, z), \qquad \text{ReLU}'(z) = \mathbb{1}_{z>0}.$$

Trois propriétés expliquent son succès : gradient non atténué dans la région active, coût de calcul négligeable, sparsité naturelle (environ la moitié des neurones s'annulent). Sa faiblesse, le *dying ReLU*, apparaît lorsqu'un neurone reste définitivement dans la zone négative. Les variantes LeakyReLU, ELU, GELU et Swish atténuent ce problème. GELU et Swish sont aujourd'hui standard dans les Transformers, et GELU équipe le TFT du chapitre 5.

Activation	**Formule**	**Sortie**	**∇ max**	**Usage**
Sigmoïde	$\frac{1}{1+e^{-z}}$	$(0, 1)$	0,25	Portes LSTM
Tanh	$\frac{e^z-e^{-z}}{e^z+e^{-z}}$	$(-1, 1)$	1,0	LSTM
ReLU	$\max(0, z)$	$[0, \infty)$	1,0	CNN, MLP
GELU	$z\,\Phi(z)$	$\mathbb{R}$	1,0	Transformers
Swish	$z\,\sigma(z)$	$\mathbb{R}$	1,0	Transformers
Softmax	$\frac{e^{z_k}}{\sum_j e^{z_j}}$	$(0, 1)^q$	variable	Sortie multi-classe
Identité	z	$\mathbb{R}$	1,0	Régression

Table 3.1 : Récapitulatif des fonctions d'activation.

La couche de sortie suit la même logique : identité pour une régression scalaire, sigmoïde pour une probabilité binaire, softmax pour une distribution sur q classes :

$$\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_{j=1}^{q} e^{z_j}}.$$

En pratique, on calcule $\text{softmax}(z - \max(z))$ pour éviter les débordements numériques.

3.3 Fonctions de coût et métriques d'évaluation

Entraîner un réseau revient à minimiser une fonction de coût qui traduit l'écart entre prédiction et vérité en un scalaire *différentiable* : c'est elle, et non la métrique, qui pilote la descente de gradient. Les métriques d'évaluation, mesurées sur un jeu de test indépendant, jugent la qualité des prévisions ; libres de toute contrainte de dérivabilité, elles expriment l'écart en des termes interprétables pour l'exploitant. Le pipeline `deep_aero_sn` rapporte deux familles de métriques : les *déterministes*, pour la prévision ponctuelle (souvent la médiane prédite), et les *probabilistes*, pour les intervalles de confiance.

Les pertes effectivement optimisées sont peu nombreuses. En prévision ponctuelle, il s'agit de l'erreur quadratique moyenne $\text{MSE}(\hat{y}, y) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$, dérivable et sensible aux grands écarts. En prévision probabiliste, il s'agit de la perte pinball, qui évalue un quantile q :

$$\text{QL}(y, \hat{y}, q) = q\max(y - \hat{y}, 0) + (1 - q)\max(\hat{y} - y, 0),$$

et se réduit à l'erreur absolue pour $q = 0{,}5$. Le pipeline combine ces deux objectifs par la perte hybride donnée en fin de section.

Dans les formules ci-dessous, les moyennes sont notées $\bar{y} = \frac{1}{n}\sum_i y_i$ pour les observations et $\bar{\hat{y}} = \frac{1}{n}\sum_i \hat{y}_i$ pour les prévisions.

Erreur absolue moyenne (MAE). La **MAE** vaut

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\hat{y}_i - y_i| \,.$$

Elle exprime l'erreur moyenne dans l'unité de la cible : une MAE de 0,5 MW signifie que la prévision s'en écarte de 0,5 MW en moyenne. Ne pénalisant pas davantage les grandes erreurs, elle reste robuste aux extrêmes mais masque une défaillance concentrée sur quelques points.

Racine de l'erreur quadratique moyenne. La **RMSE** vaut

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}.$$

Le carré donne un poids accru aux grandes erreurs, car un écart de 3 MW contribue neuf fois plus qu'un écart de 1 MW ; d'où sa sensibilité aux pics mal prévus (passages nuageux brusques, couverture surestimée) et son statut de métrique de référence pour les applications réseau, où les écarts extrêmes coûtent cher.

Erreur absolue moyenne en pourcentage (MAPE). La **MAPE** s'écrit

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n} \left|\frac{\hat{y}_i - y_i}{y_i}\right| \ \%.$$

Elle reste toutefois *indéfinie* dès qu'une observation est nulle, cas permanent en photovoltaïque (nuit, panne) : la division par une valeur proche de zéro produirait des erreurs astronomiques et non informatives. Le pipeline ne calcule donc la MAPE que sur les points dépassant un seuil relatif $\varepsilon = \max\bigl(10^{-6},\ 0{,}05 \cdot \text{médiane}(|y|)\bigr)$; si aucun ne passe le seuil (séquence entièrement nocturne), il bascule sur la **sMAPE**, bornée par 200 % :

$$\mathrm{sMAPE} = \frac{200}{n}\sum_{i=1}^{n} \frac{|\hat{y}_i - y_i|}{|y_i| + |\hat{y}_i|} \ \%.$$

Coefficient de détermination. Le R^2 vaut

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}.$$

Il mesure la part de variance expliquée relativement au modèle constant $\bar{y}$. Un R^2 de 0,877 (TCN sur Diass) signifie que le modèle réduit de 87,7 % l'erreur quadratique du prédicteur naïf. Contrairement à une idée répandue, il peut devenir négatif quand la prévision est pire que la moyenne, comme l'illustre la persistance sur les séries très variables ; ce comportement constitue en soi un signal diagnostique.

Erreur quadratique moyenne normalisée (NRMSE). La **NRMSE** (commande `nrmse`) rapporte la RMSE à l'amplitude de la série observée :

$$\mathrm{NRMSE} = \frac{\mathrm{RMSE}}{\max(y) - \min(y) + 10^{-8}},$$

le terme 10^{-8} écartant la division par zéro. En rapportant l'erreur à l'étendue des valeurs, cette normalisation autorise la comparaison entre sites de puissances ou horizons différents, là où la RMSE brute dépend de l'échelle de la centrale ; c'est la métrique employée au chapitre 6 pour comparer les architectures.

Couverture. La **couverture** est la proportion d'observations tombant dans l'intervalle :

$$\mathrm{Cov} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\left[y_i \in [\hat{y}_i^{\mathrm{bas}}, \hat{y}_i^{\mathrm{haut}}]\right].$$

Pour des quantiles $q = 0{,}1$ et $q = 0{,}9$, la couverture attendue vaut 80 % : plus le modèle s'en approche, plus le niveau de confiance annoncé est honnête. Sur Diass, le TCN atteint 79,8 % contre 74,2 % pour le TFT (chapitre 7.1.8).

Largeur d'intervalle. La **largeur moyenne** moyenne la largeur de l'intervalle :

$$\mathrm{Width} = \frac{1}{n}\sum_{i=1}^{n}\left(\hat{y}_i^{\mathrm{haut}} - \hat{y}_i^{\mathrm{bas}}\right).$$

À couverture égale, un intervalle plus étroit est préférable : il traduit une incertitude mieux maîtrisée, donc des prévisions plus utiles.

Score de Winkler. Le **score de Winkler** (commande `winkler_80`, seuil $\alpha = 0{,}2$) pénalise à la fois la largeur de l'intervalle et les écarts hors bornes :

$$\mathrm{Winkler} = \frac{1}{n}\sum_{i=1}^{n}\left[\mathrm{Width}_i + \frac{2}{\alpha}\Delta_i\right],$$

où Δ_i est nul si y_i appartient à l'intervalle, et vaut sinon la distance de y_i à la borne la plus proche. À la différence de la seule couverture, ce score punit les intervalles trop larges comme les sorties de borne, offrant un compromis unique entre finesse et honnêteté.

Perte hybride. Le pipeline combine les deux objectifs par une pondération w_{mse} :

$$\mathcal{L} = w_{\mathrm{mse}} \cdot \mathrm{MSE}(\hat{y}_{0,5}, y) + (1 - w_{\mathrm{mse}}) \cdot \overline{\mathrm{Pinball}}(\hat{y}_q, y), \quad q \in \{0{,}1, 0{,}5, 0{,}9\}.$$

Cette formulation, centrale pour le chapitre 6, n'est rappelée ici que pour mémoire : elle est analysée dans son contexte applicatif.

3.4 Optimisation

3.4.1 Descente de gradient

L'algorithme de base déplace les paramètres dans la direction opposée au gradient :

$$\theta \leftarrow \theta - \eta \, \nabla_\theta \mathcal{L}(\theta).$$

Selon la taille du lot utilisée à chaque mise à jour, on distingue trois régimes : le batch complet (gradient exact, coût prohibitif), le SGD pur (un exemple par mise à jour, forte variance) et le mini-batch, standard en pratique, dont le bruit agit comme une régularisation implicite en favorisant les minima plats. Le taux d'apprentissage η est l'hyperparamètre le plus critique ; les schedules usuels vont du step decay au cosine annealing, jusqu'au warmup suivi d'un decay, standard pour les Transformers et utilisé par le TFT.

Sur une fonction quadratique, la convergence est garantie si $\eta < 2/\lambda_{\max}$, avec un nombre d'itérations en $O(\kappa \log(1/\varepsilon))$. En grande dimension non convexe, les mauvais minima locaux sont rares ; les difficultés réelles sont les points-selles et les plateaux, que le bruit du mini-batch aide à traverser.

3.4.2 Rétropropagation

La rétropropagation [15] calcule $\nabla_\theta \mathcal{L}$ en appliquant la règle de la chaîne de la sortie vers l'entrée, en $O(D)$ opérations, soit la même complexité que la passe avant. En notant $\delta^{(\ell)} = \partial \mathcal{L} / \partial \mathbf{z}^{(\ell)}$, la récurrence s'écrit

$$\delta^{(\ell)} = \left(W^{(\ell+1)\top} \delta^{(\ell+1)} \right) \odot \varphi'(\mathbf{z}^{(\ell)}), \qquad \frac{\partial \mathcal{L}}{\partial W^{(\ell)}} = \delta^{(\ell)} \mathbf{h}^{(\ell-1)\top}.$$

Le gradient d'un poids est donc le produit externe du signal d'erreur qui remonte et de l'activation qui descend : plus l'activation est grande, plus le poids est ajusté. Cette forme est exactement celle du gradient sigmoïde+BCE ; elle explique aussi pourquoi les activations à gradient borné (sigmoïde, tanh) provoquent le vanishing gradient analysé plus loin.

En PyTorch, la rétropropagation est automatisée via l'autograd : `loss.backward()` peuple les accumulateurs `.grad`, qu'il faut remettre à zéro avant chaque itération (`optimizer.zero_grad()`).

3.4.3 Optimiseurs adaptatifs

Momentum accumule une inertie, $v_t = \beta v_{t-1} + \nabla_\theta \mathcal{L}$, qui amortit les oscillations dans les directions de forte courbure. Adagrad divise le pas par la racine de la somme cumulée des gra-

dients au carré, mais son taux décroît indéfiniment. RMSProp corrige ce défaut par une moyenne mobile. Adam [12] combine les deux idées avec une correction de biais :

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\nabla_\theta \mathcal{L}, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2)(\nabla_\theta \mathcal{L})^2,$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon}\hat{m}_t, \qquad \hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}.$$

Valeurs par défaut : $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$. AdamW [18] découple le weight decay de l'adaptation,

$$\theta_{t+1} = (1-\eta\lambda)\theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon}\hat{m}_t,$$

ce qui évite que la pénalisation L_2 soit écrasée par la normalisation adaptative. C'est l'optimiseur retenu pour le TFT, comme indiqué au chapitre 5.

Architecture	**Optimiseur**	**Hyperparamètres**
CNN + batch norm	Adam	$\eta = 10^{-3}$
Transformer	AdamW + warmup	$\lambda = 0.01$, warmup 4000 pas
Généralisation critique	SGD + momentum	$\eta = 0.01$, schedule cosinus
Prototype rapide	Adam	Valeurs par défaut

Table 3.2 : Recommandations d'optimiseurs.

3.5 Régularisation

3.5.1 Compromis biais-variance

L'erreur totale d'un modèle se décompose en biais^2, variance et bruit irréductible. Un biais élevé correspond au sous-apprentissage, une variance élevée au surapprentissage (figure 3.6). La régularisation augmente légèrement le biais mais réduit significativement la variance, déplaçant l'optimum vers une complexité plus faible.

3.5.2 Pénalités L_1, L_2 et Elastic Net

La pénalité L_2,

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \frac{\lambda}{2}\sum_{\ell} \|W^{(\ell)}\|_F^2,$$

modifie le gradient en $\partial\mathcal{L}/\partial W + \lambda W$, ce qui revient à multiplier les poids par $(1-\eta\lambda)$ à chaque pas, d'où le nom *weight decay*. La pénalité L_1,

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \lambda\sum_{\ell} \|W^{(\ell)}\|_1,$$

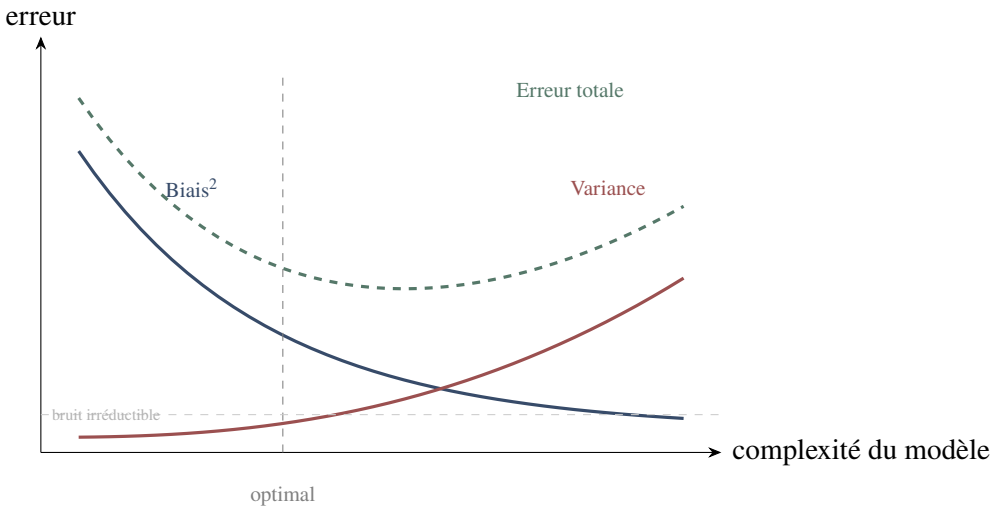


FIGURE 3.6 : Compromis biais-variance.

favorise la parcimonie : géométriquement, le losange L_1 a ses sommets sur les axes, et la perte atteint typiquement sa première intersection en un point où certains poids sont exactement nuls (figure 3.7). Elastic Net combine les deux pour obtenir à la fois parcimonie et stabilité.

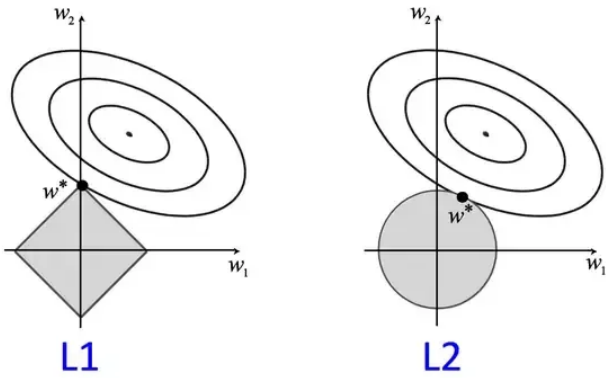


FIGURE 3.7 : Géométrie du L_1 vs L_2 : le losange L_1 induit la parcimonie, le cercle L_2 des poids petits mais non nuls.

3.5.3 Dropout

Le dropout [27] désactive aléatoirement chaque neurone avec probabilité p pendant l'entraînement, puis rescale les activations restantes par $1/(1-p)$ pour conserver la magnitude moyenne :

$$\tilde{h}_j = \frac{m_j}{1-p} h_j, \qquad m_j \sim \text{Bernoulli}(1-p).$$

À l'inférence, tous les neurones sont actifs. L'interprétation bayésienne (Gal & Ghahramani, 2016) y voit une approximation de l'inférence sur l'ensemble des sous-réseaux. En pratique, $p = 0{,}5$ sur les couches denses, $p = 0{,}1$–$0{,}2$ sur la couche d'entrée, et aucun dropout en sortie.

3.5.4 Normalisation

Quatre variantes se distinguent par l'axe de normalisation. La Batch Normalization normalise par feature sur le mini-batch ; elle dépend donc de la taille de lot et se comporte différemment à l'entraînement et à l'inférence. La Layer Normalization,

$$\mu = \frac{1}{H}\sum_{k=1}^{H} h_k, \qquad \sigma^2 = \frac{1}{H}\sum_{k=1}^{H}(h_k-\mu)^2, \qquad \tilde{h}_k = \gamma_k \frac{h_k-\mu}{\sqrt{\sigma^2+\epsilon}} + \beta_k,$$

normalise par échantillon sur les features, ce qui la rend indépendante du batch, propriété essentielle pour les Transformers qui traitent des séquences de longueur variable. C'est la normalisation utilisée par le TFT et le TCN (chapitre 5). L'Instance Normalization opère par canal et par échantillon, la Group Normalization par groupes de canaux, indépendamment du batch.

Le débat sur le mécanisme d'action de la BN a été tranché par Santurkar et al. (2018) : elle agit principalement en lissant le paysage de la perte, plutôt qu'en réduisant l'internal covariate shift.

3.6 Vanishing et exploding gradients

La rétropropagation multiplie les gradients couche par couche. Si chaque facteur est inférieur à 1 en magnitude, comme pour une sigmoïde dont le gradient maximal vaut 0,25, le gradient décroît exponentiellement avec la profondeur : après dix couches, il est multiplié par $0{,}25^{10} \approx 10^{-6}$, et les couches proches de l'entrée cessent d'apprendre. Le phénomène inverse (facteurs > 1) fait exploser la perte en NaN.

Quatre leviers corrigent le vanishing. L'activation ReLU (gradient $\in \{0, 1\}$) ne réduit pas le gradient dans sa zone active. Les initialisations de He et Xavier ajustent la variance des poids à la dimension des couches, écartant l'explosion comme l'annulation des activations. Les connexions résiduelles,

$$\mathbf{h}^{(\ell)} = \mathbf{h}^{(\ell-1)} + \mathcal{F}(\mathbf{h}^{(\ell-1)}), \qquad \frac{\partial \mathbf{h}^{(\ell)}}{\partial \mathbf{h}^{(\ell-1)}} = I + \frac{\partial \mathcal{F}}{\partial \mathbf{h}^{(\ell-1)}},$$

garantissent un terme identité dans la jacobienne, ce qui empêche le gradient de s'annuler ; c'est ce qui a permis d'entraîner des réseaux à plusieurs centaines de couches (ResNet), et l'on retrouve ce mécanisme dans les blocs résiduels du TCN (chapitre 5). Les LSTM, enfin, résolvent le problème dans les séquences grâce à un canal de mémoire à flux additif $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$, plutôt que multiplicatif.

Pour l'explosion, la parade est le gradient clipping : si $\|g\| > \tau$, on remplace g par $\tau g/\|g\|$, avec $\tau = 1$ ou 5. La technique est systématique pour les RNN et les Transformers ; elle est appliquée au TFT du chapitre 5.

Architecture	Remèdes
MLP profond	ReLU + He init + skip connections
CNN profond	ResNet + BatchNorm
RNN	LSTM/GRU + gradient clipping
Transformer	LayerNorm + gradient clipping

TABLE 3.3 : Stratégies anti-vanishing par architecture.

3.7 Généralisation et protocole d'évaluation

3.7.1 Découpage des données

Le découpage standard sépare entraînement (60–80 %, ajustement des poids), validation (10–20 %, hyperparamètres et early stopping) et test (10–20 %, évaluation finale unique). Pour les séries temporelles, l'ordre chronologique est préservé : on ne mélange pas les échantillons, et la normalisation est ajustée sur l'entraînement seul puis gelée. La validation croisée classique cède la place au walk-forward : chaque pli entraîne sur tout le passé disponible et teste sur la fenêtre suivante, ce qui garantit qu'aucune donnée future n'est utilisée (figure 3.8).

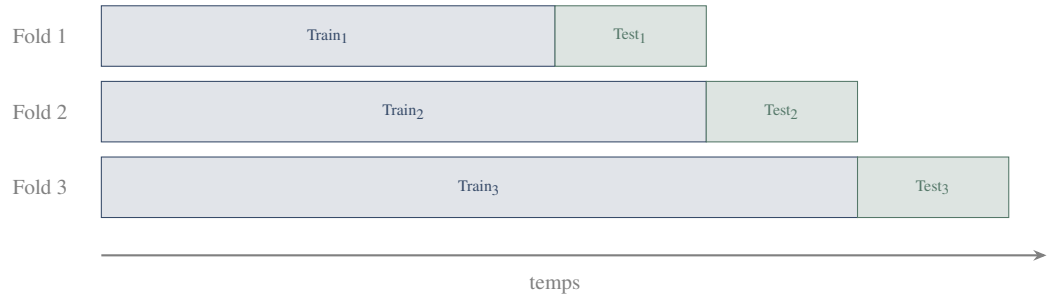


FIGURE 3.8 : Validation croisée walk-forward pour séries temporelles.

3.7.2 Fuite de données

La fuite de données désigne toute contamination de l'évaluation par une information indisponible au moment de la prévision. Elle se rencontre le plus souvent sous l'une de trois formes : ajustement de la normalisation sur l'ensemble complet, sélection de features ou d'hyperparamètres guidée par le test, usage de features construites avec le futur. Cette dernière forme est la plus insidieuse, car elle se dissimule aisément dans une longue liste de colonnes. Les garde-fous du pipeline sont détaillés au chapitre 7.1.8, où ils s'appliquent au cas de Diass : ajustement exclusif du scaler sur l'entraînement, sélection confinée à l'entraînement et à la validation, ingénierie causale excluant automatiquement les dérivées quasi linéaires de la cible.

3.7.3 Optimisation des hyperparamètres

L'optimisation des hyperparamètres se heurte à quatre difficultés : structure nichée (chaque évaluation exige un entraînement complet), coût en heures-GPU, espace mixte continu/entier/catégoriel à dépendances conditionnelles, et objectif non lisse. La recherche sur grille devient ingérable au-delà de quatre paramètres ; la recherche aléatoire de Bergstra & Bengio (2012) reste une référence lorsque peu de dimensions comptent réellement. Les méthodes modernes se répartissent en quatre familles : optimisation bayésienne, estimateur de Parzen arborescent (TPE), méthodes multi-fidélité (successive halving, Hyperband, ASHA) et méthodes populationnelles (CMA-ES, PBT). Franceschi et al. (2024) en donnent une synthèse.

Ce travail retient Optuna, avec un échantillonneur TPE et un élagage médian. La perte minimisée est la perte hybride MSE+pinball (section 3.3), et les essais sont journalisés dans MLflow pour assurer la traçabilité des configurations. Le détail de la recherche, les valeurs retenues pour Diass et les résultats comparés figurent au chapitre 7.1.8.

3.7.4 Arrêt anticipé

On surveille la perte de validation et l'on arrête l'entraînement lorsqu'elle cesse de décroître, typiquement après une patience de 5 à 20 époques, en restaurant les poids du meilleur point. Ce mécanisme est utilisé pour tous les modèles du chapitre 7.1.8, avec une patience de 25 époques pour le TCN et le TFT.

Chapitre 4

Modèles pour séries temporelles

Ce chapitre présente les cadres de modélisation qui exploitent la dimension temporelle. Il examine successivement les réseaux convolutifs 1D, qui extraient des motifs locaux par partage de poids ; les réseaux récurrents (RNN, LSTM, GRU), qui entretiennent un état caché pour suivre la dépendance séquentielle ; le mécanisme d'attention, qui pondère directement l'ensemble des états passés ; et le Transformer, qui abandonne la récurrence au profit d'une auto-attention entièrement parallélisable. Ces briques forment le socle des architectures spécialisées TFT et TCN, détaillées au chapitre 5.

4.1 Réseaux convolutifs (CNN)

Les réseaux denses traitent chaque entrée isolément, sans exploiter la topologie spatiale ou temporelle. Les réseaux convolutifs (CNN) y remédient en imposant localité et partage de poids, ce qui leur permet d'analyser des séquences longues à nombre de paramètres modéré.

4.1.1 Motivation : de la densité à la convolution

Un perceptron multicouche reliant une entrée de dimension p à N neurones mobilise $p \times N$ paramètres ; sur une entrée de forte dimension, cette croissance quadratique fait rapidement basculer l'entraînement en surapprentissage. Les CNN l'évitent par trois contraintes structurelles. La **localité** limite chaque neurone à un sous-ensemble restreint de l'entrée, son champ réceptif local. Le **partage des poids** applique un même filtre sur toute la séquence, ramenant le coût d'un filtre à la taille k de son noyau. L'**invariance par translation** garantit qu'une caractéristique apprise en un point reste détectable en toute autre position.

Ces contraintes ramènent la complexité paramétrique de $O(p \times N)$ à $O(k \times N)$, autorisant l'entraînement sur des séquences temporelles de grande longueur.

4.1.2 Convolution 1D et causalité

En prévision temporelle, un filtre 1D de taille k glisse le long du temps en calculant le produit scalaire entre ses poids w et la fenêtre d'entrée. Pour un signal x, la convolution 1D discrète s'écrit :

$$(x * w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t+i}.$$

Interdire toute fuite d'information du futur vers le passé impose une contrainte de **causalité**, qui restreint le calcul aux pas de temps antérieurs ou égaux à t :

$$(x *_c w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i}.$$

Le mode de remplissage (*padding*) fixe la dimension de la carte de sortie. En mode **valid**, aucun remplissage n'est ajouté et la sortie compte $T - k + 1$ pas. En mode **same**, un remplissage symétrique conserve la longueur initiale T. En mode **causal**, le remplissage est rejeté exclusivement à gauche : la longueur T est préservée sans qu'aucune information future ne remonte.



Figure 4.1 : Comportement des modes de remplissage (*padding*) : **valid**, **same** et **causal**.

4.1.3 Convolution 2D et blocs d'extraction

Pour les représentations bidimensionnelles (spectrogrammes issus du signal temporel, par exemple), l'opération s'étend sur deux axes. Une entrée X de dimensions $H \times W$ et C canaux convoluée par un filtre $W \in \mathbb{R}^{C_f \times k_h \times k_w}$ produit :

$$(X * W)_{i,j} = \sum_{c=1}^{C_f} \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} W_{c,m,n} \cdot X_{c,\, i+m,\, j+n}.$$

Une telle couche compte $C_f \times (C_{\text{in}} \times k_h \times k_w + 1)$ paramètres.

Dans une architecture moderne, l'extraction de motifs associe la convolution à des transformations stabilisatrices :

$$\mathbf{h} = \mathrm{Dropout}\Big(\mathrm{ReLU}\big(\mathrm{BN}(\mathrm{Conv1D}_{k\times F}(\mathbf{x}))\big)\Big),$$

où BN désigne la normalisation par lot (*Batch Normalization*) et F le nombre de filtres. La représentation intermédiaire est ensuite projetée vers l'espace cible :

$$\hat{\mathbf{y}} = W_o\,\mathrm{Flatten}(\mathbf{h}) + \mathbf{b}_o, \qquad W_o \in \mathbb{R}^{q\times(T\cdot F)},$$

où q est la dimension de la sortie ($q = 3$ pour l'estimation de quantiles).

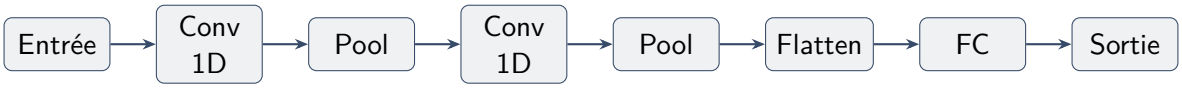


Figure 4.2 : Chaîne de traitement typique d'un CNN 1D séquentiel.

4.1.4 Sous-échantillonnage et hiérarchie des représentations

La résolution temporelle se réduit par le pas de convolution (*stride*) s ou par agrégation (*pooling*). Le max-pooling retient l'activation maximale sur une fenêtre donnée :

$$\mathrm{MaxPool}_p(X)_i = \max_{m\in[0,p)} X_{i\cdot p+m},$$

tandis que l'agrégation moyenne (*average pooling*) calcule la moyenne du voisinage. L'empilement de ces couches construit une hiérarchie de représentations, des motifs locaux haute fréquence jusqu'aux variations de faible fréquence qui portent les tendances.

4.1.5 Champ réceptif et convolutions dilatées

Le champ réceptif mesure la largeur de la séquence d'entrée qui influence un neurone donné. Pour un réseau de L couches convolutives standards de noyau k, il croît linéairement :

$$\text{Champ réceptif} = 1 + L \times (k-1).$$

Capturer des dépendances à long terme sans alourdir le réseau ni multiplier les paramètres : telle est la raison d'être des **convolutions dilatées**, qui introduisent un facteur d'espacement d :

$$(x *_d w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d\cdot i}.$$

En faisant croître la dilatation exponentiellement avec la profondeur ($d = 2^\ell$ à la couche ℓ), le champ réceptif s'étend lui aussi exponentiellement. Cette propriété est le cœur de l'architecture WaveNet [29], qui y adjoint une activation filtrée (*gating*) :

$$z = \tanh(W_f * x) \odot \sigma(W_g * x),$$

où $\odot$ désigne le produit de Hadamard.

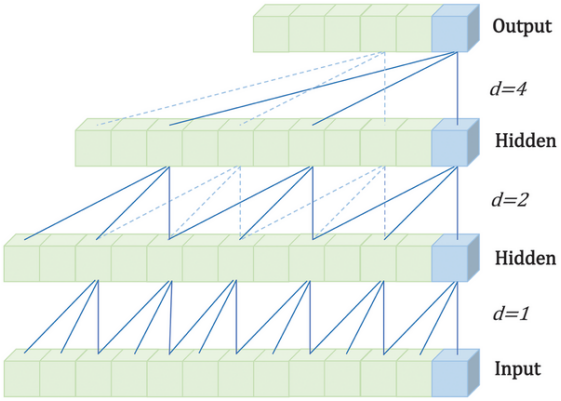


FIGURE 4.3 : Convolutions dilatées causales avec facteur d'expansion exponentiel ($d = 1, 2, 4, 8$).

4.2 Réseaux récurrents et architectures à portes (RNN, LSTM, GRU)

Les réseaux récurrents modélisent directement la dépendance séquentielle en conservant un état caché mis à jour à chaque pas de temps.

4.2.1 Réseaux de neurones récurrents (RNN)

Le RNN élémentaire traite une séquence $\mathbf{x}_1, \dots, \mathbf{x}_T$ en entretenant un état interne $\mathbf{h}_t$:

$$\mathbf{h}_t = \tanh(W_{hh}\,\mathbf{h}_{t-1} + W_{xh}\,\mathbf{x}_t + \mathbf{b}_h)\,,$$

$$\hat{\mathbf{y}}_t = W_{hy}\,\mathbf{h}_t + \mathbf{b}_y.$$

La régularisation des réseaux récurrents demande une adaptation, le dropout standard perturbant la mémoire temporelle. Le *dropout récurrent* applique un même masque de Bernoulli $\mathbf{m}$ à tous les pas de temps de la séquence :

$$\tilde{\mathbf{h}}_t = \mathbf{m} \odot \mathbf{h}_t, \qquad \mathbf{m} \sim \text{Bernoulli}(1-p).$$

L'entraînement procède par rétropropagation à travers le temps (*Backpropagation Through Time*, BPTT), dont la récurrence enchaîne les produits matriciels $\prod_k W_{hh}$. Le mécanisme de dis-

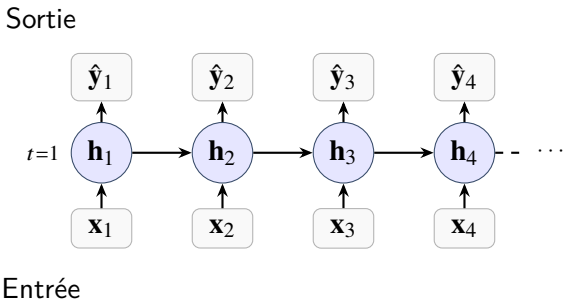


FIGURE 4.4 : Déploiement temporel d'un réseau récurrent.

parition du gradient analysé à la section 3.6 s'y manifeste pleinement : les dépendances lointaines cessent d'être apprises.

4.2.2 LSTM (Long Short-Term Memory)

Le réseau LSTM [10] résout la disparition du gradient par un vecteur d'état de cellule $\mathbf{c}_t$ régulé par trois portes d'activation sigmoïdiennes :

$$
\begin{aligned}
\mathbf{f}_t &= \sigma\big(W_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\big) && \text{(porte d'oubli)},\\
\mathbf{i}_t &= \sigma(W_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) && \text{(porte d'entrée)},\\
\tilde{\mathbf{c}}_t &= \tanh(W_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) && \text{(candidat de mémoire)},\\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t && \text{(mise à jour de l'état de cellule)},\\
\mathbf{o}_t &= \sigma(W_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) && \text{(porte de sortie)},\\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t) && \text{(état caché)}.
\end{aligned}
$$

L'opération additive $\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \ldots$ entretient un flux d'erreur linéaire le long de la séquence : c'est ce canal additif qui neutralise le vanishing gradient (section 3.6).

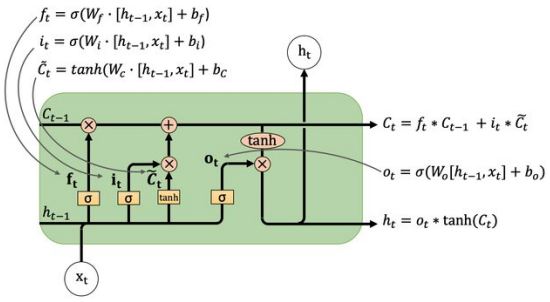


FIGURE 4.5 : Structure interne et flux d'information au sein d'une cellule LSTM.

4.2.3 GRU (Gated Recurrent Unit)

Le bloc GRU simplifie le LSTM en fusionnant état de cellule et état caché, ramenant le système à deux portes :

$$\begin{aligned}
\mathbf{z}_t &= \sigma(W_z[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z) && \text{(porte de mise à jour),}\\
\mathbf{r}_t &= \sigma(W_r[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r) && \text{(porte de réinitialisation),}\\
\tilde{\mathbf{h}}_t &= \tanh(W_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h) && \text{(état candidat),}\\
\mathbf{h}_t &= (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t && \text{(interpolation).}
\end{aligned}$$

Cette formulation réduit d'environ 25 % le nombre de paramètres par rapport au LSTM, à performances comparables.

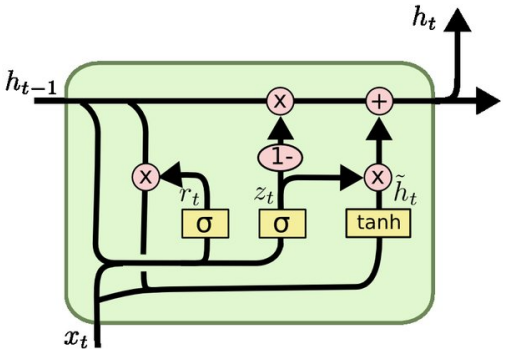


Figure 4.6 : Architecture d'une unité GRU.

4.2.4 Extensions récurrentes

Là où la séquence entière est disponible simultanément, comme dans les tâches non causales, les réseaux récurrents bidirectionnels la parcourent dans les deux sens chronologiques :

$$\mathbf{h}_t = [\overrightarrow{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t].$$

Ce traitement reste toutefois proscrit pour la prévision causale en temps réel, où le futur n'est pas connu.

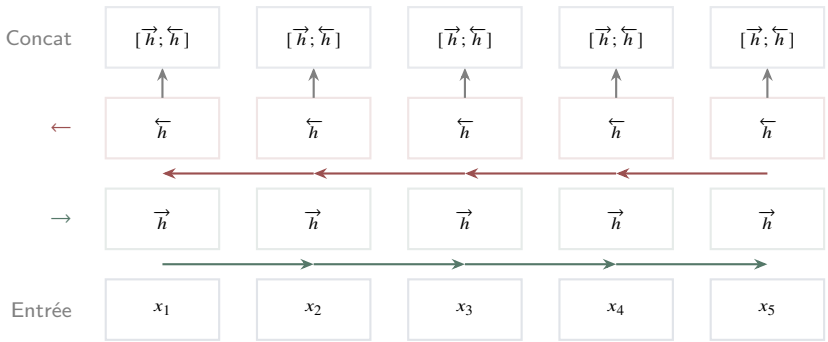


Figure 4.7 : Réseau récurrent bidirectionnel.

Critère	**RNN Standard**	**LSTM / GRU**
Mémoire long terme	Limitée	Élevée
Rétropropagation du gradient	Évanouissement	Stabilisée
Calcul parallélisable	Non (Séquentiel)	Non (Séquentiel)
Complexité temporelle	$O(T)$	$O(T)$
Nombre de paramètres	$3d_h^2 + 3d_h d_x$	$4(d_h^2 + d_h d_x)$ (LSTM)

Table 4.1 : Comparaison synthétique des modèles récurrents.

4.3 Mécanisme d'attention

L'attention remédie au goulot d'étranglement du vecteur d'état de dimension fixe : au lieu de comprimer tout le passé dans un seul vecteur, elle pondère directement la contribution de chaque état historique.

4.3.1 Attention additive et multiplicative

L'attention additive [3] calcule un score d'alignement $e_{t,j}$ entre l'état du décodeur $\mathbf{s}_{t-1}$ et les états de l'encodeur $\mathbf{h}_j$:

$$e_{t,j} = \mathbf{v}^\top \tanh\big(W_s\, \mathbf{s}_{t-1} + W_h\, \mathbf{h}_j\big)\,, \qquad \alpha_{t,j} = \frac{\exp(e_{t,j})}{\sum_{k=1}^{T} \exp(e_{t,k})}.$$

Le vecteur de contexte $\mathbf{c}_t = \sum_{j=1}^{T} \alpha_{t,j}\, \mathbf{h}_j$ agrège ensuite les représentations pondérées.

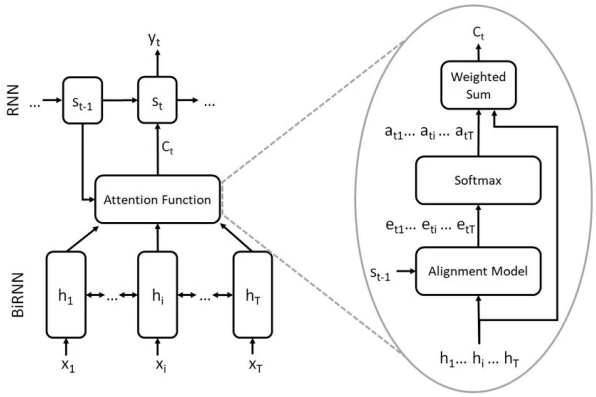


Figure 4.8 : Comparaison entre le goulot d'étranglement séquentiel et le mécanisme d'attention d'alignement.

4.3.2 Self-Attention et Multi-Head Attention

L'auto-attention (*self-attention*) projette une séquence X par trois matrices de poids, produisant requêtes (Q), clés (K) et valeurs (V) :

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

L'attention par produit scalaire normalisé s'écrit :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

où le facteur $\sqrt{d_k}$ évite la saturation du softmax pour les grandes dimensions.

Pour capter simultanément des dépendances issues de plusieurs sous-espaces de représentation, l'attention multi-têtes (*Multi-Head Attention*) exécute H projections en parallèle :

$$\text{head}_h = \text{Attention}(QW_Q^h,\, KW_K^h,\, VW_V^h),$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_H)\, W_O.$$

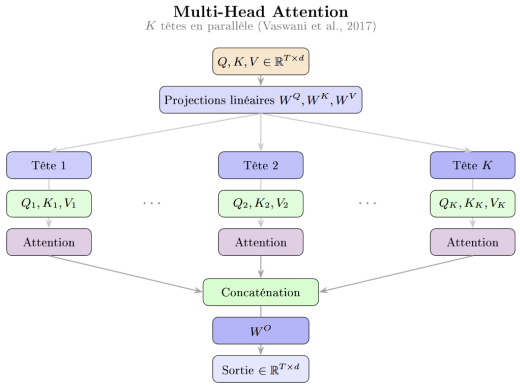


Figure 4.9 : Mécanisme d'attention multi-têtes.

Le coût computationnel de l'auto-attention, $O(T^2 \cdot d_k)$, croît quadratiquement avec la longueur de la séquence T.

4.4 Architecture Transformer

Le Transformer [30] écarte la récurrence au profit de l'auto-attention, ce qui autorise une parallélisation complète du traitement des séquences.

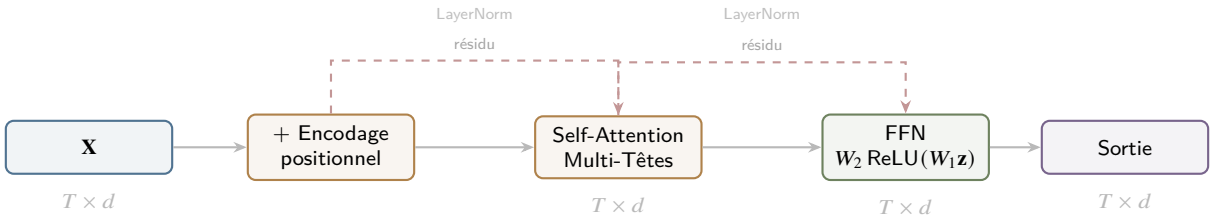


Figure 4.10 : Schéma du bloc encodeur du Transformer.

4.4.1 Encodage positionnel

L'auto-attention ne porte en elle aucune notion d'ordre : la position temporelle pos doit donc être injectée explicitement, ici par des fonctions sinusoïdales :

$$\mathbf{PE}_{(pos,\,2i)} = \sin\!\left(\frac{pos}{10000^{2i/d}}\right), \qquad \mathbf{PE}_{(pos,\,2i+1)} = \cos\!\left(\frac{pos}{10000^{2i/d}}\right),$$

où i désigne l'indice de la dimension d'encodage.

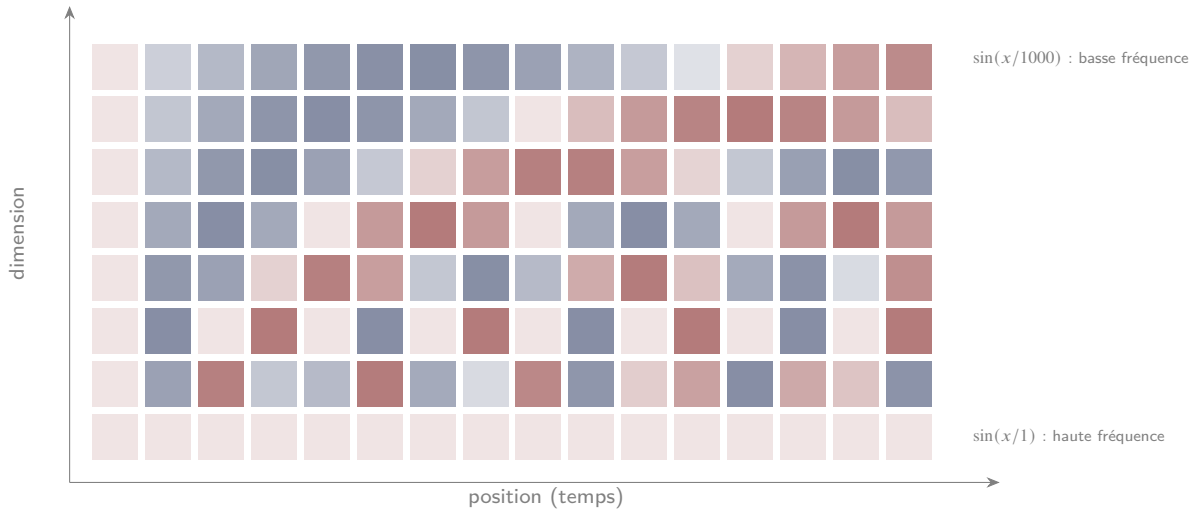


Figure 4.11 : Matrice d'encodage positionnel sinusoïdal.

4.4.2 Sous-couches et projection

Chaque sous-couche intègre une connexion résiduelle suivie d'une normalisation par couche (*Layer Normalization*) :

$$\text{Sortie} = \text{LayerNorm}(\mathbf{x} + \text{Dropout}(\text{SousCouche}(\mathbf{x}))) \,.$$

Le réseau positionnel à propagation avant (*Feed-Forward Network*, FFN) applique deux transformations affines encadrant une non-linéarité :

$$\text{FFN}(\mathbf{z}) = W_2 \cdot \text{ReLU}(W_1\mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2.$$

En prévision temporelle, la représentation latente finale $\mathbf{Z}^{(L)}$ issue de l'encodeur est projetée linéairement pour construire la prédiction sur l'horizon H :

$$\hat{\mathbf{Y}} = W_o\,\mathbf{Z}^{(L)} + \mathbf{b}_o, \qquad W_o \in \mathbb{R}^{q \times d_{\text{model}}}.$$

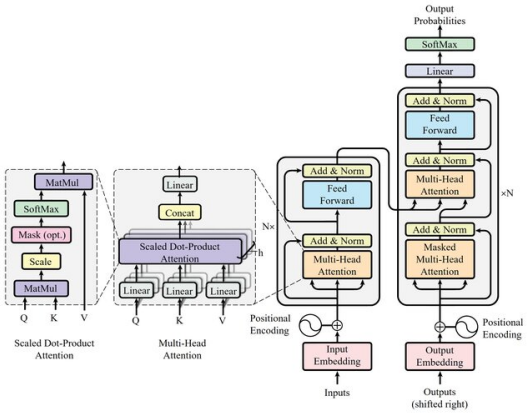


FIGURE 4.12 : Architecture globale du Transformer (Encodeur-Décodeur).

Chapitre 5

Architectures avancées appliquées

La prévision photovoltaïque consiste à estimer la production solaire à partir de séquences historiques. Sa difficulté tient à deux échelles de variabilité imbriquées : le cycle diurne et saisonnier, largement déterministe, et la couverture nuageuse, brutale et stochastique. Les méthodes de lissage, aveugles à la seconde, s'y révèlent insuffisantes. Ce chapitre présente les deux architectures de référence retenues dans ce travail, le Temporal Fusion Transformer et le Temporal Convolutional Network, ainsi que le cadre commun d'encodage et d'évaluation qui les met en regard.

5.1 Solaire : Temporal Fusion Transformer (TFT)

5.1.1 Le TFT sélectionne les variables puis pondère le passé par attention

Le Temporal Fusion Transformer (TFT) est une architecture à attention conçue pour la prévision multi-horizon de séries multivariées [17]. Son entrée combine nativement trois types de données : des **covariables statiques** (localisation du panneau, puissance installée), des **entrées futures connues** (heure, jour de la semaine, saison) et des **séries exogènes passées** (irradiance, température, vent). Son fonctionnement articule trois dispositifs : le Variable Selection Network retient, à chaque instant, les variables qui importent ; l'attention exploite les relations temporelles pertinentes ; la sortie en quantiles rend l'incertitude explicite.

Sa valeur ajoutée tient à l'interprétabilité : on peut visualiser les variables retenues par la VSN, les positions temporelles mises en avant par l'attention et les features statiques qui pèsent sur la sortie [17], un atout décisif pour les opérateurs de réseau électrique.

5.1.2 Covariables statiques → 4 contextes via encodeur statique

Les covariables statiques (localisation du panneau, puissance installée, type de capteur) traversent un encodeur statique qui produit quatre vecteurs de contexte, chacun dédié à un sous-système : la sélection de variables, l'initialisation des états LSTM et le conditionnement de la sortie.

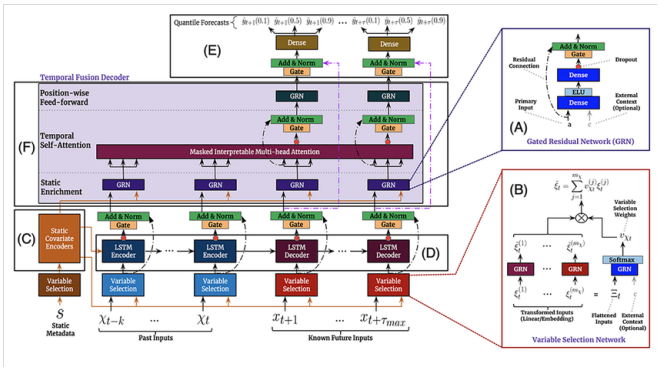


FIGURE 5.1 : Architecture du TFT : les covariables statiques (localisation, puissance installée) génèrent 4 contextes via un encodeur statique : $\mathbf{c}_s$ guide la sélection de variables (VSN), $\mathbf{c}_e/\mathbf{c}_h$ initialisent les états LSTM, et $\mathbf{c}_c$ conditionne la sortie. Les séries temporelles suivent un chemin distinct : VSN → LSTM encodeur → LSTM décodeur → attention interprétable multi-tête → FFN de sortie. Les *gated skip connections* (portes sigmoid entre chaque couche) garantissent la circulation du gradient sur les profondeurs importantes. Les poids de l'attention sont partagés entre têtes pour une agrégation interprétable (Lim et al., 2021).

L'encodeur statique calcule :

$$\mathbf{c}_s = \mathrm{GRN}_{\mathrm{stat}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_e = \mathrm{GRN}_{\mathrm{enc}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_h = \mathrm{GRN}_{\mathrm{hid}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_c = \mathrm{GRN}_{\mathrm{con}}(\mathbf{x}_{\mathrm{stat}})$$

où $\mathbf{x}_{\mathrm{stat}}$ est le vecteur des covariables statiques. Le contexte $\mathbf{c}_s$ alimente la Variable Selection Network, $\mathbf{c}_e$ et $\mathbf{c}_h$ initialisent les états cachés des LSTM encodeur et décodeur, et $\mathbf{c}_c$ conditionne la couche de sortie.

Cette séparation laisse le modèle exploiter une même information statique de plusieurs manières selon le sous-système : la sélection de variables réclame un résumé global ($\mathbf{c}_s$), là où les LSTM attendent un état initial ($\mathbf{c}_e$, $\mathbf{c}_h$). Chaque GRN apprend une transformation qui lui est propre, ce qui évite un partage excessif de paramètres.

5.1.3 Le bloc fondateur : Gated Residual Network (GRN)

Traitons d'abord le constituant fondamental du TFT. Sélection de variables, traitement statique et décodage reposent tous sur le même type de réseau résiduel : le Gated Residual Network.

Le GRN est un réseau résiduel doté d'une porte GLU (Gated Linear Unit) qui module le flux d'information : le sigmoïde écarte les features non pertinentes, tandis que la connexion résiduelle préserve le gradient et l'information d'origine.

Le GRN calcule :

$$\mathrm{GRN}(\mathbf{a}, \mathbf{c}) = \mathrm{LayerNorm}\left(\mathbf{a} + \mathrm{GLU}(\eta_1)\right)$$

$$\eta_1 = W_1\eta_2 + \mathbf{b}_1, \qquad \eta_2 = \mathrm{ELU}(W_2\mathbf{a} + W_3\mathbf{c} + \mathbf{b}_2)$$

où $\mathbf{a}$ est l'entrée principale (features temporelles ou statiques) et $\mathbf{c}$ une condition optionnelle (contexte statique ou temporel). La transformation non linéaire η_2 recourt à une ELU et sert à l'extraction de caractéristiques ; η_1 est la projection linéaire qui suit. La porte GLU segmente

les $2d$ canaux en deux moitiés : la première fait office de porte, la seconde de candidat, selon $\mathrm{GLU}(\eta_1) = \sigma(\eta_1^{(1:d)}) \odot \eta_1^{(d+1:2d)}$.

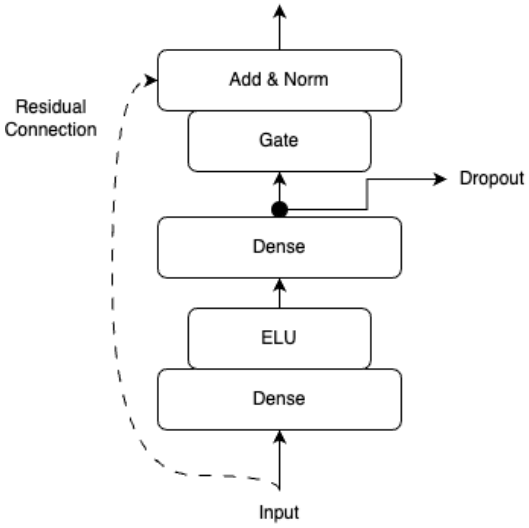


Figure 5.2 : Illustration du Gated Residual Network (GRN) tel que présenté par Lim et al. (2021). L'entrée **a** est transformée par une couche Dense, une activation ELU, puis une seconde Dense produisant $2d$ valeurs. La porte GLU filtre les dimensions non pertinentes via un sigmoid, tandis que la connexion résiduelle et la LayerNorm stabilisent l'entraînement.

Le GRN se retrouve partout dans le TFT : sélection de variables, traitement des features statiques, décodage. Sa force tient à la porte GLU, dont le sigmoïde « ferme » approximativement les dimensions inutiles. La connexion résiduelle **a**+. . . et la Layer Normalization [2] garantissent que l'information d'entrée n'est jamais entièrement perdue.

5.1.4 Variable Selection Network (VSN)

La VSN répond à une question mouvante : quelles variables d'entrée importent à cet instant précis ? L'irradiance est déterminante à midi mais sans objet la nuit, la température reste pertinente en permanence. La VSN calcule donc un poids d'importance $\boldsymbol{\xi}_t$ par variable, ce qui concentre le modèle sur les plus informatives.

Ces poids sont produits par un GRN dédié :

$$\boldsymbol{\xi}_t = \mathrm{Softmax}\left(\mathrm{GRN}_{\mathbf{v}}(\mathbf{X}_t, \mathbf{c}_s)\right)$$

Le vecteur $\boldsymbol{\xi}_t \in \mathbb{R}^{N_v}$, de somme unité, pondère les N_v colonnes de la matrice $\mathbf{X}_t \in \mathbb{R}^{N_v \times d}$ à l'instant t ; le contexte $\mathbf{c}_s$ encode le site. Les variables considérées vont de l'irradiance et la température au vent et à l'heure.

La sortie filtrée est la somme pondérée :

$$\tilde{\mathbf{x}}_t = \sum_{j=1}^{N_v} \xi_t^{(j)} \cdot \tilde{\mathbf{x}}_t^{(j)}$$

où $\tilde{\mathbf{x}}_t^{(j)} = \mathrm{GRN}_j(\mathbf{x}_t^{(j)})$ est la variable j filtrée par son propre GRN.

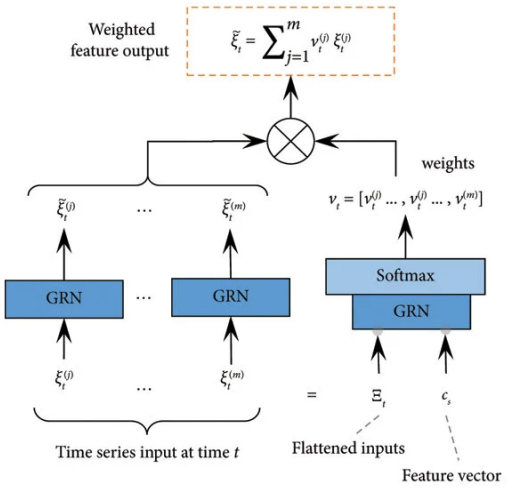


Figure 5.3 : Sélection de variables (VSN) : chaque variable $\mathbf{x}_t^{(j)}$ passe par un GRN indépendant. Les N_v sorties sont concaténées puis un GRN de contexte (GRN_v) prédit les poids d'importance $\boldsymbol{\xi}_t$ via un softmax. La sortie $\tilde{\mathbf{x}}_t$ est la somme pondérée des variables filtrées.

La VSN est interprétable : en suivant les poids $\boldsymbol{\xi}_t$ au fil du temps, on lit quelles variables dominent la prédiction ; on s'attend à un poids élevé de l'irradiance le jour et nul la nuit, la température demeurant toujours significative. C'est un avantage net sur les modèles « boîte noire ».

5.1.5 Attention multi-head interprétable

Les variables filtrées forment une séquence temporelle $\tilde{\mathbf{x}}_1, \ldots, \tilde{\mathbf{x}}_T$. Il reste à encoder ces dépendances séquentielles, puis à les mobiliser au moment de prédire. Le décodeur du TFT combine pour cela un LSTM local, pour les motifs courts, et une attention interprétable, pour les dépendances à longue portée.

L'attention « interprétable » partage la projection de valeur entre les têtes, ce qui autorise la moyenne des cartes d'attention et fournit une attention globale unique.

L'attention multi-head interprétable s'écrit :

$$\mathrm{InterpretableMultiHead}(Q,K,V) = \frac{1}{H}\sum_{h=1}^{H} \mathrm{Attention}(QW_Q^{(h)}, KW_K^{(h)}) \cdot VW_V$$

où Q, K, V proviennent du LSTM local ; les projections $W_Q^{(h)}$ et $W_K^{(h)}$ sont propres à chaque tête, W_V est partagée entre elles, et H désigne le nombre de têtes (4 à 8 en pratique).

Le partage de W_V distingue cette attention de l'attention standard : la moyenne des cartes d'attention garde un sens, et l'on peut agréger les poids de toutes les têtes en une carte interprétable. Appliquée entre passé (encodeur) et futur (décodeur), elle révèle quelles positions passées pèsent le plus sur la prédiction.

5.1.6 Sortie en quantiles

Le TFT ne prédit pas une valeur unique, mais plusieurs quantiles simultanément, à savoir $q = 0{,}1$ (pire cas), $q = 0{,}5$ (médiane) et $q = 0{,}9$ (meilleur cas), ce qui livre une mesure complète de l'incertitude.

La perte en quantiles (pinball, section 3.3) est :

$$\mathrm{QL}(y, \hat{y}, q) = q \cdot \max(y - \hat{y}, 0) + (1 - q) \cdot \max(\hat{y} - y, 0)$$

Pour $q = 0{,}5$, la pénalité est symétrique : surestimation et sous-estimation coûtent autant. Pour $q = 0{,}1$, sous-estimer coûte neuf fois plus que surestimer, ce qui pousse le modèle vers le bas de la distribution, comme l'exige la gestion de réseau, où l'on planifie sur le pire cas plutôt que de risquer un blackout.

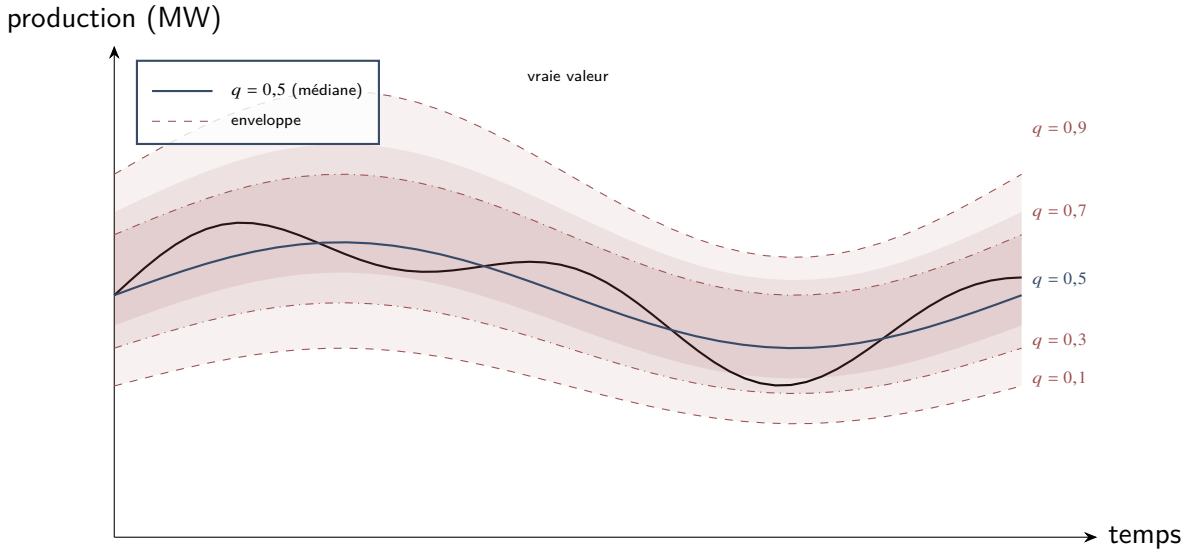


Figure 5.4 : Sortie en quantiles du TFT : au lieu d'une seule prédiction, le modèle fournit une enveloppe de confiance ($q = 0{,}1$ à $0{,}9$) qui capture l'incertitude liée à la variabilité nuageuse.

5.2 Photovoltaïque : Temporal Convolutional Network (TCN)

5.2.1 Convolution dilatée et filtre $k = 3$

Le Temporal Convolutional Network (TCN) s'appuie sur des convolutions causales dilatées pour modéliser les dépendances longues à moindre coût que les RNN, tout en se parallélisant intégralement [4]. Pour la prévision PV, son champ réceptif exponentiel capte bien les motifs cycliques journaliers et hebdomadaires.

Un bloc TCN combine convolution causale, dilatation exponentielle et connexion résiduelle. La convolution causale n'observe que le passé, ce qui écarte toute fuite de données :

$$(x *_c w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i}$$

La dilatation $d = 2^\ell$ étend ensuite le champ réceptif à chaque couche ℓ :

$$(x *_d w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d\cdot i}$$

Enfin, un bloc résiduel (connexion skip et Layer Normalization [2]) préserve la circulation du gradient.

5.2.2 Le champ réceptif

Le champ réceptif d'un TCN de profondeur L, de filtre k et de dilatations exponentielles vaut :

$$R = 1 + \sum_{\ell=0}^{L-1} (k-1) \cdot 2^\ell = 1 + (k-1)(2^L - 1)$$

R compte les pas de temps couverts, k est la taille du filtre ($k = 3$ typiquement), L la profondeur, et la dilatation vaut 2^ℓ à la couche ℓ.

Avec $k = 3$ et $L = 10$ couches, $R = 1 + 2(2^{10} - 1) = 2047$ pas de temps, soit plus de trois semaines en données horaires. Le TCN traitant la séquence en parallèle, et non pas à pas comme un LSTM, son entraînement s'en trouve accéléré.

5.2.3 Architecture TCN appliquée à la prévision PV

Le TCN empile des blocs résiduels, chacun renfermant deux convolutions dilatées causales, une activation, une normalisation et une connexion résiduelle. La connexion skip projette l'entrée dans l'espace de sortie lorsque les dimensions diffèrent.

Un bloc résiduel TCN s'écrit :

$$\mathbf{h} = \mathrm{LayerNorm}(\mathbf{x} + \mathrm{Conv1D}_2(\mathrm{ReLU}(\mathrm{LayerNorm}(\mathrm{Conv1D}_1(\mathbf{x})))))$$

L'entrée $\mathbf{x} \in \mathbb{R}^{T \times C_{\text{in}}}$ traverse deux convolutions causales dilatées ($\mathrm{Conv1D}_1$ puis $\mathrm{Conv1D}_2$, de même dilatation d), séparées par une LayerNorm et un ReLU ; la somme résiduelle $\mathbf{x} + \ldots$ est stabilisée par une LayerNorm finale.

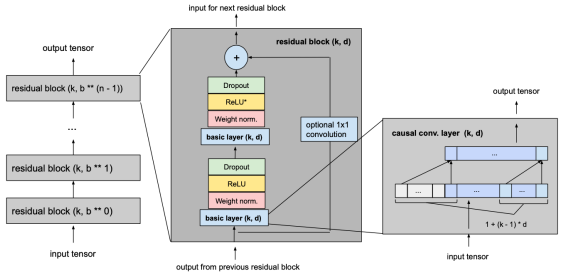


FIGURE 5.5 : Architecture TCN empilée : chaque bloc contient un bloc résiduel avec une dilatation $d = 2^\ell$. Le **padding causal** assure que chaque sortie ne dépend que du passé. Les skip connections sont sommées en sortie. Le champ réceptif croît exponentiellement : $RF = 1 + \sum_{\ell=0}^{L-1}(k-1)\cdot 2^\ell = O(k \cdot 2^L)$, permettant de couvrir des séquences très longues avec peu de couches.

5.2.4 Pourquoi ce choix pour le PV

Le TCN convient particulièrement à la prévision PV : son champ réceptif exponentiel couvre les cycles diurne et hebdomadaire, la parallélisation totale accélère l'entraînement sur de longues séquences, et sa complexité mémoire linéaire $O(T)$ surclasse la quadraticité $O(T^2)$ du Transformer.

Il s'entraîne plus vite qu'un LSTM (parallélisme total) et reste plus stable qu'un Transformer (pas de quadraticité). En contrepartie, il ne gère pas nativement les variables statiques (localisation du panneau) et n'offre pas l'interprétabilité d'une attention. C'est un bon choix lorsque la vitesse d'entraînement prime.

Les deux architectures de référence étant posées, nous détaillons les stratégies d'encodage et d'évaluation communes à ce travail.

5.3 Entraînement : encodage et évaluation

5.3.1 Encodage sin/cos de l'heure

L'encodage cyclique de l'heure est indispensable : 23 h et 0 h occupent le même point du cycle journalier, qu'une représentation linéaire disloquerait. Les coordonnées sin/cos préservent cette circularité.

L'heure h (0–23) se code en deux dimensions :

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \qquad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right)$$

Le couple $h_{\sin}, h_{\cos}$ possède une distance euclidienne qui respecte la proximité entre 23 h et 0 h.

Avec cette représentation, la distance euclidienne entre 10 h et 11 h égale celle entre 22 h et 23 h, comme il se doit. Sans encodage cyclique, le modèle tiendrait 23 h et 0 h pour très éloignées.

5.3.2 La baseline à battre : la persistance

La persistance est la baseline la plus simple : elle prédit que la valeur future égalera la valeur courante. Difficile à battre à court terme ($H < 6$ h), la production d'énergie présentant une forte inertie.

La prédiction de persistance est :

$$\hat{y}_{t+h} = y_t$$

$\hat{y}_{t+h}$ reprend simplement y_t, la valeur observée en t, pour un horizon h.

Le skill score quantifie l'amélioration par rapport à cette baseline :

$$\text{Skill Score} = 1 - \frac{\text{RMSE}_{\text{modèle}}}{\text{RMSE}_{\text{persistance}}}$$

Un skill score positif signale un modèle meilleur que la persistance ; une valeur de 0,2 correspond à un gain de 20 %.

La persistance est un benchmark réaliste : à très court terme, la production présente estime déjà correctement celle de +1 h. Un skill score positif indique que le modèle exploite des informations additionnelles (tendances, corrélations, cycles). Aux horizons longs ($H > 12$ h), la persistance se dégrade naturellement et le skill score grimpe.

Deux architectures de référence et complémentaires ont été présentées pour la prévision de la production solaire. Le Temporal Fusion Transformer mise sur la sélection de variables et l'attention interprétable ; le Temporal Convolutional Network privilégie la légèreté et la vitesse d'entraînement par ses convolutions causales dilatées. L'encodage circulaire de l'heure et la baseline de persistance fixent en outre le cadre commun dans lequel ces deux modèles seront comparés dans la suite du mémoire.

Chapitre 6

Stratégie MIMO et prévision probabiliste par quantiles

Avant d'entraîner un modèle à 72 h, deux décisions conditionnent le reste du dispositif : comment produire les H horizons à partir de l'historique, et sous quelle forme restituer l'incertitude. Dans ce mémoire, la première est la stratégie **MIMO** (*Multiple-Input Multiple-Output*) ; la seconde est la **régression quantile**. Les deux sont liées : MIMO fournit naturellement la matrice $H \times Q$ qu'attend la seconde. Ce chapitre expose ce couplage, la perte qui l'entraîne et le protocole qui le mesure.

6.1 La stratégie MIMO de prévision multi-horizon

Prévoir la production solaire des 72 prochaines heures peut se faire de deux manières : produire les H valeurs futures en une seule passe, ou les engendrer séquentiellement en réinjectant chaque prédiction comme entrée de la suivante. Nous retenons la première option. Elle traite la séquence future comme un vecteur de sortie, ce qui préserve la cohérence entre horizons et supprime la propagation des erreurs d'inférence.

MIMO prédit en une seule passe le vecteur complet des horizons futurs :

$$\hat{\mathbf{y}} = \left[\hat{y}_{t+1}, \ldots, \hat{y}_{t+H}\right] = f_{\boldsymbol{\theta}}(\mathbf{x}_{t-T:t}) \in \mathbb{R}^{H},$$

La fenêtre d'entrée $\mathbf{x}_{t-T:t}$ couvre T pas d'historique : covariables météorologiques, variables calendaires et réalisations décalées. En prévision probabiliste, la sortie devient une matrice $H \times Q$:

$$\hat{\mathbf{Y}} = \left[\hat{y}^{(1)}_{t+1}, \ldots, \hat{y}^{(Q)}_{t+1}; \ldots; \hat{y}^{(1)}_{t+H}, \ldots, \hat{y}^{(Q)}_{t+H}\right] \in \mathbb{R}^{H \times Q},$$

où Q est le nombre de quantiles prédits pour chaque horizon. C'est le paramétrage du *Temporal Fusion Transformer*, qui produit nativement des quantiles sur plusieurs horizons [17], comme celui des implémentations TCN du pipeline expérimental (section 3.7 et section 6.6).

Nous avons écarté la prévision récursive pour deux raisons pratiques. Réinjecter une prédiction comme entrée de la suivante accumule mécaniquement la variance d'erreur sur 72 pas. Et un modèle unique pour tous les horizons coûte un seul entraînement au lieu de 72. La contrepartie

est la dimension de sortie : pour $H = 72$ pas et $Q = 3$ quantiles, le réseau doit produire 216 valeurs simultanées, ce qui accroît le risque de surapprentissage sur des séries de longueur modeste. C'est précisément ce coût que les architectures MIMO modernes [17] cherchent à contenir, par sélection de variables et partage de représentation, détaillés au chapitre 5.

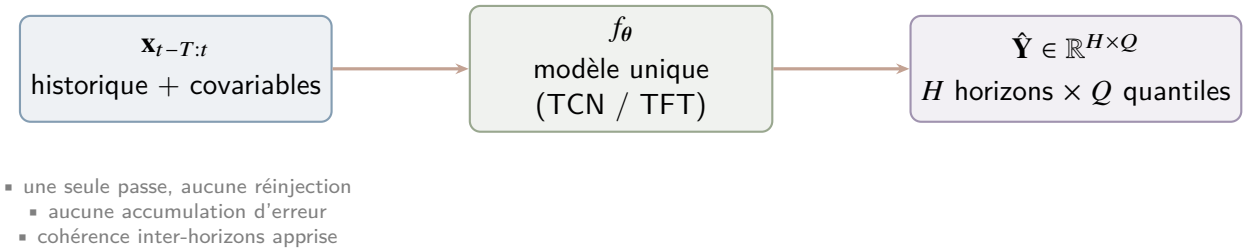


Figure 6.1 : La stratégie multi-horizon MIMO retenue : un modèle unique projette la fenêtre d'entrée $\mathbf{x}_{t-T:t}$ sur l'ensemble des horizons futurs en une seule passe. En sortie probabiliste, la matrice $H \times Q$ contient les Q quantiles de chaque horizon. Cette architecture est nativement supportée par le TFT [17] et implémentée pour le TCN du pipeline expérimental.

6.2 La prévision par quantiles : type de sortie probabiliste

Une prévision ponctuelle donne la production attendue ; elle ne dit pas quelle réserve mobiliser pour couvrir les cas défavorables. Dimensionner une réserve, arbitrer entre excès et déficit, sécuriser un contrat d'approvisionnement supposent de connaître la queue basse de la distribution de production, pas sa seule tendance centrale. Faute de pouvoir estimer la distribution complète avec trois têtes de sortie, nous en approximons les quantiles : $Q = 3$ niveaux, 10 %, 50 % et 90 %, soit une médiane et une enveloppe de confiance à 80 %.

La régression quantile [14, 13] estime le quantile conditionnel $q_\alpha(\mathbf{x}_t)$ en minimisant la perte en quantiles (pinball) [14], qui pénalise à chaque pas le résidu $y - a$ entre l'observation y et la borne prédite a :

$$\mathrm{QL}_\alpha(y,\, a) \;=\; \big[\alpha - \mathbb{1}(y < a)\big]\,(y - a). \tag{6.1}$$

Pour une architecture à sortie Q-dimensionnelle, la perte totale est la moyenne des pertes attachées aux Q têtes de sortie :

$$\mathcal{L}_{\text{quantile}} = \frac{1}{Q}\sum_{q=1}^{Q} \mathrm{QL}_{\alpha_q}\Big(y,\ \hat{y}^{(q)}\Big), \qquad \alpha_1 < \alpha_2 < \cdots < \alpha_Q.$$

Cette formulation est *séparable* : chaque tête q s'optimise indépendamment des autres, ce qui simplifie et stabilise l'entraînement. En contrepartie, rien ne garantit l'*ordre* des quantiles prédits : deux quantiles voisins peuvent se croiser pour certaines entrées, produisant un intervalle de largeur négative.

Ce défaut classique, le croisement des quantiles, appelle deux corrections : pénaliser explicitement tout croisement, ou paramétrer la sortie par des incréments positifs contraints, $\hat{y}^{(q)} = \hat{y}^{(1)} + \sum_{j<q} \mathrm{softplus}(\Delta_j)$. Dans le code expérimental, la fréquence de croisement est *mesurée*

(`quantile_crossing`) et reste nulle sur le jeu de test pour les deux architectures retenues, comme le rapporte le chapitre d'étude de cas ; la perte hybride décrite ci-dessous joue de surcroît un rôle régularisateur.

6.3 L'approche d'incertitude retenue dans le code : perte hybride multi-tâche

Les modèles TCN et TFT ne sont pas entraînés par une simple perte quadratique. Ils recourent à une **fonction de perte hybride multi-tâche**, qui combine deux objectifs pondérés par `mse_weight` :

$$\mathcal{L} = \underbrace{w_{\text{mse}} \cdot \text{MSE}(\hat{y}_{0,5},\, y)}_{\text{exactitude ponctuelle}} + \underbrace{(1 - w_{\text{mse}}) \cdot \overline{\text{Pinball}}(\hat{y}_q,\, y)}_{\text{calibration probabiliste}}. \tag{6.2}$$

La composante MSE porte sur la médiane prédite, la composante pinball étant moyennée sur les quantiles $q \in \{0{,}1, 0{,}5, 0{,}9\}$. Le poids `mse_weight` pilote le compromis entre les deux tâches.

Table 6.1 : Arbitrage fixé par le poids `mse_weight` de la perte hybride : précision ponctuelle (MSE sur la médiane) contre calibration des intervalles (pinball).

Valeur de `mse_weight`	Stratégie d'apprentissage	Effet sur les résultats
1.0	Poids entier sur le MSE	Précision ponctuelle maximale, intervalles sans garantie
0.5	**Deux tâches à parts égales**	**Précision correcte *et* intervalles bien calibrés**
0.0	Poids entier sur le pinball	Intervalles bien calibrés, précision possiblement dégradée

Pour Diass, le poids retenu est 0.5 : ce défaut du schéma de configuration est confirmé par la recherche bayésienne d'hyperparamètres, qui explore l'intervalle [0.3, 0.8]. Ce compromis se justifie par la nature **sahélienne** du site ; les fortes variations d'irradiance (passages nuageux rapides, tempêtes de poussière de l'harmattan) rendent l'estimation de l'incertitude aussi critique que la prévision ponctuelle pour la conduite du réseau, et la plage explorée adapte l'arbitrage au contexte local sans le figer a priori. Sur le jeu de test, les meilleurs essais retiennent des valeurs proches du défaut (TFT : 0.617, TCN : 0.765), ce qui confirme empiriquement l'équilibre retenu.

Sous-jacente à cette perte, la distinction entre les deux sources d'incertitude éclaire la lecture des résultats. L'incertitude *aléatoire* est irréductible : même avec une description parfaite de l'atmosphère, la position d'un passage nuageux reste imprévisible au-delà de quelques heures à l'échelle du kilomètre, et aucune quantité de données ne la supprime. L'incertitude *épistémique* est réductible : elle traduit un manque de données ou de capacité de modèle. La régression quantile approche la variabilité aléatoire conditionnelle ; l'injection des covariables futures NWP réduit, elle, la composante épistémique en informant le modèle de l'état atmosphérique à venir.

L'entraînement hybride produit des quantiles dont la calibration n'est pas garantie en échantillon fini. Le code y adjoint donc une étape de *recalibrage* a posteriori.

6.4 Recalibrage de l'enveloppe : le CQR adopté dans le code

La perte ponctuelle+quantile livre des intervalles dont la couverture effective peut s'écarter de la cible, surtout loin de la médiane. L'implémentation ajoute donc une étape d'**inférence conforme quantile** (*Conformalized Quantile Regression*, CQR) [21], selon un schéma *split conformal* [31, 26] : un jeu de calibration disjoint fournit le score de non-conformité

$$s_i = \max\{\hat{y}_i^{\text{bas}} - y_i,\ y_i - \hat{y}_i^{\text{haut}}\},$$

et l'intervalle recalibré s'écrit, pour le niveau α :

$$\mathcal{I}(\mathbf{x}) \;=\; \big[\, \hat{y}^{\text{bas}}(\mathbf{x}) - q_{(k)}(C),\ \hat{y}^{\text{haut}}(\mathbf{x}) + q_{(k)}(C) \,\big], \qquad k = \lceil (m+1)(1-\alpha) \rceil, \tag{6.3}$$

où $q_{(k)}(C)$ est le k-ième plus petit score de non-conformité sur le jeu de calibration de taille m. La garantie $\mathbb{P}\{y \in \mathcal{I}\} \geq 1 - \alpha$ [31] vaut sans hypothèse sur le processus, à condition que les données de calibration soient *échangeables* avec le point à prédire.

Dans le code, le recalibrage CQR est appliqué avec $\alpha = 0.20$ sur le jeu de validation, puis évalué sur le test. Les journaux du notebook consignent son effet sur la couverture P10–P90 : pour le TCN, elle passe de 60,8 % à 79,8 %, proche de la cible de 80 % ; pour le TFT, de 71,2 % à 74,2 %, avec une enveloppe plus étroite et une largeur moyenne nettement inférieure (0.095 MW contre 0.463 MW). C'est cette étape qui transforme l'enveloppe brute de la perte hybride en un intervalle à garantie de couverture vérifiable, sans réentraînement du réseau. La largeur de l'intervalle étant un quantile *absolu* des résidus de calibration, elle s'élargit naturellement avec l'horizon h, ce qui préserve une couverture stable.

Le protocole suivant mesure ce que le recalibrage a apporté.

6.5 Scores stricts et calibration : juger une prévision par quantiles

Une prévision probabiliste se juge par un *score propre*, quantité dont l'espérance sous la vraie loi est minimisée lorsque la loi prédite est la loi vraie [9]. La largeur moyenne seule est triviale à minimiser (un intervalle infini y suffit), et la couverture seule récompense l'honnêteté sans la compétence. Nous rapportons donc systématiquement la couverture, la largeur moyenne et un score propre (pinball ou score de Winkler). C'est exactement ce que produit le code pour chaque modèle avancé : `coverage`, `interval_width`, `winkler_80`, ainsi que les pertes de quantiles `pinball_lower`/`pinball_upper`.

Un intervalle $[\hat{y}^{\text{bas}}, \hat{y}^{\text{haut}}]$ de niveau nominal $1 - 2\alpha$ est dit *calibré* si la fréquence empirique de couverture vérifie :

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\{\hat{y}_i^{\text{bas}} \leq y_i \leq \hat{y}_i^{\text{haut}}\} \;=\; 1 - 2\alpha \;+\; \varepsilon_n, \qquad \varepsilon_n \to 0. \tag{6.4}$$

Le terme ε_n fluctue selon la loi binomiale : pour un intervalle à 80 % évalué sur n échantillons, la couverture observée s'écarte du nominal d'un ordre de grandeur $1/\sqrt{n}$.

La couverture ne distingue pas sur-couverture et sous-couverture. Un diagnostic plus fin, la *transformation intégrale de probabilité* (PIT), complète le triplet lorsque la loi complète est disponible. Avec trois quantiles, le code se restreint à la couverture, à la largeur moyenne, au score de Winkler et aux pertes de quantiles, ce qui suffit pour départager deux architectures à horizon donné.

6.6 Protocole d'évaluation sur le cas Diass

Le protocole d'évaluation de l'incertitude appliqué à Diass comporte cinq étapes :

1. **Couverture par horizon.** Pour chaque $h \in \{1, \ldots, 72\}$, fréquence empirique de couverture de l'intervalle P10–P90 et écart à la cible de 80 % ;
2. **Largeur par horizon.** Largeur moyenne de l'enveloppe, en MW et en pourcentage de $P^{\max}$, pour comparer deux architectures à couverture égale ;
3. **Score propre.** Pinball moyen sur les trois quantiles et score de Winkler à 80 % ;
4. **Diagnostic de croisement.** Fréquence de $P_{10} > P_{50}$ ou $P_{50} > P_{90}$, qui doit être nulle ;
5. **Comparaison au référentiel.** Score de calibration par rapport à la climatologie (section 3.7).

Ce protocole s'applique après l'étape CQR, sur des fenêtres de test identiques pour les deux architectures : 1049 fenêtres couvrant le 16 juillet au 28 août 2026, avec 168 h d'historique et 72 h d'horizon. Les valeurs numériques ci-dessous portent donc sur l'*enveloppe recalibrée*, et non sur la sortie brute de la perte hybride.

6.7 Conclusion

La stratégie expérimentale retenue tient à trois décisions. Premièrement, la sortie suit la stratégie **MIMO** : un modèle unique produit les H horizons en une seule passe, sans réinjection des prédictions, et apprend la cohérence entre horizons. Deuxièmement, cette sortie est **quantile**, avec $Q = 3$ niveaux (10 %, 50 %, 90 %) estimes par la régression quantile séparable. Troisièmement, l'incertitude est traitée par une perte hybride multi-tâche (MSE sur la médiane et pinball sur les quantiles, pondérés par `mse_weight`), complétée d'un recalibrage *conformalized quantile regression* destiné à garantir la couverture de l'enveloppe en échantillon fini.

Avant d'aborder les résultats, trois points d'attention se dégagent. Le premier est méthodologique : une prévision probabiliste ne se juge pas par une métrique unique, et nous rapporterons systématiquement la couverture, la largeur moyenne et un score propre. Le second borne ce qu'on peut espérer : sans les covariables NWP, aucun modèle ne produira d'intervalle utile à 72 h ; c'est l'information d'entrée qui fixe le plafond, pas l'architecture. Le troisième est un choix assumé :

$Q = 3$ recalibré constitue le meilleur compromis entre information, coût d'inférence et faisabilité dans le cadre de ce mémoire.

Troisième partie

APPLICATION ET ÉVALUATION

Chapitre 7

Étude de cas : Diass (solaire)

Les chapitres précédents ont posé le cadre physique, les architectures et la stratégie probabiliste. Reste à vérifier que l'ensemble tient sur une centrale réelle. Diass, première centrale solaire publique du Sénégal, sert de cas d'étude : sa structure fixe, son climat sahélien et sa production annualisée d'environ 34 GWh en font un terrain représentatif des contraintes que rencontrera la SENELEC à mesure que le solaire monte en puissance. Le chapitre suit le trajet des données, de l'export SCADA au vecteur de features, puis présente l'entraînement, les résultats et leur discussion.

La prévision répond à un besoin opérationnel : anticiper la ressource renouvelable pour planifier l'entretien et les investissements, équilibrer l'offre et la demande en ajustant les moyens thermiques et hydrauliques, réduire les coûts de réserve et de curtailment, et préserver la sécurité du réseau en évitant les déséquilibres fréquence–puissance qui mènent au délestage.

7.1 Le site de Diass, centrale solaire photovoltaïque

7.1.1 Description du site

Le site de Diass est la **première centrale solaire photovoltaïque publique du Sénégal**, détenue et exploitée par la **SENELEC**. Située dans le département de Mbour (région de Thiès), à environ 40–50 km au sud-est de Dakar, non loin de l'aéroport international Blaise Diagne, elle a été mise en service en mai 2022 et constitue un jalon majeur pour la transition énergétique du pays [24, 23]. Son financement a été assuré par un prêt de la banque allemande KfW (∼18 milliards FCFA).

La centrale est équipée de **modules polycristallins** montés sur une **structure fixe** inclinée calée sur la latitude de Diass ($\varphi = 14{,}65°$ N) : cette configuration maximise le captage annuel sans la complexité mécanique d'un tracker et simplifie l'exploitation et la maintenance, tout en produisant une série régulière structurée par l'arc diurne. La localisation en zone sahélienne offre un gisement solaire parmi les plus élevés d'Afrique, avec une irradiance globale annuelle typique de l'ordre de 2 000 kWh/m²/an [1].

Table 7.1 : Caractéristiques techniques de la centrale de Diass.

Paramètre	**Valeur**
Localisation	Diass, Mbour, Thiès, Sénégal
Coordonnées	14,65° N, 17,10° W
Puissance nominale AC	24,48 MW (36 × 680 kW, limitée à 20,16 MW)
Puissance crête DC	27,28 MWc (85 248 × 320 Wc)
Puissance publiée (MP)	23,114 MW (source SENELEC, écart documenté à la section 7.2.3)
Technologie	Modules polycristallins Jinko JKM320PP-72-V
Structure	Fixe (inclinaison 15°, azimut 0° plein sud)
Nombre de modules	85 248
Onduleurs	36 Schneider Conext Core XC-680 (12 stations × 3)
Surface du champ	~40 ha
Mise en service	Mai 2022
Propriétaire/exploitant	SENELEC (centrale publique, PPA 25 ans)
Production annuelle	~34 GWh/an
Période d'exploitation couverte	30/08/2025 – 31/08/2026
Résolution des exports SCADA	~15 min
Résolution du dataset de modélisation	1 h après resampling
Volumétrie	35 196 lignes à 15 min (58 colonnes, 55 hors imputation) puis 8 800 lignes horaires (428 colonnes)
Grandeurs d'exploitation	~440 (36 onduleurs, compteur HTA, station météo)

7.1.2 Préparation des données : nature, provenance et traçabilité

Trois familles de données entrent dans le jeu final : les mesures SCADA de la centrale, les réanalyses externes (NASA POWER, ERA5, CAMS) et les variables calculées à partir de la géométrie du site. Elles n'ont ni la même résolution, ni la même latence, ni la même fiabilité. Plutôt que de les fondre en une série indifférenciée, le pipeline conserve pour chaque colonne son origine, parce que la prévision hérite de l'incertitude propre à chacune.

Données SCADA. Les données d'exploitation couvrent la période du 30 août 2025 au 31 août 2026. Elles sont réparties dans six classeurs Excel issus du système de supervision Schneider : paramètres DC, paramètres AC, mesures des DC Box, températures des cartes de puissance et deux ensembles de mesures météorologiques. Les fichiers décrivent les équipements de la centrale ainsi que le compteur de livraison HTA et la station météorologique. Après lecture et normalisation des horodatages, les différentes sources sont ramenées à une même série temporelle de référence à 15 minutes. Le notebook d'ingestion obtient ainsi **35 196 lignes à 15 minutes et 58 colonnes**, dont environ 34 600 observations non manquantes pour les variables SCADA (T_{inv} : 34 606, P_{ac} : 34 602, G_{sw} : 34 601). Cette résolution source est ensuite agrégée à 1 heure par le pipeline de données, avant le feature engineering et l'apprentissage.

Les grandeurs électriques sont ensuite ramenées à l'échelle de la centrale. Pour les mesures disponibles sur les 36 onduleurs, les tensions et courants sont agrégés par moyenne, tandis que les puissances sont additionnées lorsque la grandeur représente une contribution de chaque équipement. Les compteurs d'énergie sont traités comme des grandeurs cumulatives : leur consommation ou production sur un intervalle est obtenue par différence entre deux valeurs successives, avec une borne inférieure à zéro afin d'éviter qu'un retour ou une remise à zéro du compteur ne produise une énergie négative. Les puissances extraites des fichiers SCADA étant exprimées en kW, les variables `P_dc`, `P_ac` et `P_dc_inv` sont converties en MW avant leur utilisation par la chaîne de modélisation.

Variables météorologiques et radiatives externes. La station météorologique de Diass ne fournit pas l'ensemble des variables nécessaires à la caractérisation du rayonnement solaire. Les données SCADA sont donc complétées par des réanalyses horaires. NASA POWER, associé ici aux données MERRA-2, constitue la source principale pour plusieurs variables météorologiques et pour le GHI. Pour la période de juin à août 2026, pour laquelle le GHI de NASA POWER n'était pas encore disponible au moment de l'extraction, les données d'Open-Meteo basées sur ERA5 sont utilisées en complément.

Les composantes DNI et DHI sont obtenues à partir d'Open-Meteo sur l'ensemble de la période considérée, car elles ne sont pas disponibles à la résolution horaire retenue dans l'interrogation de NASA POWER. La même source fournit également la couverture nuageuse et plusieurs variables météorologiques complémentaires.

Les deux sources ne sont pas simplement concaténées. Les séries horaires sont d'abord alignées sur les horodatages SCADA, puis projetées sur la grille de 15 minutes. Pour les variables

communes, NASA POWER est privilégié lorsque la donnée est disponible et Open-Meteo intervient en remplacement lorsque cette valeur est absente. Cette règle permet de conserver une source principale tout en évitant de perdre les derniers mois de la période d'étude. Le dataset transmis au feature engineering est ensuite obtenu après agrégation horaire, selon le rôle physique de chaque colonne.

Variables calculées et paramètres d'installation. Certaines variables du jeu final ne correspondent pas à des mesures. La grandeur `clear_sky_ghi` est calculée à partir du modèle physique d'Ineichen–Perez et des coordonnées du site ; le nom a été choisi pour éviter toute ambiguïté avec l'albédo de surface. Les paramètres `surface_tilt` et `surface_azimuth` décrivent la géométrie de l'installation et sont fixés respectivement à 15° et 0°. Le paramètre `albedo_sol` est renseigné comme constante d'installation avec la valeur 0,2.

Ces variables sont conservées dans le jeu de données parce qu'elles peuvent être utiles aux étapes ultérieures de modélisation, mais elles ne doivent pas être interprétées comme des observations SCADA. La provenance de chaque variable est donc conservée selon quatre catégories : mesure locale, réanalyse externe, variable calculée et paramètre d'installation.

Prévisions météorologiques numériques (NWP). Les prévisions du modèle **ECMWF IFS HRES**, figé dans la configuration, sont récupérées via l'API *Single Runs* d'Open-Meteo et intégrées au pipeline comme covariables futures. Trois variables décrivant la couverture nuageuse totale, les nuages bas et le rayonnement à courte longueur d'onde sont injectées aux fenêtres sous forme de tenseur par le canal des covariables futures des modèles TCN et TFT. Elles n'entrent ni dans le scaler des features ni dans les baselines déterministes : seul le modèle qui les consomme reçoit une tête supplémentaire.

La règle de causalité appliquée est une règle de disponibilité opérationnelle : pour une fenêtre émise à $t_{\text{ém}}$, le run retenu est le dernier dont init + 6 h $\leq t_{\text{ém}}$, où 6 heures est la borne haute de latence documentée par Open-Meteo. L'horizon demandé par run est dérivé automatiquement (72 h + latence + marge = 85 heures, fonction `required_forecast_hours`) et chaque run est mis en cache sur disque. Sur la plage du projet, 1 461 cycles sont demandés et 1 460 sont exploitables ; trois runs sont incomplets dans l'archive (dont 2026-06-11, 11 heures manquantes sur 84 attendues, traitées par troncature de queue). Sur 8 342 fenêtres candidates, 95 sont écartées (1,14 %) parce que le run sélectionné ne couvre pas tous les temps cibles, et 8 247 fenêtres sont conservées avec un âge de run de 6 à 12 heures et un horizon maximal de 72 heures.

Gestion des valeurs manquantes. Une interruption réelle de télémesure d'environ six jours, entre le 9 et le 15 décembre 2025, est présente dans les exports SCADA. Ces observations n'existant pas dans les fichiers sources, elles ne sont pas reconstruites par interpolation. Après remise sur la grille temporelle, elles restent donc manquantes. Cette règle vaut pour l'évaluation : une absence de mesure n'est pas assimilée à une production nulle. Les périodes nocturnes sont distinguées des véritables absences de télémesure à l'aide des informations temporelles et radiatives disponibles.

Construction du jeu final. Après normalisation des noms de variables, agrégation des mesures SCADA, harmonisation temporelle à 15 minutes, enrichissement par les réanalyses et ajout des variables physiques, les données sources sont enregistrées dans `raw_input.parquet` (35 196 lignes à 15 minutes, 58 colonnes dont 55 hors imputation). Le pipeline applique ensuite le resampling horaire et sauvegarde le jeu de features utilisé par les modèles (`diass_features.parquet`, 8 800 lignes horaires et 428 colonnes dans le run du 6 octobre 2026, pour 427 features générées). Les deux volumétries sont rapportées séparément et ne doivent pas être confondues.

La chaîne de traitement distingue trois niveaux : les observations directement issues de la centrale (**mesure**), les informations provenant de sources externes (**réanalyse**) et les variables produites par calcul ou fixées à partir des caractéristiques de l'installation (**paramètre**). Le notebook `diass.ipynb` sert de référence : toute valeur citée dans ce chapitre y est vérifiable.

7.1.3 Parcours des données : de l'ingestion SCADA au jeu de features

Ce parcours, fidèle au notebook `diass.ipynb` (source de vérité) et au script `diass.py`, retrace le cheminement des données depuis les exports du système SCADA jusqu'au vecteur de **features** alimentant les modèles. La transparence de ce cheminement est essentielle : elle permet d'affirmer la validité des résultats présentés plus loin, en distinguant à chaque étape ce qui est **mesuré**, **téléchargé**, **reconstruit** ou **calculé**.

Ingestion SCADA : lecture et transformations de `diass.py`

Le script `diass.py` construit de façon reproductible le parquet brut de la centrale. La fonction `load_scada` lit les **six classeurs Excel** issus du superviseur Schneider : paramètres DC, paramètres AC, mesures des DC Box, températures des cartes de puissance et deux ensembles de mesures météorologiques. Chaque classeur est identifié par un fragment de nom de fichier. La lecture est suivie de plusieurs transformations systématiques. La fonction `_parse_timestamp` normalise d'abord les horodatages en combinant la colonne `Date` (format `%d/%m/%Y`) et l'heure extraite de `Temps`, pour produire un index `timestamp` unifié puis trié, première garantie de cohérence entre des sources de formats hétérogènes. Les colonnes utiles sont ensuite retrouvées par expressions régulières, ce qui rend la lecture robuste aux variations de libellés. Les grandeurs sont agrégées à l'échelle de la centrale : tensions et courants sont moyennés sur les équipements, tandis que les puissances contributives sont sommées, `P_dc` étant par exemple la somme des puissances DC des boxes. Les compteurs cumulatifs (`ENERGIA` ...) sont différenciés par `diff` puis bornés à zéro, afin qu'un retour ou une remise à zéro ne produise jamais d'énergie négative. Les puissances exprimées en kW sont enfin converties en MW, et les grandeurs structurantes sont récupérées selon la même logique : tension réseau (`V_ac`), fréquence (`grid_frequency`), facteur de puissance (`cos_phi`), irradiance...

Enrichissement par réanalyses et variables physiques

La station météorologique du site ne fournit qu'une partie des signaux utiles. Trois sources horaires publiques complètent le jeu : NASA POWER pour le GHI, les températures, le vent, la rosée, l'humidité, la pression et la pluie ; CAMS, interrogé via l'API qualité de l'air d'Open-Meteo, pour l'épaisseur optique des aérosols, les poussières et les particules fines ; ERA5, via l'archive Open-Meteo, pour les composantes directe et diffuse du rayonnement, la couverture nuageuse, la température et la pression. Les valeurs sentinelles des réanalyses, qui marquent une donnée absente, sont traduites en valeurs manquantes.

L'ingestion fusionne ensuite les sources sur une **grille unique à 15 minutes**. Les séries SCADA y sont réindexées et les réanalyses propagées vers l'avant ; pour les variables communes, la priorité attribuée aux mesures locales, puis à NASA POWER et enfin à ERA5, reflète la confiance décroissante que mérite chaque source. Les trous courts de télémesure sont comblés par une interpolation temporelle bornée à 24 heures, sans extrapolation, et les directions de vent sont décomposées en composantes sinusoïdales puis recombinées, ce qui évite les sauts artificiels autour du nord géographique.

Les variables calculées sont produites par le moteur physique solaire du package : le GHI de ciel clair y est évalué selon le modèle Ineichen–Perez, puis aligné sur la géométrie du site. Les **variables électriques historiques** sont enfin dérivées de façon strictement causale : retards de 24 heures sur les tensions, les courants et la fréquence réseau (dont les écarts restent bornés à ±5 Hz), rendements onduleur encadrés entre 0,5 et 1,0 avec un repli nominal de 0,97, rapport des courants alternatif et continu, indice d'encrassement établi à la veille, borné puis propagé, et compteurs d'énergie ramenés en incréments ou en cumuls sur 24 heures. Aucune de ces colonnes n'utilise d'information future : la causalité est garantie par la construction même des variables, toutes décalées de 96 pas.

La figure 7.1 synthétise ce cheminement : fabriquer les données, de l'import SCADA au parquet de features enrichi des réanalyses ; apprendre, du fenêtrage à la calibration probabiliste, traçabilité comprise ; prédire enfin, en sélectionnant le modèle approprié et en produisant une inférence par lots assortie de son enveloppe P10–P90.

Technologies et APIs mobilisées, et leur rôle

Le pipeline mobilise quelques briques standard : Great Expectations pour le contrôle des schémas, scikit-learn et SHAP pour la sélection, Optuna pour l'optimisation, MLflow pour la traçabilité et Prefect pour l'orchestration.

7.1.4 Exploration des données (EDA)

L'exploration des données permet de comprendre les caractéristiques de la production solaire de Diass avant toute modélisation. Cette phase identifie les patterns temporels, les corrélations entre variables et les spécificités du site.

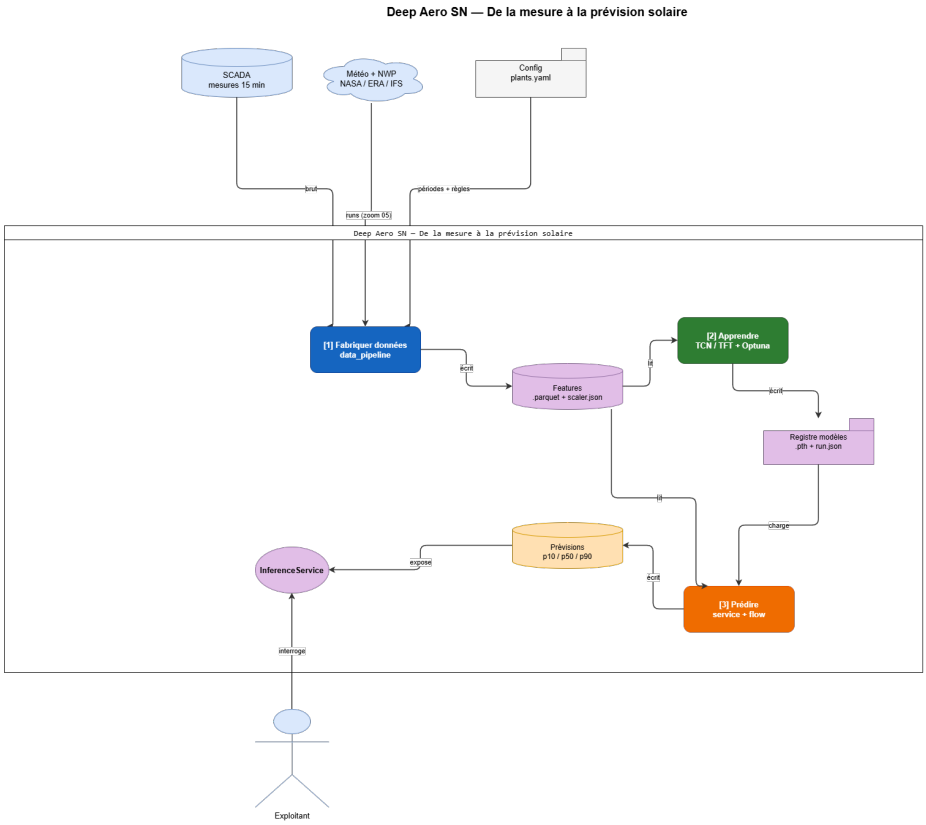


FIGURE 7.1 : Vue d'ensemble du système Deep Aero SN : des mesures (SCADA à 15 minutes, météos NASA/ERA/IFS, configuration) aux prévisions P+72 h.

Le profil journalier moyen campe l'arc diurne typique du site : irradiance et production culminent vers midi, la température ambiante suit avec un retard d'environ deux heures et le vent présente un minimum en fin de nuit (figure 7.2). À l'échelle d'une semaine (par exemple celle du 6 juin 2026, figure 7.3), la production suit étroitement l'irradiance, avec des chutes brutales lors des passages nuageux, principale source d'erreur à court terme.

Le modèle NOCT relie la température de cellule à l'ambiance via $\gamma = -0{,}43\ \%/°C$; sur Diass, il donne une T_{cell} moyenne de 33,3 °C (maximum 70,8 °C) pour une perte thermique moyenne de $-3{,}56\ \%$, facteur non négligeable de la production estivale.

Du côté des aérosols, l'épaisseur optique τ_a tourne autour de 0,31 en moyenne sur la période et culmine en mai ; la figure 7.7 met l'irradiance en regard de cet indice et détaille son évolution mensuelle.

L'EDA campe un site solaire typique du Sahel : forte irradiance annuelle, variabilité nuageuse marquée pendant l'hivernage et aérosols significatifs en saison sèche. Ces trois traits orientent directement le choix des features.

Synthèse statistique des données

L'analyse statistique des données de Diass révèle les distributions suivantes :

Deux remarques de lecture. La médiane du GHI est très basse (8,18 W/m²) alors que sa moyenne atteint 241,95 W/m² : c'est la signature de l'alternance jour/nuit sur un jeu à 15 minutes,

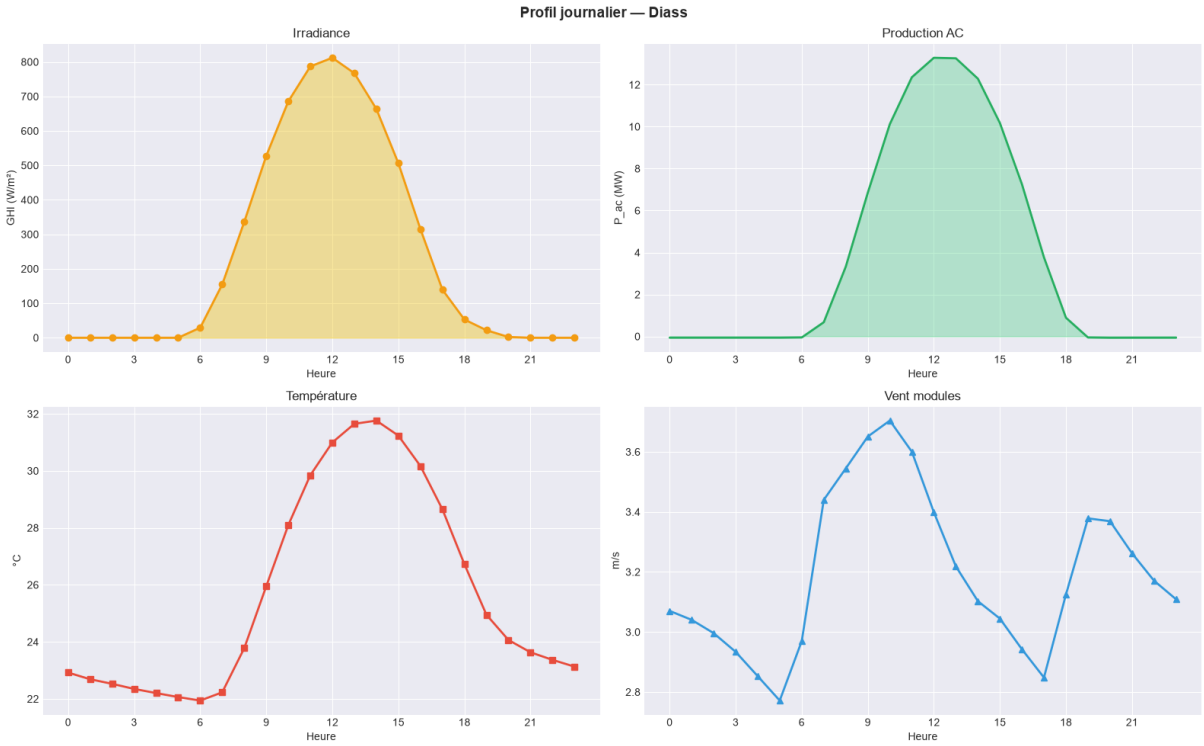


FIGURE 7.2 : Profil journalier moyen sur la période : irradiance, production, température ambiante et vent au niveau des modules.

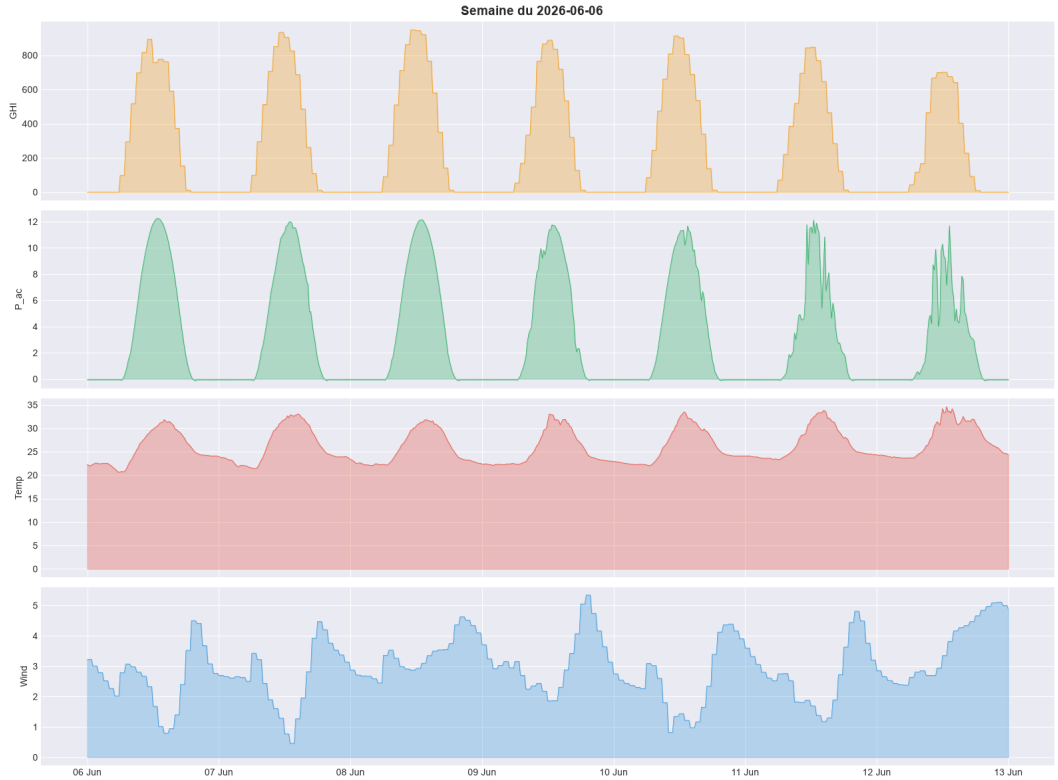


FIGURE 7.3 : Sept jours au pas horaire, semaine du 6 juin 2026 : les arcs diurnes successifs de l'irradiance et de la production, la température ambiante et le vent ; les passages nuageux du 12 juin découpent nettement la production.

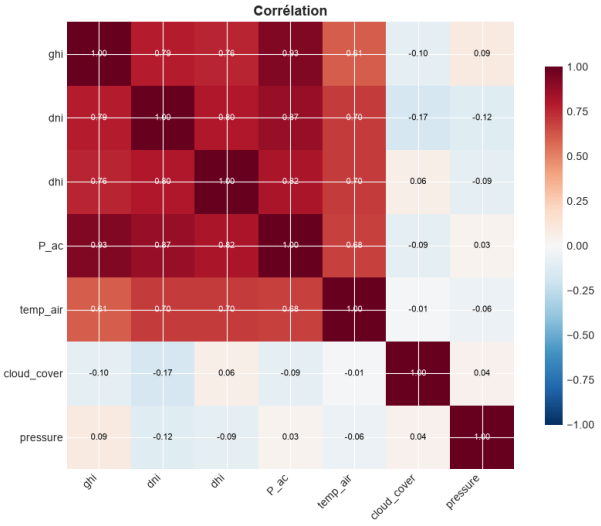


FIGURE 7.4 : Matrice de corrélation horaire des sept variables principales : `ghi`, `dni`, `dhi`, `P_ac`, `temp_air`, `cloud_cover` et `pressure`. L'irradiance est le déterminant dominant de la production, tandis que la couverture nuageuse s'y oppose.



FIGURE 7.5 : Relation GHI–production au pas de 10 minutes, colorée par la température ambiante. La relation est quasi linéaire sous ciel clair et se disperse sous ciel nuageux ; aucune saturation franche n'apparaît sur la plage observée.

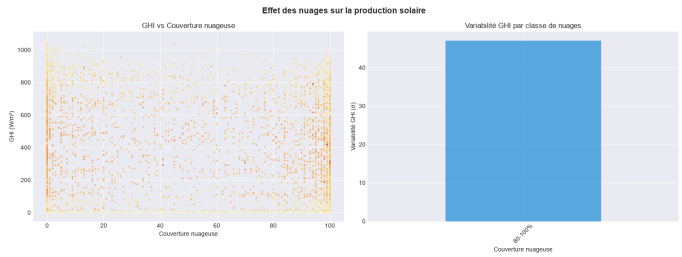


FIGURE 7.6 : Effet de la couverture nuageuse sur la variabilité du GHI : à gauche, GHI en fonction de la couverture coloré par la variabilité horaire ; à droite, variabilité moyenne par classe de couverture. La variabilité croît nettement avec la nébulosité, ce qui motive les lags courts d'irradiance.

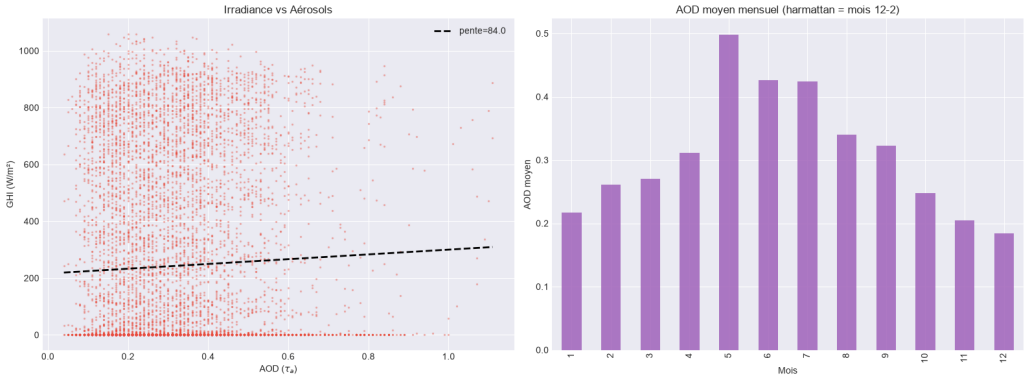


FIGURE 7.7 : À gauche, GHI en fonction de l'épaisseur optique des aérosols avec sa droite de tendance ; à droite, AOD moyen mensuel avec repérage de l'harmattan (décembre–février).

TABLE 7.2 : Statistiques descriptives du parquet brut de Diass (30/08/2025–31/08/2026, 35 196 lignes à 15 min, 55 colonnes hors indicateurs d'imputation ; run du 6 octobre 2026). Les comptes inférieurs à 35 196 traduisent les absences réelles de télémesure, dont la coupure de décembre 2025.

Variable	N	Min	Médiane	Moyenne	Max	Écart-type
GHI (W/m²)	35 196	0	8,18	241,95	1 059,53	320,13
Production P_{ac} (MW)	34 602	−0,14	−0,03	3,90	18,45	5,38
Température air (°C)	35 196	14,16	25,70	25,71	40,80	4,75
Humidité (%)	35 196	6,92	74,43	70,05	100,0	22,79
Vitesse vent 2 m (m/s)	35 196	0,05	3,22	3,19	7,54	1,40
DNI (W/m²)	35 196	0	0	223,31	856,20	284,28
Couverture nuageuse (%)	35 196	0	63,0	53,96	100,0	41,96
AOD τ_a	35 196	0,04	0,29	0,31	1,11	0,15

et non une anomalie. Le minimum de production est légèrement **négatif** (−0,14 MW) car les onduleurs consomment une faible puissance en mode veille la nuit ; la médiane proche de zéro traduit la même chose. Les variables électriques SCADA comptent environ 34 600 observations non manquantes (T_{inv} : 34 606, P_{ac} : 34 602, G_{sw} : 34 601), l'écart à 35 196 correspondant aux absences réelles conservées comme discontinuités.

Le minimum de GHI est nul (nuit) et celui de production légèrement négatif, la puissance de veille des onduleurs étant soustraite en heures creuses ; ce masque temporel s'impose lors de l'évaluation des métriques, seuls les pas de temps diurnes étant pertinents pour la prévision solaire. La distribution de la production présente un pic à 0 (nuit) et un second pic aux environs de 13–14 MW (conditions ensoleillées), avec une distribution quasi-uniforme entre ces deux modes [7].

Patterns temporels identifiés

L'EDA met en évidence quatre échelles de variation. Le **cycle diurne** domine : production nulle la nuit, croissance à l'aube (6h–7h), pic à midi solaire (12h–13h), décroissance au coucher (18h–19h), la forme de l'arc dépendant de la géométrie solaire locale ($\varphi = 14{,}65°$ N) et de l'inclinaison fixe des modules. Le **cycle hebdomadaire** est faible mais mesurable, lié à l'activité météorologique (passages de fronts en hivernage). Le **cycle saisonnier** oppose nettement la saison sèche (production élevée et régulière, GHI ∼6 kWh/m²/jour) à l'hivernage (production réduite et variable, GHI ∼4–5 kWh/m²/jour). Enfin, des **perturbations ponctuelles** s'ajoutent : chutes brutales dues aux passages nuageux en hivernage, réductions progressives dues au soiling en saison sèche et baisses d'irradiance dues à l'harmattan de décembre à février.

Ces patterns sont directement exploitables par les modèles de deep learning : le cycle diurne est capturé par les lags horaires, le cycle saisonnier par les features temporelles (jour julien, indicateur de saison), et les perturbations par les features d'irradiance et de météorologie.

7.1.5 Physique du site

Géométrie solaire locale

À la latitude de Diass ($\varphi = 14{,}65°$ N), le Soleil atteint une hauteur maximale de 75,8° au solstice d'été (juin) et de 51,9° au solstice d'hiver (décembre) [1]. Cette variation saisonnière de la hauteur solaire module l'irradiance reçue sur le plan des panneaux :

$$\alpha_{s,\max} = 90° - \varphi + \delta$$

où δ est la déclinaison solaire (±23,45°). Pour Diass, le Soleil passe presque au zénith aux équinoxes ($\alpha_s \approx 75°$), ce qui est favorable à la production. Les modules, montés sur une structure fixe avec une inclinaison de **15**° orientée **plein sud** (azimut 0°), captent le rayonnement de manière optimale toute l'année sans suivi actif.

Profil d'irradiance typique

Le site présente un contraste saisonnier marqué entre la **saison sèche** (novembre–mai) et l'**hivernage** (juin–octobre). En saison sèche, l'irradiance est élevée et régulière (GHI moyen ~6 kWh/m²/jour), le ciel généralement dégagé malgré l'harmattan de décembre à février : c'est la période de production maximale. Pendant l'hivernage, l'irradiance est réduite et variable (GHI moyen ~4–5 kWh/m²/jour) et les passages nuageux et précipitations rendent la production plus irrégulière, mais les températures plus basses réduisent les pertes thermiques.

Températures ambiantes élevées

Le climat sahélien de la région de Thiès se caractérise par des températures ambiantes élevées, en particulier en saison chaude (mars–juin) : les températures maximales atteignent régulièrement **35–40 °C**, avec des records dépassant 45 °C. La température de cellule T_{cell} peut alors atteindre 65–75 °C, entraînant des pertes thermiques significatives :

$$\Delta P_{therm} = \gamma \cdot (T_{cell} - 25^{\circ}C) \approx -0{,}43\,\%/^{\circ}C \times 45^{\circ}C \approx -19\,\%$$

Le refroidissement convectif par le vent (v_{wind}) atténue partiellement cet effet, ce qui fait de la vitesse du vent une variable d'entrée pertinente même pour un site solaire.

Impact de l'harmattan

L'harmattan, vent d'est venu du Sahara, transporte d'importantes masses de poussière pendant la saison sèche (novembre–février) et affecte la production de deux manières. Il réduit d'abord l'irradiance directe : l'épaisseur optique des aérosols τ_a augmente et diffuse une fraction notable du rayonnement, la DNI pouvant chuter de 15 à 30 % par rapport à un ciel clair. Il encrasse ensuite les modules : les dépôts de poussière sur les surfaces vitrées réduisent la transparence et provoquent des pertes de 5 à 15 % sur plusieurs semaines sans nettoyage.

Ces deux effets sont distincts de la variabilité nuageuse et doivent être modélisés séparément dans le feature engineering.

La physique du site contraint directement le modèle : il doit restituer le cycle diurne (géométrie solaire), la variabilité nuageuse (hivernage), l'effet des aérosols (harmattan) et les pertes thermiques (température ambiante élevée). Chacune de ces causes opère à une échelle différente, du journalier au saisonnier, ce qui justifie des features multi-échelles.

Influence des périodes de pluie

La figure 7.8 objective l'effet des épisodes pluvieux sur la production : les jours où le cumul quotidien dépasse 1 mm (fond rouge) correspondent systématiquement à des creux de P_{ac}, alors que les périodes sèches (fond bleu) restent proches du profil nominal. Le run courant compte **96 jours pluvieux contre 271 jours secs**, avec une production moyenne de **3,7 MW par jour pluvieux contre 4,0 MW par jour sec (−6 %)**, ce qui confirme la précipitation comme variable discriminante de l'hivernage.

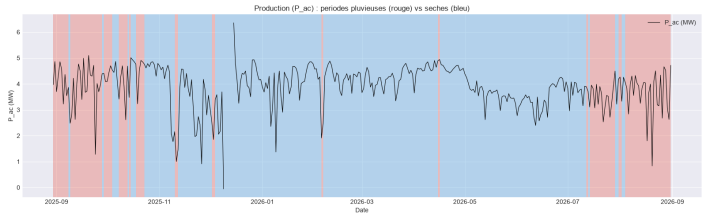


FIGURE 7.8 : Production P_{ac} moyenne journalière avec périodes pluvieuses (cumul > 1 mm, fond rouge) et sèches (fond bleu). Les épisodes de pluie, concentrés pendant l'hivernage, coïncident avec les baisses marquées de production.

7.1.6 Transformation des variables électriques SCADA : du data leakage à l'information causale

Le problème : la circularité des variables SCADA contemporaines

Les exports SCADA de Diass fournissent des variables électriques instantanées (`I_ac`, `P_dc`, `V_dc`, `V_dc_inv`, `I_dc`, `I_dc_inv`, `P_dc_inv`, `V_ac`, `cos_phi`, `energy_*kwh` et `grid_frequency`) mesurées au même instant t que la cible `P_ac`. Utiliser ces variables brutes comme features constitue un **biais de circularité mathématique** (data leakage) : le capteur de puissance AC et le capteur d'intensité AC mesurent simultanément le même flux d'électrons en sortie d'onduleur, liés par une équation déterministe stricte d'électrotechnique :

$$P_{ac} = V_{ac} \times I_{ac} \times \cos(\varphi) \times \sqrt{3}$$

Un modèle de deep learning (MLP, LSTM, TCN) qui reçoit ces grandeurs brutes choisit par descente de gradient la **solution de facilité** : apprendre cette formule instantanée au lieu d'anticiper les passages nuageux ou les conditions météo. En production, à l'instant t pour prédire t+24 h, ces télémesures sont par définition **physiquement inexistantes** : un modèle entraîné sur cette variante est donc inutilisable en conditions réelles.

Le problème de la persistance temporelle

La puissance PV est une série très continue de jour : des lags électriques trop proches (t-1h, t-2h) transforment le modèle en simple opérateur de décalage qui prédit « demain = aujourd'hui ». Mais à Diass, les phénomènes sahéliens (passages nuageux rapides, tempêtes de poussière, vents de mousson) créent des variations de puissance brutales : un modèle persistant affiche un excellent R^2 moyen par ciel bleu mais des erreurs catastrophiques dès qu'un nuage passe, mettant en péril la stabilité du réseau.

La démarche : variables causales (Physics-Informed ML)

L'objectif n'est pas de supprimer le SCADA électrique, mais de le transformer en **variables causales** : les mesures brutes à l'instant t (futur, circularité) deviennent des indicateurs d'état connus à $t-24$ h (passé légal *day-ahead*). Les variables électriques de la veille ne prédisent pas le soleil de demain, mais elles décrivent l'état de dégradation thermique de l'onduleur et l'encrasse-

ment des panneaux. En combinant physique et SCADA passé (ex. : ratio $P_{dc,\text{lag_24h}}/G_{sw,\text{lag_24h}}$), on crée un indicateur de Performance Ratio dynamique : c'est lui qui permet aux modèles avancés (TFT, TCN) d'ajuster le modèle météo global aux spécificités techniques et aux pertes réelles de la centrale.

Matrice de transformation

Le tableau 7.3 présente la correspondance entre chaque variable SCADA brute et sa transformation causale. Les 11 variables contemporaines interdites sont remplacées par 11 variables transformées, toutes décalées d'au moins 24 heures ou calculées sur des fenêtres glissantes passées.

Table 7.3 : Substitution des variables électriques brutes : toute grandeur contemporaine cède la place à un retard de 24 heures ou à un indicateur reconstruit sur le passé.

Variable brute	Nature du risque	Remplacement	Ce que le remplacement apprend
`I_ac`, `I_dc`	Fuite totale	`I_dc_lag_24h` et rapport `I_dc_lag_24h/G_sw_lag_24h`	Encrassement des modules
`V_dc`, `V_dc_inv`	Fuite indirecte	`V_dc_lag_24h` et écart `V_dc_lag_4h − temp_air_lag_4h`	Surchauffe de cellule déduite de la chute de tension
`P_dc`, `P_dc_inv`	Fuite la plus forte	Rapport `P_ac_lag_24h/P_dc_lag_24h`	Rendement de conversion réel de l'onduleur
`V_ac`, `grid_freq`	Bruit proche de la cible	`V_ac_std_24h`, écart-type glissant	Stabilité du réseau et curtailment
`cos_phi`	Fuite électrotechnique	`cos_phi_lag_24h`	Comportement de régulation de l'onduleur
`energy_*kwh`	Cumul ouvert sur la durée	Différentiel `energy_ac_lag_24h − energy_ac_lag_25h`	Productivité globale et vieillissement long terme
`insolacion_kwh_m2`	Intégration clôturée sur elle-même	`insolacion_lag_24h`	Inertie thermique résiduelle du sol

Implémentation

Ces transformations sont implémentées dans le script `diass.py`, le notebook n'en conservant que la justification scientifique. Le décalage temporel porte sur 96 pas, soit 24 heures à la résolution de 15 minutes. Les retards de 24 heures appliqués aux courants, aux tensions, au facteur de puissance et à l'insolation sont obtenus par décalage d'autant de pas et restent indéfinis sur les 96 premiers pas, faute de passé. Trois rapports composites mettent en regard le passé électrique et l'irradiance : l'encrassement, quotient du courant continu de la veille et de l'irradiance au plan de la veille ; la conversion de l'onduleur, quotient des puissances alternative et continue de

la veille ; et le rapport des courants alternatif et continu de la veille. Enfin, un écart-type glissant sur 24 heures, purement passé, résume la tension réseau sur la fenêtre $[t-95,\ t]$.

Les onze variables électriques brutes mesurées à l'instant même, courants, tensions, puissances, facteur de puissance, insolation et fréquence réseau, ne sont **jamais copiées** telles quelles dans le jeu de sortie. Seules les versions transformées, récapitulées au tableau 7.3, y survivent, et le parquet qu'elles composent constitue l'entrée du pipeline de feature engineering.

Cette transformation causale convertit des variables interdites (circularité instantanée) en indicateurs d'état interprétables (encrassement, rendement d'onduleur, stabilité réseau), accessibles en conditions réelles *day-ahead*. Combinée à l'exclusion automatique des fuites par corrélation (section 7.1.7), elle garantit que les modèles n'apprennent que des relations causales exploitables en opération.

7.1.7 Feature Engineering

Le feature engineering de Diass repose sur le registre déterministe `DEFAULT_PLUGINS` du module `features/engineering.py`, qui instancie **sept plugins** exécutés en séquence. Cette liste constitue la source de vérité d'exécution.

Table 7.4 : Features spécifiques au site de Diass (extrait).

Catégorie	Feature	Description
Solaire	`solar_elevation`	Hauteur solaire (α_s)
	`clear_sky_ghi`	GHI théorique ciel clair (Ineichen–Perez)
	`g_poa`	Irradiance sur le plan des modules
	`module_temp`	Température de cellule (modèle NOCT)
Temporel	`hour_sin/cos`	Heure cyclique
	`is_harmattan`	Indicateur saison sèche (déc.–fév.)
	`is_mousson`	Indicateur hivernage (juil.–sept.)
Lags	`ghi_lag_1h, _24h, _72h`	Lags causaux d'irradiance
	`P_ac_lag_1h – _72h`	Lags causaux de puissance
	`soiling_ratio_hist_-24h`	Indice d'encrassement $J-1$ (diass.py)

Les familles de features mobilisées sont les suivantes : la **géométrie solaire** (`solar_elevation`, `solar_azimuth`, `clear_sky_ghi`, déterministes et calculables à l'avance) ; l'**irradiance** (`ghi`, `dni`, `dhi`, `g_poa`) ; la **température** (`temp_air`, `module_temp` via le modèle NOCT) ; les **aérosols et nuages** (`aod`, `dust`, `pm10`, `pm2_5`, `cloud_cover`) ; les **variables temporelles** (`hour_sin/cos`, jour de l'année, `is_harmattan`, `is_mousson`) ; et les **lags et statistiques glissantes** causaux (`_lag_1h` à `_72h`, moyennes et écarts-types sur 24 heures). Les variables électriques historiques (`soiling_ratio_hist_24h`, rendements onduleur, stabilité réseau) sont

construites en amont dans `diass.py` par décalage de 24 heures et consommées telles quelles par les plugins, sans jamais introduire de grandeur contemporaine de la cible.

Dans le run de référence du 6 octobre 2026, cette chaîne produit 543 variables numériques en entrée de sélection, pour une union finale de 424 features (cible exclue), soit une dimension d'entrée de 425 pour les modèles et un parquet de features de 8 800 lignes et 428 colonnes.

Détail des sept plugins de feature engineering

Les sept plugins du registre, dans leur ordre d'exécution, sont les suivants. Chacun ajoute ses colonnes au DataFrame et la cible `P_ac` est préservée tout au long de la chaîne.

1. **`TemporalFeatureEngineer`** : il encode le temps de manière cyclique (heure, jour de semaine, jour de l'année et mois en sinus/cosinus) et construit les indicateurs `is_daytime`, `is_harmattan`, `is_mousson` et `is_hivernage`, qui structurent les régimes saisonniers sahéliens.
2. **`CommonWeatherEngineer`** : il dérive les variables météorologiques communes (humidité, point de rosée, pression, précipitations) et leurs transformations directement exploitables par les modèles.
3. **`GridFrequencyEngineer`** : il traite la fréquence du réseau et ses écarts à 50 Hz comme indicateurs de stabilité et de curtailment, à partir des historiques $J-1$ exclusivement.
4. **`SolarPhysicalEngineer`** : il calcule les grandeurs physiques solaires (élévation, azimut et zénith solaires, déclinaison, masse d'air, `clear_sky_ghi`, indices de ciel clair, `g_poa`, température de cellule et pertes thermiques) à partir de la latitude du site et du modèle d'Ineichen–Perez.
5. **`SolarWeatherEngineer`** : il constitue le point d'extension documenté pour les features météorologiques spécifiquement solaires et transmet sans altération les variables requises par les étapes aval.
6. **`SolarElectricalEngineer`** : il consomme exclusivement les colonnes historiques $J-1$ produites par `build_diass_raw` (rendements onduleur bornés, ratios de conversion, drapeaux de clipping et d'état opérationnel) et refuse par construction toute grandeur électrique contemporaine de la cible, ainsi que tout terme en ΔP qui en serait une transformation quasi linéaire.
7. **`LagRollingFeatureEngineer`** : il construit les retards causaux (`shift` strictement positif, par exemple 1, 2, 3, 24, 48 et 72 heures pour `ghi` et `P_ac`) et les statistiques glissantes calculées sur le passé et le présent uniquement, ce qui garantit l'absence d'accès au futur.

Deux modules complémentaires ne font pas partie du registre par défaut : le `FrequencyFeatureEngineer`, activable explicitement pour l'analyse spectrale, et le `SolarLossEngineer` (constantes de pertes LID, PID, mismatch, câblage et dégradation annuelle), qui reste disponible sans être exécuté dans le run courant. L'indice de soiling `soiling_ratio_hist_24h` n'est pas produit par un plugin : il est calculé dans `diass.py` comme le rapport $I_{\mathrm{dc},J-1}/G_{\mathrm{sw},J-1}$ borné puis propagé, et il est ensuite consommé comme tout autre historique causal.

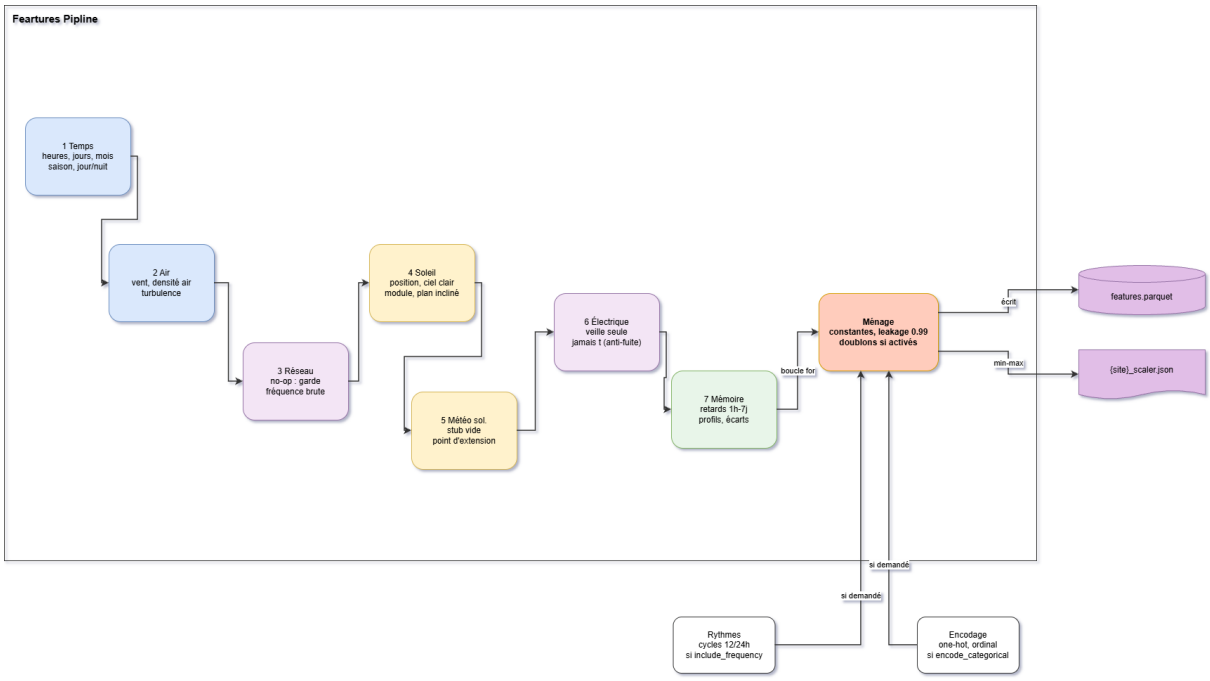


FIGURE 7.9 : Boucle de feature engineering : les sept plugins de `DEFAULT_PLUGINS` s'exécutent en séquence déterministe, suivis du ménage anti-fuite (constantes, corrélation > 0,99, doublons) et des étapes opt-in (rythmes, encodage).

Prévention du data leakage dans les lags et rolling statistics

Chaque plugin de lags et de statistiques glissantes est conçu pour être **causal** : à l'instant t, seules les données antérieures ou contemporaines ($\leq t$) sont accessibles, ce que garantissent trois mécanismes. La fonction `shift(`h`)` décale la série de h pas vers le futur : à l'instant t, la feature `col_lag_`h`h` contient la valeur de `col` à $t-h$, les h premiers pas restant à `NaN` faute de passé disponible. La fenêtre `.rolling(window=`w`, min_periods=1)` opère sur l'intervalle $[t-w+1,\ t]$, exclusivement passé et présent ; `col_mean_24h` à l'instant t est ainsi la moyenne des 24 dernières heures. Enfin, `diff(`p`)` calcule value$[t]$ − value$[t-p]$, et les profils horaire et journalier recourent à une moyenne cumulée causale (`cumsum/cumcount` par groupe) qui n'intègre que les occurrences $\leq t$. Ces garanties sont vérifiées par construction : aucune feature n'accède à des valeurs futures de la cible ou des covariables.

Exclusion automatique des fuites de données

Le pipeline exclut automatiquement, en amont de la sélection, toute feature numérique dont la corrélation absolue de Pearson avec la cible `P_ac` dépasse le seuil `config.features.leakage_threshold` (0,99), à l'exception des drivers physiques explicitement autorisés (`leakage_allowlist` : irradiance, position solaire, couverture nuageuse). Dans le run de référence du 6 octobre 2026, une seule variable est ainsi écartée (`P_ac_seasonal_dev`). Cette vérification garantit que les modèles n'accèdent pas à la cible par des voies dérivées indirectes et fonde la validité de l'évaluation sur le segment de test.

Pipeline de feature engineering : du parquet aux features

Le parquet brut (`raw_input.parquet`, 58 colonnes à 15 minutes, 55 hors imputation) est chargé par la fonction `data_pipeline()`, qui enchaîne six opérations. Le rééchantillonnage passe de 15 minutes à 1 heure (8 800 lignes), par moyenne pour les grandeurs instantanées, somme pour les taux et report de la dernière valeur pour les compteurs cumulatifs, selon le rôle physique de chaque colonne. Great Expectations valide ensuite les colonnes critiques. Le prétraitement nettoie les horodatages, borne physiquement les valeurs aberrantes, interpole sur 6 heures au plus, propage sur 24 heures au plus et remplace par `NaN` les valeurs hors de $3 \times$ IQR. Le feature engineering exécute les sept plugins du registre `DEFAULT_PLUGINS` en séquence déterministe, chacun ajoutant ses colonnes. Un nettoyage post-plugins supprime les colonnes à variance nulle (`nunique` ≤ 1, cible préservée), exclut les dérivées quasi linéaires de la cible ($|\rho| > 0{,}99$, section 7.1.7) et, en option, les colonnes strictement dupliquées. La sélection applique enfin les sept méthodes en série puis en fait l'union (section 7.1.7).

Sélection de features par union de 7 méthodes

La sélection est réalisée par le module `FeatureSelector` qui applique 7 méthodes indépendantes. La sélection finale est l'**union** des features retenues par chaque méthode (stratégie conservatrice maximisant le rappel) :

Table 7.5 : Résultats de la sélection sur Diass (run du 6 octobre 2026) : 543 variables en entrée, 424 retenues en union des sept méthodes (cible exclue). Têtes d'union : `T_inv`, `G_sw`, `ghi`, `dni`, `dhi`, `cloud_cover`.

Méthode	Retenues	Sur	%	Critère
Correlation	349	543	64,3	$\|r\| > 0{,}01$
Mutual Information	2	543	0,4	Top 2 (`P_ac_max_3h`, `P_ac_max_6h`)
PCA	0	543	0,0	(composantes, pas features)
RFE	50	543	9,2	Rang 1 (`dust`, `pressure`, `wind_gust`…)
VIF	527	543	97,1	VIF $\leq 5{,}0$
Permutation	2	543	0,4	Top 2 (`P_ac_trend_dev`, `G_sw`)
SHAP	2	543	0,4	Top 2 (`P_ac_trend_dev`, `P_ac_hourly_profile`)
Union brute	542	543	99,8	—
Redondances dédupliquées	118	—	—	$\|r\| > 0{,}90$
Union finale	**424**	**543**	**78,1**	—

La stratégie d'union (plutôt qu'intersection) est conservatrice et maximise le rappel : le consensus entre méthodes est faible (aucune feature retenue par les sept, 194 par une seule), de sorte qu'un vote majoritaire éliminerait les informations que seule une méthode sait isoler.

Discussion des méthodes et de leurs usages

Les **sept méthodes** mises en concurrence ne jouent pas le même rôle : elles diffèrent par ce qu'elles mesurent (liaison linéaire, dépendance non linéaire, redondance, contribution prédic-

TABLE 7.6 : Répartition par famille de l'union finale (424 features, section 3.2 du notebook).

Famille	**N**	**%**
Lags / fenêtres $J-1$	137	32,3
Réanalyse / atmosphère	123	29,0
Autres	62	14,6
Météo locale (station)	54	12,7
Physique PV	23	5,4
Rendement / onduleur	15	3,5
Temporel (sin/cos/heure)	10	2,4
194 retenues par une seule méthode, **aucune** par les sept	—	—

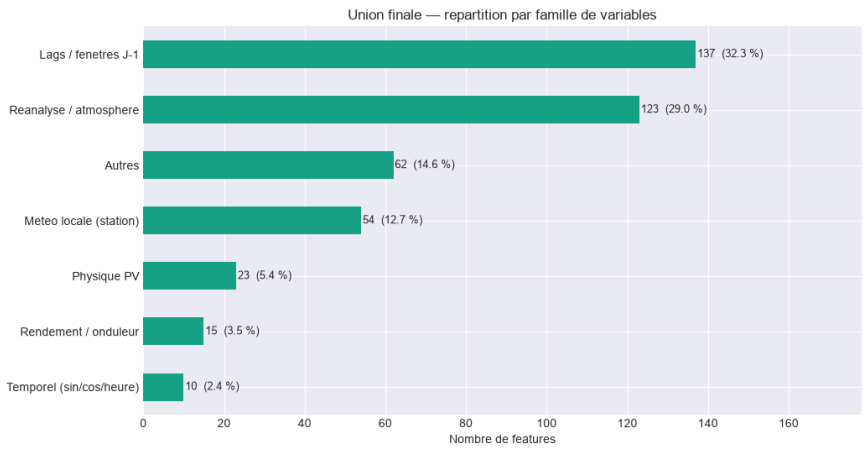


FIGURE 7.10 : Répartition de l'union finale des 424 variables retenues par famille ; les lags de la veille dominent, suivis des réanalyses atmosphériques.

tive), par le type de modèle qu'elles supposent et par l'information qu'elles produisent (rang, importance, variance). Le tableau 7.5 et la figure 7.11 en résument les enseignements :

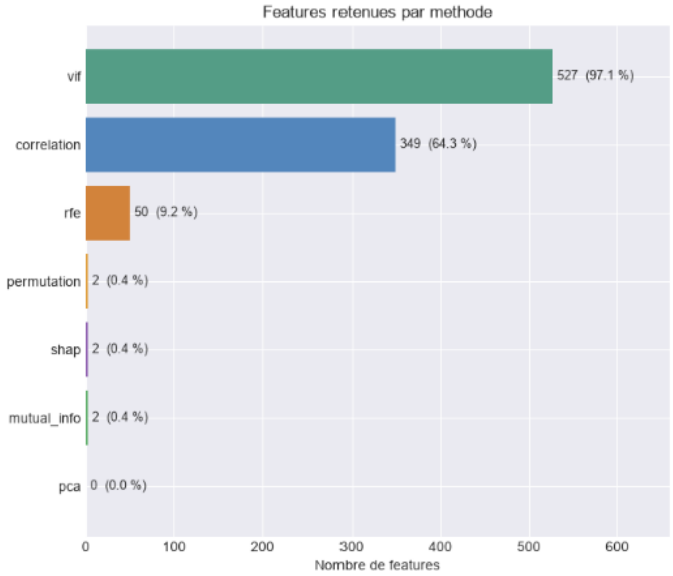


FIGURE 7.11 : Nombre de variables retenues par chacune des sept méthodes de sélection.

La **corrélation de Pearson** ($|r|$ avec P_{ac}, seuil $|r| > 0{,}01$) est un filtre *linéaire* et rapide : elle capte les drivers physiques directs (irradiance, `G_sw`) mais manque les dépendances non linéaires, et reste, avec 349 retenues (64,3

L'issue dépend de l'échelle de décision : une **union** de 424 features (figure 7.12) conserve l'essentiel du spectre, réparti entre réanalyse/atmosphère (29,0

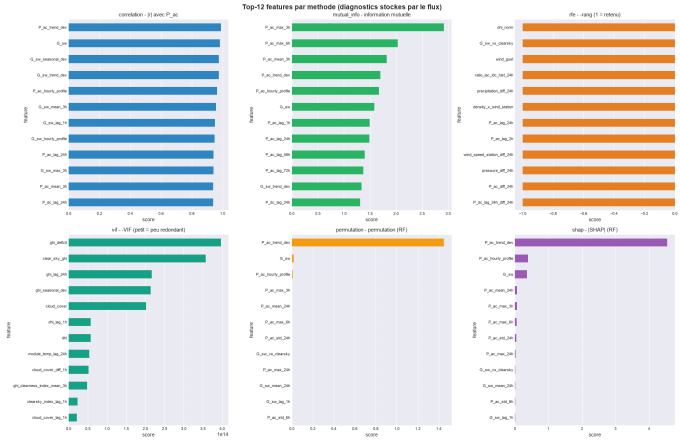


FIGURE 7.12 : Top-12 features de chaque méthode sur leur score normalisé. Chaque méthode met en avant des familles différentes (physique pour la corrélation et le VIF, météo pour le RFE, dérivées de la cible pour la permutation et le SHAP), confirmant la complémentarité des perspectives.

En résumé, 58 colonnes brutes entrent dans le pipeline, 543 features en sortent, et la sélection en retient 424 après exclusion des fuites et déduplication des redondances. Les familles préservées sont celles qu'on attend d'un site solaire : lags et fenêtres $J-1$ (32

Optimisation des hyperparamètres avec Optuna

L'entraînement des modèles avancés (TCN, TFT) repose sur une recherche d'hyperparamètres pilotée par **Optuna**. Les hyperparamètres (taux d'apprentissage, `batch_size`, `mse_weight`, planificateur de taux, fenêtres, architecture) ne sont pas fixés arbitrairement : Optuna les propose et **évalue chaque combinaison** en entraînant le modèle et en mesurant sa performance de validation, remplaçant ainsi la grille exhaustive ou le réglage manuel. L'échantillonneur retenu est un **TPE** (Tree-structured Parzen Estimator), méthode bayésienne qui modélise la distribution des bons résultats et concentre les essais dans les régions prometteuses de l'espace plutôt que d'explorer uniformément ; chaque essai est tracé avec son objectif, ce qui permet de suivre la convergence. Un élagage **médian** interrompt par ailleurs les essais déjà nettement pires que la médiane des essais en cours, économisant le temps de calcul sans compromettre le résultat. L'objectif minimise une métrique de validation adaptée à la prévision probabiliste, la perte hybride MSE + pinball pondérée par `mse_weight` = 0,5 (chapitre 6), en explorant `mse_weight` $\in [0{,}3; 0{,}8]$ sur deux décades de taux d'apprentissage et plusieurs planificateurs (plateau, cosinus, warmup cosinus). Pour les baselines, dix essais suffisent car leur espace est réduit ; pour le TCN et le TFT, davantage d'essais sont consacrés à l'architecture et à la stratégie d'horizon. Le meilleur essai est ensuite figé (graine 42, arrêt précoce configuré séparément) et enregistré dans MLflow avec son `run_id`.

La même graine et les mêmes bornes permettent de retrouver exactement les modèles évalués à la section 7.1.8.

7.1.8 Entraînement et résultats

Cinq modèles ont été entraînés sur les données de Diass avec un horizon de prévision de **72 heures** : les trois repères usuels, la persistance, le MLP et le LSTM de base, entraînés via le pipeline des baselines avec dix essais d'optimisation ; puis le TCN et le TFT, entraînés via le pipeline général avec dix essais, la perte hybride de MSE et de pinball, et les covariables météorologiques NWP injectées au canal futur. Tous sont évalués sur le même segment de test, **1 049 fenêtres** allant d'un historique de 168 heures vers 72 heures d'horizon, sur la période du 16/07/2026 06h00 au 28/08/2026 22h00 prolongée de 72 h ; les métriques ci-dessous sont issues du notebook `diass.ipynb` (run du 6 octobre 2026) :

Temps de calcul du run courant : persistence 3 s, MLP 519 s, `lstm_baseline` 863 s, TCN 1 206 s, TFT 2 016 s. Les baselines ne produisent que des prévisions ponctuelles (métriques de calibration non applicables).

La MAPE très élevée des baselines (3282,8 % pour la persistence) tient à la production quasi nulle en début et fin de journée, où le moindre écart pèse énormément en relatif. Les modèles avancés la réduisent d'un ordre de grandeur ; à l'inverse, la MAPE du TFT (502

Perte hybride et hyperparamètres retenus

Les modèles TCN et TFT ne sont pas entraînés avec une simple MSE : ils utilisent la **perte hybride** multi-tâche du chapitre 6 (équation (6.2)), dont la composante MSE optimise l'exacti-

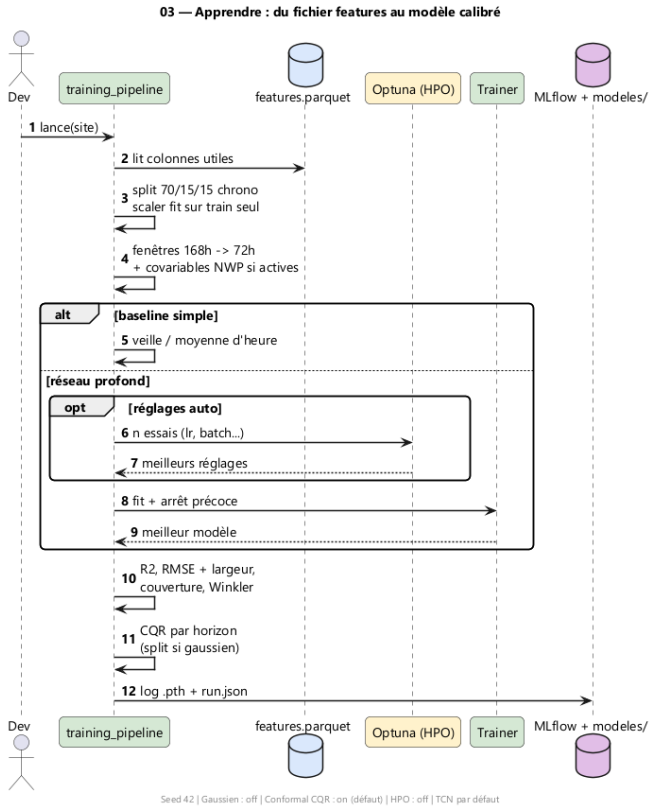


FIGURE 7.13 : Pipeline d'entraînement `training_pipeline` : découpage chronologique 70/15/15 avec normalisation ajustée sur l'entraînement seul, optimisation Optuna optionnelle, apprentissage avec arrêt précoce, évaluation et calibration conforme (CQR par défaut), puis journalisation MLflow et locale.

TABLE 7.7 : Résultats sur le segment de test de Diass (horizon 72 h, 1 049 fenêtres) : métriques ponctuelles pour tous les modèles, métriques probabilistes pour TCN et TFT.

Modèle	RMSE (MW)	MAE (MW)	nRMSE	R^2	MAPE (%)
persistence	6,905	4,987	0,444	−1,013	3282,8
MLP	2,323	1,275	0,149	0,772	381,5
lstm_baseline	2,043	1,148	0,131	0,824	333,3
TCN	1,707	0,989	0,110	0,877	362,2
TFT	1,818	1,157	0,117	0,861	502,0

TABLE 7.8 : Métriques probabilistes sur le test (quantiles 0,1/0,5/0,9, α=0,20) : couverture et largeur avant recalibrage, score de Winkler, pinball des bornes, puis couverture et largeur après recalibrage CQR.

Modèle	Couv.	Largeur	Winkler	Pinball bas/haut	Couv. CQR	Largeur CQR
TCN	0,608	1,670	5,742	0,325 / 0,250	0,798	2,596
TFT	0,713	2,456	5,964	0,323 / 0,273	0,742	2,646

Croisements de quantiles : 0,0 pour les deux modèles. s_h moyen/max : TCN 0,463/0,613 MW ; TFT 0,095/0,156 MW.

tude ponctuelle (R^2, RMSE) et la composante pinball la calibration des intervalles. La valeur retenue pour Diass est $w_{\text{mse}} = 0{,}5$ par défaut (contribution égale), la plage HPO explorant $w_{\text{mse}} \in [0{,}3; 0{,}8]$. Ce compromis équilibré est justifié par le climat sahélien : les passages nuageux rapides et les tempêtes de poussière rendent l'estimation de l'incertitude aussi critique que la prévision ponctuelle pour la gestion du réseau.

Chaque modèle a fait l'objet de dix essais Optuna, conduits avec l'échantillonneur TPE et l'élagage médian présentés à la section 7.1.7. Les meilleurs essais retenus sont les suivants. Le MLP combine un poids hybride de 0,354, trois couches de 256 neurones, un dropout de 0,286, des lots de 64, un plateau et un taux d'apprentissage de $1{,}35\times10^{-3}$. Le LSTM de base retient le même lot et la même profondeur, un dropout de 0,10, un planning cosinus et un taux de $1{,}88\times10^{-4}$, pour un poids de 0,440. Le TCN retient des canaux de 64, 128, 256 et 256, un noyau de 5, un dropout de 0,252, 64 par lot, une montée en charge cosinus de cinq époques et un taux de $3{,}29\times10^{-4}$, pour un poids de 0,765. Le TFT retient une dimension de 256 sur deux têtes, un dropout de 0,15, des lots de 128, un plateau et un taux de $6{,}92\times10^{-4}$, pour un poids de 0,617.

Résultats TCN

Le TCN atteint sur le test une RMSE de **1,707 MW** et une MAE de **0,989 MW** (R^2=0,877). Sa couverture P10–P90 avant recalibrage vaut 60,8 % (largeur 1,670 MW, Winkler 5,742) et passe à **79,8 %** après recalibrage CQR (α=0,20, s_h moyen 0,463 MW, largeur 2,596 MW), proche de la cible de 80 %.

Résultats TFT

Le TFT atteint **RMSE 1,818 MW**, **MAE 1,157 MW**, R^2=0,861. Sa couverture avant recalibrage vaut 71,2 % (largeur 2,456 MW, Winkler 5,964) et passe à **74,2 %** après CQR (s_h moyen 0,095 MW, largeur 2,646 MW). Son interprétabilité (sélection de variables, attention) en fait un outil précieux côté opérateur, au prix d'une couverture calibrée inférieure à celle du TCN.

7.1.9 Analyse des résultats

Courbes d'entraînement

Les courbes d'entraînement du run courant (section 5.1 du notebook) montrent une convergence régulière des deux modèles avancés, avec early stopping (patience 25, maximum 100 époques) : le TCN s'arrête à l'époque 57 et le TFT va au terme des 100 époques. Les pertes finales de validation restent proches des pertes d'entraînement, ce qui indique une bonne généralisation sans surapprentissage marqué.

Performance sur la fenêtre de test

Le TCN reproduit fidèlement le cycle diurne et capte les variations rapides liées au passage des nuages ; ses écarts les plus marqués surviennent aux transitions jour–nuit et lors des changements brusques d'irradiance, ce qui est attendu d'un modèle convolutionnel.

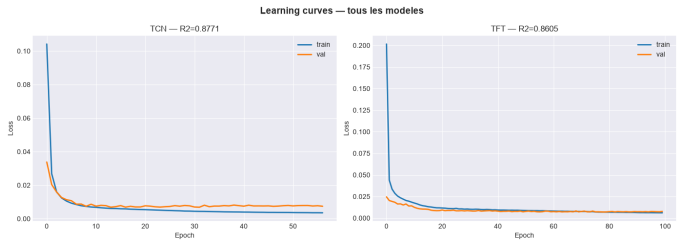


FIGURE 7.14 : Courbes d'entraînement (pertes train/validation) du TCN (R^2=0,877) et du TFT (R^2=0,861) sur Diass (section 5.1 du notebook).

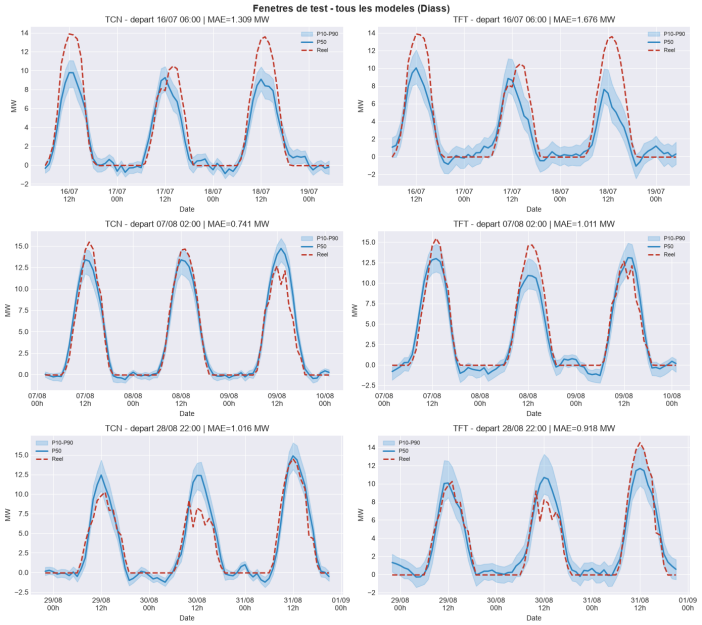


FIGURE 7.15 : Fenêtres de test représentatives (début, milieu et fin du test) : médiane P50, enveloppe P10–P90 et production réelle pour le TCN et le TFT, avec la MAE de chaque fenêtre. Les deux modèles suivent le cycle diurne et les chutes liées aux nuages ; les écarts les plus importants surviennent aux transitions jour/nuit.

Comparaison des métriques sur le test

La figure 7.16 confirme la supériorité du TCN (RMSE 1,707 MW, R^2=0,877) sur le TFT (RMSE 1,818 MW, R^2=0,861), tandis que les baselines (persistence, MLP, `lstm_baseline`) restent nettement en retrait. L'écart entre les deux architectures avancées est toutefois limité : sur ce site, la couverture de l'enveloppe P10–P90 après CQR est le critère qui les départage le plus nettement (TCN 79,8 % vs TFT 74,2 %).

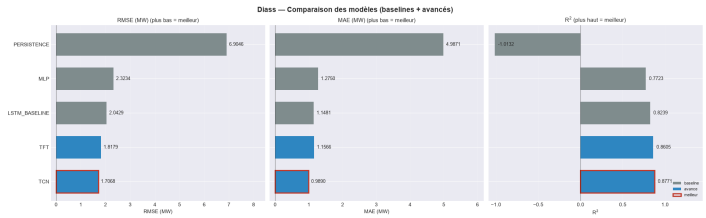


Figure 7.16 : Comparaison des métriques RMSE, MAE et R^2 sur le test : barres triées, meilleur modèle entouré en rouge, baselines en gris et modèles avancés en bleu. Le TCN devance légèrement le TFT sur les trois métriques ponctuelles.

Prévision batch à 72 heures

Le pipeline d'inférence produit en mode batch une prévision à 72 h avec enveloppe P10–P90 : sur le run courant, la prévision du site vaut p_{50} = 0,965 MW.

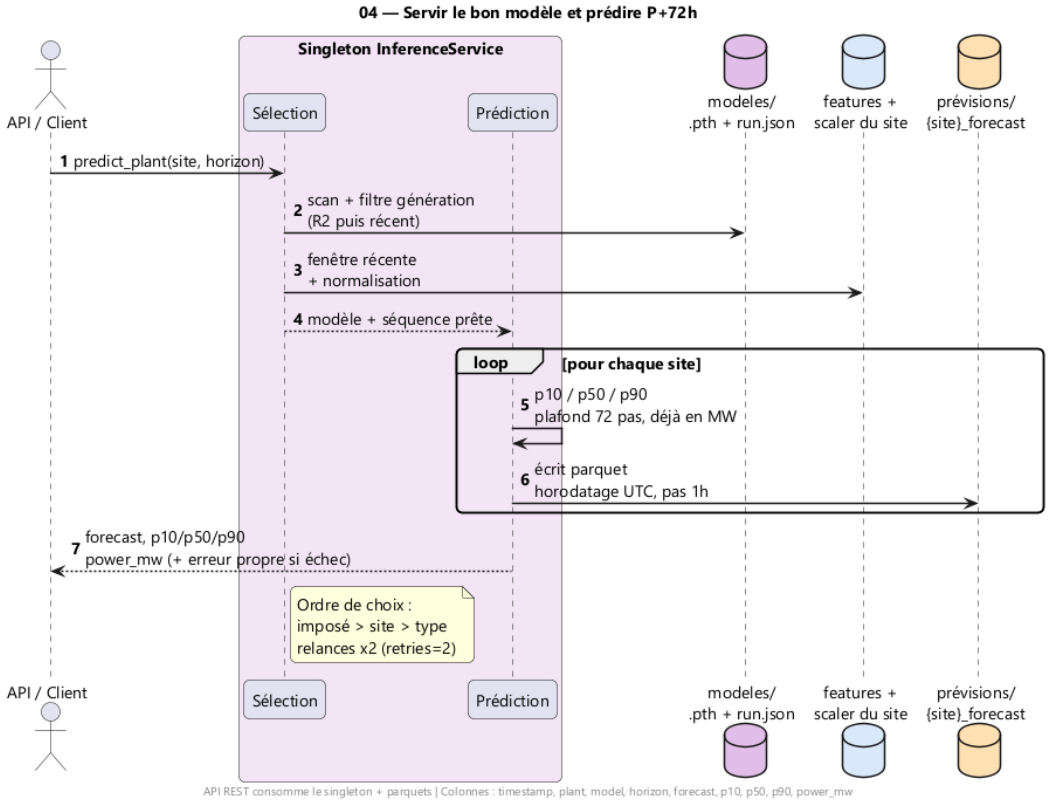


Figure 7.17 : Serving et inférence : le singleton `InferenceService` sélectionne le modèle de la génération courante (imposé > site > type, meilleur R^2), construit la dernière fenêtre normalisée et prédit P+72 h avec enveloppe P10–P90, persistée en parquet horodaté.

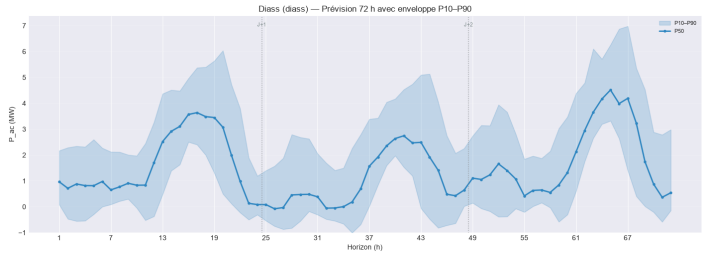


FIGURE 7.18 : Prévision batch à 72 heures : médiane P50 et enveloppe P10–P90, séparateurs J+1 et J+2. L'enveloppe s'élargit avec l'horizon, conformément à la croissance de l'incertitude.

7.2 Discussion et perspectives

7.2.1 Compromis TCN / TFT

Les performances des modèles sont quantifiées avec les métriques définies à la section 3.7, sans redéfinir ici leurs formules. Le tableau 7.7 rassemble les résultats ponctuels des cinq modèles sur le test de Diass et le tableau 7.8 les métriques probabilistes des deux architectures avancées.

Sur Diass, le TCN devance le TFT sur les trois métriques ponctuelles (R^2 0,877 vs 0,861 ; RMSE 1,71 vs 1,82 MW) et sur la couverture calibrée (79,8

7.2.2 Implications pour la SENELEC

Précision nécessaire

La SENELEC gère un réseau à marge de manœuvre limitée. Pour le site de Diass (27,3 MWc installés, 23,1 MW publiés), une marge d'erreur de **5 MW** est jugée acceptable pour le dispatch quotidien, soit une exigence de RMSE inférieure à 5 MW, ou 22 % de la capacité publiée. Cette marge définit la précision que les modèles doivent atteindre pour être opérationnels à 72 heures. Les deux architectures avancées la respectent largement, ce qui laisse une marge de sécurité confortable pour l'exploitant.

Intervalles pour le dispatch

Un intervalle P10–P90 est directement exploitable pour le dispatch. Sa borne haute dimensionne la réserve de sécurité à mobiliser, sa borne basse indique le plancher de production sur lequel la SENELEC peut compter pour ne pas démarrer de thermique inutilement. Entre les deux, la distribution des quantiles permet d'estimer la probabilité de franchir un seuil critique (10

7.2.3 Comparaison aux performances publiées sur le site de Diass

Avant d'évaluer la qualité prédictive des modèles (section 7.1.8), il convient de situer le **gisement mesuré et le rendement obtenu** face aux valeurs publiées pour cette même centrale. Quatre références ont été vérifiées à la source : deux travaux de performance énergétique [20, 22],

une étude de prévision par réseaux de neurones [6] et une référence de modélisation stochastique du rayonnement [19].

Le calcul suit la norme IEC 61724 sur la période d'exploitation réellement couverte par les données, avec pour puissance de référence le nominatif AC des onduleurs ($P_{\text{nom}} = 36 \times 680 =$ 24,48 MW). Le gisement de référence Y_{ref} est intégré sur l'irradiance globale horizontale, afin de rester comparable à la source publiée.

Table 7.9 : Comparaison du gisement et du rendement de Diass aux valeurs publiées. deep-aero-sn : 30/08/2025–31/08/2026 (367 jours, 8 800 h).

Grandeur	**deep-aero-sn**	**Ndiaye et al.**	**Écart**
Période	2025–2026	2022	–
Gisement Y_{ref} (h/j)	5,80	5,83	−0,5 %
Rendement final Y_{f} (h/j)	3,76	3,95	−4,8 %
Performance ratio (%)	64,8	64,65–75,82	dans la bande
Énergie annualisée (GWh/an)	33,6	~33,3	+0,9 %
Puissance de référence (MW)	24,48 (AC)	23,114 (MP)	+5,9 %

Le gisement est fidèlement reproduit, à un demi-pour-cent près de la valeur publiée, ce qui atteste la cohérence du site, de son instrumentation et du calcul d'irradiance avec la source. Le rendement final reste légèrement en retrait, mais le *performance ratio* obtenu tombe dans la plage publiée. Deux précautions de méthode s'imposent : le PR publié est un **PR de champ**, mesuré en fonctionnement continu, et non un PR final ; et le nôtre dépend de la convention retenue pour la puissance de référence, sachant qu'en reprenant la puissance publiée, le rendement et le PR restent également dans la plage attendue. **La conclusion reste donc robuste au choix de la puissance de référence.**

Un écart de capacité demeure non résolu : le matériel installé donne 85 248 × 320 W = 27,28 MWc en continu, contre 23,114 MP publiés, soit 15 % de moins. La puissance unitaire provient de la fiche technique du module Jinko JKM320PP-72-V et le nombre de modules est connu sans ambiguïté ; nous avons privilégié le matériel vérifiable et signalé l'écart plutôt que de l'ajuster artificiellement. Ce point demanderait une confirmation à partir des documents de réception de la centrale.

Deux remarques finales complètent ce contrôle : la géométrie retenue (inclinaison 15°, azimut 0°) correspond à la latitude du site, ce que corrobore la littérature sahélienne [22] ; et le rapport $g_{\text{poa}}/g_{\text{hi}} \simeq 0{,}88$, inférieur à 1, est physiquement attendu (à faible élévation, une part du flux diffus horizontal n'est pas interceptée par un plan incliné). Par ailleurs, les métriques de Diop et al. [6] (RMSE 0,003 kWh inférieure à sa MAE 0,0223 kWh, mathématiquement impossible) ne sont pas retenues comme référence, et Mbaye et al. [19] porte sur le rayonnement à 24 h, non sur la puissance. Le contrôle croisé confirme ainsi la cohérence du site : gisement et PR

concordent avec les valeurs publiées, et les écarts résiduels portent sur la capacité nominale, non sur la ressource.

7.3 Conclusion

L'étude de cas de Diass valide l'ensemble du pipeline, de l'exploration des données à l'évaluation probabiliste, sur un site réel aux caractéristiques représentatives. Le feature engineering produit le vecteur d'entrée du run courant (543 variables, 424 retenues en union) ; les architectures TCN et TFT, chacune adaptée à un type de variabilité, fournissent des prévisions fiables à 72 heures. Le TCN devance légèrement le TFT sur les métriques ponctuelles (R^2=0,877) et la couverture calibrée (79,8 %) ; le TFT conserve pour sa part une interprétabilité (VSN, attention) que le TCN n'offre pas nativement.

Une année d'entraînement suffit pour montrer que le pipeline tient sur Diass, pas pour garantir que les hyperparamètres retenus resteront stables d'une saison à l'autre. C'est la principale limite de ce travail : la stabilité devra être vérifiée sur plusieurs années avant un déploiement opérationnel. Une seconde limite, plus structurelle, tient au pas horaire : les passages nuageux sahéliens durent souvent moins d'une heure et sont lissés par le rééchantillonnage, ce qui plafonne mécaniquement la précision atteignable à 72 h. Un modèle dédié aux horizons courts (1–6 h, résolution 5–15 min) comblerait cette lacune, au prix d'une architecture distincte. Enfin, le coût mémoire du TFT, engendré par l'attention quadratique posée sur la fenêtre d'entrée, reste un frein pratique au déploiement embarqué, même si son interprétabilité en fait un outil précieux côté opérateur.

La **reproductibilité** combine trois dispositifs : un `run_id` unique par expérience, qui fixe hyperparamètres, graine et signature des features ; l'archivage des configurations dans des fichiers JSON ; et des données de Diass issues de sources publiques, réutilisables par d'autres chercheurs.

Ce travail ouvre également trois pistes : l'apprentissage par transfert vers un autre site solaire (le pipeline est déjà structuré par centrale), des modèles dédiés aux horizons de 1 à 6 heures à résolution fine, et l'apprentissage fédéré multi-sites sans partage des données brutes. La prochaine étape opérationnelle consiste à intégrer le pipeline au système de gestion du réseau de la SENELEC, en commençant par des phases pilotes sur Diass.

Bibliographie

[1] Taïb Ajzoul. Cours de l'énergie solaire photovoltaïque — partie I : Cellule, module et champ photovoltaïques ; partie II : Conception et dimensionnement des installations PV. Département de Physique, Faculté des Sciences de Tétouan, n.d.

[2] Jimmy Lei Ba, Jamie R Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv :1607.06450*, 2016.

[3] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.

[4] Shaojie Bai, J Zico Kolter, and Vladlen Koltun. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv :1803.01271*, 2018.

[5] Nogoye Diaw, Thi Thi Soe, A. Swathi, Prasun Kumar Das, and G. Giridhar. Estimation of solar potential in senegal using GIS application. *International Journal of Advanced Research in Education & Technology*, 4(1) :59–68, 2017.

[6] Sambalaye Diop, Papa Silly Traore, and Mamadou Lamine Ndiaye. Power and solar energy predictions based on neural networks and principal component analysis with meteorological parameters of two different cities : Case of Diass and Taıba Ndiaye. In *2022 IEEE International Conference on Electrical Sciences and Technologies in Maghreb (CISTEM)*, Tunis, Tunisia, 2022. doi : 10.1109/CISTEM55808.2022.10044065.

[7] M. C. Diouf, M. Faye, A. Thiam, A. Ndiaye, and V. Sambou. Analysis performance of large scale grid connected photovoltaic power plants in the tropical region. *International Journal of Engineering Sciences & Research Technology*, 10(1), 2021. doi : 10.29121/ijesrt.v10.i1.2021.5.

[8] Global Solar Atlas (Solargis / Banque mondiale). Cartes du gisement solaire (ghi, dni, dhi) au sénégal. https ://globalsolaratlas.info, n.d.

[9] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477) :359–378, 2007. doi : 10.1198/016214506000001437.

[10] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8) :1735–1780, 1997.

[11] Sergey Ioffe and Christian Szegedy. Batch normalization : accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 448–456, 2015.

[12] Diederik P Kingma and Jimmy Ba. Adam : A method for stochastic optimization. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.

[13] Roger Koenker. *Quantile Regression*. Cambridge University Press, Cambridge, 2005. doi : 10.1017/CBO9780511754098.

[14] Roger Koenker and Gilbert Bassett. Regression quantiles. *Econometrica*, 46(1) :33–50, 1978. doi : 10.2307/1913643.

[15] Yann LeCun, Bernhard Boser, John S Denker, Donnie Henderson, Richard E Howard, Wayne Hubbard, and Lawrence D Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1 :541–551, 1989.

[16] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553) : 436–444, 2015.

[17] Bryan Lim, Sercan O Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4) :1748–1764, 2021.

[18] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

[19] A. Mbaye, Mamadou Ndiaye, D. M. Ndione, M. Diaw, V. Traoré, A. Ndiaye, M. C. Sylla, M. C. Aidara, V. Diaw, A. Traoré, and P. Ndiaye. ARMA model for short-term forecasting of solar potential : application to a horizontal surface on Dakar site. *Materials and Devices*, 4(1), 2019. doi : 10.23647/ca.md20191103.

[20] Fatim Amadou Ndiaye, Mohamed Cherif Aidara, Diatta Sene, Oumar Drame, and Mamadou Lamine Ndiaye. Analysis of real performance and seasonal prediction of a 23 MWp grid-connected photovoltaic plant in Senegal : Case of Diass. *Energy for Sustainable Development*, 85 :101660, 2025. doi : 10.1016/j.esd.2025.101660.

[21] Yaniv Romano, Evan Patterson, and Emmanuel Candès. Conformalized quantile regression. *Advances in Neural Information Processing Systems*, 32, 2019.

[22] Adama Sarr and Diatta Sene. Enhancing solar energy production : A comprehensive model for fixed-panel systems applied to the solar power plant in Diass, Senegal. In *2025 IEEE 53rd Photovoltaic Specialists Conference (PVSC)*, Montreal, QC, Canada, 2025. doi : 10.1109/PVSC59419.2025.11132696.

[23] SENELEC. Centrale solaire de diass — première centrale photovoltaïque publique du sénégal. https ://www.senelec.sn, https ://www.kfw.de, n.d.

[24] SENELEC. Chiffres clés 2025, 2025. Site officiel, https ://www.senelec.sn.

[25] SENELEC. Production du réseau interconnecté — mai 2026, 2026. Site officiel, https ://www.senelec.sn.

[26] Glenn Shafer and Vladimir Vovk. A tutorial on conformal prediction. *Journal of Machine Learning Research*, 9 :371–421, 2008.

[27] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout : a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56) :1929–1958, 2014.

[28] Nihed Toumi and Iskandar Kouda. Prédiction de la production d'une centrale solaire photovoltaïque autonome — énergie solaire photovoltaïque et système photovoltaïque autonome, 2021. Projet de fin d'études de Licence, Département d'Électrotechnique, Université Badji Mokhtar — Annaba, dir. M. Adjabi, 2021.

[29] Aaron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, and Koray Kavukcuoglu. Wavenet : A generative model for raw audio. *arXiv preprint arXiv :1609.03499*, 2016.

[30] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[31] Vladimir Vovk, Alexander Gammerman, and Glenn Shafer. *Algorithmic Learning in a Random World*. Springer, 2005. doi : 10.1007/b106715.