



UNIVERSITÉ CHEIKH ANTA DIOP DE DAKAR

FACULTÉ DES SCIENCES ET TECHNIQUES

DÉPARTEMENT MATHÉMATIQUES ET INFORMATIQUE

Section Informatique

Mémoire de Licence en Informatique

Thème :

Prévision probabiliste de la production photovoltaïque par apprentissage profond : application à la centrale de Diass

Présenté par :

Baye Mor Gaye

Encadrant :

Dr Ndiouma Bame

Maîtres de stage :

Dr Saidou Abdoul Soumare

Dr Abdoulaye Ba

ANNÉE UNIVERSITAIRE 2025–2026

Table des matières

Résumé 3
Remerciements 4

Introduction générale **5**

I Potentiel solaire et technologie photovoltaïque 7

1 Cadre de la transition énergétique au Sénégal et présentation des sites **8**
1.1 Mix énergétique sénégalais 8
1.2 Analyse et constats sur la prévision 10
1.3 Défis de la production et potentiel photovoltaïque 10
1.4 Conclusion 13

2 Physique et technologie photovoltaïque **15**
2.1 Physique du rayonnement solaire 15
2.2 Principe physique de la conversion photovoltaïque 17
2.3 Analyse de la variabilité et de l'intermittence 19
2.4 Référentiel unifié des variables pour la centrale de Diass 19
2.5 Conclusion 21

II Architectures d'apprentissage profond 22

3 Fondations de l'apprentissage supervisé et régularisation **23**
3.1 Du modèle linéaire au perceptron multicouche 23
3.2 Fonctions d'activation 26
3.3 Fonctions de coût et métriques d'évaluation 27
3.4 Optimisation 30
3.5 Régularisation 31
3.6 Vanishing et exploding gradients 33

3.7 Généralisation et protocole d'évaluation 34
3.8 Conclusion 35

4 Modèles pour séries temporelles 36
4.1 Réseaux convolutifs (CNN) 36
4.2 Réseaux récurrents et architectures à portes (RNN, LSTM, GRU) 39
4.3 Mécanisme d'attention 42
4.4 Architecture Transformer 43
4.5 Conclusion 45

5 Architectures avancées appliquées 46
5.1 Solaire : Temporal Fusion Transformer (TFT) 46
5.2 Photovoltaïque : Temporal Convolutional Network (TCN) 50
5.3 Entraînement : encodage et évaluation 52
5.4 Conclusion 53

6 Stratégie MIMO et prévision probabiliste par quantiles 54
6.1 La stratégie MIMO de prévision multi-horizon 54
6.2 La prévision par quantiles : type de sortie probabiliste 55
6.3 L'approche d'incertitude retenue : perte hybride multi-tâche 56
6.4 Recalibrage de l'enveloppe : le CQR adopté 56
6.5 Scores stricts et calibration : juger une prévision par quantiles 57
6.6 Protocole d'évaluation sur le cas Diass 57
6.7 Conclusion 58

III Modélisation de la prévision photovoltaïque 59

7 Cas d'application à la centrale solaire de Diass 60
7.1 Objectifs et méthodologie 60
7.2 Présentation du site de Diass 61
7.3 Jeux de données 64
7.4 Mise en œuvre 72
7.5 Analyse des résultats et déductions 82
7.6 Conclusion et perspectives 85

Résumé

Ce mémoire porte sur la prévision, à 72 heures, de la production photovoltaïque de la centrale de Diass au Sénégal à l'aide de modèles d'apprentissage profond. L'étude s'appuie d'abord sur un ensemble de variables décrivant à la fois le fonctionnement de la centrale, les caractéristiques du site et les conditions climatiques propres au contexte sahélien. Les prévisions météorologiques issues des modèles de prévision numérique du temps (NWP) sont ensuite intégrées comme variables futures. Une sélection par union est utilisée afin de conserver les variables retenues par les différentes méthodes tout en respectant la séparation temporelle entre les données d'apprentissage et de test.

Deux architectures sont étudiées et comparées : le Temporal Convolutional Network (TCN) et le Temporal Fusion Transformer (TFT). Les deux modèles fournissent des prévisions à plusieurs horizons sous forme de quantiles, puis ces prévisions sont recalibrées à l'aide de la conformalized quantile regression (CQR). Sur les 1 049 fenêtres de test, le TCN obtient les meilleurs résultats, avec un RMSE de 1,707 MW et un coefficient de détermination R^2 de 0,877. Après recalibrage, son intervalle P10–P90 couvre 79,8 % des observations. Le TFT présente des performances légèrement inférieures, avec un RMSE de 1,818 MW, un R^2 de 0,861 et une couverture de 74,2 %. Ces résultats montrent qu'il est possible d'associer à une prévision de production à 72 heures une estimation de son incertitude, offrant ainsi à la SENELEC un outil d'aide à l'anticipation de la production photovoltaïque.

This thesis focuses on 72-hour-ahead forecasting of the photovoltaic power output of the Diass plant in Senegal using deep learning models. The study first defines a set of variables describing the plant operation, site characteristics, and climatic conditions specific to the Sahelian context. Weather forecasts from numerical weather prediction (NWP) models are then incorporated as future covariates. A union-based selection strategy is used to retain variables identified by the different selection methods while preserving the temporal separation between training and test data.

Two architectures are investigated and compared : the Temporal Convolutional Network (TCN) and the Temporal Fusion Transformer (TFT). Both models produce multi-horizon forecasts in the form of quantiles, which are subsequently recalibrated using conformalized quantile regression (CQR). On the 1,049 test windows, the TCN achieves the best overall performance, with an RMSE of 1.707 MW and an R^2 of 0.877. After recalibration, its P10–P90 interval covers 79.8% of the observations. The TFT performs slightly less well, with an RMSE of 1.818 MW, an R^2 of 0.861, and a coverage of 74.2%. These results show that a 72-hour photovoltaic power forecast can be accompanied by an explicit estimate of its uncertainty, providing SENELEC with an additional tool for anticipating photovoltaic production.

Remerciements

*Je tiens à remercier du fond du cœur ma mère, **Ndeye Ndapu Cissé**, mon père, **Sahide Gaye**, mes sœurs et mes frères, ainsi que ma tante **Fama Niang**, pour leur soutien et leurs encouragements tout au long de ce parcours.*

Mes remerciements vont également à mes amis et aux membres de ma famille qui m'ont accompagné et encouragé durant cette période.

*J'adresse ma profonde gratitude à mes professeurs du lycée, ainsi qu'à mes encadrants académique et de stage, le **Dr Ndiouma Bame**, le **Dr Saidou Abdoul Soumare** et le **Dr Abdoulaye Ba**, pour leur encadrement, leur disponibilité, leur écoute et la qualité de leur suivi.*

Enfin, je remercie mes camarades de stage au CFPP de Cap des Biches, avec qui j'ai partagé des moments de travail, d'apprentissage et d'échange qui ont contribué à rendre cette expérience particulièrement enrichissante.

Introduction générale

Contexte et motivation

Le secteur électrique sénégalais doit garantir l'accès à une électricité fiable tout en intégrant davantage de renouvelables au réseau interconnecté de la SENELEC. Dans le cadre du Partenariat pour une transition énergétique juste (JETP), signé le 22 juin 2023 avec la France, l'Allemagne, le Royaume-Uni, le Canada et l'Union européenne, le pays s'est engagé à porter la part des énergies renouvelables à 40 % de la capacité installée d'ici 2030 [18].

Les parcs solaires de Ten Merina, Senergy, Santhiou Mékhé, Diass, Kahone, Malicounda et Sakal, complétés par l'éolien de Taïba N'Diaye (chapitre 1), ont levé une partie du verrou infrastructurel ; la question se déplace désormais vers la prévision de la production. Le climat sahélien rend cette production intermittente : alternance de saisons sèches et humides, passages nuageux, harmattan de novembre à février, hivernage de juillet à septembre. Chaque erreur de prévision se traduit par des déséquilibres sur le réseau et par un appel aux réserves thermiques.

Ce travail construit un cadre d'apprentissage profond adapté au climat sénégalais, qui produit des prévisions photovoltaïques à 72 heures et en quantifie l'incertitude.

Problématique

La question posée est la suivante :

> *Comment modéliser par apprentissage profond et quantifier l'incertitude de la production photovoltaïque à 72 heures pour sécuriser le pilotage du réseau électrique au Sénégal ?*

Objectifs et contributions

Pour y répondre, ce mémoire s'organise autour de trois objectifs complémentaires.
Le premier consiste à construire un **référentiel unifié des variables** adapté à la centrale de Diass : il relie les grandeurs issues de la physique photovoltaïque aux spécificités météorologiques et climatiques du contexte sahélien, notamment l'harmattan, l'empoussièrement et l'hivernage. Ce référentiel est ensuite enrichi des covariables futures issues des modèles de prévision numérique du temps (NWP), avec une sélection par union conçue pour limiter les risques de fuite d'information.
Le deuxième objectif est de **concevoir et comparer deux architectures d'apprentissage profond pour la prévision de séries temporelles longues** : le Temporal Convolutional Network (TCN) et le Temporal Fusion Transformer (TFT). Les deux modèles opèrent en prévision multi-horizon à 72 heures et produisent des intervalles quantiles qui représentent l'incertitude ; ces sorties sont ensuite recalibrées par la conformalized quantile regression (CQR).
Le troisième objectif est **d'évaluer ces approches sur les données réelles de la centrale de Diass** et d'analyser la portée des résultats pour la prévision et la gestion de la production photovoltaïque par la SENELEC.
Ces trois objectifs forment une progression : **construire le référentiel de données**, puis **modéliser et quantifier l'incertitude**, enfin **évaluer les résultats et en dégager la portée opérationnelle**.

Plan du mémoire

Le mémoire s'organise en trois parties : du cadre physique à la modélisation, puis à l'évaluation expérimentale.

- **La Partie I — Potentiel solaire et technologie photovoltaïque** présente le contexte énergétique sénégalais et les principales centrales solaires. Elle introduit ensuite les principes physiques de la conversion photovoltaïque, les sources de variabilité de la production et le référentiel unifié des variables retenu pour la centrale de Diass.
- **La Partie II — Architectures d'apprentissage profond** établit le cadre méthodologique. Elle rappelle les fondements de l'apprentissage supervisé et de la régularisation, présente les principaux modèles utilisés pour les séries temporelles, puis détaille les architectures TCN et TFT. Elle se termine par la stratégie de prévision multi-horizon et l'approche probabiliste par quantiles, avec son recalibrage par CQR.
- **La Partie III — Modélisation de la prévision photovoltaïque** met en œuvre la méthodologie sur les données de la centrale de Diass. Elle présente le site et les jeux de données, décrit la mise en œuvre expérimentale, puis analyse les performances obtenues et leurs implications pour la prévision de la production photovoltaïque.

Première partie

POTENTIEL SOLAIRE ET TECHNOLOGIE PHOTOVOLTAÏQUE

Chapitre 1

Cadre de la transition énergétique au Sénégal et présentation des sites

Ce chapitre présente le cadre énergétique du cas d'étude : le mix électrique sénégalais, la montée en puissance du renouvelable et le gisement solaire national. La dernière section est consacrée au site de Diass, première centrale solaire publique du pays, dont les choix techniques conditionnent les modèles de prévision.

1.1 Mix énergétique sénégalais

La SENELEC gère toute la chaîne électrique, de la production à la distribution. Les chiffres clés publiés pour 2022–2025 donnent le contexte du cas d'étude.

Puissances installées par source.

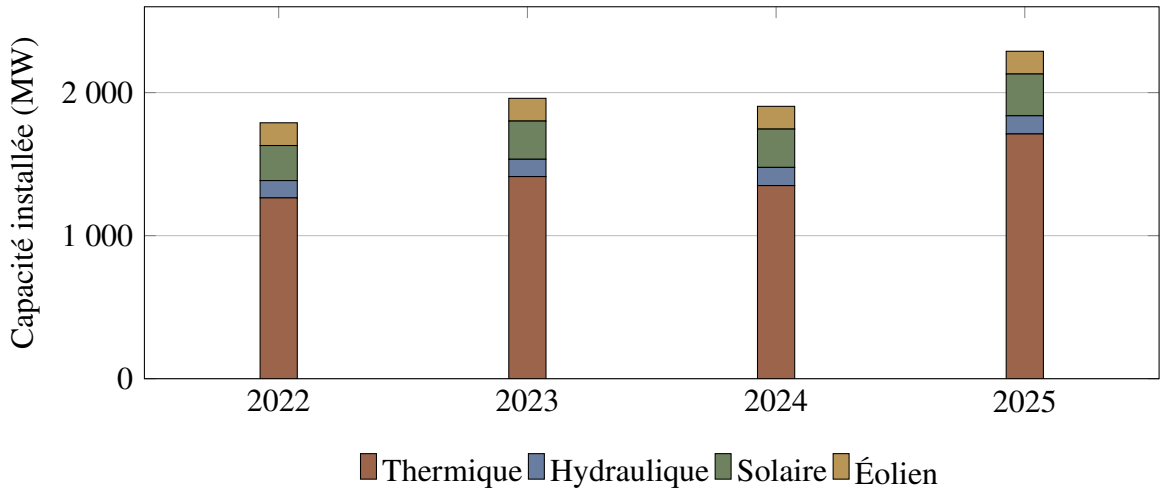


FIGURE 1.1 : Puissances installées par source, 2022–2025 [47].

Le thermique domine encore le mix. En 2025, il représente 1 711,14 MW en place, contre 1 264,30 MW en 2022. À lui seul, il a ajouté 447 MW au parc sur la période. La capacité totale atteint 2 289,52 MW, soit 74,7 % de parts thermiques. La trajectoire est en dents de scie : 1 789,00 MW en 2022, 1 960,14 MW en 2023, un repli à 1 903,81 MW en 2024, puis une reprise en 2025, comme le montre la figure 1.1.

Le solaire progresse de 245 MW en 2022 à 292,47 MW en 2025, soit +19,4 %. L'éolien ne bouge pas : le parc de Taïba Ndiaye compte 158,7 MW. L'hydraulique reste à 127 MW.

Production et achats.

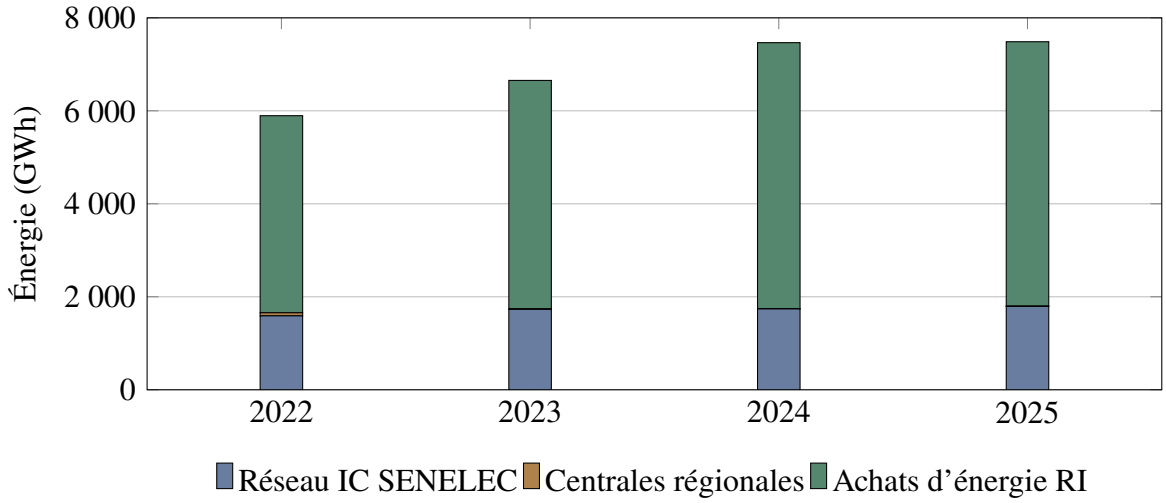


Figure 1.2 : Production et achats d'énergie, 2022–2025 [47].

La production brute totale, production propre plus achats, atteint 7 486,3 GWh en 2025. C'est 26,7 % de plus que les 5 908,3 GWh de 2022 [1] Le détail par année figure dans le tableau 1.1 et dans la figure 1.2.

	2022	2023	2024	2025
Production brute totale (GWh)	5 908,3	6 654,2	7 465,8	7 486,3
Ventes d'énergie (GWh)	4 862,6	5 404,5	6 063,5	6 218,1

Table 1.1 : Production brute totale et ventes d'énergie, 2022–2025 [47].

La croissance vient surtout des achats. Ils pèsent 5 687,1 GWh en 2025, contre 4 238,7 GWh en 2022. En parts, cela représente 76,0 % du total publié en 2025, contre 71,7 % en 2022. La production propre du réseau interconnecté n'a crû que de 12,8 %, passant de 1 589,5 à 1 792,4 GWh. Les centrales régionales sont devenues marginales. Elles livrent environ 7 GWh par an depuis 2023.

La SENELEC a vendu 6 218,13 GWh d'électricité à ses clients en 2025, contre 4 862,58 GWh en 2022, soit +27,9 %. Production brute et ventes ne se recouvrent pas : la production compte l'énergie brute, produite ou achetée, tandis que les ventes comptent l'énergie livrée aux clients, export compris. L'écart en 2025, environ 1 268 GWh, correspond pour l'essentiel aux pertes du réseau.

En mai 2026, la production globale progresse de 7,7 % sur le mois et de 8,6 % sur l'année. Toute la hausse vient des achats, en progression de 10,6 % et de 12,3 % respectivement, tandis que la production interne recule de 2,1 % sur le mois et de 3,5 % sur l'année [48].

1. La somme des composantes publiées pour 2022 donne 5 894,2 GWh, soit environ 14 GWh de moins que le total de 5 908,3 GWh publié par la SENELEC. La source ne détaille pas l'écart.

1.2 Analyse et constats sur la prévision

En 2023, la production brute d'électricité s'établit à 6 654,02 GWh. Les renouvelables comptent pour 19,48 % de ce volume. Elles pèsent davantage dans la capacité installée, où elles représentent 27,35 %, avec 13,62 % de solaire, 8,10 % d'éolien et 6,17 % d'hydraulique, tandis que le thermique occupe les 72,11 % restants [36]. [2]

Les renouvelables pèsent donc plus dans la capacité que dans la production. C'est l'effet de l'intermittence : les flux naturels ne sont pas continus. L'AIE rapporte pour 2022, 245 MW de solaire, soit 14 % de la capacité, et 159 MW d'éolien, soit 9 % [23].

Les achats fournissent les trois quarts de l'énergie acheminée. La SENELEC n'en pilote donc pas la plus grande partie. À cela s'ajoute un parc solaire de 292,47 MW en 2025, variable par nature. La prévision sert à ajuster l'appel au thermique et à amortir ces à-coups. Sans prévision solide, le dispatching mobilise des réserves thermiques en permanence.

Le réseau est synchronisé avec le Mali et la Guinée, via l'OMVS et l'OMVG. Les flux croisés lissent en partie les déséquilibres locaux. Le parc, lui, est très hétérogène. Les panneaux sont fixes à Ten Merina et à Diass, avec des modules Jinko et Renesola. À Kahone, les modules sont bifaciaux ; à Sakal, les structures sont motorisées par des suiveurs solaires. Aucun modèle unique ne peut convenir à la fois : chaque site exige un calage sur ses spécificités techniques.

1.3 Défis de la production et potentiel photovoltaïque

Le rayonnement solaire est converti directement en électricité par effet photovoltaïque dans des matériaux semi-conducteurs [2].

Le développement à l'échelle industrielle est récent. L'AIE date la mise en service des premières installations solaires sénégalaises de 2017 [23]. Depuis, la capacité raccordée a augmenté chaque année. De 245 MW en 2022, elle est passée à 267 MW en 2023, puis 268,07 MW en 2024 et 292,47 MW en 2025 [47]. Ces centrales sont pour la plupart des producteurs indépendants sous contrat d'achat, notamment Senergy, Ten Merina, Sakal, Kahone, Santhiou Mékhé et Malicounda. Diass reste la seule centrale publique.

Les ventes atteignent 6 218,13 GWh en 2025. Elles reposent davantage sur les achats, 5 687,1 GWh, que sur la production propre, 1 792,4 GWh. Les trois quarts de l'énergie acheminée sont donc achetés, non produits. La SENELEC ne maîtrise pas la majorité de ce qui transite sur son réseau. C'est là que la prévision devient décisive. Anticiper la ressource intermittente réduit le recours aux réserves thermiques et aux achats de complément.

2. Le site du ministère donne aussi 27,89 % pour les renouvelables en capacité, onglet « Transition énergétique ». Les deux chiffres sont affichés sans explication ; nous reprenons ici 27,35 %.

1.3.1 Défis de la production photovoltaïque

Une prévision fine se justifie par deux réalités de terrain. D'abord, la production réelle d'un champ photovoltaïque reste inférieure aux prévisions nominales. La température des cellules, les ombrages, l'empoussièrement, l'usure du matériel et d'autres pertes en sont la cause [2]. Ensuite, la ressource est volatile. Nuages et variations saisonnières imposent des fluctuations que les modèles du chapitre 4 cherchent à maîtriser.

1.3.2 Présentation des principales centrales solaires du Sénégal

A. Ten Merina (29,5 MWc, première centrale solaire du Sénégal)

Première centrale solaire raccordée au réseau, Ten Merina a été inaugurée en novembre 2017 à Mérina Dakhar, à 145 km au nord-est de Dakar, dans la région de Thiès. Le projet est porté par Meridiam et Eiffage, rejoints par le FONSIS à hauteur de 10 %. Le site affiche 29,5 MWc pour 92 000 panneaux polycristallins de 320 Wp, assortis de douze onduleurs de 2 MVA. Lié à la SENELEC par un contrat d'achat de 25 ans, le site produit environ 50 GWh chaque année [50].

D. Diass (23 MWc, centrale publique SENELEC, cas d'étude)

La centrale de Diass a été mise en service le 22 mai 2022 à Diass, dans le département de Mbour, à environ 40–50 km au sud-est de Dakar, près de l'aéroport Blaise Diagne. C'est la première centrale solaire publique du pays. Propriété de la SENELEC, qui l'exploite en direct, elle a été financée par un prêt de 18 milliards de FCFA de la KfW allemande [46]. Le site couvre 40 hectares. Il regroupe 85 248 modules polycristallins sur structures fixes, épaulés par 36 onduleurs et 16 transformateurs. La centrale injecte environ 34 GWh par an, avec un performance ratio publié qui varie entre 64,7 et 75,8 % [37]. Elle est implantée vers 14,65°N et 17,10°O.

Cette centrale fait l'objet du cas d'étude, illustré à la figure 1.3.



Figure 1.3 : Localisation de la centrale solaire de Diass.

E. Kahone (44 MWc, développée par un IPP)

Kahone a été mise en service en mai 2021 dans la région de Kaolack, à environ 200 km au sud-est de Dakar. La centrale est portée par le consortium Meridiam/ENGIE/FONSIS. Elle s'est distinguée par un tarif record en Afrique subsaharienne, à 3,80 centimes d'euro par kWh sur un PPA de 25 ans. Elle est répartie sur 36 hectares et reliée au réseau par une liaison souterraine de 300 m. Elle produit près de 80 GWh par an [13].

G. Sakal (20 MWc, première centrale à trackers)

Sakal a été mise en service en 2018 dans la région de Louga. Développée en entier par InnoVent pour 17 millions d'euros, cette centrale de 20 MWc se distingue par son installation. Ses 62 100 panneaux reposent sur 240 suiveurs solaires mono-axe, connectés à 354 onduleurs Delta, qui pivotent au rythme du soleil. Le suivi dynamique optimise la production, qui atteint environ 41 800 MWh par an [24].

1.3.3 Potentiel solaire du Sénégal

Le gisement solaire national s'évalue à partir des données de la base NASA-SSE, moyennées sur 22 ans et 65 points d'observation répartis dans les 14 régions, comme le montre la figure 1.4. Le rayonnement global horizontal y oscille entre 1 825 et 2 194 kWh/m²/an. La composante directe monte jusqu'à 2 325 kWh/m²/an ; la composante diffuse se situe entre 613 et 686 kWh/m²/an. On compte près de 3 000 heures d'ensoleillement par an [10].

Sur le plan géographique, la ressource varie peu d'une région à l'autre, avec un léger gradient d'ouest en est. Le littoral Dakar–Thiès affiche les valeurs maximales, proches de 2 190 kWh/m²/an. Saint-Louis suit avec environ 2 179, puis la région centrale autour de 2 160 et l'est avec environ 2 127 kWh/m²/an.

Cartes du gisement solaire (GHI, DNI, DHI).

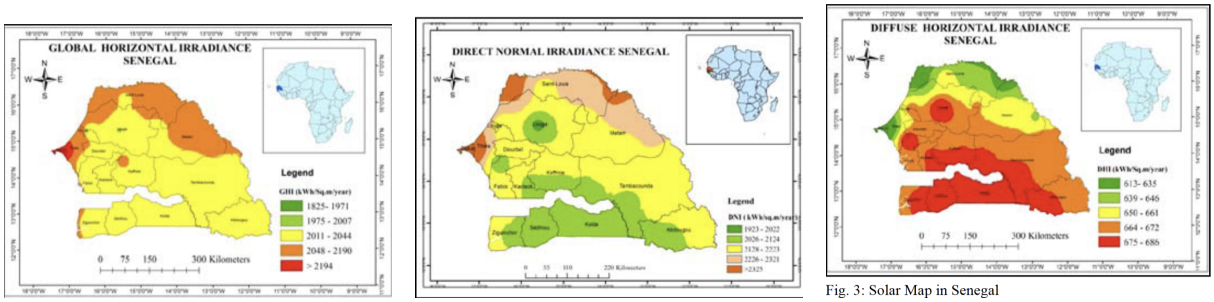


Fig. 3: Solar Map in Senegal

(a) Irradiance globale horizontale. **(b)** Irradiance directe normale. **(c)** Irradiance diffuse horizontale.

Figure 1.4 : Gisement solaire du Sénégal : GHI, DNI et DHI [16].

Les surfaces disponibles représentent environ 42 613 km², soit 21 % du pays. Si l'on exploitait seulement 3 % de ces espaces, avec une densité de 50 MW/km², des modules monocristallins à 15,64 % de rendement et un ratio de performance de 75 %, le potentiel installable atteindrait près de 63 920 MW, comme illustré à la figure 1.5. Le gisement se concentre à l'intérieur des

terres. Tambacounda arrive largement en tête avec environ 20 879 MW, suivie de Kédougou, autour de 12 359 MW, et de Saint-Louis, autour de 10 628 MW.

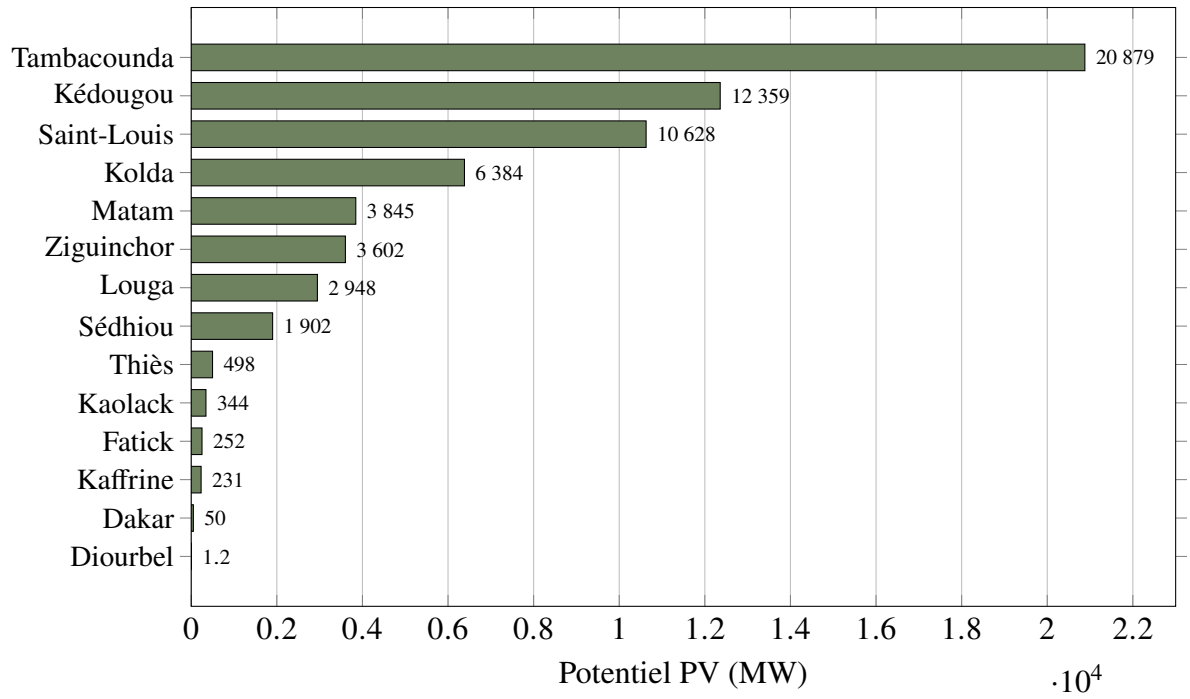


Figure 1.5 : Potentiel PV par région (adapté de Diaw et al. [10]).

Ce potentiel est toutefois très mal réparti. Trois régions concentrent à elles seules près de 31 682 MW, soit la moitié du total national. L'est et le nord détiennent la quasi-totalité des réserves. Des zones comme Dakar, avec environ 50 MW, ou Diourbel, avec environ 1 MW, disposent d'un foncier très restreint. Le gisement est loin des puits de consommation côtiers : c'est tout le décalage que le transport d'électricité devra combler [10].

1.4 Conclusion

Le thermique domine encore le mix. En 2025, il pèse 1 711,14 MW sur 2 289,52 MW installés. Le solaire atteint 292,47 MW, soit 12,8 % du total [47]. La production brute totale passe de 5 908,3 à 7 486,3 GWh, en hausse de 26,7 %. Cette croissance repose à 76,0 % sur les achats aux producteurs indépendants, contre 71,7 % en 2022. La production propre du réseau interconnecté n'augmente que de 12,8 %. L'exploitant dépend donc de plus en plus d'une production qu'il ne pilote pas.

En 2023, les renouvelables représentent 27,35 % de la capacité, pour seulement 19,48 % de la production brute [36]. La prévision sert à ajuster l'appel au thermique et les réserves. Les centrales de Ten Merina, Diass, Kahone et Sakal n'ont pas les mêmes configurations, certains modules fixes, d'autres bifaciaux ou sur suiveurs. Aucun modèle unique n'est transposable d'un site à l'autre. Le gisement national, estimé entre 1 825 et 2 194 kWh/m²/an, représente près de 63 920 MW de potentiel, mais il est concentré à l'est et au nord, loin des zones de consomma-

tion [10]. Diass, première centrale solaire publique du pays, fournit des données d'exploitation suffisantes pour servir de cas d'étude dans la suite du mémoire.

Chapitre 2

Physique et technologie photovoltaïque

Ce chapitre présente les bases physiques de la filière photovoltaïque et les mécanismes qui régissent la production d'électricité. Du rayonnement solaire au comportement de la cellule semi-conductrice, chaque maillon éclaire les grandeurs qu'un modèle de prévision doit capturer.

2.1 Physique du rayonnement solaire

2.1.1 Structure et fonctionnement du Soleil

Le Soleil est une étoile d'environ **1 400 000 km de diamètre** animée par des réactions de **fusion d'hydrogène en hélium**, qui libèrent des quantités colossales d'énergie [2]. Une infime fraction de ce flux parvient jusqu'à la Terre sous forme de rayonnement électromagnétique.

La puissance globale émise par un corps incandescent obéit à la **loi de Stefan–Boltzmann** :

$$P_{\text{dégagée}} = S \cdot \sigma \cdot T^4$$

où S représente la surface de l'astre, σ la constante de Stefan–Boltzmann, et T sa température de surface. La puissance rayonnée augmentant avec la quatrième puissance de la température, de légères variations thermiques influencent considérablement l'énergie émise par l'étoile.

En dehors de l'atmosphère, la référence est le spectre **AM0** (Air Mass 0), qui correspond à une irradiance extraterrestre d'environ **1 367 W/m²**. Au niveau du sol, la convention **AM1,5** modélise le rayonnement après la traversée d'une masse d'air standard et fixe la puissance incidente de référence à **1 000 W/m²**. La figure 2.1 compare ces deux spectres.

2.1.2 Géométrie solaire et orientation du panneau

L'énergie interceptée par un panneau dépend directement de la position apparente du Soleil, liée à la latitude du site, à la date et à l'heure. Les angles sont exprimés dans le repère local (x, y, z) (x vers l'est, y vers le nord, z vers le zénith), avec des azimuts comptés depuis le nord et positifs vers l'est (0° = nord, 90° = est, 180° = sud, 270° = ouest).

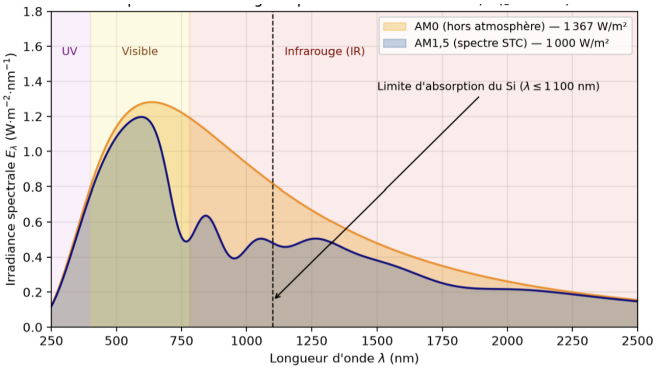


FIGURE 2.1 : Spectres solaires AM0 (extraterrestre) et AM1,5 (au sol).

La latitude φ du site ($\varphi = 14{,}65°$ N à Diass) et le jour de l'année N dictent la trajectoire solaire. La **déclinaison solaire** δ, qui traduit la latitude du point subsolaire, s'obtient par la formule de Cooper [2] :

$$\delta = 23{,}45° \cdot \sin\left(\frac{360°}{365}\,(N - 81)\right).$$

Elle varie de $-23{,}45°$ à $+23{,}45°$ au fil des saisons, un calcul repris directement par le pipeline.

Pour caler l'heure civile sur la course réelle du Soleil, l'**équation du temps** E_q (en minutes) corrige l'excentricité de l'orbite terrestre :

$$E_q = 9{,}87\,\sin(2b) - 7{,}53\,\cos b - 1{,}5\,\sin b, \qquad b = \frac{360°}{365}\,(N - 81).$$

Le temps solaire local t_{sl} s'en déduit, ce qui permet de calculer l'**angle horaire** $\omega = 15° \cdot (t_{sl} - 12)$, nul à midi solaire.

La hauteur solaire α_s et l'azimut A_s se déduisent de ces coordonnées. Pour un panneau caractérisé par son inclinaison β et son azimut A_p (par exemple $\beta = 15°$ et $A_p = 180°$ pour la structure fixe de Diass), l'**angle d'incidence** θ_i entre les rayons solaires et la normale du panneau $\mathbf{n}$ s'exprime via le produit scalaire $\cos\theta_i = \mathbf{n} \cdot \mathbf{s}$:

$$\cos\theta_i = \sin\beta\cos\alpha_s\cos(A_p - A_s) + \cos\beta\sin\alpha_s.$$

Cette relation détermine l'apport direct d'irradiance sur le module : $G_{\text{dir,POA}} = G_{\text{dir}}\cos\theta_i$. Les trackers solaires exploitent justement ce principe, en ajustant en continu l'orientation du panneau pour maintenir $\cos\theta_i \approx 1$. La figure 2.2 récapitule les angles mis en jeu.

2.1.3 Rayonnement solaire

Hors de l'atmosphère, l'irradiance extraterrestre AM0 atteint environ **1 367 W/m²** [51]. En traversant la couche atmosphérique, ce flux subit des pertes par diffusion et absorption, une atténuation quantifiée par la masse d'air AM [2].

Au sol, le rayonnement se décompose en trois apports (figure 2.3) : l'**irradiance directe** (G_{dir}), reçue en ligne droite depuis le disque solaire ; l'**irradiance diffuse** (G_{dif}), renvoyée dans

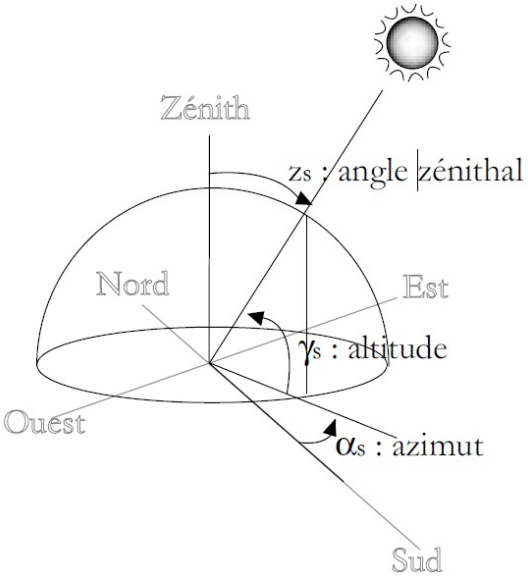


FIGURE 2.2 : Géométrie solaire et angles caractéristiques du panneau.

toutes les directions par un ciel nuageux ou chargé d'aérosols ; et le rayonnement **réfléchi** par le sol, ou albédo (ρ_g). L'irradiance globale reçue sur le plan incliné du panneau (G_{POA}) est la somme de ces contributions :

$$G_{POA} = G_{\text{dir,POA}} + G_{\text{dif,POA}} + G_{\text{ref,POA}}.$$

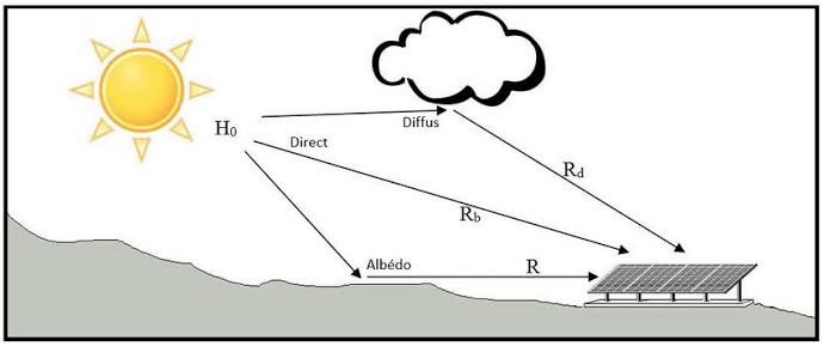


FIGURE 2.3 : Composantes du rayonnement solaire au sol.

2.2 Principe physique de la conversion photovoltaïque

2.2.1 Structure atomique du silicium et bandes d'énergie

Matériau de référence pour plus de 90 % des cellules mondiales, le **silicium (Si)** possède 4 électrons de valence qui forment un réseau cristallin stable par liaisons covalentes. À l'état pur, il se comporte toutefois comme un isolant à température ambiante.

La théorie des bandes distingue la **bande de valence** (presque pleine à basse température) de la **bande de conduction** (où les électrons libres assurent le transport du courant). Entre les deux

s'étend la **bande interdite** ($E_g \approx 1{,}12$ eV à 300 K pour le silicium) [2]. Lorsqu'un photon d'énergie supérieure à E_g frappe le matériau, il excite un électron de la bande de valence vers la bande de conduction. Le tableau 2.1 donne les valeurs de E_g pour les principaux semi-conducteurs photovoltaïques.

TABLE 2.1 : Valeurs de bande interdite E_g des principaux semi-conducteurs.

Matériau	E_g (eV)	Type
Silicium (Si)	1,12	Indirect
Germanium (Ge)	0,66	Indirect
Arséniure de gallium (GaAs)	1,42	Direct
Séléniure de cuivre–indium–gallium (CIGS)	1,0–1,7 (variable)	Direct
Tellure de cadmium (CdTe)	1,45	Direct
Pérovskites ($CH_3NH_3PbI_3$)	~1,55	Direct

2.2.2 Dopage et jonction PN

Pour rendre le silicium conducteur, on réalise un **dopage** en y introduisant des impuretés contrôlées. Le **type N (donneur)** s'obtient par l'ajout d'éléments à cinq électrons (comme le phosphore) pour libérer des charges négatives excédentaires, tandis que le **type P (accepteur)** fait appel à des éléments à trois électrons (comme le bore) pour générer des lacunes mobiles, appelées trous.

La mise en contact intime de ces deux matériaux engendre la **jonction PN**. Au voisinage de l'interface, la diffusion des porteurs de charge crée une zone d'appauvrissement exempte de charges libres, dite zone de déplétion, qui donne naissance à un **champ électrique interne**. Ce champ joue un rôle moteur : il agit à la fois comme barrière naturelle et comme séparateur de charges (figure 2.4).

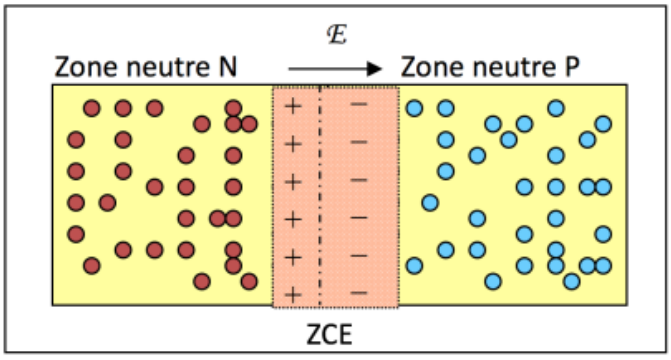


FIGURE 2.4 : Jonction PN à l'équilibre et champ électrique interne.

2.2.3 Effet photovoltaïque

La conversion de la lumière en électricité s'opère à travers un enchaînement de processus physiques continus. Tout d'abord, l'**absorption** des photons incidents par le semi-conducteur

fournit l'énergie nécessaire à la **génération** de paires électron–trou. Sous l'action du champ électrique de la jonction PN, ces porteurs sont aussitôt **séparés** spatialement, ce qui prévient leur recombinaison précoce [2]. Enfin, la **collecte** de ces charges par les contacts métalliques frontaux et arrière alimente le circuit extérieur sous forme de courant continu (figure 2.5).

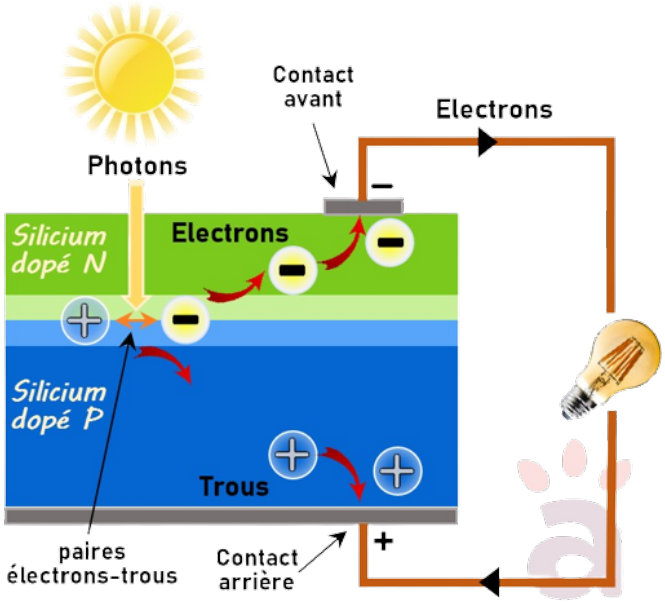


FIGURE 2.5 : Effet photovoltaïque dans une cellule au silicium.

2.3 Analyse de la variabilité et de l'intermittence

La production d'une centrale photovoltaïque mêle deux composantes. La première est déterministe : elle suit la mécanique céleste (cycle journalier et saisonnier) et se calcule par les éphémérides et la géométrie du panneau ($\cos\theta_i$). La seconde est stochastique : elle vient de la dynamique atmosphérique (passages nuageux rapides, épisodes d'harmattan, dépôt de poussières τ_a) et reste imprévisible par le calcul. C'est cette part que les modèles d'apprentissage profond doivent capturer (figure 2.6).

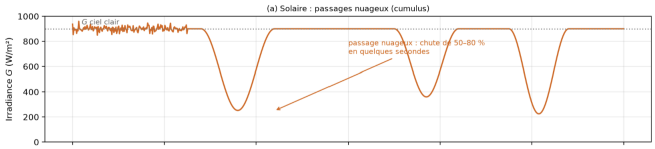


FIGURE 2.6 : Variabilité de la production liée aux passages nuageux.

2.4 Référentiel unifié des variables pour la centrale de Diass

Les grandeurs mesurées ou calculées sur le site de Diass (23 MWc) sont regroupées dans un dictionnaire structuré (tableau 2.2). Ce référentiel limite le surapprentissage et préserve l'expli-

cabilité des modèles, notamment par les mécanismes d'attention temporelle et de sélection de variables du TFT [32].

TABLE 2.2 : Référentiel unifié des variables, centrale de Diass.

Catégorie	**Variable / Feature**	**Définition et rôle physique**
Météorologie et Climat	$G, G_{dir}, G_{dif}, G_{POA}$	Irradiances globale, directe, diffuse et dans le plan du panneau (W/m²).
	$c_{cov}, G_{sw}, \alpha_c$	Fraction nuageuse (%), rayonnement descendant et albédo de ciel clair.
	T_{amb}, T_{mod}, T_d	Températures de l'air, de la surface du module et du point de rosée (°C).
	v_{2m}, P_{atm}, RH	Vitesse du vent (m/s), pression atmosphérique (hPa) et humidité relative (%).
	τ_a	Épaisseur optique des aérosols (suivi des poussières sahariennes et de l'harmattan).
Grandeurs Électriques	P_{dc}, V_{dc}, I_{dc}	Puissance brute (kW), tension (V) et courant (A) continus mesurés côté champ.
	$P_{ac}, V_{ac}, I_{ac}, E_{ac}$	Puissance active injectée (kW), tension, courant et énergie livrée au réseau (kWh).
	$\eta_{inv}, T_{inv}, V_{dc,inv}$	Rendement (%), température interne (°C) et tension d'entrée de l'onduleur.
	$\mathbb{1}_{clip}, \mathbb{1}_{op}, \mathbb{1}_{run}$	Indicateurs binaires d'écrêtage (*clipping*), de fonctionnement normal et de disponibilité.
Exploitation et Milieu	S_f, Soiling	Ratio d'encrassement (perte de transmission due au sable) et historique des lavages.
	$\theta_{AOI}, \theta_z, \gamma_{az}$	Angle d'incidence et coordonnées célestes (angle zénithal, azimut solaire).
	Degradation, LID, PID	Paramètres de vieillissement lent des cellules et de pertes par polarisation.
Temporalité et Features Dérivées	Encodage cyclique	Représentations trigonométriques (sin/cos) de l'heure, du jour et du mois.
	Lags et statistiques	Retards temporels ($t-1$h à $t-168$h) et moyennes glissantes sur 24 heures.

Suite page suivante

(suite)

Catégorie	**Variable / Feature**	**Définition et rôle physique**
	ξ_{cc} (Ciel clair)	Indice de nébulosité relatif défini par le rapport $\xi_{cc} = G_{obs}/G_{clear}$.
	Indicateurs saisonniers	Marqueurs binaires spécifiques au contexte sahélien (`is harmattan`, `is hivernage`).

2.5 Conclusion

Le rendement d'un module se joue à trois niveaux : le rayonnement reçu, la géométrie de l'installation et la qualité du matériau semi-conducteur. Au sol, le rayonnement utile combine une composante directe, une composante diffuse et une composante réfléchie par le sol, dont la somme définit l'irradiance dans le plan des modules. La hauteur et l'azimut du Soleil fixent l'angle d'incidence et donc la part de direct effectivement captée ; c'est ce même principe que les suiveurs solaires exploitent.

Côté matériau, la bande interdite du silicium (1,12 eV) et la jonction PN déterminent quels photons sont absorbés et comment les porteurs de charge sont séparés puis collectés aux contacts. L'analyse de la variabilité a ensuite distingué deux contributions : celle du mouvement des astres, calculable par éphémérides, et celle de l'atmosphère, faite de nuages, d'harmattan et de poussières. C'est cette seconde contribution, non prévisible par le calcul, que les modèles d'apprentissage profond doivent apprendre à partir du référentiel de variables présenté en fin de chapitre.

Deuxième partie

ARCHITECTURES D'APPRENTISSAGE PROFOND

Chapitre 3

Fondations de l'apprentissage supervisé et régularisation

Ce chapitre fixe les notions théoriques que mobilisent les chapitres suivants : le neurone artificiel et le perceptron multicouche, les fonctions d'activation et de coût, l'optimisation par descente de gradient et rétropropagation, les schémas de régularisation, enfin le protocole d'évaluation. Les développements historiques (perceptron de Rosenblatt, régression logistique, classification multi-classe) restent à l'écart : aucune des architectures évaluées aux chapitres 5 à 8 ne les réactive. L'ambition est de fournir un socle opérationnel, non un panorama ; la figure 3.1 en résume la boucle.

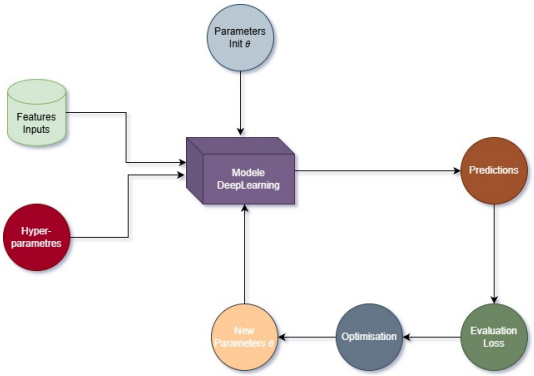


FIGURE 3.1 : Boucle d'apprentissage supervisé.

3.1 Du modèle linéaire au perceptron multicouche

3.1.1 Régression linéaire et conditionnement

Le point de départ est la régression linéaire. Pour un jeu de N observations (x_i, y_i), on cherche a et b minimisant la somme des carrés des écarts

$$f(a, b) = \sum_{i=1}^{N} (ax_i + b - y_i)^2.$$

Géométriquement, f définit un paraboloïde dont les lignes de niveau sont des ellipses d'autant plus allongées que le conditionnement $\kappa = \lambda_{\max}/\lambda_{\min}$ de la Hessienne est grand. Cette anisotropie, illustrée à la figure 3.2, annonce la difficulté qui traverse tout le chapitre : dans une vallée étroite, la descente de gradient oscille transversalement et progresse lentement le long de l'axe utile. C'est cette observation qui motivera les optimiseurs adaptatifs de la section 3.4.

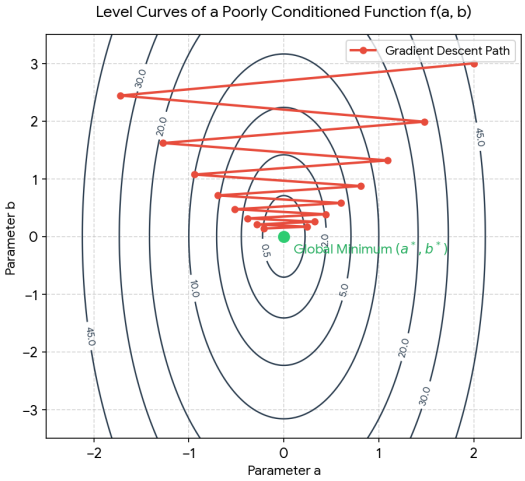


FIGURE 3.2 : Lignes de niveau de $f(a, b)$, étirées par le conditionnement.

La généralisation à p variables suit immédiatement. Avec $\hat{y} = Wx + b$, annuler le gradient conduit aux équations normales $W = (X^\top X)^{-1} X^\top Y$.

3.1.2 Neurone artificiel

Un neurone artificiel généralise cette forme en intercalant une transformation non linéaire φ entre la combinaison linéaire et la sortie :

$$z = Wx + b, \qquad \hat{y} = \varphi(z).$$

La frontière de décision reste l'hyperplan $z = 0$; φ n'en modifie que la transition. Le produit scalaire Wx s'interprète comme une mesure de similarité entre l'entrée et le motif encodé par les poids. Le biais s'absorbe en posant $x_0 = 1$, ce qui permet d'écrire $\hat{y} = \varphi(W'x')$ avec $x' \in \mathbb{R}^{p+1}$, convention systématiquement retenue en pratique (figure 3.3).

Pour un lot de n exemples, la forme matricielle s'écrit $\hat{Y} = \varphi(WX + b\mathbb{1}^\top)$: un seul produit matriciel réalise $q \times n$ produits scalaires en parallèle, ce qui explique pourquoi ces modèles tirent si bien parti des processeurs graphiques. Si φ est linéaire, la composition de plusieurs couches se réduit à un produit matriciel unique. La non-linéarité n'est donc pas un raffinement : c'est la condition d'existence du deep learning.

3.1.3 Perceptron multicouche

Le perceptron multicouche répond à une limite structurelle du modèle linéaire, que résume le problème du XOR : les classes $\{(0,0),(1,1)\}$ et $\{(0,1),(1,0)\}$ ne sont séparables par aucune

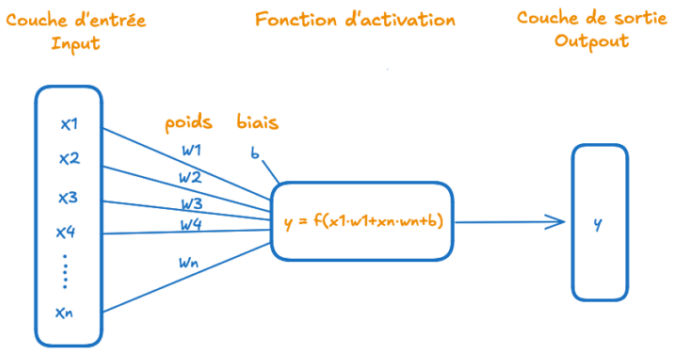


FIGURE 3.3 : Architecture d'un neurone artificiel.

droite, si bien qu'un neurone isolé ne peut les distinguer (figure 3.4). L'empilement de couches et l'intercalation de non-linéarités permettent de construire de telles frontières de décision non linéaires.

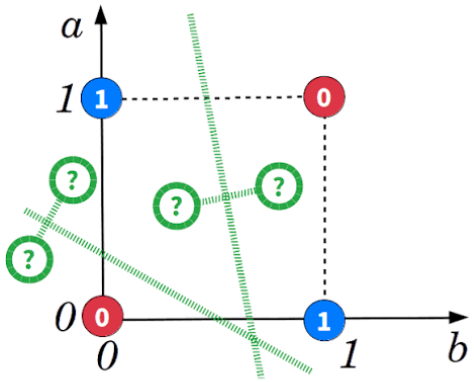


FIGURE 3.4 : Problème du XOR : classes non linéairement séparables.

L'empilement des couches produit le perceptron multicouche (MLP), dont la figure 3.5 donne l'architecture. Pour $\ell = 1, \ldots, L$:

$$\mathbf{h}^{(\ell)} = \varphi_\ell\left(W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right), \qquad \mathbf{h}^{(0)} = \mathbf{x}.$$

Le vecteur $\mathbf{h}^{(\ell)}$ constitue une représentation interne des données. L'intérêt de la profondeur est hiérarchique : les premières couches détectent des motifs simples, les suivantes les combinent en structures plus abstraites. À capacité égale, un réseau profond nécessite généralement moins de paramètres qu'un réseau large pour approximer une même fonction.

Un résultat classique justifie a posteriori cette architecture : toute fonction continue sur un compact peut être approximée à précision arbitraire par un réseau à une seule couche cachée suffisamment large [21]. Le théorème ne dit rien sur la généralisation ni sur la facilité d'apprentissage : la profondeur reste utile en pratique, non pour la capacité de représentation, mais pour l'efficacité statistique.

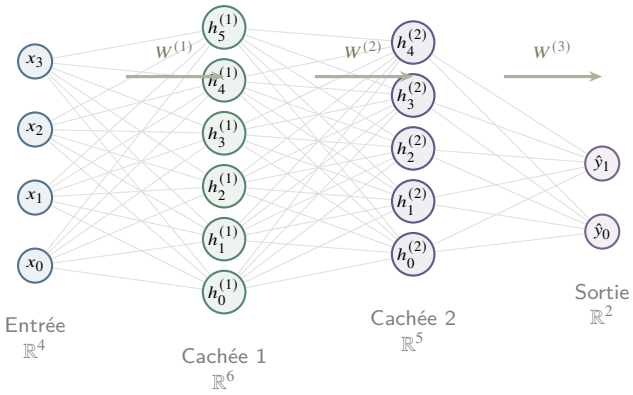


FIGURE 3.5 : Architecture d'un MLP à deux couches cachées.

3.1.4 Stabilité de l'entraînement : normalisation, dropout, initialisation

La stabilité de l'entraînement des réseaux profonds repose sur trois mécanismes complémentaires. La Batch Normalization [25] normalise les activations par mini-batch, ce qui lisse le paysage de la perte et autorise des taux d'apprentissage plus élevés. Le Dropout [49] désactive aléatoirement chaque neurone avec probabilité p, forçant le réseau à ne pas dépendre d'une unité particulière.

Les initialisations Xavier/Glorot ($\mathcal{N}(0, 2/(n_{\text{in}} + n_{\text{out}}))$) et He/Kaiming ($\mathcal{N}(0, 2/n_{\text{in}})$) préservent la variance des activations à travers les couches, He doublant la variance pour compenser la moitié des neurones annulés par ReLU. Ces trois leviers sont réexaminés à la section 3.5, sous l'angle de la régularisation.

3.2 Fonctions d'activation

Le choix de l'activation détermine la dynamique du gradient. Sigmoïde et tanh, historiquement dominantes, souffrent d'un gradient maximal borné (0,25 et 1,0 respectivement). Dans un réseau de L couches, le gradient est multiplié par un produit de L facteurs inférieurs à 1 : c'est le *vanishing gradient*, analysé à la section 3.6.

ReLU [31] lève cette limitation en adoptant un gradient constant de 1 pour $z > 0$:

$$\text{ReLU}(z) = \max(0, z), \qquad \text{ReLU}'(z) = \mathbb{1}_{z>0}.$$

Trois propriétés expliquent son succès : gradient non atténué dans la région active, coût de calcul négligeable, sparsité naturelle (environ la moitié des neurones s'annulent). Sa faiblesse, le *dying ReLU*, apparaît lorsqu'un neurone reste définitivement dans la zone négative. Les variantes LeakyReLU, ELU, GELU et Swish atténuent ce problème. GELU et Swish sont aujourd'hui standard dans les Transformers, et GELU équipe le TFT du chapitre 5. Le tableau 3.1 récapitule les activations usuelles.

Activation	**Formule**	**Sortie**	**∇ max**	**Usage**
Sigmoïde	$\frac{1}{1+e^{-z}}$	$(0, 1)$	0,25	Portes LSTM
Tanh	$\frac{e^{z}-e^{-z}}{e^{z}+e^{-z}}$	$(-1, 1)$	1,0	LSTM
ReLU	$\max(0, z)$	$[0, \infty)$	1,0	CNN, MLP
GELU	$z\,\Phi(z)$	$\mathbb{R}$	1,0	Transformers
Swish	$z\,\sigma(z)$	$\mathbb{R}$	1,0	Transformers
Softmax	$\frac{e^{z_k}}{\sum_j e^{z_j}}$	$(0, 1)^q$	variable	Sortie multi-classe
Identité	z	$\mathbb{R}$	1,0	Régression

Table 3.1 : Récapitulatif des fonctions d'activation.

La couche de sortie suit la même logique : identité pour une régression scalaire, sigmoïde pour une probabilité binaire, softmax pour une distribution sur q classes :

$$\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_{j=1}^{q} e^{z_j}}.$$

En pratique, on calcule $\text{softmax}(z - \max(z))$ pour éviter les débordements numériques.

3.3 Fonctions de coût et métriques d'évaluation

Entraîner un réseau revient à minimiser une fonction de coût qui traduit l'écart entre prédiction et vérité en un scalaire *différentiable* : c'est elle, et non la métrique, qui pilote la descente de gradient. Les métriques d'évaluation, mesurées sur un jeu de test indépendant, jugent la qualité des prévisions ; libres de toute contrainte de dérivabilité, elles expriment l'écart en des termes interprétables pour l'exploitant. Le pipeline rapporte deux familles de métriques : les *déterministes*, pour la prévision ponctuelle (souvent la médiane prédite), et les *probabilistes*, pour les intervalles de confiance.

Les pertes effectivement optimisées sont peu nombreuses. En prévision ponctuelle, il s'agit de l'erreur quadratique moyenne $\text{MSE}(\hat{y}, y) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$, dérivable et sensible aux grands écarts. En prévision probabiliste, il s'agit de la perte pinball, qui évalue un quantile q :

$$\text{QL}(y, \hat{y}, q) = q\max(y - \hat{y}, 0) + (1 - q)\max(\hat{y} - y, 0),$$

et se réduit à l'erreur absolue pour $q = 0{,}5$. Le pipeline combine ces deux objectifs par la perte hybride donnée en fin de section.

Dans les formules ci-dessous, les moyennes sont notées $\bar{y} = \frac{1}{n}\sum_i y_i$ pour les observations et $\bar{\hat{y}} = \frac{1}{n}\sum_i \hat{y}_i$ pour les prévisions.

Erreur absolue moyenne (MAE). La **MAE** vaut

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\hat{y}_i - y_i| \,.$$

Elle exprime l'erreur moyenne dans l'unité de la cible : une MAE de 0,5 MW signifie que la prévision s'en écarte de 0,5 MW en moyenne. Ne pénalisant pas davantage les grandes erreurs, elle reste robuste aux extrêmes mais masque une défaillance concentrée sur quelques points.

Racine de l'erreur quadratique moyenne. La **RMSE** vaut

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}.$$

Le carré donne un poids accru aux grandes erreurs, car un écart de 3 MW contribue neuf fois plus qu'un écart de 1 MW ; d'où sa sensibilité aux pics mal prévus (passages nuageux brusques, couverture surestimée) et son statut de métrique de référence pour les applications réseau, où les écarts extrêmes coûtent cher.

Erreur absolue moyenne en pourcentage (MAPE). La **MAPE** s'écrit

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n} \left|\frac{\hat{y}_i - y_i}{y_i}\right| \ \%.$$

Elle reste toutefois *indéfinie* dès qu'une observation est nulle, cas permanent en photovoltaïque (nuit, panne) : la division par une valeur proche de zéro produirait des erreurs astronomiques et non informatives. Le pipeline ne calcule donc la MAPE que sur les points dépassant un seuil relatif $\varepsilon = \max\bigl(10^{-6},\ 0{,}05 \cdot \text{médiane}(|y|)\bigr)$; si aucun ne passe le seuil (séquence entièrement nocturne), il bascule sur la **sMAPE**, bornée par 200 % :

$$\mathrm{sMAPE} = \frac{200}{n}\sum_{i=1}^{n} \frac{|\hat{y}_i - y_i|}{|y_i| + |\hat{y}_i|} \ \%.$$

Coefficient de détermination. Le R^2 vaut

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}.$$

Il mesure la part de variance expliquée relativement au modèle constant $\bar{y}$. Un R^2 de 0,877 (TCN sur Diass) signifie que le modèle réduit de 87,7 % l'erreur quadratique du prédicteur naïf. Contrairement à une idée répandue, il peut devenir négatif quand la prévision est pire que la moyenne, comme l'illustre la persistance sur les séries très variables ; ce comportement constitue en soi un signal diagnostique.

Erreur quadratique moyenne normalisée (NRMSE). La **NRMSE** (commande `nrmse`) rapporte la RMSE à l'amplitude de la série observée :

$$\mathrm{NRMSE} = \frac{\mathrm{RMSE}}{\max(y) - \min(y) + 10^{-8}},$$

le terme 10^{-8} écartant la division par zéro. En rapportant l'erreur à l'étendue des valeurs, cette normalisation autorise la comparaison entre sites de puissances ou horizons différents, là où la RMSE brute dépend de l'échelle de la centrale ; c'est la métrique employée au chapitre 6 pour comparer les architectures.

Couverture. La **couverture** est la proportion d'observations tombant dans l'intervalle :

$$\mathrm{Cov} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\left[y_i \in [\hat{y}_i^{\mathrm{bas}}, \hat{y}_i^{\mathrm{haut}}]\right].$$

Pour des quantiles $q = 0{,}1$ et $q = 0{,}9$, la couverture attendue vaut 80 % : plus le modèle s'en approche, plus le niveau de confiance annoncé est honnête. Sur Diass, le TCN atteint 79,8 % contre 74,2 % pour le TFT (chapitre 7).

Largeur d'intervalle. La **largeur moyenne** moyenne la largeur de l'intervalle :

$$\mathrm{Width} = \frac{1}{n}\sum_{i=1}^{n}\left(\hat{y}_i^{\mathrm{haut}} - \hat{y}_i^{\mathrm{bas}}\right).$$

À couverture égale, un intervalle plus étroit est préférable : il traduit une incertitude mieux maîtrisée, donc des prévisions plus utiles.

Score de Winkler. Le **score de Winkler** (commande `winkler 80`, seuil $\alpha = 0{,}2$) pénalise à la fois la largeur de l'intervalle et les écarts hors bornes :

$$\mathrm{Winkler} = \frac{1}{n}\sum_{i=1}^{n}\left[\mathrm{Width}_i + \frac{2}{\alpha}\Delta_i\right],$$

où Δ_i est nul si y_i appartient à l'intervalle, et vaut sinon la distance de y_i à la borne la plus proche. À la différence de la couverture seule, ce score pénalise à la fois les intervalles trop larges et les sorties de bornes : il offre un compromis unique entre finesse et honnêteté.

Perte hybride. Le pipeline combine les deux objectifs par une pondération w_{mse} :

$$\mathcal{L} = w_{\mathrm{mse}} \cdot \mathrm{MSE}(\hat{y}_{0,5}, y) + (1 - w_{\mathrm{mse}}) \cdot \overline{\mathrm{Pinball}}(\hat{y}_q, y), \quad q \in \{0{,}1, 0{,}5, 0{,}9\}.$$

Cette formulation, centrale pour le chapitre 6, n'est rappelée ici que pour mémoire : elle est analysée dans son contexte applicatif.

3.4 Optimisation

3.4.1 Descente de gradient

L'algorithme de base déplace les paramètres dans la direction opposée au gradient :

$$\theta \leftarrow \theta - \eta \, \nabla_\theta \mathcal{L}(\theta).$$

Selon la taille du lot utilisée à chaque mise à jour, on distingue trois régimes : le batch complet (gradient exact, coût prohibitif), le SGD pur (un exemple par mise à jour, forte variance) et le mini-batch, standard en pratique, dont le bruit agit comme une régularisation implicite en favorisant les minima plats. Le taux d'apprentissage η est l'hyperparamètre le plus critique ; les schedules usuels vont du step decay au cosine annealing, jusqu'au warmup suivi d'un decay, standard pour les Transformers et utilisé par le TFT.

Sur une fonction quadratique, la convergence est garantie si $\eta < 2/\lambda_{\max}$, avec un nombre d'itérations en $O(\kappa \log(1/\varepsilon))$. En grande dimension non convexe, les mauvais minima locaux sont rares ; les difficultés réelles sont les points-selles et les plateaux, que le bruit du mini-batch aide à traverser.

3.4.2 Rétropropagation

La rétropropagation [29] calcule $\nabla_\theta \mathcal{L}$ en appliquant la règle de la chaîne de la sortie vers l'entrée, en $O(D)$ opérations, soit la même complexité que la passe avant. En notant $\delta^{(\ell)} = \partial \mathcal{L} / \partial \mathbf{z}^{(\ell)}$, la récurrence s'écrit

$$\delta^{(\ell)} = \left(W^{(\ell+1)\top} \delta^{(\ell+1)} \right) \odot \varphi'(\mathbf{z}^{(\ell)}), \qquad \frac{\partial \mathcal{L}}{\partial W^{(\ell)}} = \delta^{(\ell)} \mathbf{h}^{(\ell-1)\top}.$$

Le gradient d'un poids est donc le produit externe du signal d'erreur qui remonte et de l'activation qui descend : plus l'activation est grande, plus le poids est ajusté. Cette forme est exactement celle du gradient sigmoïde+BCE ; elle explique aussi pourquoi les activations à gradient borné (sigmoïde, tanh) provoquent le vanishing gradient analysé plus loin.

Les bibliothèques d'apprentissage profond calculent ces gradients automatiquement : la rétropropagation remplit les accumulateurs de gradient, qu'il faut remettre à zéro avant chaque itération.

3.4.3 Optimiseurs adaptatifs

Momentum accumule une inertie, $v_t = \beta v_{t-1} + \nabla_\theta \mathcal{L}$, qui amortit les oscillations dans les directions de forte courbure. Adagrad divise le pas par la racine de la somme cumulée des gra-

dients au carré, mais son taux décroît indéfiniment. RMSProp corrige ce défaut par une moyenne mobile. Adam [26] combine les deux idées avec une correction de biais :

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\nabla_\theta \mathcal{L}, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2)(\nabla_\theta \mathcal{L})^2,$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon}\hat{m}_t, \qquad \hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}.$$

Valeurs par défaut : $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$. AdamW [34] découple le weight decay de l'adaptation,

$$\theta_{t+1} = (1-\eta\lambda)\theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon}\hat{m}_t,$$

ce qui évite que la pénalisation L_2 soit écrasée par la normalisation adaptative. C'est l'optimiseur retenu pour le TFT, comme indiqué au chapitre 5. Le tableau 3.2 regroupe ces recommandations par architecture.

Architecture	**Optimiseur**	**Hyperparamètres**
CNN + batch norm	Adam	$\eta = 10^{-3}$
Transformer	AdamW + warmup	$\lambda = 0.01$, warmup 4000 pas
Généralisation critique	SGD + momentum	$\eta = 0.01$, schedule cosinus
Prototype rapide	Adam	Valeurs par défaut

Table 3.2 : Recommandations d'optimiseurs.

3.5 Régularisation

3.5.1 Compromis biais-variance

L'erreur totale d'un modèle se décompose en biais^2, variance et bruit irréductible. Un biais élevé correspond au sous-apprentissage, une variance élevée au surapprentissage (figure 3.6). La régularisation augmente légèrement le biais mais réduit significativement la variance, déplaçant l'optimum vers une complexité plus faible.

3.5.2 Pénalités L_1, L_2 et Elastic Net

La pénalité L_2,

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \frac{\lambda}{2}\sum_{\ell} \|W^{(\ell)}\|_F^2,$$

modifie le gradient en $\partial\mathcal{L}/\partial W + \lambda W$, ce qui revient à multiplier les poids par $(1-\eta\lambda)$ à chaque pas, d'où le nom *weight decay*. La pénalité L_1,

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \lambda\sum_{\ell} \|W^{(\ell)}\|_1,$$

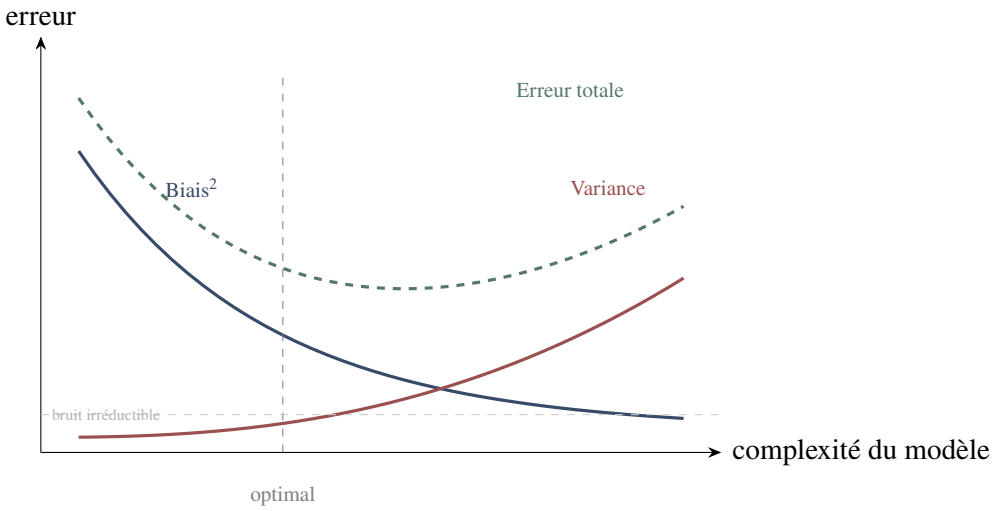


FIGURE 3.6 : Compromis biais-variance.

favorise la parcimonie : géométriquement, le losange L_1 a ses sommets sur les axes, et la perte atteint typiquement sa première intersection en un point où certains poids sont exactement nuls (figure 3.7). Elastic Net combine les deux pour obtenir à la fois parcimonie et stabilité.

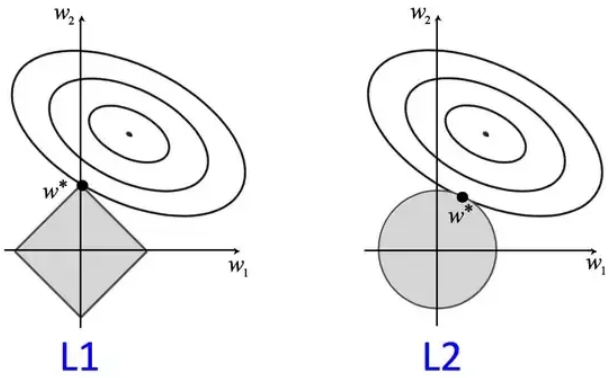


FIGURE 3.7 : Géométrie des pénalités L_1 et L_2.

3.5.3 Dropout

Le dropout [49] désactive aléatoirement chaque neurone avec probabilité p pendant l'entraînement, puis rescale les activations restantes par $1/(1-p)$ pour conserver la magnitude moyenne :

$$\tilde{h}_j = \frac{m_j}{1-p} h_j, \qquad m_j \sim \text{Bernoulli}(1-p).$$

À l'inférence, tous les neurones sont actifs. L'interprétation bayésienne [15] y voit une approximation de l'inférence sur l'ensemble des sous-réseaux. En pratique, $p = 0{,}5$ sur les couches denses, $p = 0{,}1$–$0{,}2$ sur la couche d'entrée, et aucun dropout en sortie.

3.5.4 Normalisation

Quatre variantes se distinguent par l'axe de normalisation. La Batch Normalization normalise par feature sur le mini-batch ; elle dépend donc de la taille de lot et se comporte différemment à l'entraînement et à l'inférence. La Layer Normalization,

$$\mu = \frac{1}{H}\sum_{k=1}^{H} h_k, \qquad \sigma^2 = \frac{1}{H}\sum_{k=1}^{H}(h_k-\mu)^2, \qquad \tilde{h}_k = \gamma_k \frac{h_k-\mu}{\sqrt{\sigma^2+\epsilon}} + \beta_k,$$

normalise par échantillon sur les features, ce qui la rend indépendante du batch, propriété essentielle pour les Transformers qui traitent des séquences de longueur variable. C'est la normalisation utilisée par le TFT et le TCN (chapitre 5). L'Instance Normalization opère par canal et par échantillon, la Group Normalization par groupes de canaux, indépendamment du batch.

Le débat sur le mécanisme d'action de la BN a été tranché par [43] : elle agit principalement en lissant le paysage de la perte, plutôt qu'en réduisant l'internal covariate shift.

3.6 Vanishing et exploding gradients

La rétropropagation multiplie les gradients couche par couche. Si chaque facteur est inférieur à 1 en magnitude, comme pour une sigmoïde dont le gradient maximal vaut 0,25, le gradient décroît exponentiellement avec la profondeur : après dix couches, il est multiplié par $0{,}25^{10} \approx 10^{-6}$, et les couches proches de l'entrée cessent d'apprendre. Le phénomène inverse (facteurs > 1) fait exploser la perte, qui devient non finie.

Quatre leviers corrigent le vanishing. L'activation ReLU (gradient $\in \{0, 1\}$) ne réduit pas le gradient dans sa zone active. Les initialisations de He [19] et Xavier ajustent la variance des poids à la dimension des couches, écartant l'explosion comme l'annulation des activations. Les connexions résiduelles,

$$\mathbf{h}^{(\ell)} = \mathbf{h}^{(\ell-1)} + \mathcal{F}(\mathbf{h}^{(\ell-1)}), \qquad \frac{\partial \mathbf{h}^{(\ell)}}{\partial \mathbf{h}^{(\ell-1)}} = I + \frac{\partial \mathcal{F}}{\partial \mathbf{h}^{(\ell-1)}},$$

garantissent un terme identité dans la jacobienne, ce qui empêche le gradient de s'annuler ; c'est ce qui a permis d'entraîner des réseaux à plusieurs centaines de couches (ResNet), et l'on retrouve ce mécanisme dans les blocs résiduels du TCN (chapitre 5). Les LSTM, enfin, résolvent le problème dans les séquences grâce à un canal de mémoire à flux additif $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$, plutôt que multiplicatif.

Pour l'explosion, la parade est le gradient clipping [38] : si $\|g\| > \tau$, on remplace g par $\tau g/\|g\|$, avec $\tau = 1$ ou 5. La technique est systématique pour les RNN et les Transformers ; elle est appliquée au TFT du chapitre 5. Le tableau 3.3 récapitule ces remèdes par architecture.

Architecture	Remèdes
MLP profond	ReLU + He init + skip connections
CNN profond	ResNet + BatchNorm
RNN	LSTM/GRU + gradient clipping
Transformer	LayerNorm + gradient clipping

TABLE 3.3 : Stratégies anti-vanishing par architecture.

3.7 Généralisation et protocole d'évaluation

3.7.1 Découpage des données

Le découpage standard sépare entraînement (60–80 %, ajustement des poids), validation (10–20 %, hyperparamètres et early stopping) et test (10–20 %, évaluation finale unique). Pour les séries temporelles, l'ordre chronologique est préservé : on ne mélange pas les échantillons, et la normalisation est ajustée sur l'entraînement seul puis gelée. La validation croisée classique cède la place au walk-forward : chaque pli entraîne sur tout le passé disponible et teste sur la fenêtre suivante, ce qui garantit qu'aucune donnée future n'est utilisée (figure 3.8).

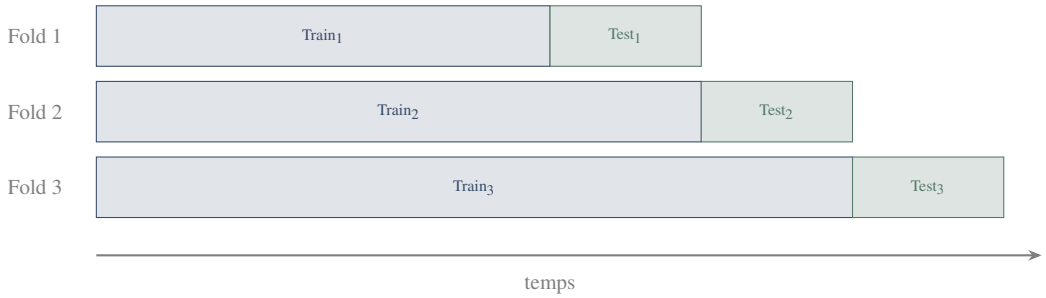


FIGURE 3.8 : Validation croisée walk-forward pour séries temporelles.

3.7.2 Fuite de données

La fuite de données désigne toute contamination de l'évaluation par une information indisponible au moment de la prévision. Elle se rencontre le plus souvent sous l'une de trois formes : ajustement de la normalisation sur l'ensemble complet, sélection de features ou d'hyperparamètres guidée par le test, usage de features construites avec le futur.

Cette dernière forme est la plus insidieuse, car elle se dissimule aisément dans une longue liste de colonnes. Les garde-fous du pipeline sont détaillés au chapitre 7, où ils s'appliquent au cas de Diass : ajustement exclusif du scaler sur l'entraînement, sélection confinée à l'entraînement et à la validation, ingénierie causale excluant automatiquement les dérivées quasi linéaires de la cible.

3.7.3 Optimisation des hyperparamètres

L'optimisation des hyperparamètres se heurte à quatre difficultés : structure nichée (chaque évaluation exige un entraînement complet), coût en heures-GPU, espace mixte continu/entier/catégoriel à dépendances conditionnelles, et objectif non lisse. La recherche sur grille devient ingérable au-delà de quatre paramètres ; la recherche aléatoire [8] reste une référence lorsque peu de dimensions comptent réellement. Les méthodes modernes se répartissent en quatre familles (optimisation bayésienne, estimateur de Parzen arborescent, multi-fidélité, populationnelles), dont [14] donne une synthèse.

Ce travail retient Optuna, avec un échantillonneur TPE et un élagage médian. La perte minimisée est la perte hybride MSE+pinball (section 3.3), et les essais sont journalisés dans MLflow pour assurer la traçabilité des configurations. Le détail de la recherche, les valeurs retenues pour Diass et les résultats comparés figurent au chapitre 7.

3.7.4 Arrêt anticipé

On surveille la perte de validation ; quand elle cesse de décroître, on arrête l'entraînement, typiquement après une patience de 5 à 20 époques, en restaurant les poids du meilleur point. Ce mécanisme est utilisé pour tous les modèles du chapitre 7, avec une patience de 25 époques pour le TCN et le TFT.

3.8 Conclusion

Parti de la régression linéaire, ce chapitre a montré pourquoi un empilement de couches non linéaires peut représenter des relations qu'un modèle linéaire laisse de côté, le problème du XOR en étant l'illustration la plus simple. Les fonctions d'activation conditionnent la propagation du gradient ; les fonctions de coût traduisent l'objectif visé (erreur quadratique pour la valeur centrale, pinball pour les quantiles) ; les métriques (MAE, RMSE, R^2, NRMSE, couverture, largeur, score de Winkler) servent à comparer les modèles sur un jeu de test indépendant. L'optimisation va de la descente de gradient aux optimiseurs adaptatifs, avec la rétropropagation pour le calcul des gradients et Adam ou AdamW pour l'entraînement.

La régularisation (pénalités L_1 et L_2, dropout, normalisation) contient la variance sans amputer la capacité du modèle. L'analyse du *vanishing* et de l'*exploding gradient* justifie les choix techniques qui reviendront dans les chapitres suivants : ReLU, initialisations de He et Xavier, connexions résiduelles, LSTM et gradient clipping.

Le protocole d'évaluation fixe les conditions de comparaison : découpage chronologique, validation *walk-forward*, prévention des fuites de données, optimisation des hyperparamètres par Optuna, journalisation MLflow et arrêt anticipé. Ce sont ces règles qui s'appliquent au cas de Diass.

Chapitre 4

Modèles pour séries temporelles

Ce chapitre présente les cadres de modélisation qui exploitent la dimension temporelle. Il examine successivement les réseaux convolutifs 1D, qui extraient des motifs locaux par partage de poids ; les réseaux récurrents (RNN, LSTM, GRU), qui entretiennent un état caché pour suivre la dépendance séquentielle ; le mécanisme d'attention, qui pondère directement l'ensemble des états passés ; et le Transformer, qui abandonne la récurrence au profit d'une auto-attention entièrement parallélisable. Ces briques forment le socle des architectures spécialisées TFT et TCN, détaillées au chapitre 5.

4.1 Réseaux convolutifs (CNN)

Les réseaux denses traitent chaque entrée isolément, sans exploiter la topologie spatiale ou temporelle. Les réseaux convolutifs (CNN) y remédient en imposant localité et partage de poids, ce qui leur permet d'analyser des séquences longues à nombre de paramètres modéré.

4.1.1 Motivation : de la densité à la convolution

Un perceptron multicouche reliant une entrée de dimension p à N neurones mobilise $p \times N$ paramètres ; sur une entrée de forte dimension, l'entraînement bascule vite dans le surapprentissage. Les CNN l'évitent par trois contraintes structurelles [30]. La **localité** limite chaque neurone à un sous-ensemble restreint de l'entrée, son champ réceptif local. Le **partage des poids** applique un même filtre sur toute la séquence, ramenant le coût d'un filtre à la taille k de son noyau. L'**invariance par translation** garantit qu'une caractéristique apprise en un point reste détectable en toute autre position.

Ces contraintes ramènent la complexité paramétrique de $O(p \times N)$ à $O(k \times N)$, autorisant l'entraînement sur des séquences temporelles de grande longueur.

4.1.2 Convolution 1D et causalité

En prévision temporelle, un filtre 1D de taille k glisse le long du temps en calculant le produit scalaire entre ses poids w et la fenêtre d'entrée. Pour un signal x, la convolution 1D discrète s'écrit :

$$(x * w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t+i}.$$

Interdire toute fuite d'information du futur vers le passé impose une contrainte de **causalité**, qui restreint le calcul aux pas de temps antérieurs ou égaux à t :

$$(x *_c w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i}.$$

Le mode de remplissage (*padding*) fixe la dimension de la carte de sortie. En mode **valid**, aucun remplissage n'est ajouté et la sortie compte $T - k + 1$ pas. En mode **same**, un remplissage symétrique conserve la longueur initiale T. En mode **causal**, le remplissage est placé exclusivement à gauche : la longueur T est préservée sans qu'aucune information future ne remonte (figure 4.1).



Figure 4.1 : Modes de remplissage : valid, same et causal.

4.1.3 Convolution 2D et blocs d'extraction

Pour les représentations bidimensionnelles (spectrogrammes issus du signal temporel, par exemple), l'opération s'étend sur deux axes. Une entrée X de dimensions $H \times W$ et C canaux convoluée par un filtre $W \in \mathbb{R}^{C_f \times k_h \times k_w}$ produit :

$$(X * W)_{i,j} = \sum_{c=1}^{C_f} \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} W_{c,m,n} \cdot X_{c,\,i+m,\,j+n}.$$

Une telle couche compte $C_f \times (C_{\text{in}} \times k_h \times k_w + 1)$ paramètres.

Dans une architecture moderne, l'extraction de motifs associe la convolution à des transformations stabilisatrices :

$$\mathbf{h} = \mathrm{Dropout}\Big(\mathrm{ReLU}\big(\mathrm{BN}(\mathrm{Conv1D}_{k\times F}(\mathbf{x}))\big)\Big),$$

où BN désigne la normalisation par lot (*Batch Normalization*) et F le nombre de filtres. La représentation intermédiaire est ensuite projetée vers l'espace cible :

$$\hat{\mathbf{y}} = W_o\,\mathrm{Flatten}(\mathbf{h}) + \mathbf{b}_o, \qquad W_o \in \mathbb{R}^{q\times(T\cdot F)},$$

où q est la dimension de la sortie ($q = 3$ pour l'estimation de quantiles). La figure 4.2 en résume la chaîne typique.

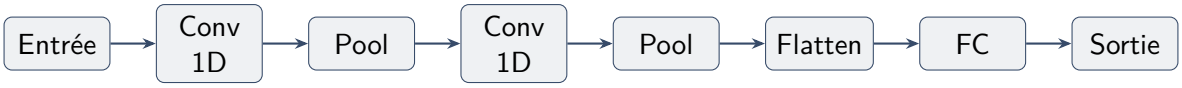


Figure 4.2 : Chaîne de traitement typique d'un CNN 1D séquentiel.

4.1.4 Sous-échantillonnage et hiérarchie des représentations

La résolution temporelle se réduit par le pas de convolution (*stride*) s ou par agrégation (*pooling*). Le max-pooling retient l'activation maximale sur une fenêtre donnée :

$$\mathrm{MaxPool}_p(X)_i = \max_{m\in[0,p)} X_{i\cdot p+m},$$

tandis que l'agrégation moyenne (*average pooling*) calcule la moyenne du voisinage. L'empilement de ces couches construit une hiérarchie de représentations, des motifs locaux haute fréquence jusqu'aux variations de faible fréquence qui portent les tendances.

4.1.5 Champ réceptif et convolutions dilatées

Le champ réceptif mesure la largeur de la séquence d'entrée qui influence un neurone donné. Pour un réseau de L couches convolutives standards de noyau k, il croît linéairement :

$$\text{Champ réceptif} = 1 + L \times (k - 1).$$

Capturer des dépendances à long terme sans alourdir le réseau ni multiplier les paramètres : telle est la raison d'être des **convolutions dilatées**, qui introduisent un facteur d'espacement d :

$$(x *_d w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d\cdot i}.$$

Si la dilatation croît exponentiellement avec la profondeur ($d = 2^\ell$ à la couche ℓ), le champ réceptif s'étend lui aussi exponentiellement. Cette propriété est le cœur de l'architecture WaveNet [52], qui y adjoint une activation filtrée (*gating*) :

$$z = \tanh(W_f * x) \odot \sigma(W_g * x),$$

où $\odot$ désigne le produit de Hadamard (figure 4.3).

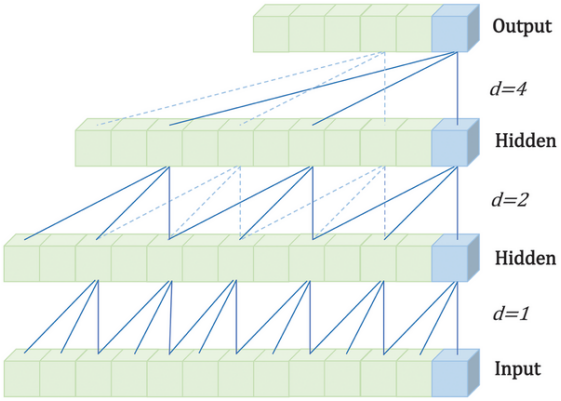


Figure 4.3 : Convolutions dilatées causales ($d = 1, 2, 4, 8$).

4.2 Réseaux récurrents et architectures à portes (RNN, LSTM, GRU)

Les réseaux récurrents modélisent directement la dépendance séquentielle en conservant un état caché mis à jour à chaque pas de temps.

4.2.1 Réseaux de neurones récurrents (RNN)

Le RNN élémentaire traite une séquence $\mathbf{x}_1, \dots, \mathbf{x}_T$ en entretenant un état interne $\mathbf{h}_t$:

$$\mathbf{h}_t = \tanh(W_{hh}\,\mathbf{h}_{t-1} + W_{xh}\,\mathbf{x}_t + \mathbf{b}_h)\,,$$

$$\hat{\mathbf{y}}_t = W_{hy}\,\mathbf{h}_t + \mathbf{b}_y.$$

La figure 4.4 en donne le déploiement temporel.

La régularisation des réseaux récurrents demande une adaptation, le dropout standard perturbant la mémoire temporelle. Le *dropout récurrent* applique un même masque de Bernoulli $\mathbf{m}$ à tous les pas de temps de la séquence :

$$\tilde{\mathbf{h}}_t = \mathbf{m} \odot \mathbf{h}_t, \qquad \mathbf{m} \sim \text{Bernoulli}(1-p).$$

L'entraînement procède par rétropropagation à travers le temps (*Backpropagation Through Time*, BPTT), dont la récurrence enchaîne les produits matriciels $\prod_k W_{hh}$. Le mécanisme de dis-

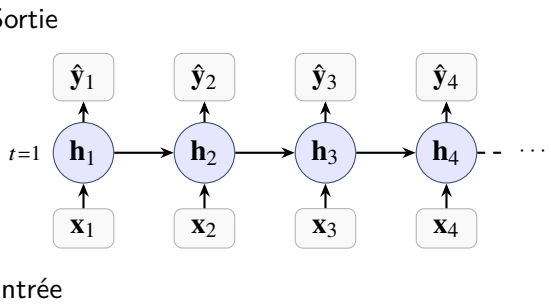


FIGURE 4.4 : Déploiement temporel d'un réseau récurrent.

parition du gradient analysé à la section 3.6 s'y manifeste pleinement : les dépendances lointaines cessent d'être apprises.

4.2.2 LSTM (Long Short-Term Memory)

Le réseau LSTM [20] résout la disparition du gradient par un vecteur d'état de cellule $\mathbf{c}_t$ régulé par trois portes d'activation sigmoïdiennes :

$$
\begin{aligned}
\mathbf{f}_t &= \sigma\big(W_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\big) && \text{(porte d'oubli)},\\
\mathbf{i}_t &= \sigma(W_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) && \text{(porte d'entrée)},\\
\tilde{\mathbf{c}}_t &= \tanh(W_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) && \text{(candidat de mémoire)},\\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t && \text{(mise à jour de l'état de cellule)},\\
\mathbf{o}_t &= \sigma(W_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) && \text{(porte de sortie)},\\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t) && \text{(état caché)}.
\end{aligned}
$$

L'opération additive $\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \ldots$ entretient un flux d'erreur linéaire le long de la séquence : c'est ce canal additif qui neutralise le vanishing gradient (section 3.6). La figure 4.5 en détaille la structure interne.

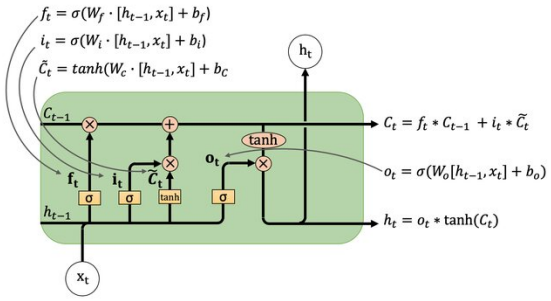


FIGURE 4.5 : Cellule LSTM et flux d'information.

4.2.3 GRU (Gated Recurrent Unit)

Le bloc GRU simplifie le LSTM en fusionnant état de cellule et état caché, ramenant le système à deux portes :

$$\begin{aligned}
\mathbf{z}_t &= \sigma(W_z[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z) && \text{(porte de mise à jour)},\\
\mathbf{r}_t &= \sigma(W_r[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r) && \text{(porte de réinitialisation)},\\
\tilde{\mathbf{h}}_t &= \tanh(W_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h) && \text{(état candidat)},\\
\mathbf{h}_t &= (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t && \text{(interpolation)}.
\end{aligned}$$

Cette formulation réduit d'environ 25 % le nombre de paramètres par rapport au LSTM, à performances comparables [9] (figure 4.6).

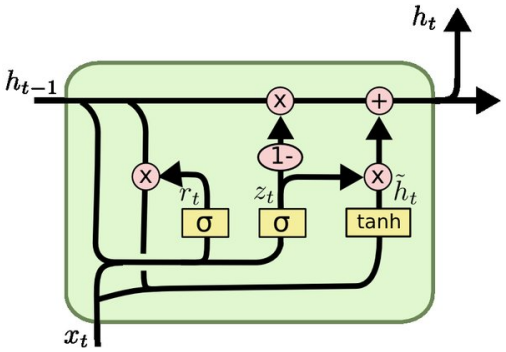


FIGURE 4.6 : Architecture d'une unité GRU.

4.2.4 Extensions récurrentes

Là où la séquence entière est disponible simultanément, comme dans les tâches non causales, les réseaux récurrents bidirectionnels la parcourent dans les deux sens chronologiques :

$$\mathbf{h}_t = [\overrightarrow{\mathbf{h}}_t ; \overleftarrow{\mathbf{h}}_t].$$

Ce traitement reste toutefois proscrit pour la prévision causale en temps réel, où le futur n'est pas connu (figure 4.7).

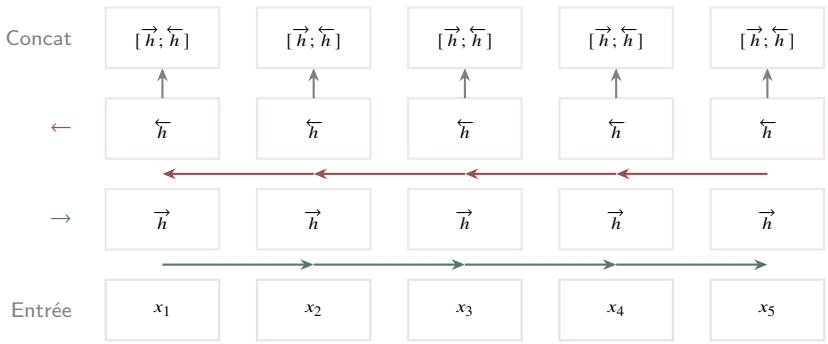


FIGURE 4.7 : Réseau récurrent bidirectionnel.

Le tableau 4.1 récapitule les différences entre les modèles récurrents standard et leurs variantes à portes.

Critère	**RNN Standard**	**LSTM / GRU**
Mémoire long terme	Limitée	Élevée
Rétropropagation du gradient	Évanouissement	Stabilisée
Calcul parallélisable	Non (Séquentiel)	Non (Séquentiel)
Complexité temporelle	$O(T)$	$O(T)$
Nombre de paramètres	$3d_h^2 + 3d_h d_x$	$4(d_h^2 + d_h d_x)$ (LSTM)

Table 4.1 : Comparaison synthétique des modèles récurrents.

4.3 Mécanisme d'attention

L'attention remédie au goulot d'étranglement du vecteur d'état de dimension fixe : au lieu de comprimer tout le passé dans un seul vecteur, elle pondère directement la contribution de chaque état historique.

4.3.1 Attention additive et multiplicative

L'attention additive [5] calcule un score d'alignement $e_{t,j}$ entre l'état du décodeur $\mathbf{s}_{t-1}$ et les états de l'encodeur $\mathbf{h}_j$:

$$e_{t,j} = \mathbf{v}^\top \tanh\big(W_s\, \mathbf{s}_{t-1} + W_h\, \mathbf{h}_j\big)\,, \qquad \alpha_{t,j} = \frac{\exp(e_{t,j})}{\sum_{k=1}^{T} \exp(e_{t,k})}.$$

Le vecteur de contexte $\mathbf{c}_t = \sum_{j=1}^{T} \alpha_{t,j}\, \mathbf{h}_j$ agrège ensuite les représentations pondérées (figure 4.8).

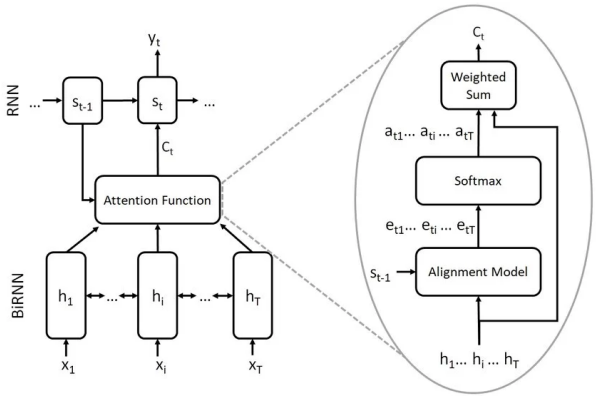


Figure 4.8 : Attention d'alignement et goulot d'étranglement séquentiel.

4.3.2 Self-Attention et Multi-Head Attention

L'auto-attention (*self-attention*) projette une séquence X par trois matrices de poids, produisant requêtes (Q), clés (K) et valeurs (V) :

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

L'attention par produit scalaire normalisé s'écrit :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V,$$

où le facteur $\sqrt{d_k}$ évite la saturation du softmax pour les grandes dimensions.

Pour capter simultanément des dépendances issues de plusieurs sous-espaces de représentation, l'attention multi-têtes (*Multi-Head Attention*) exécute H projections en parallèle :

$$\text{head}_h = \text{Attention}(QW_Q^h,\, KW_K^h,\, VW_V^h),$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_H)\, W_O.$$

La figure 4.9 en illustre le mécanisme.

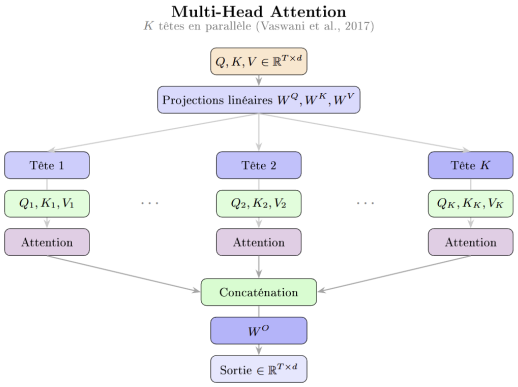


FIGURE 4.9 : Mécanisme d'attention multi-têtes.

Le coût computationnel de l'auto-attention, $O(T^2 \cdot d_k)$, croît quadratiquement avec la longueur de la séquence T.

4.4 Architecture Transformer

Le Transformer [53] écarte la récurrence au profit de l'auto-attention, ce qui autorise une parallélisation complète du traitement des séquences. La figure 4.10 détaille son bloc encodeur, et la figure 4.12 son architecture globale.

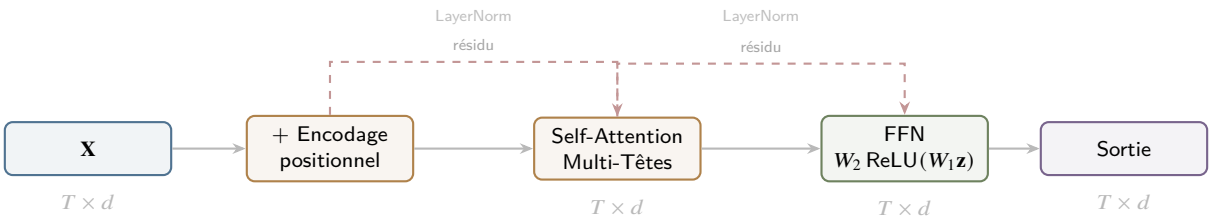


FIGURE 4.10 : Schéma du bloc encodeur du Transformer.

4.4.1 Encodage positionnel

L'auto-attention ne porte en elle aucune notion d'ordre : la position temporelle pos doit donc être injectée explicitement, ici par des fonctions sinusoïdales :

$$\mathbf{PE}_{(pos,\,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \qquad \mathbf{PE}_{(pos,\,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right),$$

où i désigne l'indice de la dimension d'encodage (figure 4.11).

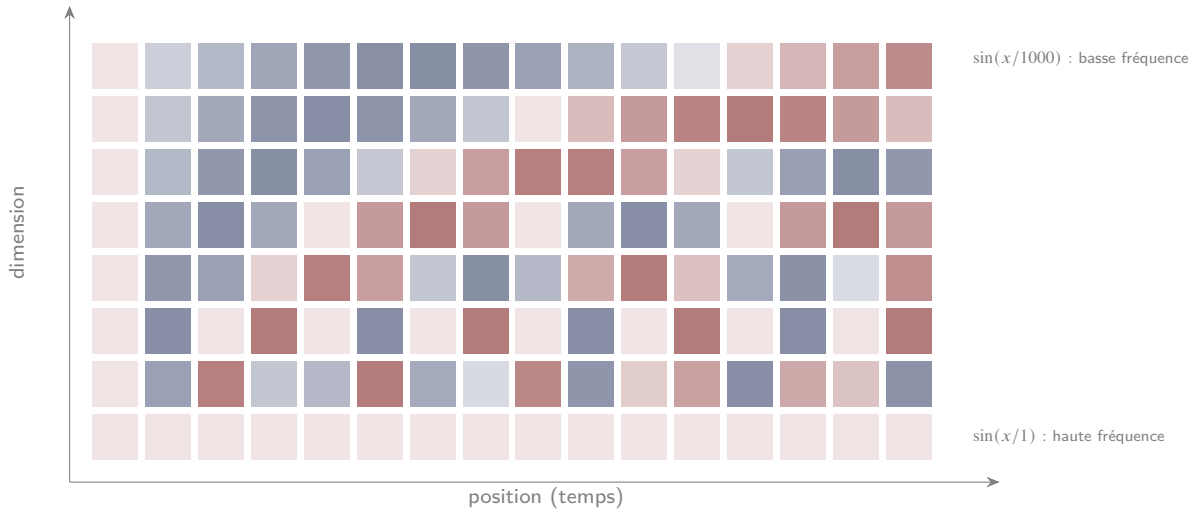


FIGURE 4.11 : Matrice d'encodage positionnel sinusoïdal.

4.4.2 Sous-couches et projection

Chaque sous-couche intègre une connexion résiduelle suivie d'une normalisation par couche (*Layer Normalization*) :

$$\text{Sortie} = \text{LayerNorm}(\mathbf{x} + \text{Dropout}(\text{SousCouche}(\mathbf{x}))) \,.$$

Le réseau positionnel à propagation avant (*Feed-Forward Network*, FFN) applique deux transformations affines encadrant une non-linéarité :

$$\text{FFN}(\mathbf{z}) = W_2 \cdot \text{ReLU}(W_1\mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2.$$

En prévision temporelle, la représentation latente finale $\mathbf{Z}^{(L)}$ issue de l'encodeur est projetée linéairement pour construire la prédiction sur l'horizon H :

$$\hat{\mathbf{Y}} = W_o\,\mathbf{Z}^{(L)} + \mathbf{b}_o, \qquad W_o \in \mathbb{R}^{q \times d_{\text{model}}}.$$

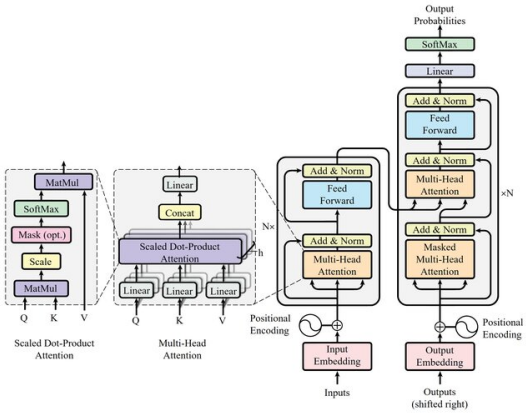


Figure 4.12 : Architecture encodeur–décodeur du Transformer.

4.5 Conclusion

Les architectures du chapitre suivant reposent sur trois familles de briques. La convolution exploite la localité et le partage de poids, ce qui réduit le nombre de paramètres par rapport à un réseau dense ; en version causale et dilatée, elle étend le champ réceptif sans regarder le futur, comme dans WaveNet.

La récurrence entretient un état caché pour suivre la dépendance séquentielle, mais le RNN élémentaire perd l'information sur les longues séquences ; le LSTM y répond par un état de cellule et trois portes, le GRU en utilise deux pour un coût plus faible. L'attention lève la limite du vecteur d'état de dimension fixe en pondérant directement les états passés ; l'auto-attention multi-têtes en est la forme générale, au prix d'un coût quadratique en longueur de séquence.

Le Transformer assemble ces éléments (auto-attention, encodage positionnel, connexions résiduelles, normalisation par couche) et se passe de récurrence, ce qui autorise la parallélisation complète. Le TFT et le TCN combinent ensuite ces briques selon deux logiques différentes, présentées au chapitre suivant.

Chapitre 5

Architectures avancées appliquées

La prévision photovoltaïque consiste à estimer la production solaire à partir de séquences historiques. Sa difficulté tient à deux échelles de variabilité imbriquées : le cycle diurne et saisonnier, largement déterministe, et la couverture nuageuse, brutale et stochastique. Les méthodes de lissage, aveugles à la seconde, s'y révèlent insuffisantes. Ce chapitre présente les deux architectures de référence retenues dans ce travail, le Temporal Fusion Transformer et le Temporal Convolutional Network, ainsi que le cadre commun d'encodage et d'évaluation qui les met en regard.

5.1 Solaire : Temporal Fusion Transformer (TFT)

5.1.1 Le TFT sélectionne les variables puis pondère le passé par attention

Le Temporal Fusion Transformer (TFT) est une architecture à attention conçue pour la prévision multi-horizon de séries multivariées [32]. Son entrée combine nativement trois types de données : des **covariables statiques** (localisation du panneau, puissance installée), des **entrées futures connues** (heure, jour de la semaine, saison) et des **séries exogènes passées** (irradiance, température, vent).

Son fonctionnement articule trois dispositifs : le Variable Selection Network retient, à chaque instant, les variables qui importent ; l'attention exploite les relations temporelles pertinentes ; la sortie en quantiles rend l'incertitude explicite. La figure 5.1 en donne l'architecture d'ensemble.

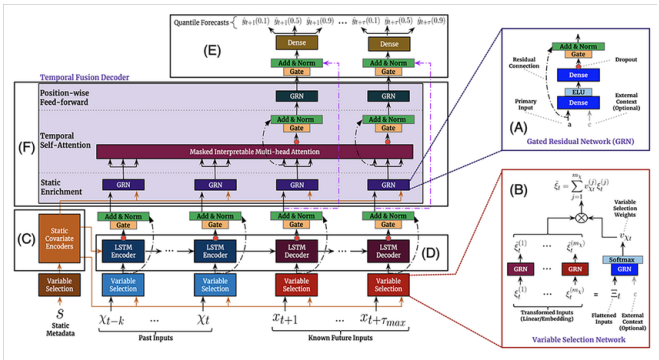


FIGURE 5.1 : Architecture du TFT : VSN, LSTM et attention interprétable.

Sa valeur ajoutée tient à l'interprétabilité : on peut visualiser les variables retenues par la VSN, les positions temporelles mises en avant par l'attention et les features statiques qui pèsent sur la sortie, un atout décisif pour les opérateurs de réseau électrique.

5.1.2 Covariables statiques → 4 contextes via encodeur statique

Les covariables statiques (localisation du panneau, puissance installée, type de capteur) traversent un encodeur statique qui produit quatre vecteurs de contexte, chacun dédié à un sous-système : la sélection de variables, l'initialisation des états LSTM et le conditionnement de la sortie.

L'encodeur statique calcule :

$$\mathbf{c}_s = \mathrm{GRN}_{\mathrm{stat}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_e = \mathrm{GRN}_{\mathrm{enc}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_h = \mathrm{GRN}_{\mathrm{hid}}(\mathbf{x}_{\mathrm{stat}}), \qquad \mathbf{c}_c = \mathrm{GRN}_{\mathrm{con}}(\mathbf{x}_{\mathrm{stat}})$$

où $\mathbf{x}_{\mathrm{stat}}$ est le vecteur des covariables statiques. Le contexte $\mathbf{c}_s$ alimente la Variable Selection Network, $\mathbf{c}_e$ et $\mathbf{c}_h$ initialisent les états cachés des LSTM encodeur et décodeur, et $\mathbf{c}_c$ conditionne la couche de sortie.

Cette séparation laisse le modèle exploiter une même information statique de plusieurs manières selon le sous-système : la sélection de variables réclame un résumé global ($\mathbf{c}_s$), là où les LSTM attendent un état initial ($\mathbf{c}_e$, $\mathbf{c}_h$). Chaque GRN apprend une transformation qui lui est propre, ce qui évite un partage excessif de paramètres.

5.1.3 Le bloc fondateur : Gated Residual Network (GRN)

Traitons d'abord le constituant fondamental du TFT. Sélection de variables, traitement statique et décodage reposent tous sur le même type de réseau résiduel : le Gated Residual Network.

Le GRN est un réseau résiduel doté d'une porte GLU (Gated Linear Unit) qui module le flux d'information : le sigmoïde écarte les features non pertinentes, tandis que la connexion résiduelle préserve le gradient et l'information d'origine.

Le GRN calcule :

$$\mathrm{GRN}(\mathbf{a}, \mathbf{c}) = \mathrm{LayerNorm}\left(\mathbf{a} + \mathrm{GLU}(\eta_1)\right)$$

$$\eta_1 = W_1\eta_2 + \mathbf{b}_1, \qquad \eta_2 = \mathrm{ELU}(W_2\mathbf{a} + W_3\mathbf{c} + \mathbf{b}_2)$$

où $\mathbf{a}$ est l'entrée principale (features temporelles ou statiques) et $\mathbf{c}$ une condition optionnelle (contexte statique ou temporel). La transformation non linéaire η_2 recourt à une ELU et sert à l'extraction de caractéristiques ; η_1 est la projection linéaire qui suit. La porte GLU segmente les $2d$ canaux en deux moitiés : la première fait office de porte, la seconde de candidat, selon $\mathrm{GLU}(\eta_1) = \sigma(\eta_1^{(1:d)}) \odot \eta_1^{(d+1:2d)}$. La figure 5.2 en donne le schéma.

Le GRN se retrouve partout dans le TFT : sélection de variables, traitement des features statiques, décodage. Sa force tient à la porte GLU, dont le sigmoïde « ferme » approximativement les dimensions inutiles. La connexion résiduelle $\mathbf{a}+\ldots$ et la Layer Normalization [4] garantissent que l'information d'entrée n'est jamais entièrement perdue.

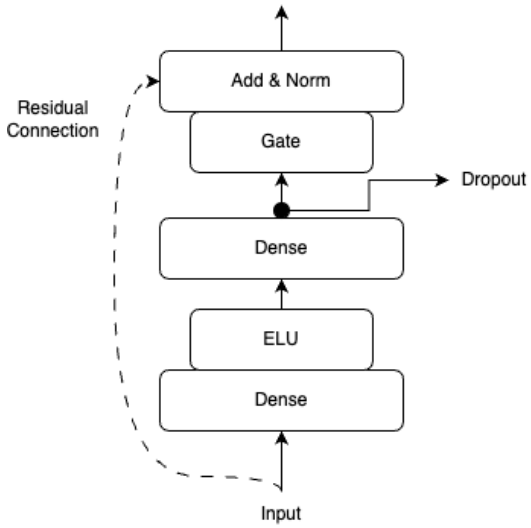


FIGURE 5.2 : Bloc GRN : porte GLU, connexion résiduelle et LayerNorm.

5.1.4 Variable Selection Network (VSN)

La VSN répond à une question mouvante : quelles variables d'entrée importent à cet instant précis ? L'irradiance est déterminante à midi mais sans objet la nuit, la température reste pertinente en permanence. La VSN calcule donc un poids d'importance $\boldsymbol{\xi}_t$ par variable, ce qui concentre le modèle sur les plus informatives.

Ces poids sont produits par un GRN dédié :

$$\boldsymbol{\xi}_t = \text{Softmax}\left(\text{GRN}_{\mathbf{v}}(\mathbf{X}_t, \mathbf{c}_s)\right)$$

Le vecteur $\boldsymbol{\xi}_t \in \mathbb{R}^{N_v}$, de somme unité, pondère les N_v colonnes de la matrice $\mathbf{X}_t \in \mathbb{R}^{N_v \times d}$ à l'instant t ; le contexte $\mathbf{c}_s$ encode le site. Les variables considérées vont de l'irradiance et de la température au vent et à l'heure.

La sortie filtrée est la somme pondérée :

$$\tilde{\mathbf{x}}_t = \sum_{j=1}^{N_v} \xi_t^{(j)} \cdot \tilde{\mathbf{x}}_t^{(j)}$$

où $\tilde{\mathbf{x}}_t^{(j)} = \text{GRN}_j(\mathbf{x}_t^{(j)})$ est la variable j filtrée par son propre GRN. La figure 5.3 détaille ce calcul.

La VSN est interprétable : en suivant les poids $\boldsymbol{\xi}_t$ au fil du temps, on lit quelles variables dominent la prédiction ; on s'attend à un poids élevé de l'irradiance le jour et nul la nuit, la température demeurant toujours significative. C'est un avantage net sur les modèles « boîte noire ».

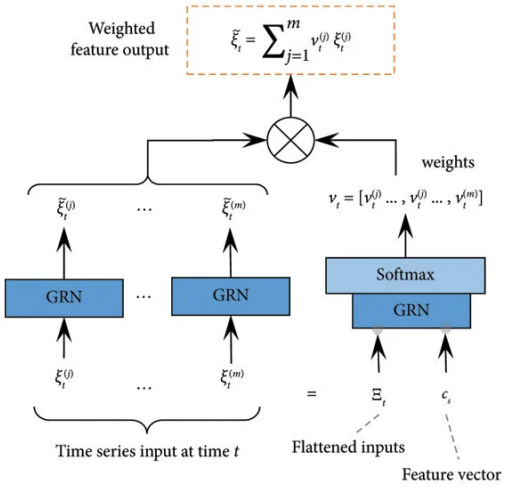


FIGURE 5.3 : Variable Selection Network (VSN).

5.1.5 Attention multi-head interprétable

Les variables filtrées forment une séquence temporelle $\tilde{\mathbf{x}}_1, \ldots, \tilde{\mathbf{x}}_T$. Il reste à encoder ces dépendances séquentielles, puis à les mobiliser au moment de prédire. Le décodeur du TFT combine pour cela un LSTM local, pour les motifs courts, et une attention interprétable, pour les dépendances à longue portée.

L'attention « interprétable » du TFT vise précisément la lisibilité : elle partage la projection de valeur entre les têtes, ce qui autorise la moyenne des cartes d'attention et fournit une attention globale unique.

L'attention multi-head interprétable s'écrit :

$$\text{InterpretableMultiHead}(Q, K, V) = \frac{1}{H} \sum_{h=1}^{H} \text{Attention}(QW_Q^{(h)}, KW_K^{(h)}) \cdot VW_V$$

où Q, K, V proviennent du LSTM local ; les projections $W_Q^{(h)}$ et $W_K^{(h)}$ sont propres à chaque tête, W_V est partagée entre elles, et H désigne le nombre de têtes (4 à 8 en pratique).

Le partage de W_V distingue cette attention de l'attention standard : la moyenne des cartes d'attention garde un sens, et l'on peut agréger les poids de toutes les têtes en une carte interprétable. Appliquée entre passé (encodeur) et futur (décodeur), elle révèle quelles positions passées pèsent le plus sur la prédiction.

5.1.6 Sortie en quantiles

Le TFT ne prédit pas une valeur unique, mais plusieurs quantiles simultanément, à savoir $q = 0{,}1$ (pire cas), $q = 0{,}5$ (médiane) et $q = 0{,}9$ (meilleur cas), ce qui livre une mesure complète de l'incertitude (figure 5.4).

La perte en quantiles (pinball, section 3.3) est [27] :

$$\mathrm{QL}(y, \hat{y}, q) = q \cdot \max(y - \hat{y}, 0) + (1 - q) \cdot \max(\hat{y} - y, 0)$$

Pour $q = 0{,}5$, la pénalité est symétrique : surestimation et sous-estimation coûtent autant. Pour $q = 0{,}1$, sous-estimer coûte neuf fois plus que surestimer, ce qui pousse le modèle vers le bas de la distribution, comme l'exige la gestion de réseau, où l'on planifie sur le pire cas plutôt que de risquer un blackout.

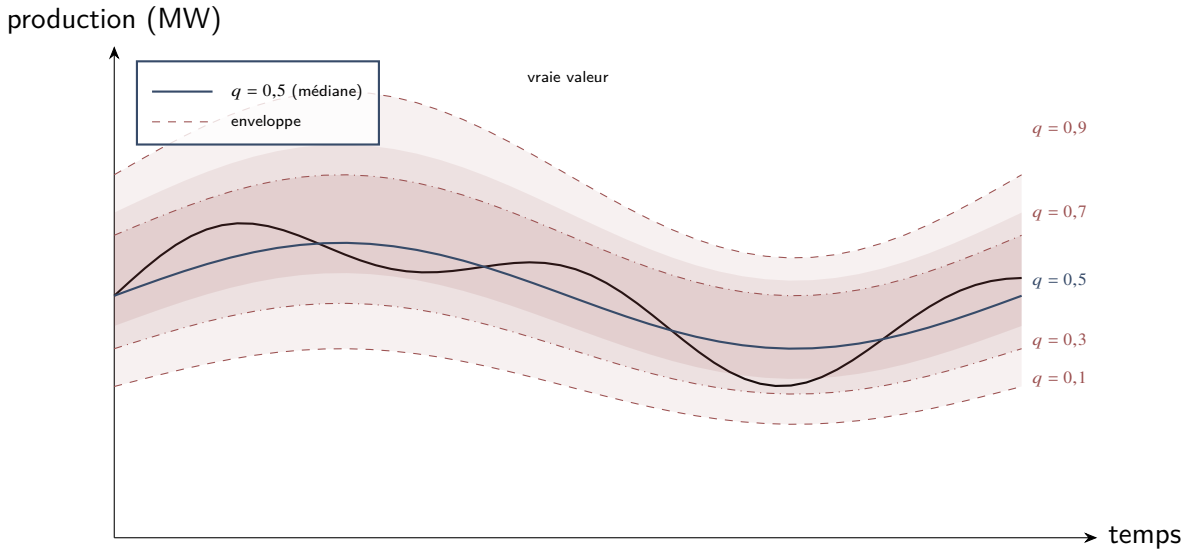


Figure 5.4 : Sortie en quantiles du TFT ($q = 0{,}1$ à $0{,}9$).

5.2 Photovoltaïque : Temporal Convolutional Network (TCN)

5.2.1 Convolution dilatée et filtre $k = 3$

Le Temporal Convolutional Network (TCN) s'appuie sur des convolutions causales dilatées pour modéliser les dépendances longues à moindre coût que les RNN, tout en se parallélisant intégralement [6]. Pour la prévision PV, son champ réceptif exponentiel capte bien les motifs cycliques journaliers et hebdomadaires.

Un bloc TCN combine convolution causale, dilatation exponentielle et connexion résiduelle. La convolution causale n'observe que le passé, ce qui écarte toute fuite de données :

$$(x *_c w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i}$$

La dilatation $d = 2^{\ell}$ étend ensuite le champ réceptif à chaque couche ℓ :

$$(x *_d w)_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d \cdot i}$$

Enfin, un bloc résiduel (connexion skip et Layer Normalization [4]) préserve la circulation du gradient.

5.2.2 Le champ réceptif

Le champ réceptif d'un TCN de profondeur L, de filtre k et de dilatations exponentielles vaut :

$$R = 1 + \sum_{\ell=0}^{L-1} (k-1) \cdot 2^{\ell} = 1 + (k-1)(2^{L} - 1)$$

R compte les pas de temps couverts, k est la taille du filtre ($k = 3$ typiquement), L la profondeur, et la dilatation vaut 2^{ℓ} à la couche ℓ.

Avec $k = 3$ et $L = 10$ couches, $R = 1 + 2(2^{10} - 1) = 2047$ pas de temps, soit plus de trois semaines en données horaires. Comme le TCN traite la séquence en parallèle, et non pas pas à pas comme un LSTM, son entraînement s'en trouve accéléré.

5.2.3 Architecture TCN appliquée à la prévision PV

Le TCN empile des blocs résiduels, chacun renfermant deux convolutions dilatées causales, une activation, une normalisation et une connexion résiduelle. La connexion skip projette l'entrée dans l'espace de sortie lorsque les dimensions diffèrent.

Un bloc résiduel TCN s'écrit :

$$\mathbf{h} = \mathrm{LayerNorm}(\mathbf{x} + \mathrm{Conv1D}_2(\mathrm{ReLU}(\mathrm{LayerNorm}(\mathrm{Conv1D}_1(\mathbf{x})))))$$

L'entrée $\mathbf{x} \in \mathbb{R}^{T \times C_{\text{in}}}$ traverse deux convolutions causales dilatées ($\mathrm{Conv1D}_1$ puis $\mathrm{Conv1D}_2$, de même dilatation d), séparées par une LayerNorm et un ReLU ; la somme résiduelle $\mathbf{x} + \ldots$ est stabilisée par une LayerNorm finale. La figure 5.5 en illustre l'empilement.

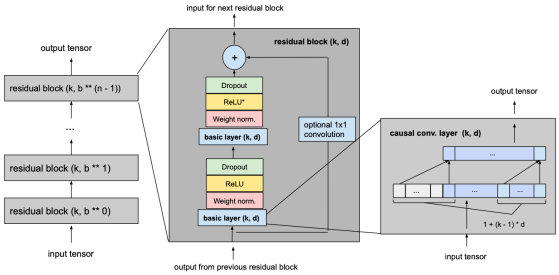


Figure 5.5 : Architecture TCN : convolutions causales dilatées et connexions résiduelles.

5.2.4 Pourquoi ce choix pour le PV

Le TCN convient particulièrement à la prévision PV : son champ réceptif exponentiel couvre les cycles diurne et hebdomadaire, la parallélisation totale accélère l'entraînement sur de longues

séquences, et sa complexité mémoire linéaire $O(T)$ surclasse la quadraticité $O(T^2)$ du Transformer.

Il s'entraîne plus vite qu'un LSTM (parallélisme total) et reste plus stable qu'un Transformer (pas de quadraticité). En contrepartie, il ne gère pas nativement les variables statiques (localisation du panneau) et n'offre pas l'interprétabilité d'une attention. C'est un bon choix lorsque la vitesse d'entraînement prime.

Les deux architectures de référence étant posées, nous détaillons les stratégies d'encodage et d'évaluation communes à ce travail.

5.3 Entraînement : encodage et évaluation

5.3.1 Encodage sin/cos de l'heure

L'encodage cyclique de l'heure est indispensable : 23 h et 0 h occupent le même point du cycle journalier, qu'une représentation linéaire disloquerait. Les coordonnées sin/cos préservent cette circularité.

L'heure h (0–23) se code en deux dimensions :

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \qquad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right)$$

Le couple $h_{\sin}, h_{\cos}$ respecte la circularité du cycle : 23 h et 0 h y restent voisins.

Avec cette représentation, la distance euclidienne entre 10 h et 11 h égale celle entre 22 h et 23 h, comme il se doit. Sans encodage cyclique, le modèle tiendrait 23 h et 0 h pour très éloignées.

5.3.2 La baseline à battre : la persistance

La persistance est la baseline la plus simple [22] : elle prédit que la valeur future égalera la valeur courante. Difficile à battre à court terme ($H < 6$ h), la production d'énergie présentant une forte inertie.

La prédiction de persistance est :

$$\hat{y}_{t+h} = y_t$$

$\hat{y}_{t+h}$ reprend simplement y_t, la valeur observée en t, pour un horizon h.

Le skill score quantifie [17] l'amélioration par rapport à cette baseline :

$$\text{Skill Score} = 1 - \frac{\text{RMSE}_{\text{modèle}}}{\text{RMSE}_{\text{persistance}}}$$

Un skill score positif signale un modèle meilleur que la persistance ; une valeur de 0,2 correspond à un gain de 20 %.

La persistance est un benchmark réaliste : à très court terme, la production présente estime déjà correctement celle de +1 h. Un skill score positif indique que le modèle exploite des informations additionnelles (tendances, corrélations, cycles). Aux horizons longs ($H > 12$ h), la persistance se dégrade naturellement et le skill score grimpe.

5.4 Conclusion

Le TFT et le TCN répondent à deux besoins différents. Le premier mise sur la sélection de variables, assurée par la VSN et ses GRN à porte GLU, sur l'attention multi-têtes interprétable et sur une sortie en quantiles ; il donne ainsi à l'exploitant une lecture des variables et des positions temporelles qui pèsent sur la prédiction. Le second privilégie la rapidité d'entraînement : ses convolutions causales dilatées portent le champ réceptif à 2 047 pas pour dix couches et un noyau de taille trois, tout en conservant une complexité mémoire linéaire et une parallélisation complète. En contrepartie, il ne traite pas nativement les variables statiques et n'offre pas l'interprétabilité de l'attention.

Le cadre commun permet de les départager sur le même terrain : l'encodage cyclique de l'heure restitue la continuité entre 23 h et 0 h, la persistance fournit la référence à battre et le skill score quantifie le gain apporté par le modèle. C'est ce que fait le chapitre suivant, sur la centrale de Diass.

Chapitre 6

Stratégie MIMO et prévision probabiliste par quantiles

Avant d'entraîner un modèle à 72 h, deux décisions conditionnent le reste du dispositif : comment produire les H horizons à partir de l'historique, et sous quelle forme restituer l'incertitude. Dans ce mémoire, la première est la stratégie **MIMO** (*Multiple-Input Multiple-Output*) ; la seconde est la **régression quantile**. Les deux sont liées : MIMO fournit naturellement la matrice $H \times Q$ qu'attend la seconde. Ce chapitre expose ce couplage, la perte qui l'entraîne et le protocole qui le mesure.

6.1 La stratégie MIMO de prévision multi-horizon

Prévoir la production solaire des 72 prochaines heures peut se faire de deux manières : produire les H valeurs futures en une seule passe, ou les engendrer séquentiellement en réinjectant chaque prédiction comme entrée de la suivante. Nous retenons la première option. Elle traite la séquence future comme un vecteur de sortie, ce qui préserve la cohérence entre horizons et supprime la propagation des erreurs d'inférence.

MIMO prédit en une seule passe le vecteur complet des horizons futurs, comme l'illustre la figure 6.1 :

$$\hat{\mathbf{y}} = \left[\hat{y}_{t+1}, \ldots, \hat{y}_{t+H}\right] = f_{\boldsymbol{\theta}}(\mathbf{x}_{t-T:t}) \in \mathbb{R}^{H},$$

La fenêtre d'entrée $\mathbf{x}_{t-T:t}$ couvre T pas d'historique : covariables météorologiques, variables calendaires et réalisations décalées. En prévision probabiliste, la sortie devient une matrice $H \times Q$:

$$\hat{\mathbf{Y}} = \left[\hat{y}^{(1)}_{t+1}, \ldots, \hat{y}^{(Q)}_{t+1}; \ldots; \hat{y}^{(1)}_{t+H}, \ldots, \hat{y}^{(Q)}_{t+H}\right] \in \mathbb{R}^{H \times Q},$$

où Q est le nombre de quantiles prédits pour chaque horizon. C'est le paramétrage du *Temporal Fusion Transformer*, qui produit nativement des quantiles sur plusieurs horizons [32] ; les implémentations TCN du pipeline expérimental adoptent le même (sections 3.7 et 6.6).

Nous avons écarté la prévision récursive pour deux raisons pratiques. Réinjecter une prédiction comme entrée de la suivante accumule mécaniquement la variance d'erreur sur 72 pas. Et un modèle unique couvre tous les horizons et ne coûte qu'un seul entraînement, au lieu de 72. La contrepartie est la dimension de sortie : pour $H = 72$ pas et $Q = 3$ quantiles, le réseau doit



Figure 6.1 : Flux MIMO : une fenêtre d'historique, un modèle unique, une matrice $H \times Q$ de prévisions.

produire 216 valeurs simultanées, ce qui accroît le risque de surapprentissage sur des séries de longueur modeste. C'est ce coût que les architectures MIMO modernes cherchent à contenir, par sélection de variables et partage de représentation, détaillés au chapitre 5.

6.2 La prévision par quantiles : type de sortie probabiliste

Une prévision ponctuelle donne la production attendue ; elle ne dit pas quelle réserve mobiliser pour couvrir les cas défavorables. Dimensionner une réserve, arbitrer entre excès et déficit, sécuriser un contrat d'approvisionnement supposent de connaître la queue basse de la distribution de production, pas sa seule tendance centrale. Trois têtes de sortie ne suffisent pas à estimer la distribution complète ; nous en approximons donc les quantiles : $Q = 3$ niveaux, 10 %, 50 % et 90 %, soit une médiane et une enveloppe de confiance à 80 %.

La régression quantile [28] estime le quantile conditionnel $q_\alpha(\mathbf{x}_t)$ en minimisant la perte en quantiles (pinball), qui pénalise à chaque pas le résidu $y - a$ entre l'observation y et la borne prédite a :

$$\mathrm{QL}_\alpha(y,\, a) \;=\; \big[\alpha - \mathbb{1}(y < a)\big]\,(y - a). \tag{6.1}$$

Pour une architecture à sortie Q-dimensionnelle, la perte totale est la moyenne des pertes attachées aux Q têtes de sortie :

$$\mathcal{L}_{\text{quantile}} = \frac{1}{Q}\sum_{q=1}^{Q} \mathrm{QL}_{\alpha_q}\Big(y,\ \hat{y}^{(q)}\Big), \qquad \alpha_1 < \alpha_2 < \cdots < \alpha_Q.$$

Cette formulation est *séparable* : chaque tête q s'optimise indépendamment des autres, ce qui simplifie et stabilise l'entraînement. En contrepartie, rien ne garantit l'*ordre* des quantiles prédits : deux quantiles voisins peuvent se croiser pour certaines entrées, produisant un intervalle de largeur négative.

Ce défaut classique, le croisement des quantiles, appelle deux corrections : pénaliser explicitement tout croisement, ou paramétrer la sortie par des incréments positifs contraints, $\hat{y}^{(q)} = \hat{y}^{(1)} + \sum_{j<q} \mathrm{softplus}(\Delta_j)$. En pratique, la fréquence de croisement est *mesurée* et reste nulle sur le jeu de test pour les deux architectures retenues, comme le rapporte le chapitre d'étude de cas ; la perte hybride décrite ci-dessous joue de surcroît un rôle régularisateur.

6.3 L'approche d'incertitude retenue : perte hybride multi-tâche

Les modèles TCN et TFT ne sont pas entraînés par une simple perte quadratique. Ils recourent à une **fonction de perte hybride multi-tâche**, qui combine deux objectifs pondérés par un poids w_{mse} :

$$\mathcal{L} \;=\; \underbrace{w_{\text{mse}} \cdot \text{MSE}(\hat{y}_{0,5},\, y)}_{\text{exactitude ponctuelle}} \;+\; \underbrace{(1 - w_{\text{mse}}) \cdot \overline{\text{Pinball}}(\hat{y}_q,\, y)}_{\text{calibration probabiliste}}. \tag{6.2}$$

La composante MSE porte sur la médiane prédite, la composante pinball étant moyennée sur les quantiles $q \in \{0{,}1, 0{,}5, 0{,}9\}$, chaque tête appliquant la perte en quantiles de l'équation (6.1). Ce poids pilote le compromis entre les deux tâches.

Sous-jacente à cette perte, la distinction entre les deux sources d'incertitude éclaire la lecture des résultats. L'incertitude *aléatoire* est irréductible : même avec une description parfaite de l'atmosphère, la position d'un passage nuageux reste imprévisible au-delà de quelques heures à l'échelle du kilomètre, et aucune quantité de données ne la supprime. L'incertitude *épistémique* est réductible : elle traduit un manque de données ou de capacité de modèle. La régression quantile approche la variabilité aléatoire conditionnelle ; l'injection des covariables futures NWP réduit, elle, la composante épistémique en informant le modèle de l'état atmosphérique à venir.

L'entraînement hybride produit des quantiles dont la calibration n'est pas garantie en échantillon fini. Une étape de *recalibrage* a posteriori vient donc s'y ajouter.

6.4 Recalibrage de l'enveloppe : le CQR adopté

La perte ponctuelle+quantile livre des intervalles dont la couverture effective peut s'écarter de la cible, surtout loin de la médiane. L'implémentation ajoute donc une étape d'**inférence conforme quantile** (*Conformalized Quantile Regression*, CQR) [41], selon un schéma *split conformal* [54] : un jeu de calibration disjoint fournit le score de non-conformité

$$s_i = \max\!\left\{\hat{y}_i^{\text{bas}} - y_i,\; y_i - \hat{y}_i^{\text{haut}}\right\},$$

et l'intervalle recalibré s'écrit, pour le niveau α :

$$\mathcal{I}(\mathbf{x}) \;=\; \left[\, \hat{y}^{\text{bas}}(\mathbf{x}) - q_{(k)}(C),\; \hat{y}^{\text{haut}}(\mathbf{x}) + q_{(k)}(C) \,\right], \qquad k = \lceil (m+1)(1-\alpha) \rceil, \tag{6.3}$$

où $q_{(k)}(C)$ est le k-ième plus petit score de non-conformité sur le jeu de calibration de taille m. La garantie $\mathbb{P}\{y \in \mathcal{I}\} \geq 1 - \alpha$ tient sans hypothèse sur le processus, à condition que les données de calibration soient *échangeables* avec le point à prédire.

Le recalibrage CQR est appliqué avec $\alpha = 0.20$ sur le jeu de validation, puis évalué sur le test. Les journaux d'entraînement consignent son effet sur la couverture P10–P90 : pour le TCN, elle passe de 60,8 % à 79,8 %, proche de la cible de 80 % ; pour le TFT, de 71,2 % à 74,2 %,

avec une enveloppe plus étroite et une largeur moyenne nettement inférieure (0.095 MW contre 0.463 MW).

C'est cette étape qui transforme l'enveloppe brute de la perte hybride en un intervalle à garantie de couverture vérifiable par l'équation (6.3), sans réentraînement du réseau. La largeur de l'intervalle étant un quantile *absolu* des résidus de calibration, elle s'élargit naturellement avec l'horizon h, ce qui préserve une couverture stable.

Le protocole suivant mesure ce que le recalibrage a apporté.

6.5 Scores stricts et calibration : juger une prévision par quantiles

Une prévision probabiliste se juge par un *score propre* [17], quantité dont l'espérance sous la vraie loi est minimisée lorsque la loi prédite est la loi vraie. La largeur moyenne seule est triviale à minimiser (un intervalle infini y suffit), et la couverture seule récompense l'honnêteté sans la compétence.

Nous rapportons donc systématiquement la couverture, la largeur moyenne et un score propre (pinball ou score de Winkler). Ce sont exactement les métriques calculées pour chaque modèle avancé : couverture, largeur moyenne, score de Winkler à 80 %, et pertes de quantiles basse et haute.

Un intervalle $[\hat{y}^{\text{bas}}, \hat{y}^{\text{haut}}]$ de niveau nominal $1 - 2\alpha$ est dit *calibré* si la fréquence empirique de couverture vérifie :

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\left\{\hat{y}_i^{\text{bas}} \le y_i \le \hat{y}_i^{\text{haut}}\right\} \;=\; 1 - 2\alpha \;+\; \varepsilon_n, \qquad \varepsilon_n \to 0. \tag{6.4}$$

Le terme ε_n fluctue selon la loi binomiale : pour un intervalle à 80 % évalué sur n échantillons, la couverture observée s'écarte du nominal d'un ordre de grandeur $1/\sqrt{n}$.

La couverture ne distingue pas sur-couverture et sous-couverture. Un diagnostic plus fin, la *transformation intégrale de probabilité* (PIT), complète le triplet lorsque la loi complète est disponible. Avec trois quantiles, le code se restreint à la couverture, à la largeur moyenne, au score de Winkler et aux pertes de quantiles, ce qui suffit pour départager deux architectures à horizon donné.

6.6 Protocole d'évaluation sur le cas Diass

Le protocole d'évaluation de l'incertitude appliqué à Diass comporte cinq étapes :

1. **Couverture par horizon.** Pour chaque $h \in \{1, \ldots, 72\}$, fréquence empirique de couverture de l'intervalle P10–P90 et écart à la cible de 80 % ;

2. **Largeur par horizon.** Largeur moyenne de l'enveloppe, en MW et en pourcentage de $P^{\max}$, pour comparer deux architectures à couverture égale ;
3. **Score propre.** Pinball moyen sur les trois quantiles et score de Winkler à 80 % ;
4. **Diagnostic de croisement.** Fréquence de $P_{10} > P_{50}$ ou $P_{50} > P_{90}$, qui doit être nulle ;
5. **Comparaison au référentiel.** Score de calibration par rapport à la climatologie (section 3.7).

Ce protocole s'applique après l'étape CQR, sur des fenêtres de test identiques pour les deux architectures : 1049 fenêtres couvrant du 16 juillet au 28 août 2026, avec 168 h d'historique et 72 h d'horizon. Les valeurs numériques ci-dessous portent donc sur l'*enveloppe recalibrée*, et non sur la sortie brute de la perte hybride.

6.7 Conclusion

La stratégie retenue tient en trois choix : une sortie MIMO, où un modèle unique produit les H horizons en une passe, sans réinjection des prédictions ; une sortie quantile à $Q = 3$ niveaux (10 %, 50 %, 90 %), estimés par régression quantile séparable ; et une perte hybride multi-tâche, MSE sur la médiane et pinball sur les quantiles, complétée par un recalibrage *conformalized quantile regression* destiné à garantir la couverture de l'enveloppe en échantillon fini.

Trois points à garder en tête avant les résultats. Une prévision probabiliste ne se juge pas sur une métrique unique : la couverture, la largeur moyenne et un score propre seront rapportés ensemble. Sans les covariables NWP, aucun modèle ne produira d'intervalle utile à 72 h ; le plafond vient de l'information d'entrée, pas de l'architecture. Enfin, $Q = 3$ recalibré constitue un compromis assumé entre information, coût d'inférence et faisabilité dans le cadre de ce mémoire.

Troisième partie

MODÉLISATION DE LA PRÉVISION PHOTOVOLTAÏQUE

Chapitre 7

Cas d'application à la centrale solaire de Diass

Les chapitres précédents ont présenté le cadre physique, les architectures et la stratégie probabiliste. Ce chapitre les met à l'épreuve sur une centrale réelle, celle de Diass, première centrale solaire publique du Sénégal. Sa structure fixe, son climat sahélien et sa production d'environ 34 GWh par an en font un cas représentatif de ce que la SENELEC devra gérer à mesure que le solaire monte en puissance.

7.1 Objectifs et méthodologie

7.1.1 Objectifs de l'étude

Pour un gestionnaire de réseau, prévoir la production solaire sert à planifier l'entretien et les investissements, à équilibrer l'offre et la demande en ajustant les moyens thermiques et hydrauliques, à limiter les coûts de réserve et de curtailment, et à éviter les déséquilibres fréquence–puissance qui conduisent au délestage [39].

Nous poursuivons ici trois objectifs. Le premier est de prévoir la production de la centrale à 72 heures. Le deuxième est d'accompagner chaque prévision d'une enveloppe d'incertitude P10–P90. Le troisième est de comparer plusieurs architectures d'apprentissage profond sur un protocole identique, pour savoir laquelle convient le mieux à ce site.

7.1.2 Démarche méthodologique

La démarche se déroule en trois temps, que résume la figure 7.1. Il faut d'abord construire les données, de l'export SCADA au fichier de features enrichi par les réanalyses. Vient ensuite l'apprentissage, du découpage en fenêtres jusqu'à la calibration probabiliste. La dernière étape est l'inférence, qui sélectionne le modèle retenu et produit une prévision par lots avec son enveloppe P10–P90. À chaque étape, nous distinguons ce qui est mesuré, téléchargé, reconstruit ou calculé, car la validité des résultats en dépend [45].

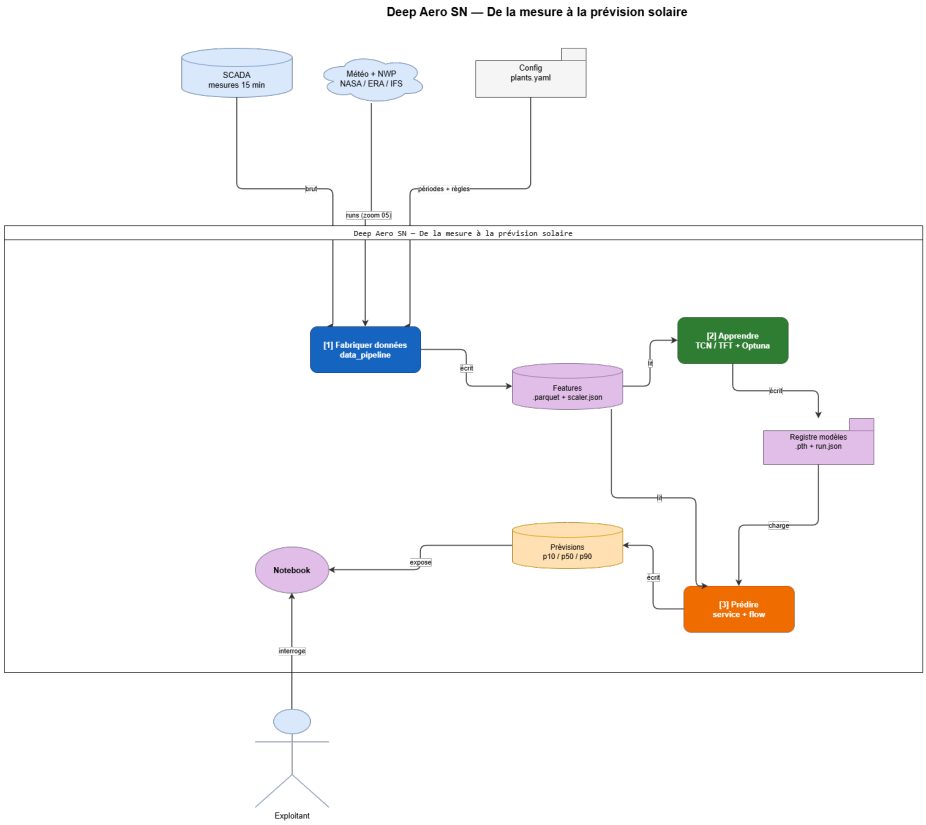


FIGURE 7.1 : Vue d'ensemble du système Deep Aero SN.

Le chapitre suit cet ordre. La section 7.2 présente le site et la section 7.3 les données. La section 7.4 détaille la mise en œuvre, de la prévention des fuites de données jusqu'à l'inférence. La section 7.5 évalue les modèles et en tire les conséquences pour la SENELEC. La section 7.6 conclut et ouvre des perspectives.

7.2 Présentation du site de Diass

7.2.1 La centrale solaire

La centrale de Diass est la première centrale solaire photovoltaïque publique du Sénégal. Elle appartient à la SENELEC, qui l'exploite. Elle se trouve dans le département de Mbour, à 40–50 km environ au sud-est de Dakar, près de l'aéroport international Blaise Diagne. Mise en service en mai 2022, elle représente un jalon pour la transition énergétique du pays [36]. Son financement repose sur un prêt de la banque allemande KfW d'environ 18 milliards de FCFA. Le tableau 7.1 rassemble ses caractéristiques.

Table 7.1 : Caractéristiques techniques de la centrale de Diass.

Paramètre	**Valeur**
Localisation	Diass, Mbour, Thiès, Sénégal
Coordonnées	14,65° N, 17,10° W
Puissance nominale AC	24,48 MW (36 × 680 kW)
Puissance crête DC	27,28 MWc (85 248 × 320 Wc)
Puissance publiée (MP)	23,114 MW
Technologie	Modules polycristallins Jinko JKM320PP-72-V
Structure	Fixe (inclinaison 15°, azimut 0° plein sud)
Nombre de modules	85 248
Onduleurs	36 Schneider Conext Core XC-680 (12 stations × 3)
Surface du champ	~40 ha
Mise en service	Mai 2022
Propriétaire et exploitant	SENELEC (centrale publique, PPA de 25 ans)
Production annuelle	~34 GWh/an
Période d'exploitation couverte	30/08/2025 – 31/08/2026
Résolution des exports SCADA	~15 min
Résolution du jeu de modélisation	1 h après rééchantillonnage
Volumétrie	35 196 lignes à 15 min (58 colonnes, dont 55 hors imputation), puis 8 800 lignes horaires (428 colonnes)
Grandeurs d'exploitation	~440 (36 onduleurs, compteur HTA, station météo)

Sources : [46, 44, 40].

Les modules sont polycristallins et posés sur une structure fixe, inclinée selon la latitude du site ($\varphi = 14{,}65°$ N). Ce choix maximise le captage annuel sans la complexité mécanique d'un tracker, et simplifie l'exploitation comme la maintenance. Il donne aussi une série de production régulière, structurée par l'arc diurne. En zone sahélienne, le gisement solaire figure parmi les plus élevés d'Afrique, avec une irradiance globale annuelle de l'ordre de 2 000 kWh/m² [16].

7.2.2 Contexte climatique et physique du site

Le modèle doit rendre compte de quatre phénomènes : le cycle diurne, imposé par la géométrie solaire, la variabilité nuageuse de l'hivernage, l'effet des aérosols pendant l'harmattan et les pertes thermiques liées aux températures élevées [2]. Chacun agit à une échelle de temps différente, du jour à la saison, ce qui justifie des variables construites à plusieurs échelles.

Géométrie solaire. À la latitude de Diass, le Soleil culmine à 75,8° au solstice d'été (juin) et à 51,9° au solstice d'hiver (décembre) [2]. La hauteur maximale suit la relation

$$\alpha_{s,\max} = 90° - \varphi + \delta,$$

où δ est la déclinaison solaire (±23,45°). Le Soleil passe presque au zénith aux équinoxes ($\alpha_s \approx 75°$), ce qui favorise la production. Orientés plein sud avec une inclinaison de 15°, les modules captent bien le rayonnement toute l'année sans suivi actif.

Profil d'irradiance. L'année se partage entre une saison sèche (novembre à mai) et l'hivernage (juin à octobre). En saison sèche, l'irradiance est élevée et régulière, avec un GHI moyen d'environ 6 kWh/m²/jour [16]. Le ciel reste globalement dégagé malgré l'harmattan de décembre à février, et c'est la période de production maximale [12]. En hivernage, le GHI moyen tombe à 4–5 kWh/m²/jour environ. Les nuages et les pluies rendent la production irrégulière, mais des températures plus basses réduisent les pertes thermiques.

Températures élevées. Les températures maximales atteignent régulièrement 35 à 40 °C en saison chaude (mars à juin), avec des records au-delà de 45 °C [1]. La température de cellule T_{cell} monte alors à 65–75 °C, ce qui coûte de la puissance :

$$\Delta P_{therm} = \gamma \cdot (T_{cell} - 25°C) \approx -0{,}43\,\%/°C \times 45°C \approx -19\,\%.$$

Le coefficient $\gamma = -0{,}43\,\%/°C$ est celui des modules polycristallins, et le calcul suit la formulation standard du modèle NOCT [2]. Le vent refroidit les modules et atténue en partie cette perte. Sa vitesse est donc une variable pertinente, même pour un site solaire [51].

Harmattan. Ce vent d'est venu du Sahara charge l'air de poussière pendant la saison sèche (novembre à février) [10]. Son effet est double. Il augmente l'épaisseur optique des aérosols τ_a et diffuse une part notable du rayonnement, si bien que la DNI peut perdre 15 à 30 % par rapport à un ciel clair [12]. Il dépose aussi de la poussière sur les modules, ce qui coûte 5 à 15 % de production après quelques semaines sans nettoyage [37]. Ces deux effets sont distincts de la variabilité nuageuse, et le feature engineering doit les traiter séparément.

Pluie. La figure 7.2 montre l'effet des épisodes pluvieux. Les jours où le cumul dépasse 1 mm (fond rouge) coïncident avec des creux de P_{ac}, alors que les périodes sèches (fond bleu) restent proches du profil nominal. Sur la période étudiée, on compte 96 jours pluvieux pour 271 jours secs, avec une production moyenne de 3,7 MW les jours de pluie contre 4,0 MW les jours secs (−6 %). La précipitation discrimine donc bien les épisodes de l'hivernage [12].

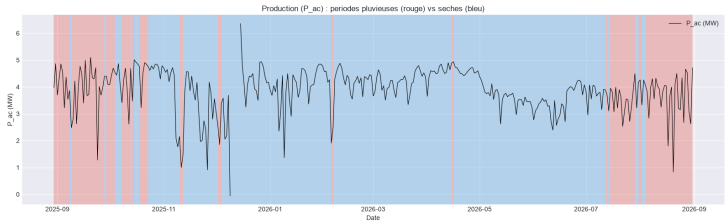


FIGURE 7.2 : Production journalière moyenne selon les périodes pluvieuses et sèches.

7.3 Jeux de données

7.3.1 Origine des données

Trois familles de données alimentent le jeu final : les mesures SCADA de la centrale, des réanalyses externes et des variables calculées à partir de la géométrie du site [33]. Leurs résolutions, leurs latences et leur fiabilité diffèrent. Plutôt que de les fondre en une série indifférenciée, le pipeline garde l'origine de chaque colonne, parce qu'une prévision hérite de l'incertitude de ses entrées [45]. Le tableau 7.2 récapitule ces sources.

Table 7.2 : Sources de données, nature et rôle dans le pipeline.

Source	Nature	Résolution	Variables
SCADA Schneider (6 classeurs Excel)	Mesure locale	~15 min	Puissances, tensions, courants, compteurs, station météo
NASA POWER (MERRA-2)	Réanalyse	Horaire	GHI, températures, vent, rosée, humidité, pression, pluie
CAMS (via Open-Meteo)	Réanalyse	Horaire	Épaisseur optique des aérosols, poussières, particules fines
ERA5 (via Open-Meteo)	Réanalyse	Horaire	DNI, DHI, couverture nuageuse, température, pression
ECMWF IFS HRES (via Open-Meteo)	Prévision NWP	Horaire	Nuages totaux, nuages bas, rayonnement courte longueur d'onde
Ineichen–Perez, installation	Calculée, paramètre	—	`clear sky ghi`, inclinaison, azimut, albédo

Données SCADA. Les données d'exploitation couvrent la période du 30 août 2025 au 31 août 2026. Elles proviennent de six classeurs Excel issus du système de supervision Schneider : paramètres DC, paramètres AC, mesures des DC Box, températures des cartes de puissance et deux ensembles de mesures météorologiques. Ces fichiers décrivent les 36 onduleurs, le compteur de livraison HTA et la station météorologique.

Réanalyses. La station météorologique du site ne fournit pas toutes les variables nécessaires pour décrire le rayonnement. Nous la complétons par des réanalyses horaires [33]. NASA POWER, associé aux données MERRA-2, est la source principale pour le GHI et plusieurs variables météorologiques. Pour juin à août 2026, son GHI n'était pas encore disponible au moment de l'extraction, et nous avons utilisé à la place les données d'Open-Meteo issues d'ERA5.

Les composantes DNI et DHI viennent d'Open-Meteo sur toute la période, car elles n'existent pas à la résolution horaire retenue dans l'interrogation de NASA POWER. La même source fournit la couverture nuageuse. CAMS, interrogé par l'API qualité de l'air d'Open-Meteo, apporte l'épaisseur optique des aérosols, les poussières et les particules fines [10].

Variables calculées et paramètres. Certaines variables ne sont pas des mesures. Le GHI de ciel clair est calculé avec le modèle d'Ineichen–Perez à partir des coordonnées du site, et son nom évite toute confusion avec l'albédo de surface [2]. L'inclinaison et l'azimut de surface décrivent la géométrie de l'installation (15° et 0°), et l'albédo du sol est une constante valant 0,2. Ces colonnes ne doivent pas être lues comme des observations SCADA, d'où le marquage de chaque variable selon quatre catégories : mesure locale, réanalyse, variable calculée ou paramètre d'installation.

Prévisions météorologiques numériques (NWP). Les prévisions du modèle ECMWF IFS HRES, figé dans la configuration, sont récupérées auprès d'Open-Meteo. Elles entrent dans le pipeline comme covariables futures. Trois variables (couverture nuageuse totale, nuages bas, rayonnement à courte longueur d'onde) sont injectées dans les fenêtres sous forme de tenseur, par le canal des covariables futures des modèles TCN et TFT [32]. Elles n'entrent ni dans le scaler des features ni dans les baselines déterministes : seul le modèle qui les consomme reçoit une tête supplémentaire.

La règle de causalité est une règle de disponibilité opérationnelle. Pour une fenêtre émise à l'instant $t_{\text{ém}}$, nous retenons le dernier run dont l'initialisation, augmentée de 6 heures, précède $t_{\text{ém}}$ (init + 6 h $\leq t_{\text{ém}}$), ces 6 heures correspondant à la borne haute de latence documentée par Open-Meteo. L'horizon demandé pour chaque run est calculé automatiquement (72 h + latence + marge = 85 heures), et chaque run est mis en cache sur disque.

Sur la période du projet, 1 461 cycles sont demandés et 1 460 sont exploitables ; trois runs sont incomplets dans l'archive, dont celui du 11 juin 2026 (11 heures manquantes sur 84 attendues, traitées par troncature de queue). Sur 8 342 fenêtres candidates, 95 sont écartées (1,14 %) parce que le run choisi ne couvre pas tous les temps cibles. Il reste 8 247 fenêtres, avec un âge de run compris entre 6 et 12 heures et un horizon maximal de 72 heures.

7.3.2 Ingestion et préparation

Cette section décrit le trajet des données, des exports SCADA jusqu'au jeu de features.

Ingestion SCADA. Nous lisons les six classeurs et normalisons les horodatages en combinant la colonne de date (format jour/mois/année) et l'heure extraite d'une seconde colonne. On obtient ainsi un index unique et trié, malgré des formats hétérogènes. Les colonnes utiles sont retrouvées par expressions régulières, pour résister aux variations de libellés.

Les grandeurs sont ramenées à l'échelle de la centrale : tensions et courants moyennés par équipement, puissances sommées (la puissance DC est la somme des puissances des boxes). Les compteurs d'énergie, cumulatifs, sont différenciés puis bornés à zéro, pour qu'une remise à zéro du compteur ne produise pas d'énergie négative. Les puissances SCADA, en kW, sont converties en MW (puissance DC, puissance AC, puissance redresseur) ; les grandeurs structurantes (tension réseau, fréquence réseau, facteur de puissance, irradiance) sont traitées de la même façon.

Fusion sur une grille à 15 minutes. Les réanalyses ne sont pas simplement concaténées aux mesures. Elles sont alignées sur les horodatages SCADA, puis projetées sur une grille unique à 15 minutes : les séries SCADA y sont réindexées et les réanalyses propagées vers l'avant.

Pour une variable disponible dans plusieurs sources, l'ordre de priorité va des mesures locales à NASA POWER, puis à ERA5, ce qui reflète la confiance accordée à chacune [33]. Open-Meteo prend le relais quand une valeur NASA POWER manque, ce qui évite de perdre les derniers mois de la période. Les valeurs sentinelles des réanalyses, qui signalent une donnée absente, sont remplacées par des valeurs manquantes. Les trous courts de télémesure sont comblés par interpolation temporelle, limitée à 24 heures et sans extrapolation. Les directions de vent sont décomposées en composantes sinusoïdales puis recombinées, pour éviter les sauts artificiels autour du nord.

Valeurs manquantes. Les exports SCADA contiennent une vraie coupure de télémesure d'environ six jours, du 9 au 15 décembre 2025. Ces observations n'existent pas dans les fichiers sources, nous ne les reconstruisons donc pas par interpolation : elles restent manquantes. Pour l'évaluation, une absence de mesure n'est jamais assimilée à une production nulle. Les périodes nocturnes sont distinguées des vraies absences de télémesure grâce aux informations temporelles et radiatives [2].

Variables calculées et historiques. Le GHI de ciel clair est évalué avec le modèle d'Ineichen–Perez, puis aligné sur la géométrie du site [2]. Les variables électriques historiques sont dérivées de manière strictement causale, comme expliqué à la section 7.4.1 : retards de 24 heures sur les tensions, les courants et la fréquence réseau (écarts bornés à ±5 Hz), rendements onduleur encadrés entre 0,5 et 1,0 avec un repli nominal à 0,97, rapport des courants alternatif et continu, indice d'encrassement établi à la veille, borné puis propagé, et compteurs d'énergie convertis en incréments ou en cumuls sur 24 heures [45].

Jeu final. Après normalisation des noms, agrégation des mesures, harmonisation temporelle, enrichissement par les réanalyses et ajout des variables physiques, les données sources sont enregistrées dans un fichier de données (35 196 lignes à 15 minutes, 58 colonnes dont 55 hors imputation). Le pipeline rééchantillonne ensuite à l'heure et sauvegarde le jeu de features utilisé par les modèles, de 8 800 lignes horaires et 428 colonnes dans le run du 6 octobre 2026, pour 427 features générées.

Le pipeline s'appuie sur des outils courants : Great Expectations pour le contrôle des schémas, scikit-learn et SHAP pour la sélection, Optuna pour l'optimisation [3], MLflow pour la traçabilité et Prefect pour l'orchestration [45].

7.3.3 Analyse exploratoire (EDA)

Avant toute modélisation, l'exploration sert à repérer les rythmes temporels, les corrélations entre variables et les particularités du site [22].

Profils temporels et corrélations

La figure 7.3 donne le profil journalier moyen, où l'on retrouve l'arc diurne attendu : l'irradiance et la production culminent vers midi, la température suit avec environ deux heures de retard, et le vent est minimal en fin de nuit [12]. La figure 7.4 détaille la semaine du 6 juin 2026 : la production épouse l'irradiance, avec des chutes brutales au passage des nuages, qui sont la principale source d'erreur à court terme [39]. La matrice de corrélation de la figure 7.5 confirme enfin que l'irradiance domine la production et que la couverture nuageuse joue en sens inverse.

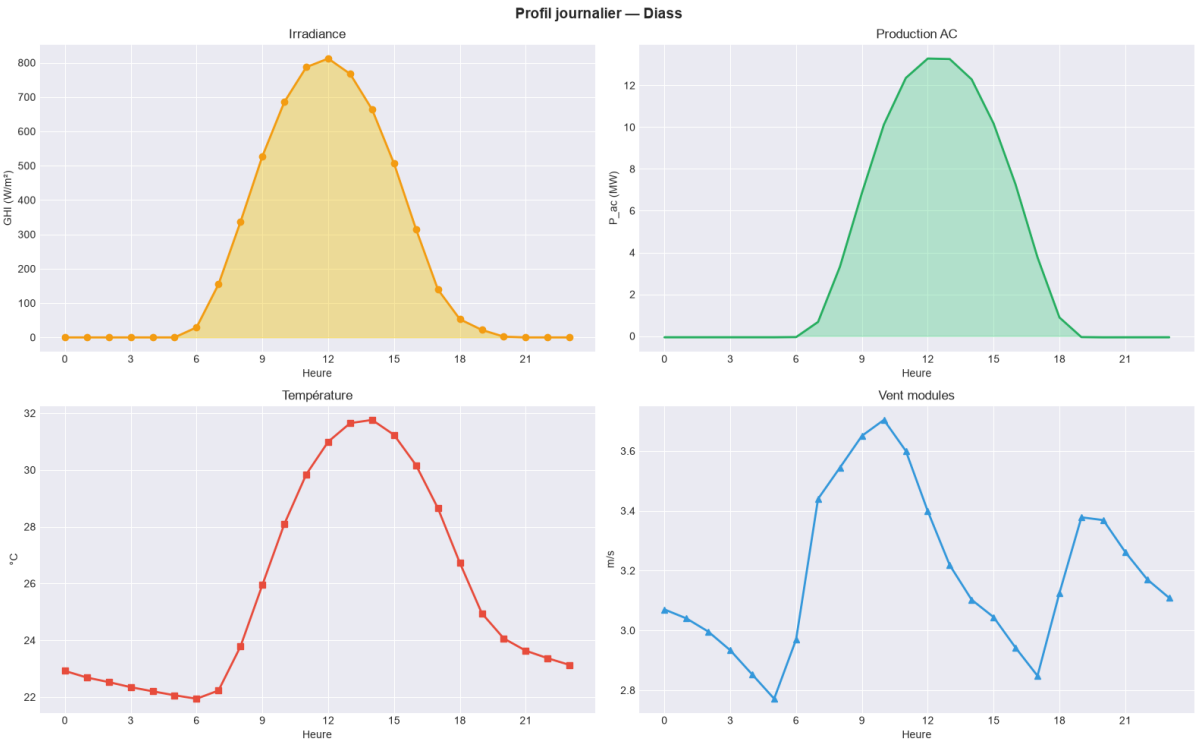


FIGURE 7.3 : Profil journalier moyen : irradiance, production, température et vent.

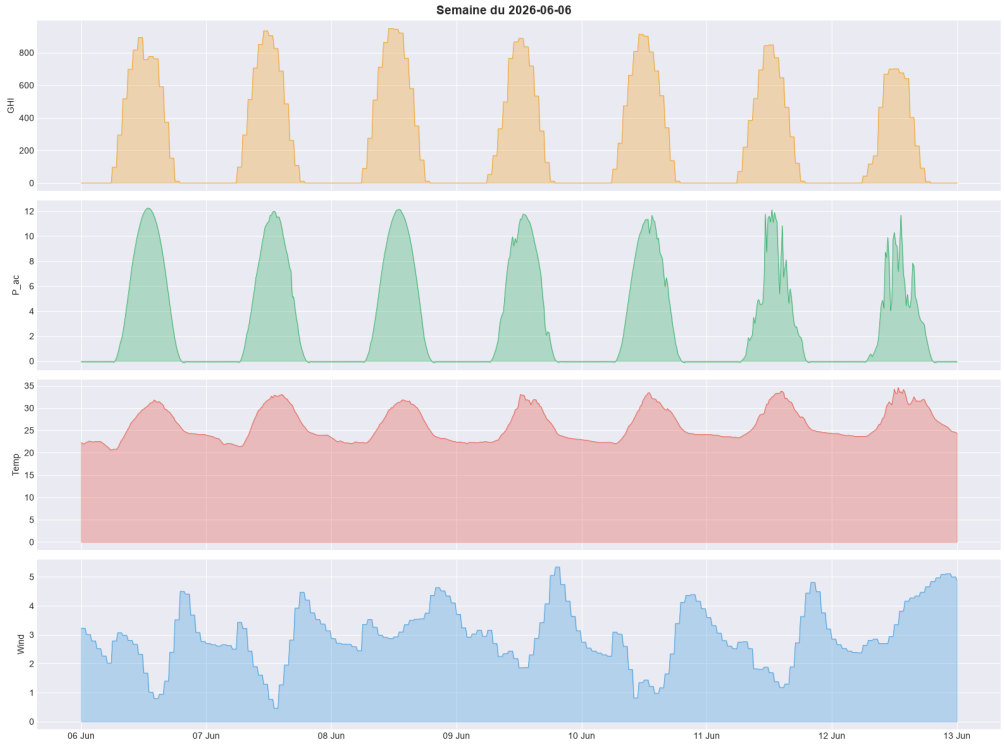


FIGURE 7.4 : Semaine du 6 juin 2026 : irradiance, production, température et vent.

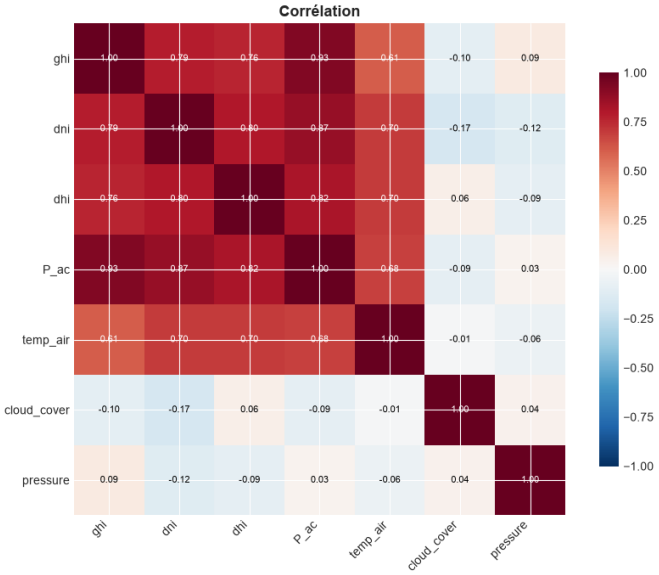


FIGURE 7.5 : Matrice de corrélation des sept variables principales.

La figure 7.6 montre une relation entre GHI et production quasi linéaire sous ciel clair, qui se disperse dès que le ciel se couvre.

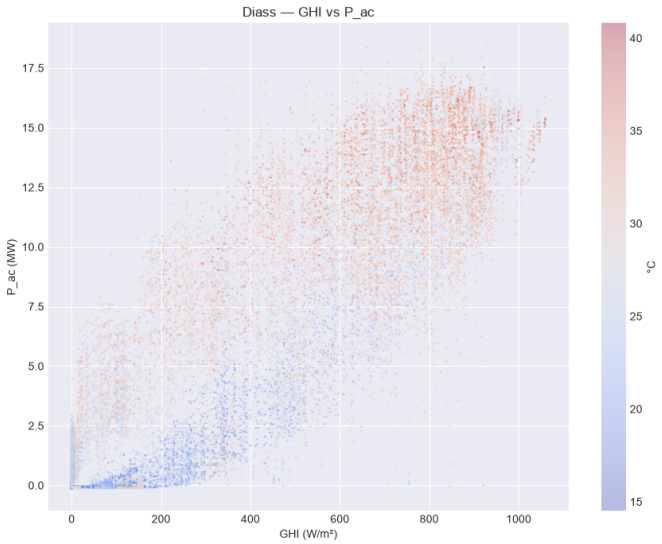


FIGURE 7.6 : Relation GHI–production, colorée par la température ambiante.

Avec le modèle NOCT et un coefficient $\gamma = -0{,}43\,\%/°C$, la température de cellule moyenne sur Diass est de 33,3 °C (maximum 70,8 °C), pour une perte thermique moyenne de $-3{,}56\,\%$ [2]. Ce n'est pas négligeable pour la production estivale. La figure 7.7 montre en outre que la variabilité du GHI augmente avec la couverture nuageuse, ce qui justifie l'usage de lags courts d'irradiance.

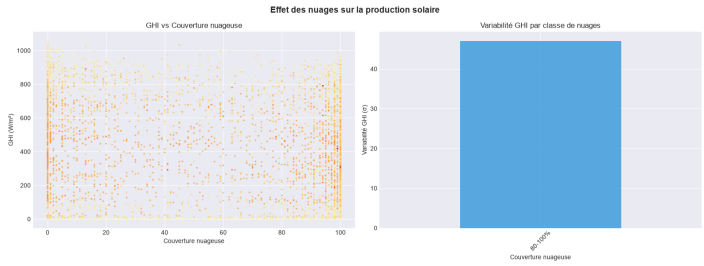


FIGURE 7.7 : Effet de la couverture nuageuse sur la variabilité du GHI.

L'épaisseur optique des aérosols τ_a vaut en moyenne 0,31 sur la période et atteint son maximum en mai [10]. La figure 7.8 met l'irradiance en regard de cet indice et en détaille l'évolution mensuelle.

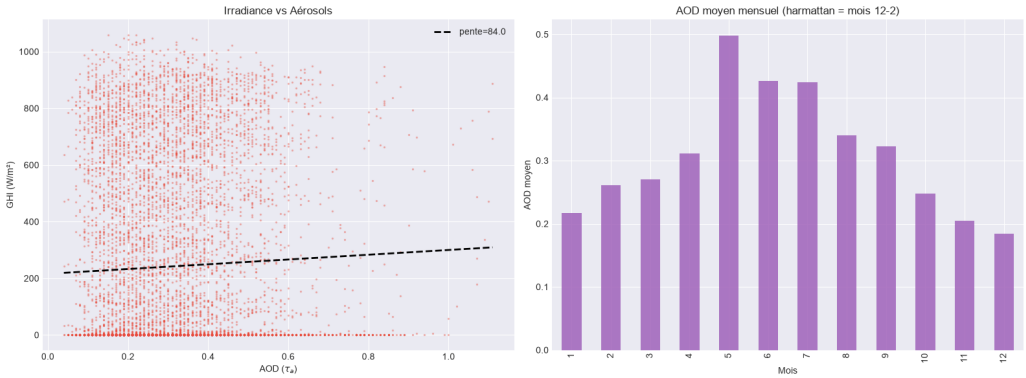


FIGURE 7.8 : GHI selon l'épaisseur optique des aérosols et AOD mensuel.

Statistiques descriptives

Le tableau 7.3 résume les principales variables.

Table 7.3 : Statistiques descriptives du fichier brut de Diass, 30/08/2025–31/08/2026.

Variable	N	Min	Médiane	Moyenne	Max	Écart-type
GHI (W/m²)	35 196	0	8,18	241,95	1 059,53	320,13
Production P_{ac} (MW)	34 602	−0,14	−0,03	3,90	18,45	5,38
Température air (°C)	35 196	14,16	25,70	25,71	40,80	4,75
Humidité (%)	35 196	6,92	74,43	70,05	100,0	22,79
Vitesse vent 2 m (m/s)	35 196	0,05	3,22	3,19	7,54	1,40
DNI (W/m²)	35 196	0	0	223,31	856,20	284,28
Couverture nuageuse (%)	35 196	0	63,0	53,96	100,0	41,96
AOD τ_a	35 196	0,04	0,29	0,31	1,11	0,15

Deux valeurs demandent une explication. La médiane du GHI est très basse (8,18 W/m²) alors que sa moyenne atteint 241,95 W/m² : cela tient à l'alternance jour/nuit sur un jeu à 15 minutes et n'a rien d'anormal [2]. Le minimum de production est légèrement négatif (−0,14 MW) parce que les onduleurs consomment un peu de puissance en veille la nuit.

Il faudra donc masquer les pas nocturnes lors de l'évaluation, seuls les pas diurnes ayant un sens pour la prévision solaire. Les variables électriques SCADA comptent environ 34 600 observations non manquantes (T_{inv} : 34 606, P_{ac} : 34 602, G_{sw} : 34 601), l'écart avec 35 196 correspondant aux absences réelles, conservées comme discontinuités. La distribution de la production présente un premier pic à 0 (nuit) et un second autour de 13–14 MW (ciel dégagé), avec une répartition à peu près uniforme entre les deux [12].

Rythmes temporels

Quatre échelles de variation se dégagent. Le cycle diurne domine : production nulle la nuit, montée à l'aube (6h–7h), pic à midi solaire (12h–13h), baisse au coucher (18h–19h), avec une forme d'arc fixée par la géométrie solaire locale et l'inclinaison des modules [2].

Le cycle hebdomadaire est faible mais mesurable, et tient à l'activité météorologique (passages de fronts en hivernage) [12]. Le cycle saisonnier oppose la saison sèche, à production élevée et régulière, à l'hivernage, à production plus basse et variable [37]. S'y ajoutent des perturbations ponctuelles : chutes brutales au passage des nuages en hivernage, baisse progressive due à l'encrassement en saison sèche, baisses d'irradiance dues à l'harmattan de décembre à février [10].

Ces rythmes guident le choix des variables. Le cycle diurne est capté par les lags horaires, le cycle saisonnier par les variables temporelles (jour de l'année, indicateur de saison), les perturbations par l'irradiance et la météorologie. Le site a donc les traits d'un site solaire typique du

Sahel : forte irradiance annuelle, variabilité nuageuse marquée en hivernage et aérosols importants en saison sèche [16].

Avant de modéliser, nous situons le gisement mesuré et le rendement obtenu par rapport aux valeurs publiées pour cette même centrale. Nous avons vérifié à la source trois références : un travail sur la performance énergétique de la centrale [37], une étude de prévision par réseaux de neurones [11] et une référence de modélisation stochastique du rayonnement [35].

Le calcul suit la norme IEC 61724 sur la période réellement couverte par nos données. La puissance de référence est la puissance nominale AC des onduleurs ($P_{\text{nom}} = 36 \times 680 = 24{,}48$ MW). Le gisement de référence Y_{ref} est intégré sur l'irradiance globale horizontale, pour rester comparable à la source publiée. Le tableau 7.4 rapproche nos grandeurs des valeurs publiées.

Table 7.4 : Comparaison du gisement et du rendement aux valeurs publiées, 30/08/2025–31/08/2026.

Grandeur	**deep-aero-sn**	**Ndiaye et al. [37]**	**Écart**
Période	2025–2026	2022	–
Gisement Y_{ref} (h/j)	5,80	5,83	−0,5 %
Rendement final Y_{f} (h/j)	3,76	3,95	−4,8 %
Performance ratio (%)	64,8	64,65–75,82	dans la bande
Énergie annualisée (GWh/an)	33,6	~33,3	+0,9 %
Puissance de référence (MW)	24,48 (AC)	23,114 (MP)	+5,9 %

Le gisement est reproduit à un demi-pour-cent près, ce qui montre que le site, son instrumentation et notre calcul d'irradiance sont cohérents avec la source. Le rendement final est un peu en retrait, mais le *performance ratio* tombe dans la plage publiée. Deux précautions s'imposent. Le PR publié est un PR de champ, mesuré en fonctionnement continu, et non un PR final. Notre valeur dépend en outre de la puissance de référence choisie ; en reprenant la puissance publiée, le rendement et le PR restent dans la plage attendue, si bien que la conclusion ne dépend pas de ce choix.

Un écart de capacité reste en revanche inexpliqué. Le matériel installé donne $85\,248 \times 320$ W = 27,28 MWc en continu, contre 23,114 MP publiés, soit 15 % de moins. La puissance unitaire vient de la fiche technique du module Jinko JKM320PP-72-V et le nombre de modules est connu sans ambiguïté. Nous avons préféré garder le matériel vérifiable et signaler l'écart plutôt que de l'ajuster. Les documents de réception de la centrale permettraient de le trancher.

Le contrôle appelle enfin deux remarques. La géométrie retenue (inclinaison 15°, azimut 0°) correspond à la latitude du site, ce que la littérature sahélienne corrobore. Le rapport $g_{\text{poa}}/g_{\text{hi}} \simeq 0{,}88$, inférieur à 1, est physiquement attendu : à faible élévation, une partie du flux diffus horizontal n'est pas interceptée par un plan incliné.

Nous n'avons pas retenu comme référence les métriques de Diop et al. [11], car leur RMSE (0,003 kWh) est inférieure à leur MAE (0,0223 kWh), ce qui est mathématiquement impossible. Mbaye et al. [35] porte, de son côté, sur le rayonnement à 24 h et non sur la puissance. Le

gisement et le PR concordent donc avec les valeurs publiées ; les écarts restants concernent la capacité nominale, pas la ressource.

Bilan de la section. Les données couvrent un an d'exploitation, avec une coupure de six jours laissée telle quelle, et leur cohérence avec les valeurs publiées est établie. Elles peuvent donc servir de base à la modélisation.

7.4 Mise en œuvre

7.4.1 Prévention du data leakage

Le problème

Les exports SCADA de Diass contiennent des variables électriques instantanées (courants et tensions AC et DC, puissances, facteur de puissance, compteurs d'énergie et fréquence réseau), mesurées au même instant t que la cible, la production instantanée. Les utiliser telles quelles crée une circularité mathématique, c'est-à-dire une fuite de données : le capteur de puissance AC et le capteur de courant AC mesurent le même flux en sortie d'onduleur, et l'électrotechnique les relie par une égalité stricte,

$$P_{ac} = V_{ac} \times I_{ac} \times \cos(\varphi) \times \sqrt{3}.$$

Un modèle de deep learning qui reçoit ces grandeurs trouve par descente de gradient la solution la plus facile : apprendre cette formule au lieu d'anticiper les nuages ou la météo [45]. En exploitation, ces télémesures n'existent pas à l'instant t lorsqu'on prédit t+24 h. Un modèle entraîné ainsi serait inutilisable.

Un second écueil tient à la persistance. La puissance PV est très continue de jour, et des lags électriques trop proches (t-1h, t-2h) transforment le modèle en simple opérateur de décalage, qui prédit « demain = aujourd'hui ». Or les phénomènes sahéliens (passages nuageux rapides, tempêtes de poussière, vents de mousson) provoquent des variations brutales [12]. Un modèle persistant affiche un bon R^2 moyen par ciel bleu, puis de fortes erreurs dès qu'un nuage passe, au détriment de la stabilité du réseau [39].

Des variables causales

Nous ne supprimons pas le SCADA électrique : nous le transformons en variables causales. Les mesures brutes à l'instant t deviennent des indicateurs d'état connus à $t-24$ h, c'est-à-dire un passé légitime pour une prévision *day-ahead*. Les variables électriques de la veille ne disent rien du soleil de demain, mais elles décrivent l'état thermique de l'onduleur et l'encrassement des panneaux [37]. En les combinant avec la physique (par exemple le rapport $P_{dc,\text{lag 24h}}/G_{sw,\text{lag 24h}}$), on obtient un Performance Ratio dynamique, qui permet au TFT et au TCN d'ajuster la météo globale aux pertes réelles de la centrale [32].

Le tableau 7.5 donne la correspondance entre chaque variable brute et sa version causale. Les 11 variables contemporaines interdites sont remplacées par 11 variables transformées, toutes retardées d'au moins 24 heures ou calculées sur des fenêtres glissantes passées.

TABLE 7.5 : Substitution anti-fuite : chaque grandeur contemporaine devient un retard de 24 heures ou un indicateur construit sur le passé.

Variable brute	Nature du risque	Remplacement	Ce que le remplacement apprend
`I ac`, `I dc`	Fuite totale	`I dc lag 24h` et rapport `I dc lag 24h` / `G sw lag 24h`	Encrassement des modules
`V dc`, `V dc inv`	Fuite indirecte	`V dc lag 24h` et écart `V dc lag 4h` − `temp air lag 4h`	Surchauffe de cellule déduite de la chute de tension
`P dc`, `P dc inv`	Fuite la plus forte	Rapport `P ac lag 24h` / `P dc lag 24h`	Rendement de conversion réel de l'onduleur
`V ac`, `grid freq`	Bruit proche de la cible	`V ac std 24h`, écart-type glissant	Stabilité du réseau et curtailment
`cos phi`	Fuite électrotechnique	`cos phi lag 24h`	Comportement de régulation de l'onduleur
`energy *kwh`	Cumul ouvert sur la durée	Différentiel `energy ac lag 24h` − `energy ac lag 25h`	Productivité globale et vieillissement long terme
`insolacion kwh m2`	Intégration refermée sur elle-même	`insolacion lag 24h`	Inertie thermique résiduelle du sol

Mise en œuvre et garanties

Ces transformations sont appliquées par le pipeline. Le décalage est de 96 pas, soit 24 heures à la résolution de 15 minutes, et les retards restent indéfinis sur les 96 premiers pas, faute de passé.

Trois rapports composites confrontent le passé électrique à l'irradiance : l'encrassement (courant continu de la veille sur irradiance au plan de la veille), la conversion de l'onduleur (puissances alternative et continue de la veille) et le rapport des courants alternatif et continu de la veille. Un écart-type glissant sur 24 heures, purement passé, résume la tension réseau sur la fenêtre $[t-95,\ t]$. Les onze variables brutes ne sont jamais copiées dans le jeu de sortie : seules leurs versions transformées y figurent.

Les étapes construisant retards et statistiques glissantes obéissent à la même règle : à l'instant t, seules les données antérieures ou contemporaines ($\leq t$) sont accessibles [7]. Le décalage temporel de h pas produit, pour chaque colonne, sa version retardée de h pas. La moyenne glissante sur w pas porte sur $[t-w+1,\ t]$, donc sur le passé et le présent. La différence à p pas vaut $\text{value}[t] - \text{value}[t-p]$, et les profils horaire et journalier utilisent une moyenne cumulée causale qui n'intègre que les occurrences $\leq t$.

Exclusion automatique des fuites résiduelles

En amont de la sélection, le pipeline écarte toute variable numérique dont la corrélation de Pearson avec la production instantanée dépasse 0,99 en valeur absolue, sauf pour les drivers physiques explicitement autorisés : irradiance, position solaire, couverture nuageuse. Dans le run du 6 octobre 2026, une seule variable est ainsi retirée, une dérivée saisonnière de la production. Avec la transformation causale, ce garde-fou assure que les modèles n'apprennent que des relations utilisables en exploitation, et il fonde la validité de l'évaluation sur le segment de test [45].

7.4.2 Ingénierie des variables

La construction des variables repose sur un registre déterministe de sept étapes, exécutées en séquence. Le tableau 7.6 donne un aperçu des variables propres au site.

Table 7.6 : Features spécifiques au site de Diass (extrait).

Catégorie	Feature	Description
Solaire	`solar elevation`	Hauteur solaire (α_s) [2]
	`clear sky ghi`	GHI théorique ciel clair (Ineichen–Perez) [2]
	`g poa`	Irradiance sur le plan des modules
	`module temp`	Température de cellule (modèle NOCT) [2]
Temporel	`hour sin/cos`	Heure cyclique
	`is harmattan`	Indicateur saison sèche (déc.–fév.) [10]
	`is mousson`	Indicateur hivernage (juil.–sept.) [12]
Lags	`ghi lag 1h, 24h, 72h`	Lags causaux d'irradiance
	`P ac lag 1h – 72h`	Lags causaux de puissance
	`soiling ratio hist 24h`	Indice d'encrassement $J-1$ [37]

Au-delà de cet extrait, l'ensemble des variables mobilisées se répartit en six familles. La distinction essentielle tient à leur régime de disponibilité : l'horloge cyclique et la géométrie solaire relèvent d'un calcul déterministe par éphémérides, connu à l'avance ; l'irradiance et la température proviennent des capteurs au sol ou des NWP ; les aérosols et les nuages décrivent l'état atmosphérique, nécessairement prévu à l'horizon de la prévision ; les lags et statistiques glissantes enfin ne s'appuient que sur le passé de la série, ce qui préserve la causalité de l'ensemble.

Voici les sept étapes de construction des variables, dans leur ordre d'exécution. Chacune ajoute ses colonnes au tableau de données, et la cible, la production instantanée, est préservée tout au long de la chaîne.

1. L'**encodage cyclique du temps** code l'heure, le jour de la semaine, le jour de l'année et le mois, et crée les indicateurs `is daytime`, `is harmattan`, `is mousson` et `is hivernage`, qui marquent les régimes saisonniers sahéliens.

2. L'**enrichissement météorologique** dérive les variables météorologiques communes (humidité, point de rosée, pression, précipitations) et leurs transformations utiles.
3. L'**analyse de la fréquence réseau** traite la fréquence du réseau et ses écarts à 50 Hz comme indicateurs de stabilité et de curtailment, à partir des historiques $J-1$ seulement [39].
4. Le **calcul de la physique solaire** détermine l'élévation, l'azimut et le zénith solaires, la déclinaison, la masse d'air, `clear sky ghi`, les indices de ciel clair, `g poa`, la température de cellule et les pertes thermiques.
5. L'**enrichissement solaire** est prévu pour les variables météorologiques propres au solaire.
6. La **transformation électrique** n'utilise que les colonnes historiques $J-1$ (rendements onduleur bornés, ratios de conversion, drapeaux de clipping et d'état opérationnel) et refuse toute grandeur électrique contemporaine de la cible.
7. La **construction des retards et des statistiques glissantes** produit les retards causaux (par exemple 1, 2, 3, 24, 48 et 72 heures pour `ghi` et `P ac`) et des statistiques glissantes calculées sur le passé et le présent uniquement [7].

Deux blocs de traitement restent hors du dispositif par défaut : l'analyse spectrale de la fréquence réseau, et les pertes détaillées des modules (dégradation LID et PID, désaccord de courant, câblage et vieillissement annuel). Ils sont disponibles mais n'ont pas été exécutés dans le run courant. L'indice d'encrassement ne provient pas de ces étapes : il est calculé directement comme le rapport $I_{\mathrm{dc},J-1}/G_{\mathrm{sw},J-1}$, borné puis propagé.

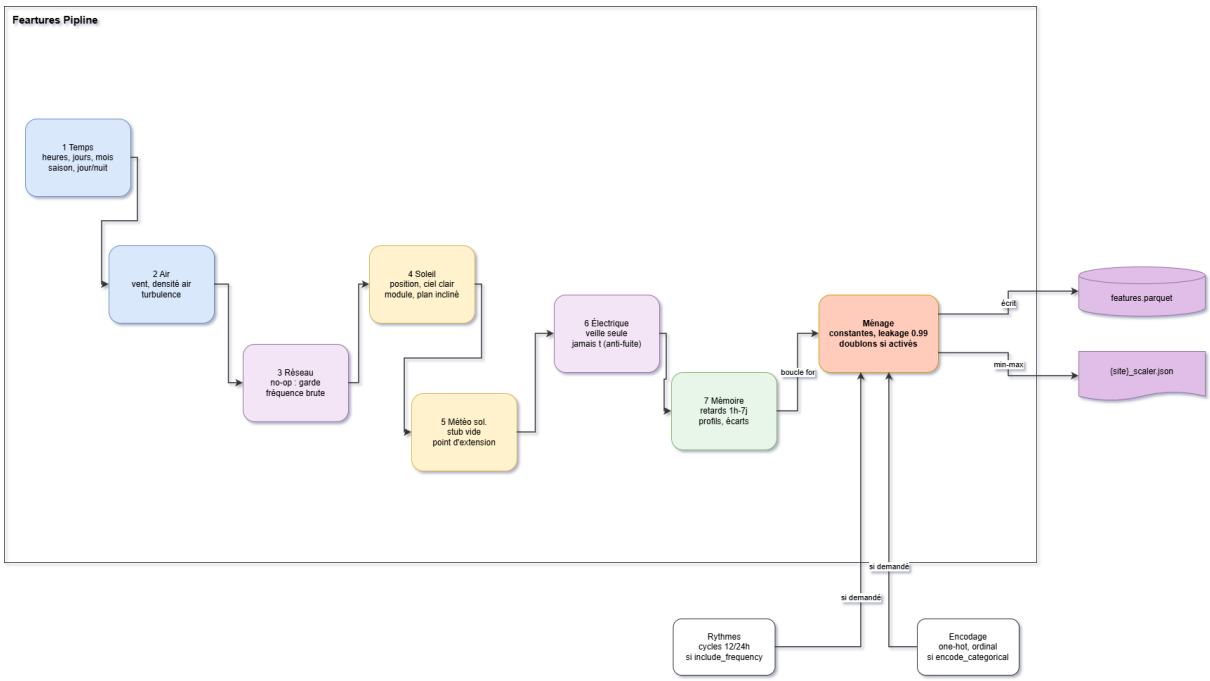


FIGURE 7.9 : Pipeline de feature engineering et contrôles anti-fuite.

La figure 7.9 résume l'enchaînement. Le pipeline charge le fichier brut et exécute six opérations. Le rééchantillonnage passe de 15 minutes à 1 heure (8 800 lignes), par moyenne pour

les grandeurs instantanées, par somme pour les taux et par report de la dernière valeur pour les compteurs cumulatifs. Great Expectations valide les colonnes critiques.

Le prétraitement nettoie les horodatages, borne les valeurs aberrantes, interpole sur 6 heures au plus, propage sur 24 heures au plus et remplace par une valeur manquante les observations situées au-delà de $3 \times \text{IQR}$. Les sept étapes de construction s'exécutent ensuite. Un nettoyage supprime les colonnes à variance nulle (la cible est préservée) et les dérivées quasi linéaires de la cible, selon le seuil $|\rho| > 0{,}99$ défini à la section 7.4.1. La sélection applique enfin les sept méthodes décrites à la section 7.4.3.

Dans le run de référence du 6 octobre 2026, la chaîne fournit 543 variables numériques à la sélection, qui en retient 424 (cible exclue). La dimension d'entrée des modèles est donc de 425.

7.4.3 Sélection de variables

La sélection applique sept méthodes indépendantes, et la sélection finale est l'union de leurs résultats. Cette stratégie est prudente : elle favorise le rappel au détriment de la compacité [14].

Table 7.7 : Résultats de la sélection sur Diass : 543 variables en entrée, 424 retenues en union des sept méthodes.

Méthode	Retenues	Sur	%	Critère
Correlation	349	543	64,3	$\lvert r \rvert > 0{,}01$
Mutual Information	2	543	0,4	Top 2 (`P ac max 3h`, `P ac max 6h`)
PCA	0	543	0,0	(composantes, pas features)
RFE	50	543	9,2	Rang 1 (`dust`, `pressure`, `wind gust`…)
VIF	527	543	97,1	VIF $\leq 5{,}0$
Permutation	2	543	0,4	Top 2 (`P ac trend dev`, `G sw`)
SHAP	2	543	0,4	Top 2 (`P ac trend dev`, `P ac hourly profile`)
Union brute	542	543	99,8	—
Redondances dédupliquées	118	—	—	$\lvert r \rvert > 0{,}90$
Union finale	**424**	**543**	**78,1**	—

Ces méthodes ne mesurent pas la même chose, comme le détaille le tableau 7.7. La corrélation de Pearson est un filtre linéaire et rapide : elle repère les drivers physiques directs (irradiance, rayonnement descendant), mais rate les dépendances non linéaires, et retient 349 variables (64,3 %). L'information mutuelle capte toute dépendance, mais reste très sélective.

La PCA réduit la dimension sans sélectionner de colonnes : elle éclaire la structure latente du jeu, dominée par l'arc diurne, mais ne fournit pas de colonnes directement interprétables pour le TFT [32]. Le RFE, élimination récursive fondée sur une régression linéaire, retient 50 variables (9,2 %), surtout météorologiques et physiques. Le VIF mesure la multicolinéarité et

non le pouvoir prédictif ; avec 527 variables retenues (97,1 %), il est le plus permissif. La permutation importance et le SHAP se calculent après l'entraînement, très sélectives, et retiennent notamment la tendance de production sur les dernières heures. La figure 7.10 compare les volumes retenus.

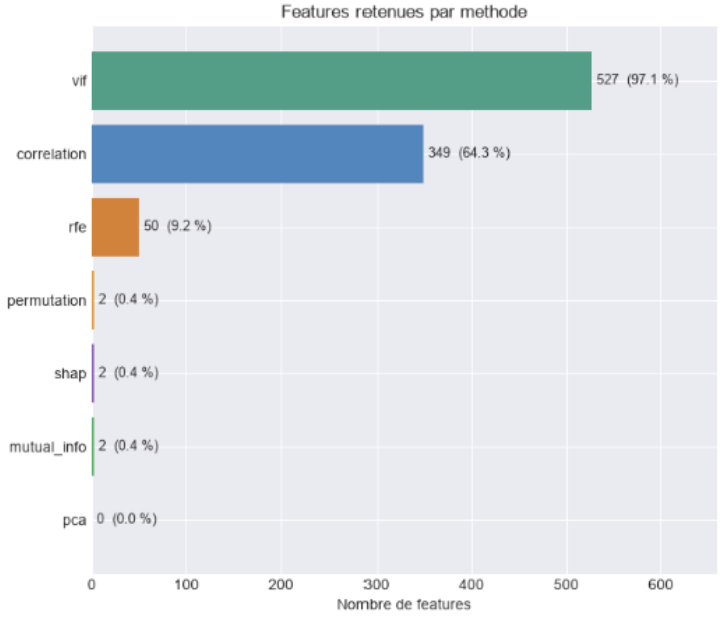


FIGURE 7.10 : Variables retenues par méthode de sélection.

Les méthodes s'accordent peu : aucune variable n'est retenue par les sept, et 194 ne le sont que par une seule. Un vote majoritaire écarterait ce que seule une méthode sait isoler ; nous gardons donc l'union. Les 424 variables retenues couvrent l'ensemble des familles attendues pour un site solaire. La figure 7.11 en donne le détail par méthode, tandis que le tableau 7.8 et la figure 7.12 en fournissent la répartition : lags et fenêtres $J-1$ (32 %), réanalyse atmosphérique (29 %), météo locale (13 %), physique PV (5 %). Aucune famille n'est sacrifiée.

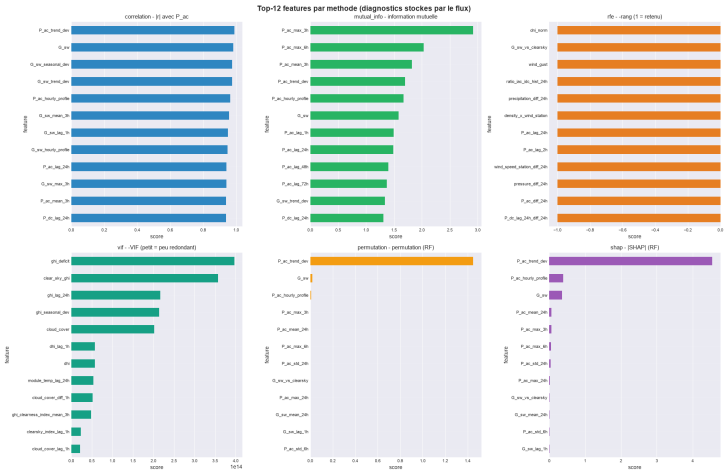


FIGURE 7.11 : Top-12 des features par méthode de sélection.

TABLE 7.8 : Répartition par famille de l'union finale (424 features).

Famille	**N**	**%**
Lags / fenêtres $J-1$	137	32,3
Réanalyse / atmosphère	123	29,0
Autres	62	14,6
Météo locale (station)	54	12,7
Physique PV	23	5,4
Rendement / onduleur	15	3,5
Temporel (sin/cos/heure)	10	2,4
194 retenues par une seule méthode, aucune par les sept		

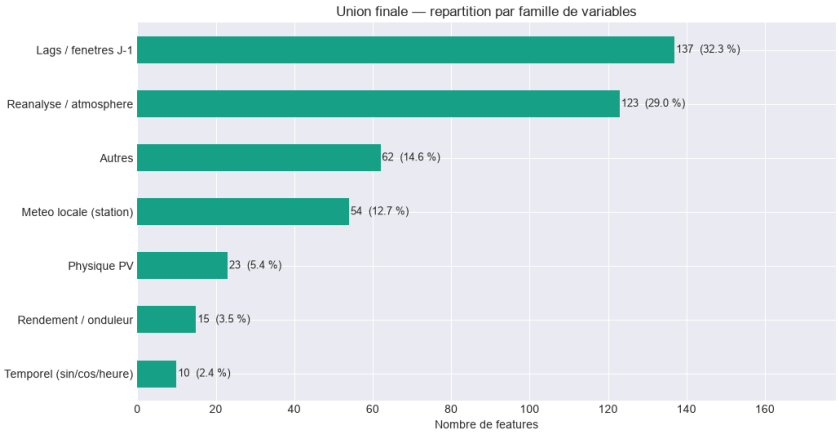


FIGURE 7.12 : Répartition des 424 variables retenues par famille.

Au bilan, 58 colonnes brutes entrent dans le pipeline, 543 variables en sortent et la sélection en garde 424, après exclusion des fuites et suppression des redondances.

7.4.4 Algorithmes retenus et justifications

Nous comparons cinq modèles sur un protocole commun. La persistance sert de repère minimal : elle donne le niveau atteint sans aucun apprentissage [22]. Le MLP de base est un repère appris sans mémoire temporelle [42], et le LSTM en ajoute une [20]. Le TCN et le TFT sont les deux architectures avancées. Elles seules reçoivent les covariables NWP par le canal des covariables futures et produisent des prévisions probabilistes.

Nous avons retenu le TCN à cause de la forme du signal. La convolution dilatée capte bien le motif diurne quasi périodique du solaire, et le TCN compte un ordre de grandeur de paramètres en moins que le TFT, ce qui limite le risque de surapprentissage sur une seule année de données [6]. Le TFT, lui, a été retenu pour son interprétabilité (sélection de variables, poids d'attention), qui permet à un opérateur de comprendre pourquoi le modèle annonce une baisse à un horizon donné [32].

Le TCN et le TFT sont entraînés avec la perte hybride multi-tâche, définie à l'équation (6.2) du chapitre 6, et non avec une simple MSE. Sa composante MSE vise l'exactitude ponctuelle (R^2, RMSE), sa composante pinball la calibration des intervalles [28].

Pour Diass, le poids de la MSE vaut $w_{\text{mse}} = 0{,}5$ par défaut, et la recherche d'hyperparamètres explore $w_{\text{mse}} \in [0{,}3; 0{,}8]$. Ce compromis se justifie par le climat sahélien : avec des passages nuageux rapides et des tempêtes de poussière, estimer l'incertitude compte autant que prévoir la valeur centrale pour gérer le réseau [17].

7.4.5 Entraînement et optimisation

Tous les modèles sont entraînés pour un horizon de 72 heures. Les trois repères (persistance, MLP, LSTM de base) passent par le pipeline des baselines, avec dix essais d'optimisation. Le TCN et le TFT passent par le pipeline général, avec dix essais, la perte hybride MSE + pinball et les covariables NWP injectées par le canal futur. La figure 7.13 décrit ce pipeline.

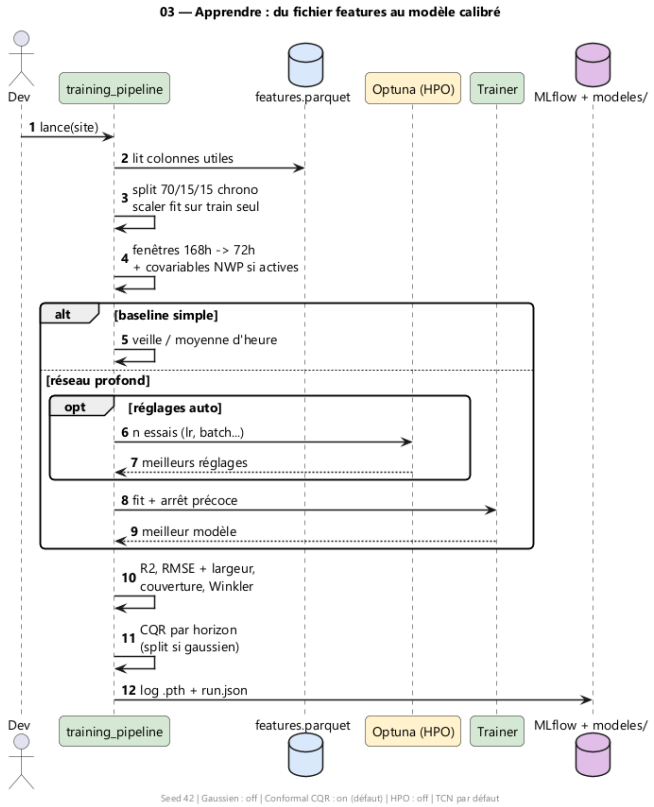


FIGURE 7.13 : Pipeline d'entraînement : découpage, Optuna, early stopping et calibration CQR.

Optimisation des hyperparamètres

Les hyperparamètres (taux d'apprentissage, taille de lot, poids de la MSE, planificateur de taux, fenêtres, architecture) ne sont pas fixés manuellement. Optuna propose des combinaisons et les évalue en entraînant le modèle puis en mesurant sa performance de validation, ce qui remplace la grille exhaustive ou le réglage manuel [3]. L'échantillonneur est un TPE (Tree-structured Parzen Estimator).

Cette méthode bayésienne modélise la distribution des bons résultats et concentre les essais là où ils sont prometteurs, au lieu d'explorer l'espace de façon uniforme. Chaque essai est tracé avec son objectif, ce qui permet de suivre la convergence. Un élagage par la médiane arrête les essais nettement moins bons que la médiane de ceux en cours, ce qui économise du temps de calcul.

L'objectif minimise la perte hybride MSE + pinball (chapitre 6) sur la validation. La recherche explore le poids de la MSE dans $[0{,}3; 0{,}8]$, deux décades de taux d'apprentissage et plusieurs planificateurs (plateau, cosinus, warmup cosinus). Dix essais suffisent pour les baselines, dont l'espace est réduit. Pour le TCN et le TFT, davantage d'essais portent sur l'architecture et sur la stratégie d'horizon.

Le meilleur essai est ensuite figé (graine 42, arrêt précoce configuré séparément).

Hyperparamètres retenus

Le tableau 7.9 donne les meilleurs essais de chaque modèle.

Table 7.9 : Hyperparamètres des meilleurs essais Optuna.

Modèle	Réglages retenus
MLP	Poids hybride 0,354 ; 3 couches de 256 neurones ; dropout 0,286 [49] ; lots de 64 ; plateau ; taux $1{,}35\times10^{-3}$
LSTM de base	Poids 0,440 ; 3 couches de 256 neurones ; dropout 0,10 ; lots de 64 ; planning cosinus ; taux $1{,}88\times10^{-4}$ [20]
TCN	Poids 0,765 ; canaux 64, 128, 256, 256 ; noyau 5 ; dropout 0,252 ; lots de 64 ; montée cosinus de 5 époques ; taux $3{,}29\times10^{-4}$ [6]
TFT	Poids 0,617 ; dimension 256 sur 2 têtes ; dropout 0,15 ; lots de 128 ; plateau ; taux $6{,}92\times10^{-4}$ [32]

Les temps de calcul du run courant sont de 3 s pour la persistance, 519 s pour le MLP, 863 s pour le LSTM de référence, 1 206 s pour le TCN et 2 016 s pour le TFT.

7.4.6 Validation et calibration

La validation sert à deux choses : décider quand arrêter l'entraînement et calibrer les intervalles [7]. L'arrêt précoce utilise une patience de 25 époques pour un maximum de 100. Les courbes du run courant, présentées à la figure 7.14, montrent une convergence régulière pour les deux modèles avancés : le TCN s'arrête à l'époque 57, le TFT va jusqu'aux 100 époques. Les pertes de validation finales restent proches de celles d'entraînement, sans surapprentissage marqué.

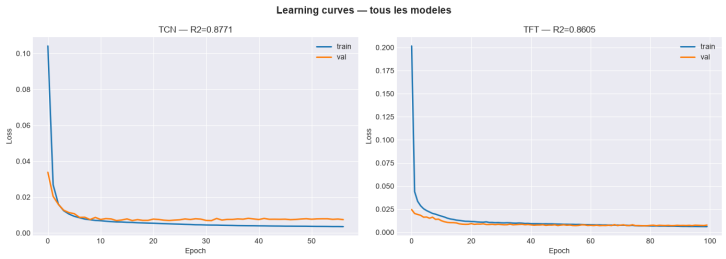


FIGURE 7.14 : Courbes d'entraînement du TCN et du TFT.

Les quantiles bruts n'atteignent pas toujours la couverture visée. Un recalibrage CQR (α=0,20, soit 80 % de couverture pour l'enveloppe P10–P90) corrige donc, selon l'équation (6.3), les bornes de l'intervalle d'une marge s_h estimée sur les données de validation [41]. Ses effets sont mesurés à la section 7.5.2.

7.4.7 Inférence

La figure 7.15 décrit le pipeline d'inférence, qui produit en mode batch une prévision à 72 h avec son enveloppe P10–P90 ; la figure 7.16 en donne un exemple. Sur le run courant, la prévision du site vaut p_{50} = 0,965 MW.

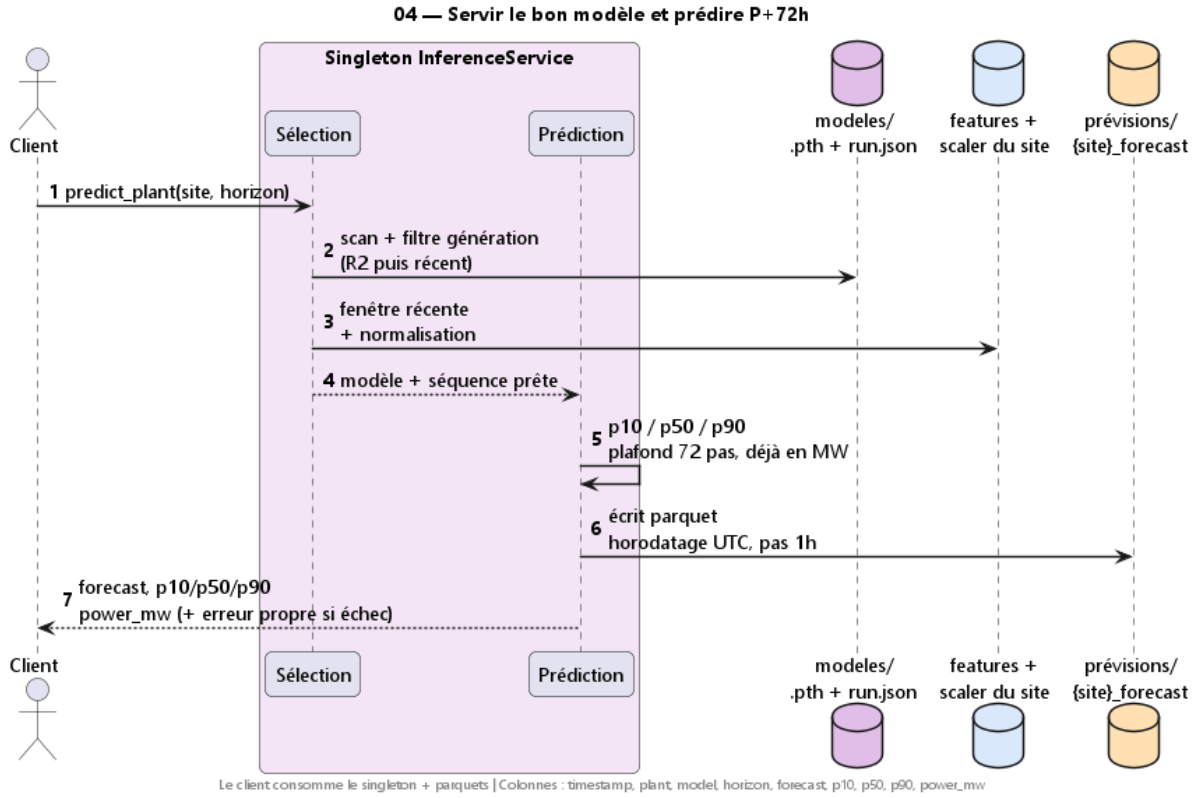


FIGURE 7.15 : Pipeline de serving et d'inférence batch.

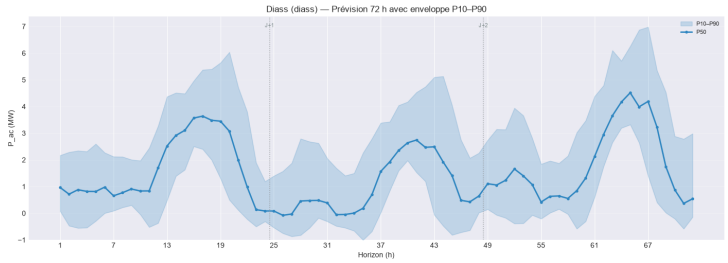


FIGURE 7.16 : Prévision batch à 72 h : P50 et enveloppe P10–P90.

7.5 Analyse des résultats et déductions

Les métriques sont celles définies à la section 3.7 ; pour les enveloppes, nous retenons la condition de calibration posée à l'équation (6.4) du chapitre 6. Nous n'en reprenons pas les formules. Le lecteur se référera à Gneiting and Raftery [17] pour la théorie des scores propres et à Koenker [27] pour la régression quantile.

Résultats en bref. Sur le test de Diass (72 h, 1 049 fenêtres), le TCN est le plus précis (RMSE 1,707 MW, R^2=0,877). Après recalibrage CQR, sa couverture P10–P90 atteint 79,8 %, près de la cible de 80 %. Le TFT le suit de près (RMSE 1,818 MW, R^2=0,861, couverture 74,2 %) et garde l'avantage de l'interprétabilité. Les repères (persistance, MLP, LSTM) sont nettement en retrait.

7.5.1 Performances ponctuelles

TABLE 7.10 : Résultats sur le segment de test, horizon 72 h, 1 049 fenêtres.

Modèle	RMSE (MW)	MAE (MW)	nRMSE	R^2	MAPE (%)
persistence	6,905	4,987	0,444	−1,013	3282,8
MLP	2,323	1,275	0,149	0,772	381,5
lstm baseline	2,043	1,148	0,131	0,824	333,3
TCN	1,707	0,989	0,110	0,877	362,2
TFT	1,818	1,157	0,117	0,861	502,0

Le tableau 7.10 classe les cinq modèles. Le TCN atteint une RMSE de 1,707 MW et une MAE de 0,989 MW (R^2=0,877). Le TFT obtient une RMSE de 1,818 MW, une MAE de 1,157 MW et un R^2 de 0,861. La figure 7.17 illustre cet ordre, et les baselines restent loin derrière. L'écart entre les deux architectures avancées est modeste : sur ce site, c'est plutôt la couverture de l'enveloppe P10–P90 après CQR qui les distingue.

La MAPE des baselines est très élevée (3282,8 % pour la persistance), parce que la production est presque nulle en début et en fin de journée et que le moindre écart pèse alors énormément en valeur relative [22]. Les modèles avancés la réduisent d'un ordre de grandeur. Pourtant, la

MAPE du TFT (502 %) dépasse celle du LSTM de base (333 %), alors que le TFT est plus précis sur les autres métriques. La MAPE est donc peu fiable près de zéro, car elle pénalise surtout les erreurs du matin et du soir. Nous nous fions au R^2 et à la RMSE, plus robustes, qui placent le TCN en tête [17].

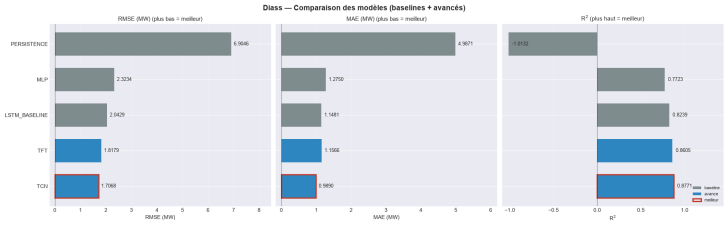


Figure 7.17 : Comparaison des métriques RMSE, MAE et R^2 sur le test.

7.5.2 Performances probabilistes

Table 7.11 : Métriques probabilistes sur le test : couverture, largeur, Winkler et pinball, avant et après recalibrage CQR.

Modèle	Couv.	Largeur	Winkler	Pinball bas/haut	Couv. CQR	Largeur CQR
TCN	0,608	1,670	5,742	0,325 / 0,250	0,798	2,596
TFT	0,713	2,456	5,964	0,323 / 0,273	0,742	2,646

Croisements de quantiles : 0,0 pour les deux modèles. s_h moyen/max : TCN 0,463/0,613 MW ; TFT 0,095/0,156 MW.

Le tableau 7.11 rassemble ces métriques. Les baselines ne produisent que des prévisions ponctuelles, et les métriques de calibration ne s'y appliquent pas. Pour le TCN, la couverture P10–P90 passe de 60,8 % avant recalibrage (largeur 1,670 MW, Winkler 5,742) à 79,8 % après CQR (s_h moyen 0,463 MW, largeur 2,596 MW), près de la cible de 80 %. Pour le TFT, elle passe de 71,2 % (largeur 2,456 MW, Winkler 5,964) à 74,2 % (s_h moyen 0,095 MW, largeur 2,646 MW). Aucun croisement de quantiles n'apparaît pour les deux modèles [41].

Le recalibrage a donc plus d'effet sur le TCN, dont les quantiles bruts étaient trop étroits, que sur le TFT, dont la couverture de départ était déjà meilleure mais qui reste un peu sous la cible [54].

7.5.3 Analyse des fenêtres de test

Les cinq modèles sont évalués sur le même segment de test, de 1 049 fenêtres : chacune part d'un historique de 168 heures pour prévoir 72 heures. Le segment s'étend du 16/07/2026 à 06h00 au 28/08/2026 à 22h00, prolongé de 72 h. Les métriques proviennent du run de référence du 6 octobre 2026.

La figure 7.18 présente des fenêtres de test représentatives. Le TCN reproduit bien le cycle diurne et suit les variations rapides dues aux nuages. Ses écarts les plus nets apparaissent aux transitions jour–nuit et lors des changements brusques d'irradiance, ce qui est normal pour un modèle convolutionnel [6].

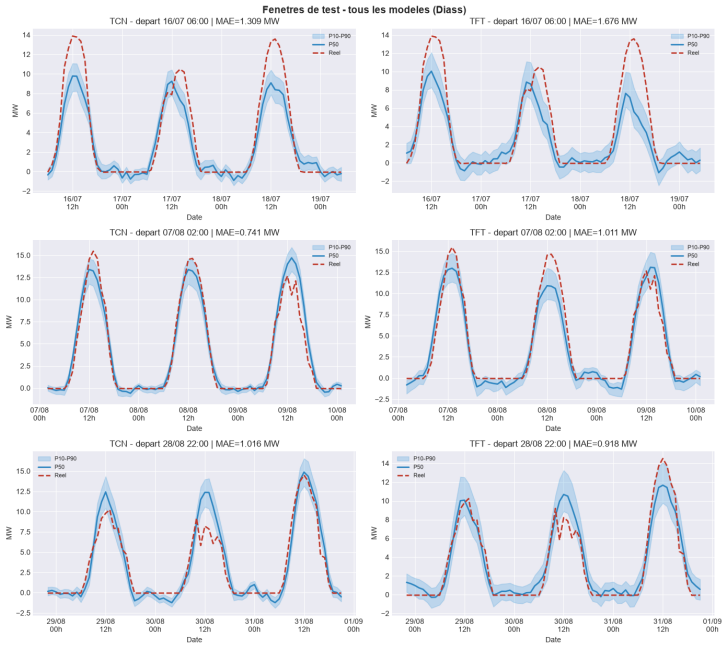


FIGURE 7.18 : Fenêtres de test représentatives : P50, P10–P90 et production réelle.

7.5.4 Discussion : compromis TCN / TFT

Sur Diass, le TCN devance le TFT sur les trois métriques ponctuelles (R^2 de 0,877 contre 0,861 ; RMSE de 1,71 contre 1,82 MW) et sur la couverture calibrée (79,8 % contre 74,2 %). Nous voyons deux explications. La convolution dilatée capte le motif diurne quasi périodique du solaire mieux que l'attention [6]. Le TCN a aussi beaucoup moins de paramètres, donc moins de risque de surapprendre sur une seule année d'entraînement [14]. Cette lecture reste une hypothèse : nous n'avons pas mené d'étude d'ablation pour la confirmer.

Le TFT garde un atout pour l'exploitation : l'interprétabilité (sélection de variables, poids d'attention). Un opérateur peut y voir pourquoi le modèle annonce une baisse à un horizon donné, ce que le TCN ne fournit pas nativement [32].

7.5.5 Implications pour la SENELEC

Précision nécessaire. Le réseau de la SENELEC a peu de marge de manœuvre [18]. Pour Diass (27,3 MWc installés, 23,1 MW publiés), nous retenons comme hypothèse de travail un seuil indicatif de 5 MW acceptable pour le dispatch quotidien, soit une RMSE inférieure à 5 MW, c'est-à-dire 22 % de la capacité publiée. Les deux architectures avancées respectent largement ce seuil, ce qui laisse une marge confortable à l'exploitant.

Intervalles pour le dispatch. L'intervalle P10–P90 s'utilise directement pour le dispatch. Sa borne haute dimensionne la réserve de sécurité à mobiliser. Sa borne basse indique la production sur laquelle la SENELEC peut compter sans démarrer de thermique inutilement [39]. Entre les deux, la distribution des quantiles permet d'estimer la probabilité de franchir un seuil critique

(10 % de la capacité, par exemple), ce que la seule prévision ponctuelle ne donne pas [17]. Associé aux prévisions de charge, cet intervalle éclaire le niveau de production thermique à activer.

7.6 Conclusion et perspectives

L'étude de Diass valide la chaîne complète, de l'exploration des données à l'évaluation probabiliste, sur un site réel. Le feature engineering fournit 543 variables, dont 424 retenues par la sélection. Sur la précision ponctuelle et sur la couverture calibrée, le TCN devance légèrement le TFT ($R^2 = 0{,}877$ contre 0,861 ; couverture de 79,8 % contre 74,2 %) [6], tandis que le TFT conserve une interprétabilité que le TCN n'offre pas [32].

Deux limites restent ouvertes. Une seule année d'entraînement ne garantit pas que les hyperparamètres restent stables d'une saison à l'autre [14], et le pas horaire lisse les passages nuageux de moins d'une heure, ce qui plafonne la précision atteignable à 72 h [12]. Le coût mémoire du TFT, lié à l'attention quadratique sur la fenêtre d'entrée, complique par ailleurs un déploiement embarqué.

Trois prolongements sont possibles : transférer le pipeline vers un autre site solaire, le pipeline étant déjà organisé par centrale ; dédier un modèle aux horizons de 1 à 6 heures, à un pas de 5 à 15 minutes, pour combler la lacune du pas horaire [39] ; tester l'apprentissage fédéré entre plusieurs sites, sans partage des données brutes [45]. Sur le plan opérationnel, l'étape suivante consiste à intégrer progressivement le pipeline au système de gestion du réseau de la SENELEC, avec des phases pilotes sur Diass [18].

Bibliographie

[1] Agence Nationale de la Statistique et de la Démographie (ANSD). Situation économique et sociale du sénégal, édition 2022–2023, 2025. Rapport annuel, https ://www.ansd.sn, 2025.

[2] Taïb Ajzoul. Cours de l'énergie solaire photovoltaïque — partie I : Cellule, module et champ photovoltaïques ; partie II : Conception et dimensionnement des installations PV. Département de Physique, Faculté des Sciences de Tétouan, n.d.

[3] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna : A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 1743–1751, 2019. doi : 10.1145/3292500.3330701.

[4] Jimmy Lei Ba, Jamie R Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv :1607.06450*, 2016.

[5] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.

[6] Shaojie Bai, J Zico Kolter, and Vladlen Koltun. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv :1803.01271*, 2018.

[7] Christoph Bergmeir and José M. Benítez. On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191 :192–213, 2012. doi : 10.1016/j.ins.2011.12.028.

[8] James Bergstra and Yoshua Bengio. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13 :281–305, 2012.

[9] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734, 2014.

[10] Nogoye Diaw, Thi Thi Soe, A. Swathi, Prasun Kumar Das, and G. Giridhar. Estimation of solar potential in senegal using GIS application. *International Journal of Advanced Research in Education & Technology*, 4(1) :59–68, 2017.

[11] Sambalaye Diop, Papa Silly Traore, and Mamadou Lamine Ndiaye. Power and solar energy predictions based on neural networks and principal component analysis with meteorological parameters of two different cities : Case of Diass and Taıba Ndiaye. In *2022 IEEE International Conference on Electrical Sciences and Technologies in Maghreb (CISTEM)*, Tunis, Tunisia, 2022. doi : 10.1109/CISTEM55808.2022.10044065.

[12] M. C. Diouf, M. Faye, A. Thiam, A. Ndiaye, and V. Sambou. Analysis performance of large scale grid connected photovoltaic power plants in the tropical region. *International Journal of Engineering Sciences & Research Technology*, 10(1), 2021. doi : 10.29121/ijesrt.v10.i1.2021.5.

[13] ENGIE, Meridiam, and FONSIS. Mise en service de la centrale solaire de kahone, 2021. Communiqué de presse, 2021.

[14] Luca Franceschi, Michele Donini, Valerio Perrone, Aaron Klein, Cédric Archambeau, Matthias Seeger, Massimiliano Pontil, and Paolo Frasconi. Hyperparameter optimization in machine learning. *arXiv preprint arXiv :2410.22854*, 2024.

[15] Yarin Gal and Zoubin Ghahramani. Dropout as a bayesian approximation. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1050–1059, 2016.

[16] Global Solar Atlas (Solargis / Banque mondiale). Cartes du gisement solaire (ghi, dni, dhi) au sénégal. https ://globalsolaratlas.info, n.d.

[17] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477) :359–378, 2007. doi : 10.1198/016214506000001437.

[18] Gouvernement du Sénégal. Plan d'investissement de la transition énergétique juste au sénégal — partenariat pour une transition énergétique juste (JETP), 2025. Ministère de l'Énergie, du Pétrole et des Mines, https ://www.vie-publique.sn/documents/10970, 2025.

[19] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers : Surpassing human-level performance on ImageNet classification. In *IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015. doi : 10.1109/ICCV.2015.123.

[20] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8) :1735–1780, 1997.

[21] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 2(5) :359–366, 1991.

[22] Rob J. Hyndman and George Athanasopoulos. *Forecasting : Principles and Practice*. OTexts, Melbourne, Australia, 3 edition, 2021. URL https://otexts.com/fpp3/.

[23] IEA/AIE. Senegal 2023 — energy policy review (revue de la politique énergétique), 2024. IEA, Paris, publiée le 25 janvier 2024, licence CC BY 4.0, https ://www.iea.org/reports/senegal-2023 (version française : https ://www.iea.org/reports/senegal-2023 ?language=fr).

[24] InnoVent Sénégal. Centrale solaire de sakal — 20 mwc à trackers, région de louga. Documents institutionnels et dossier de financement, https ://innovent.fr, n.d.

[25] Sergey Ioffe and Christian Szegedy. Batch normalization : accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 448–456, 2015.

[26] Diederik P Kingma and Jimmy Ba. Adam : A method for stochastic optimization. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.

[27] Roger Koenker. *Quantile Regression*. Cambridge University Press, Cambridge, 2005. doi : 10.1017/CBO9780511754098.

[28] Roger Koenker and Gilbert Bassett. Regression quantiles. *Econometrica*, 46(1) :33–50, 1978. doi : 10.2307/1913643.

[29] Yann LeCun, Bernhard Boser, John S Denker, Donnie Henderson, Richard E Howard, Wayne Hubbard, and Lawrence D Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1 :541–551, 1989.

[30] Yann LeCun, Léon Bottou, Genevieve B Orr, and Klaus-Robert Müller. Efficient backprop. *Neural Networks : Tricks of the Trade*, pages 9–48, 2012.

[31] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553) : 436–444, 2015.

[32] Bryan Lim, Sercan O Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4) :1748–1764, 2021.

[33] Eloi Lindas, Yannig Goude, and Philippe Ciais. Towards accurate forecasting of renewable energy : Building datasets and benchmarking machine learning models for solar and wind power in France. *Environmental Data Science*, 4 :e45, 2025. doi : 10.1017/eds.2025.10021.

[34] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

[35] A. Mbaye, Mamadou Ndiaye, D. M. Ndione, M. Diaw, V. Traoré, A. Ndiaye, M. C. Sylla, M. C. Aidara, V. Diaw, A. Traoré, and P. Ndiaye. ARMA model for short-term forecasting of solar potential : application to a horizontal surface on Dakar site. *Materials and Devices*, 4(1), 2019. doi : 10.23647/ca.md20191103.

[36] Ministère de l'Énergie, du Pétrole et des Mines du Sénégal. Transition énergétique et énergies renouvelables au sénégal, 2026. Pages officielles, consultées le 10/11/2026 : https ://energie-mines.gouv.sn/transition-energetique (72,11 % de capacité thermique, 27,89 % ENR en 2023 ; renouvelables 12,1 % en 2018 → 29,33 % en 2022) et https ://energie-mines.gouv.sn/energie-renouvelables (27,35 % de capacité ENR, 19,48 % de la production brute de 6 654,02 GWh en 2023). Les deux onglets publient des parts de capacité ENR différentes (27,35 % vs 27,89 %).

[37] Fatim Amadou Ndiaye, Mohamed Cherif Aidara, Diatta Sene, Oumar Drame, and Mamadou Lamine Ndiaye. Analysis of real performance and seasonal prediction of a 23 MWp grid-connected photovoltaic plant in Senegal : Case of Diass. *Energy for Sustainable Development*, 85 :101660, 2025. doi : 10.1016/j.esd.2025.101660.

[38] Razvan Pascanu, Tomas Mikolov, and Yoshua Bengio. On the difficulty of training recurrent neural networks. *Proceedings of the 30th International Conference on Machine Learning (ICML)*, pages 1310–1318, 2013.

[39] Pierre Pinson. Wind energy : Forecasting challenges for its operational management. *Statistical Science*, 28(4) :564–585, 2013. doi : 10.1214/13-sts445.

[40] pv magazine. Site officiel. https ://www.pv-magazine.com, n.d.

[41] Yaniv Romano, Evan Patterson, and Emmanuel Candès. Conformalized quantile regression. *Advances in Neural Information Processing Systems*, 32, 2019.

[42] Frank Rosenblatt. The perceptron : a probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6) :386–408, 1958.

[43] Sanjay Santurkar, Dimitris Tsipras, Vikas Elango, Aparna Mudigere, and Sarath Krishnan. How does batch normalization help optimization ? In *International Conference on Learning Representations (ICLR)*, 2018.

[44] Adama Sarr and Diatta Sene. Enhancing solar energy production : A comprehensive model for fixed-panel systems applied to the solar power plant in Diass, Senegal. In *2025 IEEE 53rd Photovoltaic Specialists Conference (PVSC)*, Montreal, QC, Canada, 2025. doi : 10.1109/PVSC59419.2025.11132696.

[45] D. Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-François Crespo, and Dan Dennison. Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28 :2503–2511, 2015.

[46] SENELEC. Centrale solaire de diass — première centrale photovoltaïque publique du sénégal. https ://www.senelec.sn, https ://www.kfw.de, n.d.

[47] SENELEC. Chiffres clés 2025, 2025. Page « Chiffres clés » du site officiel (tableaux : ventes d'énergie, puissances installées, production brute, achats, centrales régionales), https ://www.senelec.sn/qui-sommes-nous/chiffres-cles/, consultée le 10/11/2026.

[48] SENELEC. Production du réseau interconnecté — mai 2026, 2026. Communiqué/page du site officiel, https ://www.senelec.sn. Accès direct non vérifié le 10/11/2026 ; chiffres à contrôler auprès de la SENELEC avant soutenance.

[49] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout : a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56) :1929–1958, 2014.

[50] Ten Merina Ndakhar SA. Centrale solaire de ten merina. https ://ten-merina.com, n.d.

[51] Nihed Toumi and Iskandar Kouda. Prédiction de la production d'une centrale solaire photovoltaïque autonome — énergie solaire photovoltaïque et système photovoltaïque autonome, 2021. Projet de fin d'études de Licence, Département d'Électrotechnique, Université Badji Mokhtar — Annaba, dir. M. Adjabi, 2021.

[52] Aaron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, and Koray Kavukcuoglu. Wavenet : A generative model for raw audio. *arXiv preprint arXiv :1609.03499*, 2016.

[53] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[54] Vladimir Vovk, Alexander Gammerman, and Glenn Shafer. *Algorithmic Learning in a Random World*. Springer, 2005. doi : 10.1007/b106715.